

# 第 1 章 学习问题

## 1.1 什么是机器学习

### 定义 1.1.1 (学习)

学习是指通过对观测信息的积累，获得特定技能的过程。



### 定义 1.1.2 (机器学习)

机器学习是指通过对数据进行积累或计算，提取经验，从而获得某种技能的过程。



在实际应用中，所谓“技能”通常意味着某项性能指标的提升，例如预测准确率。因此，可以将机器学习更明确地表述为：通过从数据中提取经验，提升某项性能指标的过程。

除了作为一种学习方法，机器学习也是构建复杂系统的有效手段。相比显式地编写规则，机器学习更加适用于那些难以手工建模的问题。

### 命题 1.1.1 (机器学习方法的可行性前提)

为了使机器学习能够有效运行，通常需要满足以下三个前提条件：

1. 存在可被学习的底层模式，意味着性能指标具有提升空间。
2. 该模式难以通过显式编程方式加以定义，因此需依赖学习算法近似建模。
3. 有充足的数据可用，从中能够揭示潜在模式，为模型提供训练基础。



## 1.2 机器学习的应用

### 机器学习无处不在

表 1.2.1: 机器学习在衣食住行方面的应用

| 领域 | 数据                  | 技能             |
|----|---------------------|----------------|
| 餐饮 | Twitter 数据（文字 + 位置） | 准确判断餐厅的食物中毒可能性 |
| 服装 | 销售数字 + 客户调查         | 向客户提供合适的时尚推荐   |
| 住房 | 建筑特征及其能耗            | 精确预测其他建筑的能耗    |
| 交通 | 部分交通标志图像及其含义        | 准确识别交通标志       |

## 教育

本案例中的数据来自学生在数学辅导系统中多次小测的答题记录。机器学习的任务是根据这些历史数据，预测学生是否能够正确回答下一道小测题。

一种常见的解决方案为：

假设学生正确作答的概率主要取决于其最近的能力  $J$  是否高于题目难度  $K$ ，即

$$\text{正确作答} \approx J > K.$$

该方法使用约 3000 名学生的 900 万条答题记录作为训练数据，模型通过学习这些数据，自动推断出学生的能力水平以及题目的相对难度，从而实现较为准确的预测。

## 娱乐：推荐系统

本案例中的数据来自若干用户对部分电影的评分记录。机器学习的目标是基于这些已有评分，预测某用户对尚未观看电影的评分，从而实现个性化推荐。

一种常见的建模思路是认为：用户评分主要受其兴趣偏好与影片特征的共同影响。该关系可以表示为：

$$\text{评分} \leftarrow \text{观众的兴趣偏好} + \text{影片的内容特征}$$

在学习过程中，模型利用已有评分数据，自动归纳出每位用户的兴趣倾向与各部影片的关键特征，进而实现对用户可能喜欢的未观影片的评分预测。

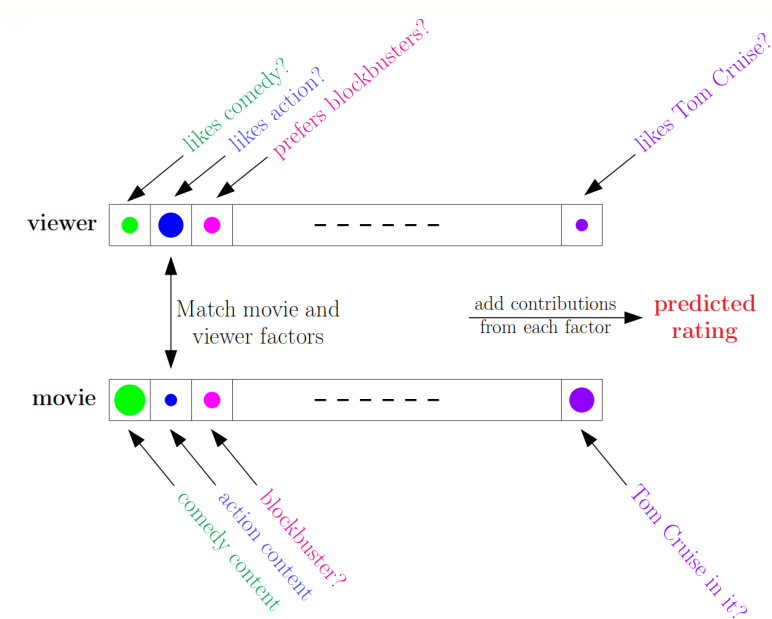


图 1.2.1: 观众评价电影的因素示意图

## 1.3 机器学习的组成部分

### 形式化学习问题

设想一家银行每天收到大量信用卡申请，为了自动化审批流程，银行希望基于历史数据学习出一条可靠的信用审批规则。下面对学习问题的各组成部分进行形式化描述：

#### 基本符号与定义：

- 输入  $x \in \mathcal{X}$ ：表示客户的申请信息，例如收入、负债、居住年限等。
- 输出  $y \in \mathcal{Y}$ ：表示审批结果，例如“好”客户或“坏”客户。
- 目标函数  $f: \mathcal{X} \rightarrow \mathcal{Y}$ ：即理想中的信用审批规则，但实际是未知的。
- 训练数据  $\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$ ：来自历史的客户申请记录及对应审批结果。
- 假设函数  $g: \mathcal{X} \rightarrow \mathcal{Y}$ ：由学习算法从数据中学习得到，用于近似目标函数  $f$ 。
- 假设空间  $\mathcal{H}$ ：所有备选的函数集合，学习算法从中选择最优的  $g$ 。

学习的目标：利用历史数据  $\mathcal{D}$ ，从假设空间  $\mathcal{H}$  中选择一个函数  $g$ ，使其尽可能逼近真实但未知的目标函数  $f$ 。当新的申请到来时，银行将基于  $g$  来做出审批决策。

## 1.4 机器学习与其他领域

### 机器学习 vs 数据挖掘

**机器学习**：利用数据学习出假设函数  $g: \mathcal{X} \rightarrow \mathcal{Y}$ ，使其逼近目标函数  $f: \mathcal{X} \rightarrow \mathcal{Y}$ 。

**数据挖掘**：从（海量）数据中发现潜在的、有价值的属性或模式。

#### 两者关系：

- 若“有趣的属性” $\equiv$ “逼近目标函数的假设”  
 $\Rightarrow$  机器学习  $\equiv$  数据挖掘（如 KDD Cup 等实际场景）
- 若“有趣的属性”与目标函数  $f$  相关但不相同  
 $\Rightarrow$  数据挖掘可辅助机器学习，反之亦然
- 数据挖掘还关注如何在大规模数据库中实现高效计算

**在实际应用中，两者往往交叉融合，界限并不明确。**

## 机器学习 vs 人工智能

**机器学习：**通过数据学习出假设  $g$ ，使其逼近某个目标函数  $f$ 。

**人工智能（AI）：**设计和构建能够展现智能行为的系统。

**两者关系：**

- 若  $g \approx f$  的逼近过程本身体现智能行为  
⇒ 机器学习可作为实现人工智能的有效途径
- 典型示例——国际象棋程序：  
传统 AI：基于博弈树的启发式搜索  
学习型 AI：从大量棋局数据中学习策略

**因此，机器学习是实现人工智能的重要手段之一，但并非唯一路径。**

## 机器学习 vs 统计学

**机器学习：**从数据中学习假设函数  $g$ ，以逼近未知的目标函数  $f$ 。

**统计学：**依据数据，对潜在的未知过程（如  $f$ ）进行推断与建模。

**两者关系：**

- 在某些学习模型中， $g$  可看作对  $f$  的统计推断结果  
⇒ 统计方法可直接应用于机器学习任务
- 统计学强调在数学假设下的可解释性与理论保证
- 传统统计学对计算复杂度关注较少，而机器学习注重可扩展性与实际效果

**统计学为机器学习提供了坚实的理论基础与丰富的方法工具。**

## 1.5 总结



## 笔记 [学习问题]

- 什么是机器学习：利用数据逼近目标函数
- 机器学习应用：几乎无处不在
- 机器学习的组成：算法接收数据集和假设空间，从而得到假设
- 机器学习与其他领域：与数据挖掘、人工智能和统计学密切相关