

第 18 章 对偶支持向量机

18.1 对偶 SVM 的动机

命题 18.1.1 (非线性硬间隔 SVM 的 QP 刻画)

给定训练集 $\{(x_n, y_n)\}_{n=1}^N$ 与特征映射 $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}^D$, 非线性硬间隔 SVM 等价于在 $D+1$ 维空间求解

$$\min_{b, w} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_n(w^\top \Phi(x_n) + b) \geq 1, \quad n = 1, \dots, N.$$

需求: 大间隔 (参数不多) 却能通过 Φ 产生复杂边界。

挑战: 当 D 很大甚至无限时, $D+1$ 个变量与 N 条约束的 QP 难以直接求解。

目标: 消除对维度 D 的显式依赖, 引出后续核技巧。

命题 18.1.2 (拉格朗日乘子: 约束转无约束)

令拉格朗日乘子 $\alpha_n \geq 0, n = 1, \dots, N$ 。对硬间隔 SVM 的原始问题

$$\min_{b, w} \frac{1}{2} w^\top w \quad \text{s.t.} \quad y_n(w^\top z_n + b) \geq 1,$$

构造拉格朗日函数

$$\mathcal{L}(b, w, \alpha) = \frac{1}{2} w^\top w + \sum_{n=1}^N \alpha_n [1 - y_n(w^\top z_n + b)].$$

等价刻画

$$\min_{b, w} \max_{\alpha \geq 0} \mathcal{L}(b, w, \alpha) = \begin{cases} +\infty, & \text{若存在约束被违反, 即存在 } k \text{ 使得 } y_k(w^\top z_k + b) \leq 1; \\ \frac{1}{2} w^\top w, & \text{若全部约束满足, 即对任意 } k \text{ 有 } y_k(w^\top z_k + b) \geq 1. \end{cases}$$

结果 所有显式约束被隐藏于 $\max_{\alpha \geq 0} \mathcal{L}(b, w, \alpha)$ 中, 实现“约束优化 \rightarrow 无约束鞍点问题”的转化。

例题 18.1 选择题: 硬间隔 SVM 的拉格朗日函数

考虑两个变换后的样本 $(z_1, +1)$ 和 $(z_2, -1)$, 其中 $z_2 = -z_1 = -z$ 。硬间隔 SVM 的拉格朗日函数 $\mathcal{L}(b, w, \alpha)$ 为:

- 1) $\frac{1}{2} w^T w + \alpha_1(1 + w^T z + b) + \alpha_2(1 + w^T z + b)$
- 2) $\frac{1}{2} w^T w + \alpha_1(1 - w^T z - b) + \alpha_2(1 - w^T z + b)$
- 3) $\frac{1}{2} w^T w + \alpha_1(1 + w^T z + b) + \alpha_2(1 + w^T z - b)$
- 4) $\frac{1}{2} w^T w + \alpha_1(1 - w^T z - b) + \alpha_2(1 - w^T z - b)$

解答 正确选项为 [2]。硬间隔 SVM 的拉格朗日函数为:

$$\mathcal{L} = \frac{1}{2} w^T w + \alpha_1(1 - y_1(w^T z_1 + b)) + \alpha_2(1 - y_2(w^T z_2 + b))$$

代入 $y_1 = +1, y_2 = -1, z_2 = -z_1 = -z$, 化简得:

$$\mathcal{L} = \frac{1}{2} w^T w + \alpha_1(1 - w^T z - b) + \alpha_2(1 - w^T z + b)$$

18.2 拉格朗日对偶 SVM

命题 18.2.1 (拉格朗日对偶问题)

记拉格朗日函数：

$$\mathcal{L}(b, w, \alpha) = \frac{1}{2} w^\top w + \sum_{n=1}^N \alpha_n [1 - y_n(w^\top z_n + b)], \quad \alpha_n \geq 0$$

对任意固定的 $\alpha' \geq 0$, (由于 $\max \geq \min$), 因此有：

$$\min_{b, w} \left(\max_{\alpha \geq 0} \mathcal{L}(b, w, \alpha) \right) \geq \min_{b, w} \mathcal{L}(b, w, \alpha')$$

取右侧对 α' 取最大, 可得：

$$\min_{b, w} \left(\max_{\alpha \geq 0} \mathcal{L}(b, w, \alpha) \right) \geq \max_{\alpha' \geq 0} \min_{b, w} \mathcal{L}(b, w, \alpha')$$

这是由于右侧是左侧的一个下界, 而最大化这个下界可以得到一个更紧的下界。

其中右侧即为拉格朗日对偶问题：

$$\max_{\alpha' \geq 0} \min_{b, w} \mathcal{L}(b, w, \alpha')$$

这表示在外层对 α 进行最大化, 等价于对原始问题下界的最大化。

强对偶性的条件：对于二次规划问题, 当满足以下条件时, 弱对偶性的不等式可以变为等式：

- 原问题是凸的
- 原问题可行 (如果数据 Φ 是可分的)
- 约束是线性的

这些条件被称为约束品性 (constraint qualification)。

当强对偶性成立时, 存在原问题和对偶问题的最优解 (b, w, α) 使得两者的最优值相等。



命题 18.2.2 (拉格朗日对偶的化简步骤)

记拉格朗日函数：

$$\mathcal{L}(b, w, \alpha) = \frac{1}{2} w^\top w + \sum_{n=1}^N \alpha_n [1 - y_n(w^\top z_n + b)], \quad \alpha_n \geq 0$$

1. 消去变量 b

对固定 α , 考虑内层无约束最小化问题：

$$\min_{b, w} \mathcal{L}(b, w, \alpha)$$

在最优解处满足偏导数为零的条件：

$$\frac{\partial \mathcal{L}(b, w, \alpha)}{\partial b} = 0 \implies \sum_{n=1}^N \alpha_n y_n = 0$$

这一条件使得 b 被消去, 目标函数仅依赖于 w 。

2. 消去变量 w

同样地, 对 w 求偏导并令其为零：

$$\frac{\partial \mathcal{L}(b, w, \alpha)}{\partial w} = 0 \implies w = \sum_{n=1}^N \alpha_n y_n z_n$$

将 w 代入拉格朗日函数，得到仅含 α 的目标函数：

$$\mathcal{L}(\alpha) = \sum_{n=1}^N \alpha_n - \frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n z_n \right\|^2$$

最终对偶问题 通过上述消元过程，原问题转化为仅含 α 的二次规划：

$$\max_{\alpha} \left\{ \sum_{n=1}^N \alpha_n - \frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n z_n \right\|^2 \right\} \quad \text{s.t.} \quad \sum_{n=1}^N \alpha_n y_n = 0, \alpha_n \geq 0.$$



命题 18.2.3 (KKT 最优性条件)

设原始问题为

$$\min_{b, w} \frac{1}{2} w^\top w \quad \text{s.t.} \quad y_n (w^\top z_n + b) \geq 1$$

化简后的对偶问题为

$$\max_{\alpha} \left\{ \sum_{n=1}^N \alpha_n - \frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n z_n \right\|^2 \right\} \quad \text{s.t.} \quad \sum_{n=1}^N \alpha_n y_n = 0, \alpha_n \geq 0$$

设 (b, w, α) 为原始-对偶最优解，则下列 Karush-Kuhn-Tucker (KKT) 条件成立，且在凸 QP 中既是必要也是充分条件：

1. 原始可行性

$$y_n (w^\top z_n + b) \geq 1, \quad n = 1, \dots, N.$$

2. 对偶可行性

$$\alpha_n \geq 0, \quad n = 1, \dots, N.$$

3. 对偶-内点最优性

$$\sum_{n=1}^N \alpha_n y_n = 0, \quad w = \sum_{n=1}^N \alpha_n y_n z_n.$$

4. 原始-内点最优性（互补松弛）

$$\alpha_n [1 - y_n (w^\top z_n + b)] = 0, \quad n = 1, \dots, N.$$

用途 利用上述 KKT 条件，可从最优 α 直接反演得到 (b, w) ，从而完成 SVM 求解。



例题 18.2 选择题：KKT 条件的验证

对于单变量 w ，考虑最小化 $\frac{1}{2}w^2$ ，约束为 $w \geq 1$ 和 $w \leq 3$ 。拉格朗日函数为 $\mathcal{L}(w, \alpha) = \frac{1}{2}w^2 + \alpha_1(1 - w) + \alpha_2(w - 3)$ 。下列哪些方程属于该优化问题的 KKT 条件？

- 1) $\alpha_1 \geq 0$ 且 $\alpha_2 \geq 0$
- 2) $w = \alpha_1 - \alpha_2$
- 3) $\alpha_1(1 - w) = 0$ 且 $\alpha_2(w - 3) = 0$
- 4) 以上所有

解答 正确选项为 [4]。KKT 条件包括：

- 拉格朗日乘子非负性： $\alpha_1 \geq 0, \alpha_2 \geq 0$ ；
- 梯度条件： $w = \alpha_1 - \alpha_2$ ；
- 互补松弛条件： $\alpha_1(1 - w) = 0, \alpha_2(w - 3) = 0$ 。

所有选项均满足 KKT 条件。 ■

18.3 求解对偶 SVM

命题 18.3.1 (支持向量机的对偶形式与 QP 形式)

硬间隔支持向量机 (SVM) 的对偶问题可以表示为以下凸二次规划 (Quadratic Programming, QP) 问题：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m (z_n^\top z_m) - \sum_{n=1}^N \alpha_n \\ \text{s.t.} \quad & \sum_{n=1}^N \alpha_n y_n = 0, \quad \alpha_n \geq 0, \quad n = 1, \dots, N. \end{aligned}$$

这是一个包含 N 个变量与 $N+1$ 条线性约束的凸二次规划问题，目标函数关于 α 严格凸，故存在唯一的全局最优解。

为方便使用标准 QP 求解器，上述问题可转写为通用 QP 形式：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^\top Q \alpha + p^\top \alpha \\ \text{s.t.} \quad & A \alpha \geq c, \end{aligned}$$

其中各项定义如下：

$$\begin{aligned} Q_{nm} &= y_n y_m z_n^\top z_m, \quad p = -\mathbf{1}_N, \\ A &= \begin{bmatrix} \mathbf{y}^\top \\ -\mathbf{y}^\top \\ I_N \end{bmatrix}, \quad c = \begin{bmatrix} 0 \\ 0 \\ \mathbf{0}_N \end{bmatrix}. \end{aligned}$$

注 其中第一行是等式约束 $\sum \alpha_n y_n = 0$ ，写作两条不等式 $\mathbf{y}^\top \alpha \geq 0$ 与 $-\mathbf{y}^\top \alpha \geq 0$ ；第三部分 I_N 实现 $\alpha_n \geq 0$ 的约束。许多数值求解器（如 CVXOPT、quadprog）对等式与边界条件会做特殊处理以保证数值稳定性。 ♠

命题 18.3.2 (由最优 α 恢复最优 (b, w) 的 KKT 公式)

设 (b, w, α) 为原始-对偶最优解，则下列 KKT 条件成立：

1. 原始可行性

$$y_n(w^\top z_n + b) \geq 1, \quad n = 1, \dots, N.$$

2. 对偶可行性

$$\alpha_n \geq 0, \quad n = 1, \dots, N.$$

3. 对偶-内点最优性

$$\sum_{n=1}^N \alpha_n y_n = 0, \quad w = \sum_{n=1}^N \alpha_n y_n z_n.$$

4. 互补松弛性

$$\alpha_n [1 - y_n(w^\top z_n + b)] = 0, \quad n = 1, \dots, N.$$

恢复公式

1. 最优 w : 由对偶-内点最优性直接给出

$$w = \sum_{n=1}^N \alpha_n y_n z_n.$$

2. 最优 b : 任取一个 $\alpha_k > 0$ (支撑向量), 利用互补松弛得

$$1 - y_k(w^\top z_k + b) = 0 \implies b = y_k - w^\top z_k.$$

3. 最终的分类决策函数为:

$$g_{\text{SVM}}(x) = \text{sign} \left(\sum_{n=1}^N \alpha_n y_n (z_n^\top z) + b \right).$$

结论 $\alpha_n > 0$ 对应的样本即为支撑向量, 位于“胖边界”上。例题 18.3 选择题: 硬间隔 SVM 的最优偏置 b

考虑两个变换后的样本 $(z_1, +1)$ 和 $(z_2, -1)$, 其中 $z_2 = -z_1 = -z$ 。假设硬间隔 SVM 的对偶问题最优解满足 $\alpha_1, \alpha_2 > 0$, 则最优偏置 b 为:

- 1) -1
- 2) 0
- 3) 1
- 4) 无法确定

解答 正确选项为 [2]。根据 KKT 条件, 最优解满足:

$$b = 1 - w^\top z \quad \text{和} \quad b = -1 + w^\top z$$

联立得 $b = 0$ 。

18.4 对偶 SVM 的启示

命题 18.4.1 (“最胖”超平面的数据表示)

设训练集 $\{(x_n, y_n)\}_{n=1}^N$, 经特征映射 $z_n = \Phi(x_n)$, 则
支撑向量机

$$w_{\text{SVM}} = \sum_{n=1}^N \alpha_n y_n z_n, \quad \alpha_n \text{ 来自对偶最优解, 且仅支撑向量对应的 } \alpha_n > 0.$$

PLA (感知器)

$$w_{\text{PLA}} = \sum_{n=1}^N \beta_n y_n z_n, \quad \beta_n \text{ 为样本 } x_n \text{ 被误分类并用于修正的次数.}$$

共性结论 所有基于梯度下降 / 随机梯度下降的 LogReg、LinReg (初值 $w_0 = 0$) 同样满足

$$w = \sum_{n=1}^N \gamma_n y_n z_n, \quad \gamma_n \in \mathbb{R}.$$

术语 称 w 由数据 $\{z_n\}$ “线性表示”；SVM 仅用支撑向量 (SVs) 即可表示 w ，实现稀疏数据依赖。

命题 18.4.2 (硬间隔 SVM 的两种等价形式)

1. 原始硬间隔 SVM

$$\min_{b,w} \quad \frac{1}{2} w^\top w \quad \text{s.t.} \quad y_n(w^\top z_n + b) \geq 1, \quad n = 1, \dots, N.$$

2. 对偶硬间隔 SVM

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^\top Q \alpha - \mathbf{1}^\top \alpha \\ \text{s.t.} \quad & y^\top \alpha = 0, \quad \alpha_n \geq 0, \quad n = 1, \dots, N, \end{aligned}$$

其中 $Q_{n,m} = y_n y_m z_n^\top z_m$ 。

规模与适用场景

- 原始形式： $d+1$ 个变量， N 条约束；适合 $d \ll N$ 。
- 对偶形式： N 个变量， $N+1$ 条简单约束；适合 $N \ll d$ 。

物理含义

- 原始：直接寻找经特殊尺度化后的 (b, w) 。
- 对偶：识别支撑向量 (z_n, y_n) 及其系数 α_n 。

最终输出 两种形式均给出同一最优 (b, w) ，对应最胖超平面；决策函数为

$$g_{\text{SVM}}(x) = \text{sign}(w^\top \Phi(x) + b).$$

例题 18.4 选择题：支持向量候选的数量

考虑在 5566 个样本上应用对偶硬间隔 SVM，得到 1126 个支持向量 (SVs)。下列哪个可能是“胖边界”样本 (SV 候选) 的数量？

- 1) 0
- 2) 1024
- 3) 1234
- 4) 9999

解答 正确选项为 [3]。支持向量候选数量需满足：

- 大于或等于实际支持向量数量 (1126)；
- 小于或等于总样本数 (5566)。

选项 3 (1234) 符合条件。

18.5 总结

笔记 [对偶支持向量机]

- 对偶 SVM 的动机：去除对维度 d 的依赖。
- 拉格朗日对偶 SVM：KKT 条件连接原始问题与对偶问题。
- 求解对偶 SVM：仍是二次规划，但可用专用求解器更高效地计算。
- 对偶 SVM 的启示：支持向量 (SVs) 刻画了“最胖”的超平面。