

第 19 章 核支持向量机

19.1 核技巧

命题 19.1.1 (对偶 SVM 再审视：脱离维度依赖的关键)

当前已将对偶 SVM 化为

$$\min_{\alpha} \frac{1}{2} \alpha^{\top} Q \alpha - \mathbf{1}^{\top} \alpha \quad \text{s.t.} \quad y^{\top} \alpha = 0, \alpha_n \geq 0,$$

其中

$$Q_{n,m} = y_n y_m \Phi(x_n)^{\top} \Phi(x_m).$$

目标 避免显式依赖维度 d ，需快速计算内积 $\Phi(x_n)^{\top} \Phi(x_m)$ 。

示例：二阶多项式核定义

$$\Phi_2(x) = \left(1, x_1, \dots, x_d, x_1^2, x_1 x_2, \dots, x_d x_1, x_d^2 \right)^{\top} \in \mathbb{R}^{\frac{(d+1)(d+2)}{2}}.$$

对任意 $x, x' \in \mathbb{R}^d$ ，其内积可化简为

$$\Phi_2(x)^{\top} \Phi_2(x') = 1 + \sum_{i=1}^d x_i x'_i + \sum_{i=1}^d \sum_{j=1}^d x_i x_j x'_i x'_j = 1 + x^{\top} x' + (x^{\top} x')^2,$$

计算复杂度仅 $O(d)$ 。

命题 19.1.2 (核技巧：变换 + 内积一步完成)

定义核函数

$$K(x, x') \triangleq \Phi(x)^{\top} \Phi(x').$$

示例核：二阶多项式

$$K_2(x, x') = 1 + x^{\top} x' + (x^{\top} x')^2.$$

1. 二次规划矩阵

$$Q_{n,m} = y_n y_m K(x_n, x_m).$$

2. 最优偏置 b 任取支撑向量 (x_s, y_s) ($\alpha_s > 0$)，则

$$b = y_s - \sum_{n=1}^N \alpha_n y_n K(x_n, x_s).$$

3. 最优假设 g_{SVM} 对测试点 x ，

$$g_{\text{SVM}}(x) = \text{sign} \left(\sum_{n=1}^N \alpha_n y_n K(x_n, x) + b \right).$$

核技巧 用高效核函数 $K(\cdot, \cdot)$ 代替显式 $\Phi(\cdot)$ ，彻底摆脱对维度 \tilde{d} 的依赖。

算法 19.1.1: 核硬间隔支持向量机 (Kernel Hard-Margin SVM)

输入: 训练集 $\{(x_n, y_n)\}_{n=1}^N \subset \mathbb{R}^d \times \{-1, +1\}$; 核函数 $K(\cdot, \cdot)$

输出: 支撑向量 $\{(x_n, y_n)\}_{n \in \mathcal{I}_{SV}}$, 对应 α_n , 偏置 b , 决策函数 g_{SVM}

1. 构造 QP 参数:

$$Q_{n,m} \leftarrow y_n y_m K(x_n, x_m), \quad \text{for } n, m = 1, \dots, N$$

$$p \leftarrow -\mathbf{1}_N, \quad A \leftarrow y^\top, \quad c \leftarrow 0$$

$$\text{下界 lb} \leftarrow \mathbf{0}_N, \quad \text{上界 ub} \leftarrow +\infty$$

2. 求解 QP:

$$\alpha \leftarrow \text{QP}(Q, p, A, c)$$

3. 提取支撑向量与偏置:

$$\mathcal{I}_{SV} \leftarrow \{n \mid \alpha_n > \varepsilon\}, \quad \varepsilon = 10^{-6}$$

$$b \leftarrow y_s - \sum_{n \in \mathcal{I}_{SV}} \alpha_n y_n K(x_n, x_s), \quad \text{for any } s \in \mathcal{I}_{SV}$$

4. 定义决策函数:

$$g_{SVM}(x) = \text{sign} \left(\sum_{n \in \mathcal{I}_{SV}} \alpha_n y_n K(x_n, x) + b \right)$$

时间复杂度说明

- $\mathcal{O}(N^2)$: 计算核矩阵 Q (N^2 次核函数计算);
- 二次规划变量数为 N , 等式约束 1 个, N 个不等式;
- $\mathcal{O}(\#\text{SV})$: 预测阶段仅依赖支撑向量核值。

备注 核 SVM 利用核技巧 (kernel trick) 避免显式映射到高维特征空间, 训练和预测均仅依赖于支撑向量。

例题 19.1 选择题: 二次核函数的计算

考虑两个样本 \mathbf{x} 和 \mathbf{x}' , 满足 $\mathbf{x}^T \mathbf{x}' = 10$ 。则二次核函数 $K_{\Phi_2}(\mathbf{x}, \mathbf{x}')$ 的值为:

- 1) 1
- 2) 11
- 3) 111
- 4) 1111

解答 正确选项为 [3]。根据二次核函数公式 $K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$, 代入 $\mathbf{x}^T \mathbf{x}' = 10$ 得:

$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = 1 + 10 + 10^2 = 111$$

■

19.2 多项式核

命题 19.2.1 (通用二阶多项式核的三种等价形式)

对任意输入 $x, x' \in \mathbb{R}^d$, 二阶多项式核可写成三种等价但几何意义不同的形式:

形式一: 带常数项与交叉项

$$\Phi_2(x) = (1, x_1, \dots, x_d, x_1^2, \dots, x_d^2), \quad K_2(x, x') = 1 + x^\top x' + (x^\top x')^2.$$

形式二: 带缩放系数

$$\Phi_2(x) = (1, \sqrt{2}x_1, \dots, \sqrt{2}x_d, x_1^2, \dots, x_d^2), \quad K_2(x, x') = 1 + 2x^\top x' + (x^\top x')^2.$$

形式三: 带额外缩放与平方项

$$\Phi_2(x) = (1, \sqrt{2\gamma}x_1, \dots, \sqrt{2\gamma}x_d, \gamma x_1^2, \dots, \gamma x_d^2), \quad K_2(x, x') = 1 + 2\gamma x^\top x' + \gamma^2 (x^\top x')^2.$$

最常用紧凑形式

$$K_2(x, x') = (1 + x^\top x')^2, \quad \text{其中隐含系数 } \gamma = 1.$$

几何差异 三种 Φ_2 的幂次相同, 但内积缩放不同, 导致特征空间中的距离与角度各异; 而在 SVM 中, 常用

$$K_2(x, x') = (1 + x^\top x')^2$$

以获得简洁表达与数值稳定。

命题 19.2.2 (通用多项式核与线性核)

1. 通用多项式核 对阶次 $Q \geq 1$ 、参数 $\gamma > 0, \zeta \geq 0$, 定义

$$K_Q(x, x') = (\zeta + \gamma x^\top x')^Q.$$

该核隐式地将样本嵌入到度为 Q 的多项式特征空间 Φ_Q , 使 SVM 可在高维空间实现大间隔多项式分类, 而计算复杂度与原始维度 d 无关。

2. 线性核 (特殊情形) 取 $Q = 1, \gamma = 1, \zeta = 0$ 得

$$K_{\text{linear}}(x, x') = x^\top x',$$

即为标准内积核, 对应原始线性 SVM, 可直接在原始空间高效求解。

19.3 高斯核

命题 19.3.1 (无限维特征变换的核函数)

若存在高效可计算的核函数 $K(x, x')$, 则即使特征映射 $\Phi(x)$ 为无限维, 仍可实际应用。

1. 高斯核的无限维展开对一维输入 $x \in \mathbb{R}$, 令

$$K(x, x') = \exp(-(x - x')^2) = \exp(-x^2) \exp(-x'^2) \exp(2xx').$$

利用泰勒级数

$$\exp(2xx') = \sum_{i=0}^{\infty} \frac{(2xx')^i}{i!},$$

可得

$$K(x, x') = \exp(-x^2) \exp(-x'^2) \sum_{i=0}^{\infty} \frac{2^i}{i!} x^i x'^i = \Phi(x)^\top \Phi(x'),$$

其中

$$\Phi(x) = \exp(-x^2) \left(1, \sqrt{2}x, \sqrt{\frac{2^2}{2!}}x^2, \dots, \sqrt{\frac{2^i}{i!}}x^i, \dots \right)^\top$$

为无限维向量。

2. 一般高斯核（RBF 核）对任意维度 d ，定义

$$K(x, x') = \exp(-\gamma \|x - x'\|^2), \quad \gamma > 0.$$

该核对应无限维特征空间，但仅需 $O(d)$ 时间即可计算核值，实现“无限维变换 + 内积”一步完成。

命题 19.3.2 (高斯核 SVM 的假设与机制)

给定核函数

$$K(x, x') = \exp(-\gamma \|x - x'\|^2), \quad \gamma > 0,$$

高斯核（又称 RBF 核）SVM 的最终假设为

$$g_{\text{SVM}}(x) = \text{sign} \left(\sum_{n \in \mathcal{I}_{\text{SV}}} \alpha_n y_n \exp(-\gamma \|x - x_n\|^2) + b \right).$$

该式可视作以各支撑向量 x_n 为中心、系数为 $\alpha_n y_n$ 的高斯径向基函数的线性组合。

支撑向量机制

- 通过核技巧，将高阶甚至无限维特征变换 $\Phi(x)$ 简化为高效核值 $K(x, x')$ 。
- 无需显式存储 w ，仅需保留少量支撑向量及其 α_n 。
- 高斯 SVM 实现“无限维线性分类”，泛化性能由大间隔理论保证。




图 19.3.1: 硬间隔高斯核函数拟合图像

命题 19.3.3 (高斯核 SVM 的实际表现与过拟合风险)

高斯核

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

随参数 γ 增大呈如下行为：

- γ 较小：高斯函数平坦，决策边界平滑，欠拟合风险；

- γ 中等：边界与数据分布匹配良好；
- γ 较大：高斯函数尖锐，决策边界剧烈波动，存在过拟合风险。

重要提醒 即使采用大间隔框架，高斯 SVM 仍可能因 γ 过大而过拟合。因此需通过交叉验证或验证集对 γ （以及软间隔参数 C ）进行谨慎选择。



例题 19.2 选择题：高斯核函数的极限行为

考虑高斯核函数 $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$ 。当 $\gamma \rightarrow \infty$ 时，该核函数收敛到：

- 1) $K_{\lim}(\mathbf{x}, \mathbf{x}') = 0$
- 2) $K_{\lim}(\mathbf{x}, \mathbf{x}') = \mathbb{I}[\mathbf{x} = \mathbf{x}']$
- 3) $K_{\lim}(\mathbf{x}, \mathbf{x}') = \mathbb{I}[\mathbf{x} \neq \mathbf{x}']$
- 4) $K_{\lim}(\mathbf{x}, \mathbf{x}') = 1$

解答 正确选项为 2。当 $\gamma \rightarrow \infty$ 时：

- 若 $\mathbf{x} = \mathbf{x}'$ ，则 $K(\mathbf{x}, \mathbf{x}') \rightarrow 1$ ；
- 若 $\mathbf{x} \neq \mathbf{x}'$ ，则 $K(\mathbf{x}, \mathbf{x}') \rightarrow 0$ 。

这等价于指示函数 $\mathbb{I}[\mathbf{x} = \mathbf{x}']$ 。



19.4 核函数比较

命题 19.4.1 (线性核的优缺点)

核函数

$$K(x, x') = x^\top x'$$

缺点

- 表达能力受限——并非所有数据都能被线性分离。

优点

- 计算高效：可利用专门的原始 QP 求解器快速求解。
- 可解释性强：权重 w 与支撑向量均具有直观含义。
- 基本原则：先尝试线性模型，必要时再引入非线性核。

结论 线性核是 SVM 工具箱中不可或缺的基础利器。



命题 19.4.2 (多项式核的优缺点)

核函数

$$K(x, x') = (\zeta + \gamma x^\top x')^Q, \quad \gamma > 0, \zeta \geq 0, Q \in \mathbb{N}.$$

缺点

- 当阶次 Q 较大时易出现数值不稳定。
- 若 $|\zeta + \gamma x^\top x'| < 1$ ，则核值趋近 0；若大于 1，则迅速放大，导致数值尺度失衡。
- 含 γ, ζ, Q 三个超参数，调参复杂。

优点

- 表达能力优于线性核，可处理非线性可分数据。

- 明确控制多项式阶次 Q ，便于解释模型复杂度。
- 对低阶 Q （如 $Q = 2, 3$ ）往往足够有效。

建议 多项式核通常仅在 Q 较小时实用；高阶时可考虑先在显式高维特征 $\Phi(x)$ 上做线性 SVM，以规避数值与调参难题。

命题 19.4.3 (高斯核的优缺点)

核函数

$$K(x, x') = \exp(-\gamma \|x - x'\|^2), \quad \gamma > 0.$$

缺点

- 模型“黑箱”化：无限维特征空间导致 w 不可解释。
- 计算速度慢于线性核。
- 表达能力过强，易过拟合。

优点

- 比线性/多项式核更强大，能刻画复杂决策边界。
- 数值稳定，不会出现多项式核的极端放大或缩小。
- 仅一个超参数 γ ，调参相对简单。

结论 高斯核是实践中使用最广的核之一，但需通过交叉验证谨慎选择 γ 与软间隔参数 C ，以防过拟合。

命题 19.4.4 (其他有效核函数与 Mercer 条件)

核函数 $K(x, x')$ 体现特定相似度 $\Phi(x)^\top \Phi(x')$ ；“任意相似度 \Rightarrow 有效核”并不成立。

Mercer 充要条件 设 $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ 为候选核，记

$$K_{ij} = K(x_i, x_j), \quad \mathbf{K} = [K_{ij}] \in \mathbb{R}^{N \times N}.$$

则 K 为有效核当且仅当

- 对称性： $K(x, x') = K(x', x)$ ；
- 半正定性：对任意有限点集 $\{x_n\}_{n=1}^N$ ，Gram 矩阵

$$\mathbf{K} = \begin{bmatrix} \Phi(x_1)^\top \Phi(x_1) & \cdots & \Phi(x_1)^\top \Phi(x_N) \\ \vdots & \ddots & \vdots \\ \Phi(x_N)^\top \Phi(x_1) & \cdots & \Phi(x_N)^\top \Phi(x_N) \end{bmatrix}$$

半正定，即 $\mathbf{K} \geq 0$ 。

自定义核 任意满足上述 Mercer 条件的对称半正定函数均可作为新核；然而构造与验证通常较为困难。

例题 19.3 选择题：无效核函数的识别

下列哪个不是有效的核函数？（提示：考虑两个 1 维向量 $\mathbf{x}_1 = (1)$ 和 $\mathbf{x}_2 = (-1)$ ，验证 Mercer 条件。）

- 1) $K(\mathbf{x}, \mathbf{x}') = (-1 + \mathbf{x}^T \mathbf{x}')^2$
- 2) $K(\mathbf{x}, \mathbf{x}') = (0 + \mathbf{x}^T \mathbf{x}')^2$
- 3) $K(\mathbf{x}, \mathbf{x}') = (1 + \mathbf{x}^T \mathbf{x}')^2$


4) $K(\mathbf{x}, \mathbf{x}') = (-1 - \mathbf{x}^T \mathbf{x}')^2$

解答 正确选项为 1。构造核矩阵并验证半正定性：

- 选项 1 的核矩阵为 $\begin{pmatrix} 0 & 4 \\ 4 & 0 \end{pmatrix}$ ，行列式为 $-16 < 0$ ，不满足 Mercer 条件。
- 其他选项的核矩阵均半正定。

■

19.5 总结

 **笔记** [核支持向量机]

- 核技巧：核函数充当“变换 + 内积”的快捷方式。
- 多项式核：嵌入经过特殊缩放的多项式特征变换。
- 高斯核：隐式嵌入无限维特征变换。
- 核函数比较：线性核追求效率，高斯核追求表达能力。