第20章 软间隔支持向量机

20.1 动机与原问题

命题 20.1.1 (硬间隔 SVM 的缺点与软间隔的引入)

1. 硬间隔过拟合风险

即使采用大间隔, 硬间隔 SVM 仍可能过拟合, 主要原因:

- 高维/无限维特征映射 Φ 带来强大表达能力;
- 强制要求"完全可分"——若数据含噪声,则模型会强行拟合异常点。
- 2. 放弃部分样本: 软间隔思想

引入松弛变量 $\xi_n \geq 0$, 将硬间隔约束

$$y_n(w^{\top}z_n + b) \ge 1, \quad \forall n$$

放宽为

$$y_n(w^{\mathsf{T}}z_n+b) \ge 1-\xi_n, \quad \forall n,$$

并优化目标

$$\min_{b,w,\xi} \frac{1}{2} ||w||^2 + C \sum_{n=1}^{N} \xi_n,$$

其中 C > 0 权衡"大间隔"与"噪声容忍":

- C大: 近似硬间隔, 对误分类惩罚高;
- · C 小: 允许更多误分类或边界违规, 提升鲁棒性。

命题 20.1.2 (软间隔 SVM 的完整表述)

引入松弛变量 $\xi_n \ge 0$ 记录第 n 个样本的"间隔违规"程度,软间隔 SVM 可统一写成如下凸二次规划:

原始问题

$$\min_{b,w,\xi} \quad \frac{1}{2} ||w||^2 + C \sum_{n=1}^{N} \xi_n$$
s.t. $y_n(w^{\mathsf{T}} z_n + b) \ge 1 - \xi_n, \quad n = 1, \dots, N,$

$$\xi_n \ge 0, \quad n = 1, \dots, N.$$

超参数 C > 0 的作用

- C大: 惩罚间隔违规, 近似硬间隔;
- C 小: 容忍较大 ξ_n , 换取更大间隔与鲁棒性。

规模 该 QP 含 $\tilde{d}+1+N$ 个变量 (b,w,ξ) 与 2N 条线性约束。

下一步目标 将原始问题导出对偶形式,从而再次利用核技巧彻底消除对维度 \tilde{a} 的显式依赖。

20.2 对偶问题

命题 20.2.1 (软间隔 SVM 的拉格朗日对偶推导)

1. 原始问题

$$\min_{b,w,\xi} \ \tfrac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \quad \text{s.t.} \quad \begin{cases} y_n(w^\top z_n + b) \ge 1 - \xi_n, \\ \xi_n \ge 0, \quad n = 1, \dots, N. \end{cases}$$

2. 拉格朗日函数

引入乘子 $\alpha_n \geq 0$, $\beta_n \geq 0$,

$$\mathcal{L}(b, w, \xi, \alpha, \beta) = \frac{1}{2} \|w\|^2 + C \sum_{n=1}^{N} \xi_n + \sum_{n=1}^{N} \alpha_n \left[1 - \xi_n - y_n(w^{\mathsf{T}} z_n + b) \right] - \sum_{n=1}^{N} \beta_n \xi_n.$$

3. 消去 ξ_n 与 β_n

对 长, 求导并令为零得

$$\frac{\partial \mathcal{L}(b, w, \xi, \alpha, \beta)}{\partial \xi_n} = C - \alpha_n - \beta_n = 0 \Longrightarrow \beta_n = C - \alpha_n.$$

于是 β_n 可被隐式约束 $0 \le \alpha_n \le C$ 取代, 且

$$\mathcal{L}(b, w, \alpha) = \frac{1}{2} ||w||^2 + \sum_{n=1}^{N} \alpha_n \left[1 - y_n(w^{\top} z_n + b) \right].$$

4. 消去 b 与 w

与硬间隔 SVM 相同,有

$$\sum_{n=1}^{N} \alpha_n y_n = 0, \qquad w = \sum_{n=1}^{N} \alpha_n y_n z_n.$$

5. 标准软间隔对偶

代入化简后得到

$$\max_{\alpha} \left(\sum_{n=1}^{N} \alpha_n - \frac{1}{2} \sum_{n,m} \alpha_n \alpha_m y_n y_m z_n^{\top} z_m \right) \quad \text{s.t.} \quad \sum_{n=1}^{N} \alpha_n y_n = 0, \ 0 \leq \alpha_n \leq C.$$

命题 20.2.2 (标准软间隔 SVM 的对偶形式)

软间隔 SVM 的对偶问题可表示为以下凸二次规划:

$$\min_{\alpha} \quad \frac{1}{2} \sum_{n=1}^{N} \sum_{m=1}^{N} \alpha_n \alpha_m y_n y_m z_n^{\top} z_m - \sum_{n=1}^{N} \alpha_n$$

s.t.
$$\sum_{n=1}^{N} y_n \alpha_n = 0$$
, $0 \le \alpha_n \le C$, $n = 1, ..., N$.

变量与约束规模

• 变量: $N \wedge \alpha_n$ 。

• 约束: 1条等式约束 + N 条下界约束 + N 条上界约束,共 2N + 1 条。

与硬间隔 SVM 的差异: 硬间隔 SVM 对 α_n 仅有非负约束, 软间隔 SVM 额外引入上界 $\alpha_n \leq C$ 。

隐式恢复

$$w = \sum_{n=1}^{N} \alpha_n y_n z_n, \qquad \beta_n = C - \alpha_n, \quad n = 1, \dots, N.$$

20.3 软间隔 SVM 的启示

算法 20.3.1: 核软间隔 SVM (Kernel Soft-Margin SVM)

输入: 训练集 $\{(x_n, y_n)\}_{n=1}^N$; 核函数 $K(\cdot, \cdot)$; 惩罚参数 C > 0

输出: 支撑向量索引集 \mathcal{I}_{SV} , 对应 α_n , 偏置 b, 决策函数 g_{SVM}

1. 构造 QP 参数

$$Q_{n,m} \leftarrow y_n y_m K(x_n, x_m), \quad n, m = 1, \dots, N,$$
 $p \leftarrow -\mathbf{1}_N, \quad A_{eq} \leftarrow y^\top, \quad c_{eq} \leftarrow 0,$ $lb \leftarrow 0_N, \quad ub \leftarrow C\mathbf{1}_N.$

2. 求解二次规划

$$\alpha \leftarrow \text{QP}(Q, p, A_{\text{eq}}, c_{\text{eq}}, \text{lb}, \text{ub}).$$

3. 提取支撑向量

$$\mathcal{I}_{SV} \leftarrow \{n \mid \alpha_n > 0\}, \quad \mathcal{I}_{free} \leftarrow \{n \mid 0 < \alpha_n < C\}.$$

4. 计算偏置 任取 $s \in \mathcal{I}_{free}$ (自由支撑向量),则

$$b \leftarrow y_s - \sum_{n \in \mathcal{I}_{\text{SV}}} \alpha_n y_n \, K(x_n, x_s).$$

5. 决策函数 对任意新样本 x,

$$g_{\text{SVM}}(x) = \operatorname{sign}\left(\sum_{n \in \mathcal{I}_{\text{SV}}} \alpha_n y_n K(x_n, x) + b\right).$$

复杂度

- 训练: $\mathcal{O}(N^3)$ (QP) + $\mathcal{O}(N^2)$ (核矩阵)。
- 预测: O(|I_{SV}|) (仅支撑向量)。

性质

- 与硬间隔 SVM 步骤几乎一致,仅增加上界约束 $\alpha_n \leq C$ 。
- 原始/对偶问题恒有解,更灵活地容忍噪声。

命题 20.3.1 (软间隔高斯核 SVM 的实际表现与调参)

高斯核

$$K(x, x') = \exp(-\gamma ||x - x'||^2)$$

与软间隔参数 C 共同决定决策边界形状:

• C=1: 较大容忍度,边界光滑,欠拟合风险;

- C = 10: 中等容忍度, 边界与数据分布基本匹配;
- C=100: 几乎不容忍违规, 边界尖锐, 过拟合风险上升。

重要提醒 即使采用软间隔,高斯 SVM 仍可能因 (γ, C) 选择不当而 过拟合。

实践要求 必须通过交叉验证或验证集,对 (γ,C) 进行谨慎联合调参。




图 20.3.1: 软间隔高斯核函数拟合图像

命题 **20.3.2** (α_n 的物理意义)

由互补松弛条件

$$\alpha_n [1 - y_n(w^{\mathsf{T}} z_n + b)] = 0, \qquad (C - \alpha_n) \xi_n = 0,$$

可将样本按 α_n 分为三类:

- 非支持向量 $(\alpha_n = 0)$
 - $\xi_n = 0$, 样本落在"胖边界"之外或之上, 对决策边界无影响。
- □自由支撑向量($0 < \alpha_n < C$)
 - $\xi_n = 0$, 样本恰好落在"胖边界"上, 用于唯一确定偏置 b。
- \triangle 边界支撑向量 $(\alpha_n = C)$
 - $\xi_n > 0$ 记录违规量, 样本已越过"胖边界", 但仍在容忍范围内。

结论 系数 α_n 不仅决定支撑向量, 还能用于后续数据分析, 如异常检测、样本重要性评估等。




图 **20.3.2:** α_n 的物理意义

例题 20.1 选择题: SVM 训练误差的范围

对于大小为 10000 的数据集,假设 SVM 的支持向量数为 1126,其中 1000 个支持向量被"有界"(bounded)。则 0/1 误差下 $E_{\text{in}}(g_{\text{SVM}})$ 的可能范围是:

- 1) $0.0000 \le E_{\text{in}}(g_{\text{SVM}}) \le 0.1000$
- 2) $0.1000 \le E_{\text{in}}(g_{\text{SVM}}) \le 0.1126$
- 3) $0.1126 \le E_{in}(g_{SVM}) \le 0.5000$
- 4) $0.1126 \le E_{\text{in}}(g_{\text{SVM}}) \le 1.0000$

解答 正确选项为 1 。有界支持向量是唯一可能违反"胖边界"的样本。当 $\xi_n \ge 1$ 时,违反会导致 0/1 错误;当 $\xi_n < 1$ 时,违反不导致 0/1 错误。因此,训练误差范围为 $0.0000 \le E_{\rm in}(g_{\rm SVM}) \le 0.1000$ 。■

20.4 模型选择

命题 20.4.1 (SVM 的留一交叉验证误差与支撑向量数的关系)

1. 留一交叉验证误差上界

对含N个样本的训练集,留一交叉验证误差满足


$$E_{\text{LOOCV}} \leq \frac{|\mathcal{I}_{\text{SV}}|}{N},$$

其中 Isv 为全部支撑向量的索引集。

直观解释 若最优解中 $\alpha_N = 0$ (即第 N 个样本为非支撑向量),则去掉该样本后剩余的最优 $\alpha_1, \ldots, \alpha_{N-1}$ 仍保持不变,因此预测误差为 0; 唯有支撑向量才可能导致留一误差。

- 2. 用支撑向量数调参
 - $n_{SV}(C,\gamma)$ 是 (C,γ) 的非光滑函数,直接优化困难;
 - 可作为计算 E_{CV} 过于耗时时的"安全检查": 在少量网格点上排除 n_{SV} 过大的危险模型;
 - 仅为上界,实际误差可能远低于该比例。

20.5 总结



- 动机与原问题:引入松弛变量 ξ_n 以允许间隔违规。
- 对偶问题: 拉格朗日乘子 α_n 被常数 C 上界约束。
- 软间隔 SVM 的启示:通过"有界/自由"支持向量进行数据分析。
- 模型选择:使用交叉验证,或近似地依据支持向量数目 nsv。