

## 第 22 章 支持向量回归

### 22.1 核岭回归

#### 算法 22.1.1: 核岭回归 (Kernel Ridge Regression, KRR)

**问题表述** 利用表示定理, 将 L2 正则岭回归写成仅与系数  $\beta$  相关的核化形式:

$$\min_{\beta \in \mathbb{R}^N} \frac{\lambda}{N} \sum_{n=1}^N \sum_{m=1}^N \beta_n \beta_m K(x_n, x_m) + \frac{1}{N} \sum_{n=1}^N \left( y_n - \sum_{m=1}^N \beta_m K(x_n, x_m) \right)^2$$

**矩阵形式** 令  $\mathbf{K} \in \mathbb{R}^{N \times N}$  为核矩阵,  $\mathbf{y} = (y_1, \dots, y_N)^\top$ , 则目标函数为

$$E_{\text{aug}}(\beta) = \frac{\lambda}{N} \beta^\top \mathbf{K} \beta + \frac{1}{N} \|\mathbf{y} - \mathbf{K} \beta\|^2 = \frac{\lambda}{N} \beta^\top \mathbf{K} \beta + \frac{1}{N} (\beta^\top \mathbf{K}^\top \mathbf{K} \beta - 2 \beta^\top \mathbf{K}^\top \mathbf{y} + \mathbf{y}^\top \mathbf{y}).$$

**解析解** 对目标函数求梯度并令其为零:

$$\nabla E_{\text{aug}}(\beta) = \frac{2}{N} (\lambda \mathbf{K}^\top \mathbf{I} \beta + \mathbf{K}^\top \mathbf{K} \beta - \mathbf{K}^\top \mathbf{y}) = 0 \Rightarrow (\lambda \mathbf{I} + \mathbf{K}) \beta = \mathbf{y}.$$

由于  $\lambda > 0$  且  $\mathbf{K}$  为半正定矩阵 (满足 Mercer 条件), 因此矩阵  $\lambda \mathbf{I} + \mathbf{K}$  可逆, 解为:

$$\beta = (\lambda \mathbf{I} + \mathbf{K})^{-1} \mathbf{y}.$$

**预测函数** 对任意新样本  $x$ , 其预测值为:

$$f(x) = \sum_{n=1}^N \beta_n K(x_n, x).$$

**复杂度**

- 训练复杂度:  $\mathcal{O}(N^3)$  (核矩阵求逆);
- 预测复杂度:  $\mathcal{O}(N)$  (对每个测试样本计算  $N$  个核值)。

表 22.1.1: 线性岭回归 vs. 核岭回归

	线性岭回归	核岭回归
解析解	$(\lambda \mathbf{I} + X^\top X)^{-1} X^\top y$	$(\lambda \mathbf{I} + K)^{-1} y$
模型能力	受限 (线性假设)	灵活 (由核函数决定)
训练复杂度	$\mathcal{O}(d^3 + d^2 N)$	$\mathcal{O}(N^3)$
预测复杂度	$\mathcal{O}(d)$	$\mathcal{O}(N)$
适用场景	$N \gg d$ 时高效	大数据时困难

**注** 线性 vs. 核岭回归: 在计算效率与模型灵活性之间权衡。

## 22.2 支持向量回归原问题

### 定义 22.2.1 (最小二乘支持向量机 (Least-Squares SVM))

最小二乘支持向量机 (LS-SVM) 是由 Suykens 和 Vandewalle 提出的一类监督学习方法，可视为传统支持向量机 (SVM) 的最小二乘版本。其核心特点包括：

- 优化目标：在正则化框架下最小化平方误差与权重范数的加权和

$$\min_{w,b,e} \frac{1}{2} w^\top w + \frac{\gamma}{2} \sum_{n=1}^N e_n^2,$$

其中松弛变量  $e_n$  满足等式约束

$$y_n(w^\top \Phi(x_n) + b) = 1 - e_n, \quad n = 1, \dots, N.$$

- 线性系统求解：通过引入拉格朗日乘子  $\alpha_n$ ，最终转化为线性 Karush-Kuhn-Tucker (KKT) 方程组

$$\begin{bmatrix} 0 & \mathbf{1}^\top \\ \mathbf{1} & K + \gamma^{-1}I \end{bmatrix} \begin{bmatrix} b \\ \alpha \end{bmatrix} = \begin{bmatrix} 0 \\ y \end{bmatrix},$$

其中  $K_{n,m} = y_n y_m k(x_n, x_m)$  为核矩阵。

- 与传统 SVM 的区别：
  - 1) 使用等式约束代替不等式约束，避免二次规划；
  - 2) 解由线性方程组给出，计算速度快；
  - 3) 失去解的稀疏性（所有样本均贡献）；
  - 4) 对误差分布假设更敏感，需额外正则化或加权处理。
- 适用场景：回归、分类、函数估计及非线性系统建模，尤其适用于样本量中等但对计算效率要求较高的任务。



表 22.2.1: 软间隔 SVM vs. 最小二乘 SVM (LS-SVM)

	软间隔 SVM	最小二乘 SVM (LS-SVM)
本质	最大间隔分类器	核岭回归用于分类
决策边界	稀疏支撑向量决定	与软间隔 SVM 近似
支撑向量	稀疏 $\alpha$ (少量 SV)	稠密 $\beta$ (所有样本)
预测复杂度	$O( \mathcal{I}_{SV} )$	$O(N)$
实际影响	预测快	预测慢，内存占用大
稀疏性	期望稀疏 $\alpha$	期望稀疏 $\beta$ (难点)

**注** LS-SVM 与核逻辑回归一样产生稠密系数；标准 SVM 的稀疏性仍是高效预测的关键。

**命题 22.2.1 (Tube 回归 ( $\varepsilon$ -不敏感回归))**

误差定义 给定容忍宽度  $\varepsilon > 0$ ，定义  $\varepsilon$ -不敏感误差

$$\text{err}(y, s) = \max(0, |s - y| - \varepsilon) = \begin{cases} 0, & |s - y| \leq \varepsilon, \\ |s - y| - \varepsilon, & |s - y| > \varepsilon. \end{cases}$$

几何意义

- 在  $|s - y| \leq \varepsilon$  的“管”内：误差为 0；
- 在管外：误差为到管边界的垂直距离。

与平方误差对比

$$\text{err}_{\text{sq}}(y, s) = (s - y)^2.$$

- 当  $|s - y| \ll \varepsilon$  时， $\text{err}(y, s) \approx 0$  而平方误差仍较小；
- 当  $|s - y| \gg \varepsilon$  时，管误差线性增长，对离群点更不敏感；
- 当  $|s - y|$  较小时， $\text{err}_{\text{tube}} \approx \text{err}_{\text{sq}}$ ，且受异常值的影响较小。




图 22.2.1: 平方误差与管误差对比图

**命题 22.2.2 (L2 正则化 Tube 回归与 SVR 的统一视角)**

原始无约束问题

$$\min_w \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \max(0, |w^\top z_n + b - y_n| - \varepsilon)$$

因含不可微的  $\max(\cdot)$  而难以直接优化。借鉴标准 SVM 的做法，引入松弛变量并转化为二次规划：

支持向量回归 (SVR) 的原始形式

$$\begin{aligned} \min_{b, w, \xi^\wedge, \xi^\vee} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s. t.} \quad & |y_n - w^\top z_n - b| \leq \varepsilon + \xi_n, \quad \xi_n \geq 0. \end{aligned}$$

化简支持向量回归 (SVR) 的原始形式

$$\begin{aligned} \min_{b, w, \xi^\wedge, \xi^\vee} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N (\xi_n^\wedge + \xi_n^\vee) \\ \text{s. t.} \quad & y_n - w^\top z_n - b \leq \varepsilon + \xi_n^\wedge, \\ & w^\top z_n + b - y_n \leq \varepsilon + \xi_n^\vee, \\ & \xi_n^\wedge, \xi_n^\vee \geq 0, \quad n = 1, \dots, N. \end{aligned}$$

后续步骤

- 利用表示定理将  $w$  表示为核函数的线性组合，实现核化；
- 构造拉格朗日对偶，导出仅含对偶变量  $\alpha_n$  的 QP；
- KKT 条件将自动给出稀疏解：仅  $|w^\top z_n + b - y_n| \geq \varepsilon$  的样本成为支撑向量。



#### 算法 22.2.2: 支持向量回归 (Support Vector Regression, SVR)

**原始问题 (Primal)** 引入松弛变量  $\xi_n^+, \xi_n^- \geq 0$  分别表示上、下管外违规量，SVR 的原始优化问题为

$$\begin{aligned} \min_{b, w, \xi^\wedge, \xi^\vee} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N (\xi_n^\wedge + \xi_n^\vee) \\ \text{s. t.} \quad & y_n - w^\top z_n - b \leq \varepsilon + \xi_n^\wedge, \\ & w^\top z_n + b - y_n \leq \varepsilon + \xi_n^\vee, \\ & \xi_n^\wedge \geq 0, \quad \xi_n^\vee \geq 0, \quad n = 1, \dots, N. \end{aligned}$$

参数解释

- $C > 0$ : 正则化与管外违规的权衡；
- $\varepsilon > 0$ : 垂直管宽度 (容忍误差范围)。

二次规划规模

- 变量:  $\tilde{d} + 1 + 2N$  ( $b, w, \xi^\wedge, \xi^\vee$ );
- 约束:  $4N$  条线性不等式。

下一步 通过拉格朗日对偶消除对维度  $\tilde{d}$  的依赖，实现核技巧。

#### 例题 22.1 选择题: SVR 松弛变量的计算

考虑使用  $\varepsilon = 0.05$  求解支持向量回归 (SVR)。在最优解处，已知  $\mathbf{w}^T \mathbf{z}_1 + b = 1.234$  和  $y_1 = 1.126$ 。则松弛变量  $\xi_1^\vee$  和  $\xi_1^\wedge$  的值为：

- 1)  $\xi_1^\vee = 0.108, \xi_1^\wedge = 0.000$
- 2)  $\xi_1^\vee = 0.000, \xi_1^\wedge = 0.108$
- 3)  $\xi_1^\vee = 0.058, \xi_1^\wedge = 0.000$
- 4)  $\xi_1^\vee = 0.000, \xi_1^\wedge = 0.058$

**解答** 正确选项为 [3]。计算偏差  $y_1 - (\mathbf{w}^T \mathbf{z}_1 + b) - \varepsilon = -0.158$ ，由于小于 0，故  $\xi_1^\vee = 0.000$ ；计算偏差  $(\mathbf{w}^T \mathbf{z}_1 + b) - y_1 - \varepsilon = 0.058$ ，故  $\xi_1^\wedge = 0.058$ 。 ■

## 22.3 支持向量回归对偶

### 命题 22.3.1 (SVR 的对偶推导与解的稀疏性)

1. 拉格朗日函数与对偶变量 引入两组拉格朗日乘子

$$\alpha_n^\wedge \geq 0 \quad \text{对应} \quad y_n - (w^\top z_n + b) \leq \varepsilon + \xi_n^\wedge, \quad \alpha_n^\vee \geq 0 \quad \text{对应} \quad (w^\top z_n + b) - y_n \leq \varepsilon + \xi_n^\vee.$$

原始拉格朗日函数 (已消去松弛变量  $\xi_n^\wedge$  和  $\xi_n^\vee$  [利用求导求极值的方式]):

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + \sum_{n=1}^N \left[ \alpha_n^\wedge (-\varepsilon + y_n - w^\top z_n - b) + \alpha_n^\vee (-\varepsilon - y_n + w^\top z_n + b) \right].$$

2. 对偶问题 通过标准推导得到

$$\begin{aligned} \min_{\alpha^\wedge, \alpha^\vee} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N (\alpha_n^\wedge - \alpha_n^\vee)(\alpha_m^\wedge - \alpha_m^\vee) K(x_n, x_m) + \varepsilon \sum_{n=1}^N (\alpha_n^\wedge + \alpha_n^\vee) - \sum_{n=1}^N y_n (\alpha_n^\wedge - \alpha_n^\vee) \\ \text{s.t.} \quad & \sum_{n=1}^N (\alpha_n^\wedge - \alpha_n^\vee) = 0, \quad 0 \leq \alpha_n^\wedge, \alpha_n^\vee \leq C, \quad n = 1, \dots, N. \end{aligned}$$

3. 稀疏性 令  $\beta_n = \alpha_n^\wedge - \alpha_n^\vee$ , 则

$$w = \sum_{n=1}^N (\alpha_n^\wedge - \alpha_n^\vee) z_n = \sum_{n=1}^N \beta_n z_n \quad \text{且} \quad f(x) = w^\top z + b = \sum_{n=1}^N \beta_n K(x_n, x) + b.$$

由互补松弛条件

$$\alpha_n^\wedge (\varepsilon + \xi_n^\wedge - y_n + w^\top z_n + b) = 0, \quad \alpha_n^\vee (\varepsilon + \xi_n^\vee + y_n - w^\top z_n - b) = 0,$$

可得

- 严格位于管内  $|f(x_n) - y_n| < \varepsilon$  时  $\xi_n^\wedge = \xi_n^\vee = 0 \Rightarrow \alpha_n^\wedge = \alpha_n^\vee = 0 \Rightarrow \beta_n = 0$ ;
- 仅位于管边界或管外的样本才成为支撑向量,  $\beta_n \neq 0$ 。

故 SVR 同样具有稀疏解。



### 例题 22.2 选择题: SVR 对偶问题的变量数量

支持向量回归 (SVR) 对偶问题的二次规划 (QP) 变量数量为:

- 1)  $\tilde{d} + 1$
- 2)  $\tilde{d} + 1 + 2N$
- 3)  $N$
- 4)  $2N$

解答 正确选项为 [4]。SVR 对偶问题的变量为拉格朗日乘数  $\alpha_i^\vee$  和  $\alpha_i^\wedge$  (各  $N$  个), 总数量为  $2N$ 。■

22.4 核模型小结

表 22.4.1: 线性模型一览 (Map of Linear Models)

	优化目标	求解方式	说明
PLA / Pocket	直接最小化 0/1 误差	迭代修正	仅线性可分时有有效
线性软间隔 SVM	正则化合页损失	QP (二次规划)	大间隔, 稀疏解
线性岭回归	正则化平方损失	解析解	稠密系数, 无稀疏性
正则化逻辑回归	正则化交叉熵	GD/SGD 等	概率输出, 稠密系数
线性 SVR (Tube 回归)	正则化 $\epsilon$ -不敏感损失	QP	稀疏支撑向量

注 线性软间隔 SVM、线性岭回归、正则化逻辑回归、线性 SVR 均为 LIBLINEAR 库中的常用算法。

表 22.4.2: 线性 / 核模型综合一览 (Comprehensive Map of Linear / Kernel Models)

类别	模型	求解方式	稀疏性	使用情况	说明
线性	PLA / Pocket	迭代修正	稀疏 (误分修正)	性能较差, 较少使用	仅线性可分时有有效
	线性软间隔 SVM	QP (二次规划)	稀疏 $\alpha$	中等规模常用	大间隔, 稀疏 $\alpha$
	线性岭回归	解析解	稠密	小数据常用	稠密系数
	正则化逻辑回归	GD / SGD	稠密	概率输出常用	概率输出, 稠密系数
	线性 SVR	QP	稀疏 $\alpha$	回归任务常用	$\epsilon$ -不敏感损失, 稀疏 $\alpha$
核化	核岭回归	解析解	稠密 $\beta$ (所有样本)	因稠密 $\beta$ , 大数据少用	非线性映射
	核逻辑回归	无约束优化	稠密 $\beta$	因稠密 $\beta$ , 大数据少用	概率输出
	核 SVM	对偶 QP	稀疏 $\alpha$	LIBSVM 主力模型	非线性边界
	核 SVR	对偶 QP	稀疏 $\alpha$	LIBSVM 主力模型	非线性回归
	概率 SVM	SVM-变换后逻辑回归	稀疏 $\alpha$	LIBSVM 扩展模型	概率校准

注 1. 核 SVM、核 SVR、核岭回归、核逻辑回归、概率 SVM 均为 LIBSVM 库中的常用核化算法。  
2. 线性模型因性能受限而较少采用; 核化稠密模型 (核岭回归、核逻辑回归) 因预测时需全部核值, 计算代价高, 大数据场景下使用受限。

22.5 总结

笔记 [支持向量回归]

- 核岭回归: 在岭回归上应用表示定理, 实现核化。
- 支持向量回归原问题: 最小化带正则的  $\epsilon$ -tube 误差。
- 支持向量回归对偶: 与 SVM 对偶类似, 仍为二次规划 (QP)。

- 核模型小结：力量越大，责任越大（使用高表达能力核函数需谨慎）。



**笔记** [支持向量回归总结] 支持向量回归通过核技巧与  $\varepsilon$ -不敏感损失，在保留线性模型优势的同时实现非线性回归，核岭回归提供核化的解析解但系数稠密，SVR 则借助对偶优化获得稀疏解（仅依赖支持向量），显著提升预测效率。这一框架需平衡模型灵活性（核函数选择）与复杂度（参数  $C$ 、 $\varepsilon$  调节），避免过拟合。整体而言，支持向量回归是连接线性方法与复杂回归任务的重要工具，其稀疏性与核化能力使其在中等规模数据场景中表现突出。