第30章 径向基函数网络

30.1 RBF 网络假设

定义 30.1.1 (径向基函数(Radial Basis Function, RBF))

径向基函数(Radial Basis Function, RBF)是一类实值函数, 其函数值仅依赖于输入向量与某一固定中心点之间的欧氏距离, 而与方向无关。数学上, 存在一元函数 $\varphi:[0,\infty)\to\mathbb{R}$, 使得

$$\Phi(x) = \varphi(\|x - c\|),$$

其中c为中心向量, $\|\cdot\|$ 为欧几里得范数。

常见实例

• 高斯径向基函数

$$\varphi(r) = \exp\left(-\frac{r^2}{2\sigma^2}\right), \quad \sigma > 0.$$

• 多二次径向基函数

$$\varphi(r) = \sqrt{r^2 + c^2}, \quad c > 0.$$

• 逆多二次径向基函数

$$\varphi(r) = \frac{1}{\sqrt{r^2 + c^2}}, \quad c > 0.$$

• 薄板样条径向基函数

$$\varphi(r) = r^2 \log r.$$

主要特性

- 径向对称, 便于高维推广;
- 局部作用:远离中心时函数值迅速衰减;
- 根据 Stone-Weierstrass 定理, RBF 组合可在紧集上任意精度逼近任意连续函数。

应用领域。函数插值、曲面重建、支持向量机核函数、RBF神经网络隐层激活函数等。

命题 30.1.1 (从神经网络到 RBF 网络)

RBF(径向基函数)网络可视为神经网络的一种特殊结构,二者仅在隐藏层计算方式不同。

- 1. 隐藏层对比
 - 神经网络: 内积+非线性

$$h_j(x) = \tanh(w_j^{\mathsf{T}} x + b_j).$$

• RBF 网络: 距离 + 径向基

$$RBF(x, \mu_m) = h_m(x) = \exp(-\gamma ||x - \mu_m||^2).$$

2. 输出层统一 均为线性聚合

$$g(x) = \sum_{m=1}^{M} \beta_m h_m(x) + b.$$

3.RBF 网络假设

给定中心 μ_m 与权重 β_m , RBF 网络定义为

$$g(x) = \sum_{m=1}^{M} \beta_m \exp(-\gamma ||x - \mu_m||^2) + b.$$

其中

- μ_m : 中心 (可随机选、K-means 或 SVM 支持向量);
- β_m : 带符号的投票权重 (可最小二乘或 SVM 对偶系数 $\alpha_m y_m$)。

4. 与 SVM 的联系

高斯核 SVM 可视为

$$M = \#SV$$
, $\mu_m = 支持向量$, $\beta_m = \alpha_m y_m$.

结论 RBF 网络以距离度量替代内积,兼具神经网络与核方法的优点,历史上被视为神经网络的重要分支。

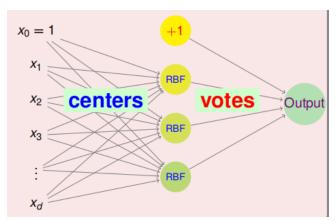


图 30.1.1: RBF 网络

命题 30.1.2 (RBF 与相似性)

RBF 网络通过"空间距离"度量输入x与中心 μ_m 的相似度,从而构造特征变换。常见相似度函数

• 神经网络神经元

Neuron
$$(x, x') = \tanh(\gamma x^{\top} x' + 1).$$

• 字符串相似度

$$DNASim(x, x') = EditDistance(x, x').$$

· 核函数(Mercer 条件)

$$Poly(x, x') = (1 + x^{T}x')^{2},$$
 $Gaussian(x, x') = exp(-\gamma ||x - x'||^{2}).$

• 截断相似度

Truncated
$$(x, x') = \max(0, 1 - ||x - x'||)^2$$
.

RBF 视角

RBF 网络将"距离到中心"的单调不增函数作为相似度, 进而

$$\Phi(x) = \left[\mathsf{Gaussian}(x, \mu_1), \dots, \mathsf{Gaussian}(x, \mu_M) \right]^\top$$

完成特征变换, 随后线性组合即可。

结论 RBF 网络把"距离 \rightarrow 相似度 \rightarrow 特征"作为统一框架,兼容核方法与神经网络思想。

例题 30.1 选择题: 径向基函数的判定

以下哪一项不是径向基函数 (radial basis function)?

- 1) $\phi(\mathbf{x}, \boldsymbol{\mu}) = \exp(-\gamma \|\mathbf{x} \boldsymbol{\mu}\|^2)$
- 2) $\phi(\mathbf{x}, \boldsymbol{\mu}) = -\sqrt{\mathbf{x}^T \mathbf{x} 2\mathbf{x}^T \boldsymbol{\mu} + \boldsymbol{\mu}^T \boldsymbol{\mu}}$
- 3) $\phi(\mathbf{x}, \boldsymbol{\mu}) = [\![\mathbf{x} = \boldsymbol{\mu}]\!]$
- 4) $\phi(\mathbf{x}, \boldsymbol{\mu}) = \mathbf{x}^T \mathbf{x} + \boldsymbol{\mu}^T \boldsymbol{\mu}$

解答 正确选项为 4。径向基函数的核心是函数值仅依赖于输入 x 与中心 μ 的距离(即 $\phi(\mathbf{x}, \mu) = \phi(\|\mathbf{x} - \mu\|)$)。

- 选项 1 是高斯径向基函数, 依赖 $\|\mathbf{x} \boldsymbol{\mu}\|^2$;
- 选项 2 化简后依赖 ||x μ||;
- 选项 3 是指示函数, 依赖 $\|\mathbf{x} \boldsymbol{\mu}\| = 0$ 的条件;
- 选项 $4 \mathbf{x}^T \mathbf{x} + \boldsymbol{\mu}^T \boldsymbol{\mu} = \mathbf{x} \times \mathbf{n} \boldsymbol{\mu}$ 的距离无关,不满足径向基函数的定义。

因此,选项4不是径向基函数。

30.2 RBF 网络学习

命题 30.2.1 (Full RBF 网络与最近邻)

当 RBF 网络将 全部训练样本设为基函数中心时,可导出两种经典模型。

1. Full RBF 网络

令中心数 M = N 且 $\mu_m = x_m$, 则

$$g_{\text{uniform}}(x) = \operatorname{sign}\left(\sum_{m=1}^{N} y_m \exp(-\gamma ||x - x_m||^2)\right).$$

物理意义: 每个样本 x_m 依据相似度 $\exp(-\gamma ||x-x_m||^2)$ 对 x 投出带符号的"一票"。

2. 最近邻 (1-NN)

若仅保留相似度最大的一项,则投票退化为选择:

nbor
$$(x) = y_m$$
, $\sharp + m = \arg\min_i ||x - x_i||$.

进一步推广到 k 个最近邻可得到 k-NN 模型:

$$g_{k-\mathrm{NN}}(x) = \mathrm{sign}\Big(\sum_{x_i \in \mathcal{N}_k(x)} y_i\Big), \quad \mathcal{N}_k(x) \; eta x \; \mathbf{n} \;$$

结论 Full RBF 网络由"全体投票"演变为"最近邻选择",揭示了 RBF、核方法与实例学习之间的内在联系。

命题 30.2.2 (全连接 RBF 网络的插值性质)

考虑平方误差意义下的回归任务, 采用全连接 RBF 网络

$$h(x) = \sum_{m=1}^{N} \beta_m \underbrace{\text{RBF}(x, x_m)}_{\text{Gaussian}}, \quad$$
其中中心 $\mu_m = x_m, \ M = N.$

线性回归视角

将输入 x 通过径向基变换映射为

 $z_n = \left[\mathrm{RBF}(x_n, x_1), \ \mathrm{RBF}(x_n, x_2), \ \dots, \ \mathrm{RBF}(x_n, x_N) \right]^{\top} \in \mathbb{R}^N, \quad Z = [z_1, \dots, z_N]^{\top} \in \mathbb{R}^{N \times N}.$ 最优系数由最小二乘给出

$$\beta = (Z^{\mathsf{T}}Z)^{-1}Z^{\mathsf{T}}y, \quad y = [y_1, \dots, y_N]^{\mathsf{T}}.$$

插值定理

若所有样本 $\{x_n\}_{n=1}^N$ 互不相同,则采用高斯 RBF 的矩阵 Z 正定、可逆,于是

$$\beta = Z^{-1}y$$
, 网络恰好插值所有训练点: $h(x_n) = y_n, \forall n$.

结论 全连接 RBF 网络在高斯核下天然具备插值能力,其系数可通过一次性求解线性方程组获得。

命题 30.2.3 (正则化全连接 RBF 网络与中心剪枝)

全连接高斯 RBF 网络在插值情形下满足

$$g_{RBF}(x_n) = y_n, \quad \forall n = 1, \dots, N, \implies E_{in} = 0,$$

称为精确插值, 但易导致过拟合。

1. 正则化系数估计

采用岭回归 (ridge regression) 代替最小二乘, 得

$$\beta = (Z^{\top}Z + \lambda I)^{-1}Z^{\top}y,$$

其中

$$Z^{\top}Z = [\operatorname{Gaussian}(x_n, x_m)]_{n,m=1}^{N} = K$$

即高斯核矩阵,于是

$$\beta = (K + \lambda I)^{-1} y,$$

等价于核岭回归。

2. 中心剪枝正则化

用 M < N 个中心 $\{\mu_m\}_{m=1}^M$ 替代全部 N 个样本中心:

$$g(x) = \sum_{m=1}^{M} \beta_m \text{ Gaussian}(x, \mu_m) + b, \quad \mu_m \$$
 为原型/质心.

- 降低参数数量,抑制过拟合;
- 物理意义: μ_m 作为数据的代表性"原型";
- 与 SVM 类比: 支持向量仅为一组有效中心。

结论 通过正则化或中心剪枝,全连接 RBF 网络从"精确插值"过渡到"稳健学习",兼顾拟合

与泛化。

4

例题 30.2 选择题:全高斯 RBF 网络 Z 矩阵变化

若 $\mathbf{x}_1 = \mathbf{x}_2$, 全高斯径向基函数 (RBF) 网络的 Z 矩阵会发生什么变化?

- 1) 矩阵的前两行相同
- 2) 矩阵的前两列不同
- 3) 矩阵可逆
- 4) 前两行和前两列交叉处的子矩阵包含常数 0

解答 正确选项为 1 。全高斯 RBF 网络中,Z 矩阵元素定义为 $Z_{ij} = \exp(-\gamma ||\mathbf{x}_i - \mathbf{x}_j||^2)$ (以训练样本为中心)。

当 $\mathbf{x}_1 = \mathbf{x}_2$ 时,对任意 j ,有:

$$Z_{1j} = \exp(-\gamma \|\mathbf{x}_1 - \mathbf{x}_j\|^2), \quad Z_{2j} = \exp(-\gamma \|\mathbf{x}_2 - \mathbf{x}_j\|^2) = \exp(-\gamma \|\mathbf{x}_1 - \mathbf{x}_j\|^2)$$

因此, Z矩阵的第一行与第二行元素完全相同。

30.3 *k*-均值算法

命题 30.3.1 (聚类原型: K-means 交替优化)

给定数据集 $\{x_n\}_{n=1}^N$, 通过聚类选取 M 个原型 $\{\mu_m\}_{m=1}^M$, 用于构造正则化 RBF 网络。其核心逻辑与步骤如下:

1. 聚类误差定义

定义由 $\{S_1,\ldots,S_M\}$ (数据集的不交并划分,满足样本无重叠、全覆盖)和原型 $\{\mu_1,\ldots,\mu_M\}$ 共同决定的 平方误差:

$$E_{ ext{in}}(S_1, \dots, S_M; \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_M) = \frac{1}{N} \sum_{n=1}^N \sum_{m=1}^M \mathbb{I}[\boldsymbol{x}_n \in S_m] \|\boldsymbol{x}_n - \boldsymbol{\mu}_m\|^2$$

该误差刻画"样本到所属簇原型的距离总和",越小代表原型对簇内样本的代表性越强。

2. K-means 交替最小化算法

因直接联合优化划分 S_m 与原型 μ_m 计算复杂,采用 交替优化 策略,分两步迭代逼近最小误差:

1. 固定原型,优化划分(样本指派)

若原型 μ_1, \ldots, μ_M 已确定,对每个样本 x_n ,将其指派到 距离最近原型 对应的簇:

$$S_m = \{ \boldsymbol{x}_n \mid ||\boldsymbol{x}_n - \boldsymbol{\mu}_m|| \le ||\boldsymbol{x}_n - \boldsymbol{\mu}_i||, \ \forall j \in \{1, \dots, M\} \}$$

此操作保证样本"唯一归属"到当前最匹配簇,最小化距离误差。

2. 固定划分,优化原型(均值更新的数学推导) 若划分 $S_1, ..., S_M$ 已确定,需更新每个簇的原型 μ_m 。此时对单个原型 μ_m ,可通过 无约束优化 推导其最优解:

(1) 梯度计算:

对聚类误差 $E_{\rm in}$ 中与 μ_m 相关的项求偏导 (仅 S_m 内样本贡献非零项):

$$\nabla_{\boldsymbol{\mu}_m} E_{\text{in}} = -2 \sum_{n=1}^N [\![\boldsymbol{x}_n \in S_m]\!] (\boldsymbol{x}_n - \boldsymbol{\mu}_m)$$

利用指示函数筛选性. 简化为:

$$abla_{\boldsymbol{\mu}_m} E_{\mathrm{in}} = -2 \left(\sum_{\boldsymbol{x}_n \in S_m} \boldsymbol{x}_n - |S_m| \boldsymbol{\mu}_m \right)$$

(2) 最优原型求解:

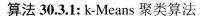
令梯度为 0 (无约束优化极值条件), 解得:

$$\boldsymbol{\mu}_m = \frac{1}{|S_m|} \sum_{\boldsymbol{x}_n \in S_m} \boldsymbol{x}_n$$

即最优原型是簇内样本均值,数学上可证明这是当前划分下平方误差最小的唯一解。

结论 K-means 交替优化通过迭代执行"样本指派 → 原型更新",同时达成:

- 聚类紧凑性: 数据被划分为内部距离紧凑的簇;
- 原型实用性: μ_m 作为簇的"共识中心",可直接用于正则化 RBF 网络的中心构造,简化模型同时保留数据簇特征。



输入: 数据集 $\{x_n\}_{n=1}^N$; 聚类数 k; 最大迭代次数 T_{max}

输出: 簇划分 $\{S_1, \ldots, S_k\}$; 聚类中心 $\{\mu_1, \ldots, \mu_k\}$

初始化

随机选取 k 个样本作为初始中心 $\mu_1^{(0)},\dots,\mu_k^{(0)}$.

repeat

分配步骤

对每个样本 x_n 执行

$$S_j \leftarrow \{x_n \mid ||x_n - \mu_j|| \le ||x_n - \mu_i||, \forall i\}.$$

更新步骤

对每个簇 $j=1,\ldots,k$ 重新计算中心

$$\mu_j \leftarrow \frac{1}{|S_j|} \sum_{x_n \in S_j} x_n.$$

until 簇划分不再变化;

收敛性 由于目标函数

$$E_{\text{in}} = \sum_{j=1}^{k} \sum_{x_n \in S_i} ||x_n - \mu_j||^2$$

在每一步交替优化中单调不增,算法必在有限步内收敛。

注 k-Means 是最流行的聚类算法之一;注意与 k-最近邻(k-NN)区分,二者同名但目的不同。

算法 30.3.2: RBF 网络结合 k-Means 的完整训练流程

输入: 训练集 $\{(x_n, y_n)\}_{n=1}^N$; 原型数 M; RBF 类型(如高斯)

输出: 预测函数 $g_{RBF}(x)$

1. 无监督原型获取

运行 k-Means 算法簇数设为 k = M,得到原型中心

$$\mu_1, \mu_2, \ldots, \mu_M$$
.

2. 构造特征变换

构建径向基特征映射

$$\Phi(x) = \left[\text{RBF}(x, \mu_1), \text{ RBF}(x, \mu_2), \dots, \text{ RBF}(x, \mu_M) \right]^{\top} \in \mathbb{R}^M.$$

3. 监督线性模型训练

对变换后的数据

$$\left\{ \left(\Phi(x_n), \, y_n \right) \right\}_{n=1}^N$$

执行线性模型 (例如线性回归或逻辑回归),得到权重

$$\beta \in \mathbb{R}^M$$
.

4. 返回模型

$$g_{\mathrm{RBF}}(x) = \mathrm{LinearHypothesis}(\beta, \Phi(x)).$$

注

- •步骤1利用无监督聚类(k-Means)完成特征提取,与自编码器思想类似;
- 典型超参数: 原型数 M、RBF 带宽 γ (高斯核 γ)。

30.4 *k*-均值与 RBF 网络实践















图 30.4.1: k-means 算法示例

k = 2	k = 4	k = 7
iteration 0	iteration 0	iteration 0

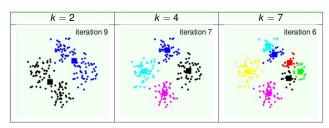
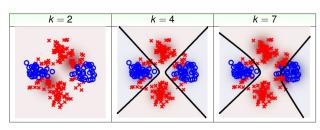
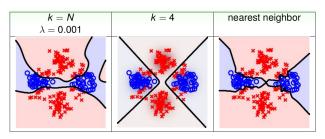


图 30.4.2: k-means 种类不同时的示例





(a) 使用 k 均值算法的径向基函数网络

(b) 全径向基函数网络

图 30.4.3: 径向基函数网络示例

例题 30.3 选择题: RBF 网络与岭回归结合的正则化程度

当与岭线性回归结合时,以下哪种 RBF 网络的"正则化程度最高 (most regularized)"?

- 1) 小 M 且小 λ
- 2) 小 Μ 且大 λ
- 3) 大 M 且小 λ
- 4) 大 M 且大 λ

解答 正确选项为 2。正则化程度由模型复杂度和正则化强度共同决定:

- M (RBF 隐藏层神经元数)越小,模型基础复杂度越低;
- λ(岭回归正则化参数)越大,对参数的惩罚越强,正则化效果越显著。
- "最正则化"要求低复杂度模型 + 强正则化惩罚,即小M且大 λ 。

30.5 总结

室 笔记 [径向基函数网络]

- RBF 网络假设:以一组原型 (prototypes) 而非神经元作为非线性变换。
- RBF 网络学习:对原型"假设"进行线性组合。
- k-均值算法: 通过交替优化实现聚类。
- k-均值与 RBF 网络实践: 原型数量的恰当选择至关重要。