



机器学习基础与进阶：从理论到实践

基于台湾大学林轩田课程的系统梳理与解析

作者：Mathematics-Yang

组织：西安交通大学

时间：2025/8/11



内容基于台湾大学林轩田的机器学习基石和机器学习技法课程

目录

引言	vii
第 1 章 机器何时能够学习?	1
1.1 学习问题	1
1.1.1 什么是机器学习	1
1.1.2 机器学习的应用	1
1.1.3 机器学习的组成部分	3
1.1.4 机器学习与其他领域	3
1.1.5 总结	4
1.2 学习回答是或否	5
1.2.1 感知机假设集	5
1.2.2 感知机学习算法 (PLA)	6
1.2.3 感知机学习算法 (PLA) 的保证	6
1.2.4 不可分数据	7
1.2.5 总结	8
1.3 学习的类型	9
1.3.1 不同输出空间的学习	9
1.3.2 基于不同数据标签的学习	10
1.3.3 不同协议的学习	12
1.3.4 不同输入空间的学习	14
1.3.5 总结	15
1.4 学习的可行性	16
1.4.1 学习是不可能的吗?	16
1.4.2 概率论提供了关键性的解决办法	16
1.4.3 与学习的关联	18
1.4.4 与真实学习的关联	19
1.4.5 总结	20
间章: 机器何时能够学习?	21
第 2 章 机器为什么能够学习?	22
2.1 训练 vs 测试	22
2.1.1 回顾与展望	22
2.1.2 有效直线数	23
2.1.3 有效假设数	25
2.1.4 断点	27
2.1.5 总结	28

2.2 泛化理论	29
2.2.1 断点的限制	29
2.2.2 界函数（基础情形）	30
2.2.3 界函数（归纳情形）	31
2.2.4 图解证明	33
2.2.5 总结	34
2.3 VC 维	35
2.3.1 VC 维的定义	35
2.3.2 线性分类器的 VC 维	36
2.3.3 VC 维的直观物理意义	37
2.3.4 VC 维的解读	38
2.3.5 总结	40
2.4 噪声与误差	41
2.4.1 噪声与概率目标	41
2.4.2 误差度量	42
2.4.3 算法级误差度量	43
2.4.4 加权分类	44
2.4.5 总结	45
间章：机器为什么能够学习？	46
第 3 章 机器如何学习？	47
3.1 线性回归	47
3.1.1 线性回归问题	47
3.1.2 线性回归算法	48
3.1.3 泛化问题	49
3.1.4 线性回归用于二分类	52
3.1.5 总结	53
3.2 逻辑回归	54
3.2.1 逻辑回归问题	54
3.2.2 逻辑回归的误差	55
3.2.3 逻辑回归误差的梯度	56
3.2.4 梯度下降	57
3.2.5 总结	58
3.3 线性模型用于分类	59
3.3.1 二分类的线性模型	59
3.3.2 随机梯度下降	61
3.3.3 逻辑回归的多分类	63
3.3.4 二元分解多分类	65
3.3.5 总结	66

3.4 非线性变换	67
3.4.1 二次假设	67
3.4.2 非线性变换	68
3.4.3 非线性变换的代价	70
3.4.4 结构化假设集	72
3.4.5 总结	73
间章：机器如何学习？	74
第 4 章 机器如何学得更好？	75
4.1 过拟合的危害	75
4.1.1 什么是过拟合？	75
4.1.2 噪声与数据量的作用	76
4.1.3 确定性噪声	77
4.1.4 应对过拟合	79
4.1.5 总结	80
4.2 正则化	81
4.2.1 正则化假设集	81
4.2.2 权重衰减正则化	82
4.2.3 正则化与 VC 理论	85
4.2.4 通用正则化项	86
4.2.5 总结	87
4.3 验证	88
4.3.1 模型选择问题	88
4.3.2 验证	89
4.3.3 留一交叉验证	91
4.3.4 V 折交叉验证	93
4.3.5 总结	95
4.4 三大学习原则	96
4.4.1 奥卡姆剃刀	96
4.4.2 采样偏差	97
4.4.3 数据偷窥	97
4.4.4 三的威力	98
4.4.5 总结	100
间章：机器如何学得更好？	101
第 5 章 嵌入大量特征：核模型	102
5.1 线性支持向量机	102
5.1.1 大间隔分离超平面	102
5.1.2 标准大间隔问题	103

5.1.3 支持向量机	104
5.1.4 大间隔超平面的理由	105
5.1.5 总结	106
5.2 对偶支持向量机	107
5.2.1 对偶 SVM 的动机	107
5.2.2 拉格朗日对偶 SVM	108
5.2.3 求解对偶 SVM	110
5.2.4 对偶 SVM 的启示	111
5.2.5 总结	112
5.3 核支持向量机	113
5.3.1 核技巧	113
5.3.2 多项式核	115
5.3.3 高斯核	115
5.3.4 核函数比较	117
5.3.5 总结	119
5.4 软间隔支持向量机	120
5.4.1 动机与原问题	120
5.4.2 对偶问题	121
5.4.3 软间隔 SVM 的启示	122
5.4.4 模型选择	124
5.4.5 总结	124
5.5 核逻辑回归	125
5.5.1 软间隔 SVM 的正则化视角	125
5.5.2 SVM vs 逻辑回归	126
5.5.3 软二分类的 SVM	127
5.5.4 核逻辑回归	128
5.5.5 总结	130
5.6 支持向量回归	131
5.6.1 核岭回归	131
5.6.2 支持向量回归原问题	132
5.6.3 支持向量回归对偶	135
5.6.4 核模型小结	136
5.6.5 总结	136
间章：嵌入大量特征：核模型	137
第 6 章 组合预测特征：聚合模型	138
6.1 混合与袋装	138
6.1.1 集成的动机	138
6.1.2 均匀混合 (Uniform Blending)	139

6.1.3 线性/任意混合	141
6.1.4 袋装 (Bagging)	142
6.1.5 总结	144
6.2 自适应提升	145
6.2.1 提升的动机	145
6.2.2 重加权带来多样性	145
6.2.3 自适应提升算法	147
6.2.4 AdaBoost 实战	149
6.2.5 总结	150
6.3 决策树	151
6.3.1 决策树假设	151
6.3.2 决策树算法	152
6.3.3 C&RT 决策树启发式	154
6.3.4 决策树实践	155
6.3.5 总结	156
6.4 随机森林	157
6.4.1 随机森林算法	157
6.4.2 袋外估计 (OOB)	158
6.4.3 特征选择	159
6.4.4 随机森林实战	160
6.4.5 总结	162
6.5 梯度提升决策树	163
6.5.1 自适应提升决策树	163
6.5.2 AdaBoost 的优化视角	165
6.5.3 梯度提升	168
6.5.4 集成模型小结	170
6.5.5 总结	171
间章：组合预测特征：聚合模型	172
第 7 章 蒸馏隐含特征：提取模型	173
7.1 神经网络	173
7.1.1 动机	173
7.1.2 神经网络假设	175
7.1.3 神经网络学习	176
7.1.4 优化与正则化	179
7.1.5 总结	180
7.2 深度学习	181
7.2.1 深度神经网络	181
7.2.2 自编码器	183

7.2.3 去噪自编码器	185
7.2.4 主成分分析	186
7.2.5 总结	189
7.3 径向基函数网络	190
7.3.1 RBF 网络假设	190
7.3.2 RBF 网络学习	192
7.3.3 k -均值算法	194
7.3.4 k -均值与 RBF 网络实践	196
7.3.5 总结	197
7.4 矩阵分解	198
7.4.1 线性网络假设	198
7.4.2 基础矩阵分解	199
7.4.3 随机梯度下降	201
7.4.4 提取模型小结	202
7.4.5 总结	204
7.5 收官	205
7.5.1 特征利用技术	205
7.5.2 误差优化技术	207
7.5.3 过拟合消除技术	209
7.5.4 机器学习实践	210
7.5.5 总结	212
间章：蒸馏隐含特征：提取模型	213

引言

在当今数字化浪潮汹涌的时代，数据以前所未有的规模与速度不断涌现。从互联网平台上的海量用户行为记录，到科学研究里复杂的实验观测数据，再到工业生产中各类设备运行产生的监测数据，数据已然成为推动社会发展与科技进步的关键要素。在这一背景下，机器学习作为一门极具活力与潜力的学科，肩负着从纷繁复杂的数据中挖掘有价值信息、揭示潜在规律的重任，进而为诸多领域的决策与创新提供有力支撑。

机器学习，作为人工智能领域的核心分支，致力于赋予计算机通过数据进行自主学习与优化的能力，而并非仅仅依靠预先设定的程序指令来执行任务。其独特之处在于，能够让计算机在面对海量数据时，自动探寻数据背后隐藏的模式与特征，并据此构建出能够对新数据进行有效预测与决策的模型。例如，在电商领域，机器学习算法能够依据用户的历史浏览、购买记录，精准地为用户推荐可能感兴趣的物品，极大提升用户购物体验与商家销售效率；在医疗领域，借助患者的病历数据、影像资料等，机器学习模型可以辅助医生进行疾病的早期诊断与病情预测，为挽救生命争取宝贵时间；在自动驾驶领域，车辆通过感知周围环境所产生的大量数据，利用机器学习技术实现对路况的实时分析与决策，保障行驶安全与顺畅。然而，机器学习这一领域知识体系极为庞大且复杂，涵盖了众多抽象的概念、严谨的理论以及纷繁多样的算法。对于刚刚踏入这片领域的初学者而言，往往会在浩如烟海的知识面前感到迷茫与困惑。无论是从基础的机器学习定义、模型分类，到感知机、线性回归等入门级算法的理解与实现，还是深入到诸如核函数、支持向量机、神经网络等进阶模型的探索，每一步都充满了挑战。不仅需要具备扎实的数学基础以理解背后的原理，如概率论、线性代数、数理统计等知识，还需掌握相应的编程技能，以便将理论转化为实际可运行的代码，在实践中不断磨砺与提升自己。

本笔记正是基于经典著作《Learning from Data》，同时深度融合台湾大学林轩田老师在 B 站上广受欢迎的“机器学习基石”与“机器学习技法”课程内容精心梳理而成。笔记从机器学习的基础概念入手，逐步深入探讨机器何时能够学习、为何能够学习等理论根基，进而延伸至如何学习、怎样学得更好等实际操作层面的方法与技巧。内容全面且系统地涵盖了线性模型、非线性变换、正则化、核方法、集成学习等机器学习领域的核心主题。在理论阐述方面，力求严谨细致，对 VC 维、泛化误差等关键概念进行清晰透彻的解读，帮助读者夯实理论基础；在实践指导环节，详细介绍了感知机算法、逻辑回归、支持向量机等经典算法的实现思路、应用场景以及实际案例分析，让读者能够在理论学习的同时，通过实践加深对知识的理解与运用能力。

衷心期望这份凝聚着知识与经验的笔记，能够如同一位贴心的学习伙伴，为初学者在机器学习的漫漫征途中指引方向。帮助大家以更加系统、高效的方式理解机器学习的本质内涵，熟练掌握核心算法的原理与应用技巧，顺利迈出机器学习学习的第一步，为日后在这一充满无限可能的领域中深入探索与实践筑牢根基。

最后引用本人非常喜欢的一句话：我们读书是为了成为提灯人去照亮黑暗，而不是为了自己有灯而沾沾自喜还要去吹灭别人的蜡烛。

这份笔记来的有点晚，但愿与诸君共勉！

第 1 章 机器何时能够学习？

1.1 学习问题

1.1.1 什么是机器学习

定义 1.1.1 (学习)

学习是指通过对观测信息的积累，获得特定技能的过程。



定义 1.1.2 (机器学习)

机器学习是指通过对数据进行积累或计算，提取经验，从而获得某种技能的过程。



在实际应用中，所谓“技能”通常意味着某项性能指标的提升，例如预测准确率。因此，可以将机器学习更明确地表述为：通过从数据中提取经验，提升某项性能指标的过程。

除了作为一种学习方法，机器学习也是构建复杂系统的有效手段。相比显式地编写规则，机器学习更加适用于那些难以手工建模的问题。

命题 1.1.1 (机器学习方法的可行性前提)

为了使机器学习能够有效运行，通常需要满足以下三个前提条件：

1. 存在可被学习的底层模式，意味着性能指标具有提升空间。
2. 该模式难以通过显式编程方式加以定义，因此需依赖学习算法近似建模。
3. 有充足的数据可用，从中能够揭示潜在模式，为模型提供训练基础。



1.1.2 机器学习的应用

机器学习无处不在

表 1.1.1: 机器学习在衣食住行方面的应用

领域	数据	技能
餐饮	Twitter 数据（文字 + 位置）	准确判断餐厅的食物中毒可能性
服装	销售数字 + 客户调查	向客户提供合适的时尚推荐
住房	建筑特征及其能耗	精确预测其他建筑的能耗
交通	部分交通标志图像及其含义	准确识别交通标志

教育

本案例中的数据来自学生在数学辅导系统中多次小测的答题记录。机器学习的任务是根据这些历史数据，预测学生是否能够正确回答下一道小测题。

一种常见的解决方案为：

假设学生正确作答的概率主要取决于其最近的能力 J 是否高于题目难度 K ，即

$$\text{正确作答} \approx J > K.$$

该方法使用约 3000 名学生的 900 万条答题记录作为训练数据，模型通过学习这些数据，自动推断出学生的能力水平以及题目的相对难度，从而实现较为准确的预测。

娱乐：推荐系统

本案例中的数据来自若干用户对部分电影的评分记录。机器学习的目标是基于这些已有评分，预测某用户对尚未观看电影的评分，从而实现个性化推荐。

一种常见的建模思路是认为：用户评分主要受其兴趣偏好与影片特征的共同影响。该关系可以表示为：

$$\text{评分} \leftarrow \text{观众的兴趣偏好} + \text{影片的内容特征}$$

在学习过程中，模型利用已有评分数据，自动归纳出每位用户的兴趣倾向与各部影片的关键特征，进而实现对用户可能喜欢的未观影片的评分预测。




图 1.1.1: 观众评价电影的因素示意图

1.1.3 机器学习的组成部分

形式化学习问题

设想一家银行每天收到大量信用卡申请，为了自动化审批流程，银行希望基于历史数据学习出一条可靠的信用审批规则。下面对学习问题的各组成部分进行形式化描述：

基本符号与定义：

- 输入 $x \in \mathcal{X}$ ：表示客户的申请信息，例如收入、负债、居住年限等。
- 输出 $y \in \mathcal{Y}$ ：表示审批结果，例如“好”客户或“坏”客户。
- 目标函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$ ：即理想中的信用审批规则，但实际是未知的。
- 训练数据 $\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$ ：来自历史的客户申请记录及对应审批结果。
- 假设函数 $g: \mathcal{X} \rightarrow \mathcal{Y}$ ：由学习算法从数据中学习得到，用于近似目标函数 f 。
- 假设空间 $\mathcal{H}$ ：所有备选的函数集合，学习算法从中选择最优的 g 。

学习的目标：利用历史数据 $\mathcal{D}$ ，从假设空间 $\mathcal{H}$ 中选择一个函数 g ，使其尽可能逼近真实但未知的目标函数 f 。当新的申请到来时，银行将基于 g 来做出审批决策。

1.1.4 机器学习与其他领域

机器学习 vs 数据挖掘

机器学习：利用数据学习出假设函数 $g: \mathcal{X} \rightarrow \mathcal{Y}$ ，使其逼近目标函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 。

数据挖掘：从（海量）数据中发现潜在的、有价值的属性或模式。

两者关系：

- 若“有趣的属性” $\equiv$ “逼近目标函数的假设”
 $\Rightarrow$ 机器学习 $\equiv$ 数据挖掘（如 KDD Cup 等实际场景）
- 若“有趣的属性”与目标函数 f 相关但不相同
 $\Rightarrow$ 数据挖掘可辅助机器学习，反之亦然
- 数据挖掘还关注如何在大规模数据库中实现高效计算

在实际应用中，两者往往交叉融合，界限并不明确。

机器学习 vs 人工智能

机器学习：通过数据学习出假设 g ，使其逼近某个目标函数 f 。

人工智能（AI）：设计和构建能够展现智能行为的系统。

两者关系：

- 若 $g \approx f$ 的逼近过程本身体现智能行为
⇒ 机器学习可作为实现人工智能的有效途径
- 典型示例——国际象棋程序：
传统 AI：基于博弈树的启发式搜索
学习型 AI：从大量棋局数据中学习策略

因此，机器学习是实现人工智能的重要手段之一，但并非唯一路径。

机器学习 vs 统计学

机器学习：从数据中学习假设函数 g ，以逼近未知的目标函数 f 。

统计学：依据数据，对潜在的未知过程（如 f ）进行推断与建模。

两者关系：

- 在某些学习模型中， g 可看作对 f 的统计推断结果
⇒ 统计方法可直接应用于机器学习任务
- 统计学强调在数学假设下的可解释性与理论保证
- 传统统计学对计算复杂度关注较少，而机器学习注重可扩展性与实际效果

统计学为机器学习提供了坚实的理论基础与丰富的方法工具。

1.1.5 总结

 笔记 [学习问题]

- 什么是机器学习：利用数据逼近目标函数
- 机器学习应用：几乎无处不在
- 机器学习的组成：算法接收数据集和假设空间，从而得到假设
- 机器学习与其他领域：与数据挖掘、人工智能和统计学密切相关

1.2 学习回答是或否

1.2.1 感知机假设集

一个简单的假设集合：感知机（Perceptron）

对于输入特征向量

$\mathbf{x} = (x_1, x_2, \dots, x_d)$ ——表示客户的各项特征，

计算加权“分数”并

- 批准信贷 若 $\sum_{i=1}^d w_i x_i > \text{阈值}$
- 拒绝信贷 若 $\sum_{i=1}^d w_i x_i < \text{阈值}$

输出： $y \in \{+1 \text{ (好客户)}, -1 \text{ (坏客户)}\}$, 0 被忽略。

线性公式 $h \in \mathcal{H}$ 定义为

$$h(\mathbf{x}) = \text{sign}\left(\sum_{i=1}^d w_i x_i - \text{阈值}\right)$$

历史上称为感知机假设。

命题 1.2.1 (感知机的向量形式)

设输入特征向量为 $\mathbf{x} = (x_1, x_2, \dots, x_d)^\top$ ，引入齐次坐标

$$\tilde{\mathbf{x}} = (1, x_1, x_2, \dots, x_d)^\top.$$

令参数向量

$$\mathbf{w} = (w_0, w_1, \dots, w_d)^\top, \quad w_0 = -\text{threshold}.$$

则感知机假设可写成

$$h(\mathbf{x}) = \text{sign}\left(\left(\sum_{i=1}^d w_i x_i\right) + (-\text{threshold})(+1)\right) = \text{sign}(\mathbf{w}^\top \tilde{\mathbf{x}})$$

每一个向量 $\mathbf{w}$ 对应一个假设 h ；几何上 $\mathbf{w}$ 定义了一个穿过原点的超平面。




图 1.2.1: 感知机在二维空间上的分类

命题 1.2.2 (感知机在二维空间中的几何意义)

设顾客特征 $\mathbf{x} = (x_1, x_2) \in \mathbb{R}^2$, 标签 $y \in \{0(+1), \times(-1)\}$ 。则感知机假设

$$h(\mathbf{x}) = \text{sign}(w_0 + w_1x_1 + w_2x_2)$$

对应平面上的直线 (在 $\mathbb{R}^d$ 中为超平面)。直线的一侧为正类, 另一侧为负类; 不同的直线即为不同的顾客分类器。因此, 感知机即线性二分类器。

**1.2.2 感知机学习算法 (PLA)****算法 1.2.1: 感知机学习算法 PLA (含 Cyclic 实现)**

输入: 数据集 $D = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$, 其中 $y_n \in \{+1, -1\}$

输出: 权重向量 $\mathbf{w}_{\text{PLA}}$ 作为最终假设 g

初始化 $\mathbf{w}^0 \leftarrow \mathbf{0}$;

选择遍历顺序 π : $\pi \leftarrow (1, 2, \dots, N)$;

// 朴素循环

或预先生成随机排列 π ;

repeat

// 直到完整一圈无误分

foreach $i = 1, \dots, N$ (按顺序 π) do

if $\text{sign}(\mathbf{w} \cdot \mathbf{x}_{\pi(i)}) \neq y_{\pi(i)}$ then

$\mathbf{w} \leftarrow \mathbf{w} + y_{\pi(i)} \mathbf{x}_{\pi(i)}$;

until 一个完整循环无更新;

return $\mathbf{w}_{\text{PLA}} \leftarrow \mathbf{w}$;



笔记 为便于可视化, 可令所有 $x_i \gg x_0$ (即取 $x_0 = 1$ 作为基准)。

1.2.3 感知机学习算法 (PLA) 的保证**命题 1.2.3 (PLA: $\mathbf{w}_t$ 与 $\mathbf{w}_f$ 越来越对齐)**

若数据集 D 线性可分, 则存在完美权重 $\mathbf{w}_f$ 使得

$$y_n = \text{sign}(\mathbf{w}_f^\top \mathbf{x}_n), \quad \forall n.$$

此时

$$y_{n(t)} \mathbf{w}_f^\top \mathbf{x}_{n(t)} \geq \min_n y_n \mathbf{w}_f^\top \mathbf{x}_n > 0.$$

更新一次后

$$\begin{aligned} \mathbf{w}_f^\top \mathbf{w}_{t+1} &= \mathbf{w}_f^\top (\mathbf{w}_t + y_{n(t)} \mathbf{x}_{n(t)}) \\ &= \mathbf{w}_f^\top \mathbf{w}_t + y_{n(t)} \mathbf{w}_f^\top \mathbf{x}_{n(t)} \\ &\geq \mathbf{w}_f^\top \mathbf{w}_t + \min_n y_n \mathbf{w}_f^\top \mathbf{x}_n > \mathbf{w}_f^\top \mathbf{w}_t. \end{aligned}$$

故 $\mathbf{w}_t$ 在每次更新后都与 $\mathbf{w}_f$ 更加对齐。



命题 1.2.4 (PLA: $\mathbf{w}_t$ 的范数增长受限)

PLA 仅在误分时更新, 此时

$$\text{sign}(\mathbf{w}_t^\top \mathbf{x}_{n(t)}) \neq y_{n(t)} \iff y_{n(t)} \mathbf{w}_t^\top \mathbf{x}_{n(t)} \leq 0.$$

于是

$$\begin{aligned} \|\mathbf{w}_{t+1}\|^2 &= \|\mathbf{w}_t + y_{n(t)} \mathbf{x}_{n(t)}\|^2 \\ &= \|\mathbf{w}_t\|^2 + 2y_{n(t)} \mathbf{w}_t^\top \mathbf{x}_{n(t)} + \|y_{n(t)} \mathbf{x}_{n(t)}\|^2 \\ &\leq \|\mathbf{w}_t\|^2 + 0 + \max_n \|\mathbf{x}_n\|^2. \end{aligned}$$

从 $\mathbf{w}_0 = \mathbf{0}$ 开始, 经 T 次误分修正后

$$\frac{\mathbf{w}_f^\top}{\|\mathbf{w}_f\|} \frac{\mathbf{w}_T^\top}{\|\mathbf{w}_T\|} \geq \sqrt{T} \cdot \text{constant}$$

**命题 1.2.5 (PLA 误分次数上界)**

定义

$$R^2 = \max_n \|\mathbf{x}_n\|^2, \quad \rho = \min_n y_n \frac{\mathbf{w}_f^\top \mathbf{x}_n}{\|\mathbf{w}_f\|}$$

则 PLA 的误分总次数 T 满足

$$T \leq \frac{R^2}{\rho^2}.$$



证明 首先, 注意到内积 $\frac{\mathbf{w}_f^\top}{\|\mathbf{w}_f\|} \frac{\mathbf{w}_t}{\|\mathbf{w}_t\|}$ 由 Cauchy-Schwarz 不等式限制, 其最大值为 1, 当 $\mathbf{w}_t$ 与 $\mathbf{w}_f$ 共线时取等。

其次, 考虑感知机算法 (PLA) 经过 T 次错误更正, 内积增量约为 $\sqrt{T} \cdot c$, 其中 c 为正常数 (由更正的平均效应决定)。

由于内积的上限为 1, 且初始内积至少为 ρ (定义 $\rho = \min_n y_n \frac{\mathbf{w}_f^\top \mathbf{x}_n}{\|\mathbf{w}_f\|}$), 更正次数 T 受限为 $\frac{1}{c^2}$ 。

结合 $R^2 = \max_n \|\mathbf{x}_n\|^2$ 和感知机收敛性, 得出 $T \leq \frac{R^2}{\rho^2}$ 。 ■

1.2.4 不可分数据**更多关于 PLA 的要点**

保证 只要数据线性可分且每次修正的都是误分, $\mathbf{w}_f^\top \mathbf{w}_t$ 会快速增长, 而 $\|\mathbf{w}_t\|$ 增长缓慢。因此 PLA 的超平面越来越与 $\mathbf{w}_f$ 对齐, 算法必然停机。

优点 实现简单、速度快、适用于任意维度 d 。

缺点

- 要求数据集线性可分才能停机;
- 事先并不知道该性质 (若已知 $\mathbf{w}_f$ 就无需 PLA);
- 无法事先确定停机时间 (上界依赖于未知的 ρ), 尽管实践中很快。

带噪声容忍的线性分类

假设场景 仅存在少量标记噪声，即大多数情况下 $y_n = f(\mathbf{x}_n)$ 。此时期望所得假设 g 在数据集 D 上与真实函数 f 足够接近，亦即

$$y_n \approx g(\mathbf{x}_n) = \text{sign}(\mathbf{w}^\top \mathbf{x}_n).$$

核心难题 求解最小化 0/1 损失的问题

$$\mathbf{w}_g \leftarrow \arg \min_{\mathbf{w}} \sum_{n=1}^N \mathbb{I}[y_n \neq \text{sign}(\mathbf{w}^\top \mathbf{x}_n)]$$

该问题已被证明是 NP-hard 问题。因此，需要一种能在多项式时间内给出“近似最优”权重的替代策略。

算法 1.2.2: Pocket 算法

输入: 数据集 $D = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$ ，其中 $y_n \in \{+1, -1\}$ ；最大迭代次数 $T_{\max}$

输出: 口袋权重 $\mathbf{w}_{\text{Pocket}}$

初始化 $\mathbf{w}_0 \leftarrow \mathbf{0}$, $\hat{\mathbf{w}} \leftarrow \mathbf{0}$;

for $t = 0$ **to** $T_{\max} - 1$ **do**

 随机选取误分样本 $(\mathbf{x}_{n(t)}, y_{n(t)})$;

$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + y_{n(t)} \mathbf{x}_{n(t)}$;

if $\mathbf{w}_{t+1}$ 的误分率低于 $\hat{\mathbf{w}}$ **then**

$\hat{\mathbf{w}} \leftarrow \mathbf{w}_{t+1}$;

return $\mathbf{w}_{\text{Pocket}} \leftarrow \hat{\mathbf{w}}$;

 **笔记** [优势] 实现简单、运行高效，可在非严格线性可分场景下获得近似最优的分类超平面。

1.2.5 总结

 **笔记** [学习回答是或否]

- 感知机假设集： $\mathbb{R}^d$ 中的超平面（线性分类器）。
- 感知机学习算法（PLA）：通过不断纠正错误来迭代改进。
- PLA 的保证：若数据线性可分，则最终不再犯错。
- 非线性可分数据：把“相对最佳”的权重保留在口袋里（Pocket 算法）。

1.3 学习的类型

1.3.1 不同输出空间的学习

多类别分类：硬币识别与其它应用

任务示例——美国硬币识别 依据“尺寸、质量”两维特征，将硬币分为

$$\mathcal{Y} = \{1\text{¢}, 5\text{¢}, 10\text{¢}, 25\text{¢}\} \text{ 或抽象为 } \mathcal{Y} = \{1, 2, \dots, K\}.$$

二分类仅为 $K = 2$ 的特例。

其它常见多类别问题

- 手写数字识别： $\mathcal{Y} = \{0, 1, \dots, 9\}$;
- 水果图像分类： $\mathcal{Y} = \{\text{苹果}, \text{橙子}, \text{草莓}\}$;
- 邮件优先级： $\mathcal{Y} = \{\text{垃圾}, \text{主要}, \text{社交}, \text{推广}, \text{更新}\}$ (Google)。

多类别分类在实际中应用广泛，尤其在“识别”任务中扮演核心角色。

回归：患者康复预测及其应用

任务示例——患者康复预测

- 二分类：根据患者特征预测 **是否生病**;
- 多分类：根据患者特征预测 **癌症类型**;
- 回归：根据患者特征预测 **康复所需天数**，即

$$y \in \mathbb{R} \text{ 或 } y \in [\text{lower}, \text{upper}] \subset \mathbb{R}.$$

更多回归问题

- 公司数据 → 股价预测;
- 气候数据 → 温度预测。

回归在统计学中被深入研究，并作为众多统计工具的核心构件，应用极其广泛。

结构化学习：序列标注问题

任务示例——词性序列标注

- 多类别分类：把单个单词映射到词性类别;
- 结构化学习：将整个句子视为一条“结构”，即为每个单词同时分配标签

$$\mathcal{Y} = \{\text{PVN}, \text{PVP}, \text{NVN}, \text{PV}, \dots\} \text{ (而非显式枚举所有组合)}.$$

更多结构化学习问题

- 蛋白质数据 → 蛋白质折叠结构预测;
- 语音数据 → 语音解析树。

结构化学习是一类高级且复杂的学习范式，需要同时预测具有内部依赖关系的整体结构。

1.3.2 基于不同数据标签的学习

定义 1.3.1 (监督学习 (Supervised Learning))

监督学习是从一组已标记的训练数据

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$$

中学习映射函数

$$f: \mathcal{X} \rightarrow \mathcal{Y},$$

使得对于任意未见样本 $\mathbf{x}' \in \mathcal{X}$, 模型能够给出正确输出 $y' \in \mathcal{Y}$ 。其中

- $\mathbf{x}_i$ 为输入特征向量;
- y_i 为对应标签, 取值
 - 离散类别 (分类任务)
 - 连续实数 (回归任务)



定义 1.3.2 (无监督学习 (Unsupervised Learning))

无监督学习是一种在没有标签的数据集

$$\mathcal{D} = \{\mathbf{x}_i\}_{i=1}^N$$

上发现隐藏结构或分布规律的机器学习方法。其核心任务包括

- 聚类 (Clustering): 将相似样本划分为若干组;
- 降维 (Dimensionality Reduction): 在保留关键信息的同时压缩特征维度;
- 密度估计 (Density Estimation): 学习数据的概率分布;
- 异常检测 (Anomaly Detection): 识别偏离主流模式的样本。



无监督学习：无标签数据的洞察

核心思想 在只含输入 $\{\mathbf{x}_n\}$ 、不含任何标签 y_n 的数据中学习隐藏结构。

典型无监督任务

- 聚类 (Clustering)
 - $\{\mathbf{x}_n\} \rightarrow \text{cluster}(\mathbf{x})$ —— 类似“无监督多类分类”，如文章 $\rightarrow$ 主题。
- 密度估计 (Density Estimation)
 - $\{\mathbf{x}_n\} \rightarrow \text{density}(\mathbf{x})$ —— 类似“无监督有界回归”，如交通报告 $\rightarrow$ 危险区域。
- 异常检测 (Outlier Detection)
 - $\{\mathbf{x}_n\} \rightarrow \text{unusual}(\mathbf{x})$ —— 类似“极端无监督二分类”，如网络日志 $\rightarrow$ 入侵警报。

无监督学习形式多样，性能目标各不相同，仍在蓬勃发展！

定义 1.3.3 (半监督学习 (Semi-Supervised Learning))


半监督学习是一种介于监督学习与无监督学习之间的混合范式。给定

$$\mathcal{D} = \underbrace{\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_k, y_k)\}}_{\text{少量标记数据}}, \underbrace{\{\mathbf{x}_{k+1}, \dots, \mathbf{x}_{k+n}\}}_{\text{大量未标记数据}}, \quad k \ll n,$$


其目标是学习映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$ ，使得模型既能在标记数据上拟合，又能利用未标记数据的潜在结构，从而对未知样本作出准确预测。




半监督学习：部分标签的硬币识别



监督学习



半监督学习



无监督学习

其它半监督应用

- 少量人脸图像 $\Rightarrow$ Facebook 人脸识别器
- 少量医药数据 $\Rightarrow$ 药物疗效预测器

核心理念：利用大量未标记数据，避免昂贵的标注成本。

定义 1.3.4 (强化学习 (Reinforcement Learning))

强化学习是机器学习的一个子领域，研究智能体在环境中通过执行动作、接收奖励（或惩罚）并观察状态转移，从而学习一个策略 $\pi(s)$ ，使其长期累积奖励

$$\mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

最大化，其中 $0 \leq \gamma < 1$ 为折扣因子， r_t 为时刻 t 的即时奖励。



强化学习：一种截然不同却自然的学习范式

训狗示例

- 命令：对狗说“坐下”
- 狗坐下 $\Rightarrow$ 奖励饼干：好狗！
- 狗乱尿 $\Rightarrow$ 惩罚：坏狗！

我们无法直接给出标签 y ，但可通过奖励/惩罚让智能体学会正确行为。

更多强化学习场景

- 顾客, 广告选择, 点击收益 $\rightarrow$ 广告推荐系统
- 牌局, 策略, 赢钱金额 $\rightarrow$ 二十一点智能体

本质 强化学习利用部分/隐式的奖励信号，通过序列决策不断优化策略。

1.3.3 不同协议的学习

定义 1.3.5 (批量学习 (Batch Learning))

批量学习是一种离线训练方法，要求一次性使用完整数据集 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ 训练模型，得到最终假设 g 。训练完成后模型参数冻结；若要吸收新数据，必须重新整合全部数据并重新训练整个模型。



批量学习：以硬币识别为例

问题设定

未知目标函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$ ，其中 $\mathcal{Y} = \{1\text{¢}, 5\text{¢}, 10\text{¢}, 25\text{¢}\}$ 。

批量监督多类别分类流程

1. 收集训练数据一次性获得批量样本

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}.$$

2. 学习阶段利用全部已知数据，在假设空间 $\mathcal{H}$ 中学习最终假设 $g \approx f$ 。
3. 部署阶段用学得 g 对新硬币进行预测。

更多批量学习场景

- 批量 (邮件, 是否为垃圾?) $\Rightarrow$ 垃圾邮件过滤器
- 批量 (患者, 是否患癌?) $\Rightarrow$ 癌症分类器
- 批量患者数据 $\Rightarrow$ 患者群体画像

特点 批量学习是最常见、最直观的训练协议：一次性收集全部数据 $\rightarrow$ 一次性训练 $\rightarrow$ 一次性部署。

定义 1.3.6 (在线学习 (Online Learning))

在线学习是一种机器学习方法，其中数据按序列顺序到达。学习者在每一步 t 观察样本 $(\mathbf{x}_t, y_t)$ (或其部分信息)，并立即更新模型参数 $\mathbf{w}_t$ ，使得对未来数据 $\mathbf{x}_{t+1}$ 的预测误差最小化。与一次性使用全部数据的批量学习不同，在线学习能够实时适应数据流和概念漂移，尤其适用于大规模或实时场景。



在线学习：持续进化的垃圾邮件过滤器

批量垃圾邮件过滤器

一次性学习已标记样本 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ ，之后用固定假设 g 进行预测。

在线垃圾邮件过滤器（顺序流程）

1. 观察邮件 $\mathbf{x}_t$;
2. 用当前假设 g_t 预测是否垃圾;
3. 获得期望标签 y_t ，立即更新 $g_t \leftarrow g_t + \Delta(\mathbf{x}_t, y_t)$ 。

与所学知识的联系

- PLA 可直接改为在线协议（逐点更新）;
- 强化学习常采用在线方式（奖励信号逐帧到达）。

核心思想 通过顺序接收数据实例，使假设持续自我改进。

定义 1.3.7 (主动学习 (Active Learning))

主动学习是一种半监督机器学习范式，其训练集由

$$\mathcal{D} = \{\text{少量标记样本}(\mathbf{x}_i, y_i)\}_{i=1}^k \cup \{\text{大量未标记样本}\mathbf{x}_j\}_{j=k+1}^N$$

组成。算法通过

$$\mathbf{x}_q = \arg \max_{\mathbf{x} \in \mathcal{U}} \text{Uncertainty}(\mathbf{x})$$

主动选取最不确定或信息量最大的样本 $\mathbf{x}_q$ ，向标注者查询标签 y_q ，然后迭代更新模型，从而在总标注量远小于随机标注的情况下达到同等甚至更高的预测精度。



主动学习：通过提问来学习

协议对比

- 批量：一次性“填鸭式”喂数据
- 在线：被动地顺序接收数据
- 主动：顺序地提问

未知目标函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$

主动学习流程

1. 学习器主动选择最有价值的样本 $\mathbf{x}_n$;
2. 查询其标签 y_n （由人工或 oracle 提供）;
3. 用新样本 $(\mathbf{x}_n, y_n)$ 更新假设，使 $g \approx f$ 。

目标 通过战略性提问，用更少的标签获得同等甚至更优的性能。

1.3.4 不同输入空间的学习

定义 1.3.8 (具体特征 (Concrete Features))

具体特征是直接从领域知识或物理测量中获得、具有明确物理意义的输入变量。它们通常表现为可解释的数值、类别或简单统计量，例如：

- 硬币识别中的“尺寸、质量”；
- 信用审批中的“年龄、年薪、负债”；
- 医疗诊断中的“血压、体温、肿瘤直径”。

与原始或抽象特征相比，具体特征无需额外转换即可被机器学习算法直接利用，因而更易于解释与建模。



具体特征示例

信用审批实例

年龄 = 23 岁

性别 = 女

年薪 = NTD 1,000,000

居住年限 = 1 年

工作年限 = 0.5 年

当前负债 = NTD 200,000

更多具体特征

- 硬币识别：尺寸、质量
- 信用审批：客户信息
- 癌症诊断：患者信息

特点 具体特征往往融入人类领域知识，是机器学习中最易于利用的输入。

定义 1.3.9 (原始特征 (Raw Features))

原始特征是从原始数据源直接获取、未经任何转换或加工的基本属性或测量值，例如图像的像素值、文本中的单词、传感器的原始读数等。这些特征通常：

- 具有明确的物理意义；
- 可能包含噪声、冗余或高维信息；
- 需要经过清洗、降维或特征提取才能有效应用于机器学习模型。



原始特征：数字识别问题

任务描述 数字识别是典型的监督多类别分类问题：将输入特征映射为数字含义。

原始特征示例

- **16×16 灰度图像**

$\mathbf{x} = (0, 0, 0.9, 0.6, \dots) \in \mathbb{R}^{256}$ ，像素值物理意义简单，对机器学习更具挑战。

- **人工提取的“具体特征”**

如对称性、密度等，便于模型直接使用。

其他原始特征场景

- 图像像素、语音信号等
- 通常需人工或机器进一步转换为具体特征后方可高效学习。

结论 原始特征往往缺乏明确的物理意义，需要额外处理才能被机器学习算法充分利用。

定义 1.3.10 (抽象特征 (Abstract Features))

抽象特征是指从原始数据经人工或算法加工后得到、不再具备直观物理意义的中间表示，例如：

- 用户-商品 ID 对（用于评分预测）；
- 节点编号或哈希编码（用于图网络）；
- 高维稀疏向量（如 one-hot 编码的广告 ID）。

这些特征需进一步转换或嵌入才能被机器学习模型有效利用。

**抽象特征：评分预测问题**

任务描述 KDDCup 2011 评分预测：给定历史 (userid, itemid, rating) 三元组，预测某用户对新商品的评分。这是一个回归问题，其中

$$y \in \mathbb{R} \text{ (评分)}, \quad \mathbf{x} = (\text{userid}, \text{itemid}) \in \mathbb{N} \times \mathbb{N}.$$

特点 特征本身缺乏物理意义，对机器学习更具挑战。

更多抽象特征场景

- 在线辅导系统中的学生 ID (KDDCup 2010)
- 在线广告系统中的广告 ID

结论 抽象特征必须借助特征转换、提取或构造，才能被模型有效利用。

1.3.5 总结**笔记 [学习的类型]**

- 输出空间不同：分类、回归、结构化学习。
- 数据标签不同：监督学习、无监督学习、半监督学习、强化学习。
- 交互协议不同：批处理、在线学习、主动学习。
- 输入空间不同：具体特征、原始数据、抽象表示。

1.4 学习的可行性

1.4.1 学习是不可能的吗？

简单二分类问题

定义 $\mathcal{X} = \{0, 1\}^3, \mathcal{Y} = \{0, 1\}$, 可以枚举所有候选 f 作为 $\mathcal{H}$ 。

问题 从 $\mathcal{H}$ 中选择 $g \in \mathcal{H}$ 使得对所有 $g(\mathbf{x}_n) = y_n$ (类似于 PLA), $g \approx f$?

没有免费的午餐

- 在 $\mathcal{D}$ 内 $g \approx f$: 当然!
- 在 $\mathcal{D}$ 外 $g \approx f$: 不! (但那才是我们真正想要的!)

从 $\mathcal{D}$ 学习 (推断 $\mathcal{D}$ 外的东西) 注定失败, 如果有任何“未知”的 f 可能发生。

$\mathbf{x}$	y	g	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8
0 0 0	0	0	0	0	0	0	0	0	0	0
0 0 1	1	1	1	1	1	1	1	1	1	1
0 1 0	1	1	1	1	1	1	1	1	1	1
0 1 1	0	0	0	0	0	0	0	0	0	0
1 0 0	1	1	1	1	1	1	1	1	1	1
1 0 1		?	0	0	0	0	1	1	1	1
1 1 0		?	0	0	1	1	0	0	1	1
1 1 1		?	0	1	0	1	0	1	0	1

图 1.4.1: 简单分类问题示意图

定理 1.4.1 (无免费午餐定理 (No Free Lunch))

在机器学习中, 不存在单一算法能够在所有问题上都达到最优性能。即对于任何给定的学习算法, 都存在至少一个问题, 在该问题上该算法的性能不会优于随机猜测。



1.4.2 概率论提供了关键性的解决办法

推断未知事物: 推断橙色概率

罐子 假设橙色概率 = μ , 绿色概率 = $1 - \mu$, 其中 μ 未知

样本 独立抽取 N 个弹珠, 橙色比例 = ν , 绿色比例 = $1 - \nu$, 现在 ν 已知

问题 样本 ν 能否说明样本外 μ 的情况?

可能与概率

样本 ν 是否能说明样本外 μ 的情况?

- 可能不能: 样本可能大部分是绿色而罐子大部分是橙色
- 可能能: 样本 ν 可能接近未知的 μ

引理 1.4.1 (Hoeffding 引理)

设随机变量 X 满足 $\mathbb{E}[X] = 0$, 且几乎处处 $X \in [a, b]$, 则对于任意实数 $\lambda \in \mathbb{R}$, 有如下不等式成立:

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2(b-a)^2}{8}\right)$$



证明 考虑任意满足 $X \in [a, b]$ 且 $\mathbb{E}[X] = 0$ 的随机变量。令 $c = b - a$ 。

我们令函数 $\phi(\lambda) = \mathbb{E}[e^{\lambda X}]$, 其为 X 的矩母函数。由于 $e^{\lambda x}$ 是关于 x 的凸函数, 且 $X \in [a, b]$, 我们可以使用凸函数的最大值原理: 在固定期望的前提下, $\mathbb{E}[e^{\lambda X}]$ 在 X 取两点分布时最大。

因此, 考虑如下构造的两个点的分布:

$$X = \begin{cases} a, & \text{概率 } p = \frac{b}{b-a} \\ b, & \text{概率 } 1-p = \frac{-a}{b-a} \end{cases} \Rightarrow \mathbb{E}[X] = pa + (1-p)b = 0$$

于是有:

$$\mathbb{E}[e^{\lambda X}] \leq pe^{\lambda a} + (1-p)e^{\lambda b} = \frac{b}{b-a}e^{\lambda a} + \frac{-a}{b-a}e^{\lambda b}$$

令 $c = b - a$, 将 $a = -\frac{c}{2}, b = \frac{c}{2}$ (无损一般性, 平移不影响证明), 则:

$$\mathbb{E}[e^{\lambda X}] \leq \frac{1}{2}e^{-\lambda c/2} + \frac{1}{2}e^{\lambda c/2} = \cosh\left(\frac{\lambda c}{2}\right)$$

由 $\cosh(x) \leq \exp\left(\frac{x^2}{2}\right)$ 对任意实数 x 成立, 因此:

$$\mathbb{E}[e^{\lambda X}] \leq \cosh\left(\frac{\lambda c}{2}\right) \leq \exp\left(\frac{\lambda^2 c^2}{8}\right)$$

即:

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2(b-a)^2}{8}\right)$$

**定理 1.4.2 (霍夫丁不等式)**

设罐中橙色概率为 μ , 样本容量为 N , 样本中橙色比例为 ν 。则对任意 $\varepsilon > 0$ 与 $N > 0$,

$$\mathbb{P}[|\nu - \mu| > \varepsilon] \leq 2\exp(-2\varepsilon^2 N).$$

该不等式适用于弹珠、硬币、民调等场景, 且与 μ 无关, 无需先验知识。当 N 足够大时, 样本比例 ν 以高概率接近真值 μ , 即

$$\nu \approx \mu \quad (\text{Probably Approximately Correct}).$$



证明 设 $X_1, X_2, \dots, X_n$ 是独立随机变量, 且对每个 i , 有 $X_i \in [a_i, b_i]$ 。定义 $S_n = \sum_{i=1}^n X_i$, 我们考虑尾部概率:

$$\mathbb{P}(S_n - \mathbb{E}[S_n] \geq t)$$

对任意 $\lambda > 0$, 由 Chernoff 结合 Markov 不等式 $\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$ 可得:

$$\mathbb{P}(S_n - \mathbb{E}[S_n] \geq t) = \mathbb{P}(e^{\lambda(S_n - \mathbb{E}[S_n])} \geq e^{\lambda t}) \leq \frac{\mathbb{E}[e^{\lambda(S_n - \mathbb{E}[S_n])}]}{e^{\lambda t}}$$

由于 X_i 独立:

$$\mathbb{E}[e^{\lambda(S_n - \mathbb{E}[S_n])}] = \prod_{i=1}^n \mathbb{E}[e^{\lambda(X_i - \mathbb{E}[X_i])}]$$

接下来对每个 i , 应用 **Hoeffding** 引理: 若 $X \in [a, b]$, 则对任意 $\lambda \in \mathbb{R}$, 有

$$\mathbb{E}[e^{\lambda(X - \mathbb{E}[X])}] \leq \exp\left(\frac{\lambda^2(b-a)^2}{8}\right)$$

因此,

$$\mathbb{P}(S_n - \mathbb{E}[S_n] \geq t) \leq \exp\left(-\lambda t + \frac{\lambda^2}{8} \sum_{i=1}^n (b_i - a_i)^2\right)$$

最小化右边对 λ , 令导数为零得最优值 $\lambda = \frac{4t}{\sum_{i=1}^n (b_i - a_i)^2}$, 代入得:

$$\mathbb{P}(S_n - \mathbb{E}[S_n] \geq t) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

将 $t = n\epsilon$ 得到:

$$\mathbb{P}(\bar{X}_n - \mathbb{E}[\bar{X}_n] \geq \epsilon) \leq \exp\left(-\frac{2n^2\epsilon^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

设 $X_1, X_2, \dots, X_N$ 是独立同分布随机变量, 且每个变量取值范围为 $[0, 1]$. 定义样本均值为:

$$\nu = \frac{1}{N} \sum_{i=1}^N X_i, \quad \mu = \mathbb{E}[X_i]$$

根据 **Hoeffding** 不等式, 对于任意 $\epsilon > 0$, 有:

$$\mathbb{P}(|\nu - \mu| \geq \epsilon) \leq \exp(-2\epsilon^2 N)$$

■

1.4.3 与学习的关联

从弹珠到学习误差

设定 未知目标函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$, 固定假设 $h: \mathcal{X} \rightarrow \mathcal{Y}$, 数据分布 P .

未知真误差

$$E_{\text{out}}(h) = \mathbb{P}_{\mathbf{x} \sim P}[h(\mathbf{x}) \neq f(\mathbf{x})].$$

已知样本误差 给定独立同分布训练集

$$\mathcal{D} = \{(\mathbf{x}_n, y_n)\}_{n=1}^N, \quad y_n = f(\mathbf{x}_n),$$

样本误差为

$$E_{\text{in}}(h) = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[h(\mathbf{x}_n) \neq y_n].$$

命题 1.4.1 (形式保证)

对任一固定的假设 h 与足够大的样本规模 N , 样本内误差 $E_{\text{in}}(h)$ 以高概率逼近样本外误差 $E_{\text{out}}(h)$ (误差不超过 ε), 即

$$\mathbb{P}[|E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon] \leq 2 \exp(-2\varepsilon^2 N).$$

该不等式与“罐子”类比相同, 对所有 N 与 ε 成立, 且不依赖未知的 $E_{\text{out}}(h)$, 也无需知道 f 或分布 P 。因此 “ $E_{\text{in}}(h) = E_{\text{out}}(h)$ ” 是 PAC 正确的。

若进一步满足 $E_{\text{in}}(h) \approx E_{\text{out}}(h)$ 且 $E_{\text{in}}(h)$ 很小, 则可推出 $E_{\text{out}}(h)$ 亦很小, 即 h 以高概率逼近 f 于分布 P 。

**单一假设的验证与学习结论**

验证 对任意固定假设 h , 当数据量足够大时,

$$E_{\text{in}}(h) \approx E_{\text{out}}(h).$$

能否宣称“学得不错” ($g \approx f$)?

是! 若算法 $\mathcal{A}$ 只考虑这一个 h 且 $E_{\text{in}}(h)$ 很小, 则 $g = h$ 满足 PAC 正确性。

否! 实际上 $\mathcal{A}$ 需在假设集 $\mathcal{H}$ 中选 g (如 PLA), 而大多数固定 h 的 $E_{\text{in}}(h)$ 并不小; 若强制取该 h 为 g , 则 $E_{\text{in}}(g)$ 大概率很大, 无法保证 PAC。

结论 真正的学习要求算法在 $\mathcal{H}$ 中主动挑选 g , 而非被迫接受某个固定 h 。

**笔记 [单一假设验证 vs 真正学习]**

- 若固定一个假设 h , 当样本数足够大时, 由 Hoeffding 不等式可得: $E_{\text{in}}(h) \approx E_{\text{out}}(h)$, 可认为 h 通过了“验证”。
- 但这并不意味着我们“学得好”, 因为学习算法并非接受一个 h , 而是从假设集 $\mathcal{H}$ 中选择最优的 g 。
- 实际上, 大多数 $h \in \mathcal{H}$ 的 $E_{\text{in}}(h)$ 都不会很小; 如果算法仅凭训练误差小就选出 g , 可能只是偶然“运气好”。
- 要想保证 $E_{\text{out}}(g)$ 也小, 必须考虑整个 $\mathcal{H}$ 的容量, 如使用 VC 维等工具对其复杂度进行控制。

结论: 验证单一假设容易, 真正学习困难。学习不仅要训练误差小, 还要能推广到未知数据——这要求我们控制假设空间的复杂性, 从而提升模型的泛化能力。

1.4.4 与真实学习的关联**命题 1.4.2 (坏样本与坏数据)**

设固定假设 h 与样本 $\mathcal{D}$ 的大小为 N 。若存在 $\mathcal{D}$ 使得样本误差 $E_{\text{in}}(h)$ 与真实误差 $E_{\text{out}}(h)$ 差距超过阈值 ε , 则称 $\mathcal{D}$ 为 h 的坏样本。

- 对单个 h , 坏样本概率 $\mathbb{P}_{\mathcal{D}}[|E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon]$ 存在上界。
- 若假设集 $\mathcal{H} = \{h_1, \dots, h_M\}$ 含 M 个假设, 则存在某个 $h \in \mathcal{H}$ 出现坏样本的概率可通过联合界控制:

$$\mathbb{P}_{\mathcal{D}}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon] \leq \sum_{m=1}^M \mathbb{P}_{\mathcal{D}}[|E_{\text{in}}(h_m) - E_{\text{out}}(h_m)| > \varepsilon].$$

iii) 当 M 增大时, 上述上界随之增大; 只有当 M 相对样本量 N 足够小时, 算法 $\mathcal{A}$ 仍能高概率保证对所有 h 都有 $E_{\text{in}}(h) \approx E_{\text{out}}(h)$ 。

定理 1.4.3 (有限假设集的霍夫丁上界)

设假设集 $\mathcal{H} = \{h_1, \dots, h_M\}$ 有限, 样本 $\mathcal{D} = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$ 独立同分布且大小为 N 。对任意 $\varepsilon > 0$, 有

$$\mathbb{P}_{\mathcal{D}}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon] \leq 2M \exp(-2\varepsilon^2 N).$$

该界对任意 M, N, ε 成立, 且与未知的目标函数 f 、分布 P 及所有 $E_{\text{out}}(h)$ 无关。因此, 若算法 $\mathcal{A}$ 选取

$$g = \arg \min_{h \in \mathcal{H}} E_{\text{in}}(h),$$

则 $E_{\text{in}}(g) \approx E_{\text{out}}(g)$ 以高概率成立, 即 PAC 成立。

笔记 [有限假设集与泛化能力]

- 对单个假设 h , Hoeffding 不等式可保证当样本足够大时, $E_{\text{in}}(h) \approx E_{\text{out}}(h)$, 即“坏样本”的概率很小。
- 若学习算法从有限假设集 $\mathcal{H} = \{h_1, \dots, h_M\}$ 中选出 $g = \arg \min_h E_{\text{in}}(h)$, 需考虑整个假设集上出现“坏样本”的联合概率。
- 使用联合界 (Union Bound) 可得: 出现某个 $h \in \mathcal{H}$ 使得 $|E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon$ 的概率上界为:

$$\mathbb{P}_{\mathcal{D}}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon] \leq 2M \exp(-2\varepsilon^2 N).$$

- 上界表明, 只有当假设集大小 M 相对样本量 N 不太大时, 才能高概率地保证所有假设的泛化误差都不大。

结论: 对于有限假设集, Hoeffding 不等式联合界为学习算法提供了 **PAC** 泛化保证。这说明控制假设空间规模是实现有效学习的关键步骤之一。

1.4.5 总结

笔记 [学习的可行性]

- 学习是不可能的吗?: 在数据集 $\mathcal{D}$ 之外, 绝对不存在“免费午餐”。
- 概率论提供了关键性的解决办法: 在 $\mathcal{D}$ 之外, 我们能做到“可能近似正确”(PAC)。
- 与学习的关联: 若对某个固定的 h , 经验误差 $E_{\text{in}}(h)$ 足够小, 则可验证其性能。
- 与真实学习的关联: 若假设空间 $|\mathcal{H}|$ 有限且最终选出的 g 满足 $E_{\text{in}}(g)$ 足够小, 则学习可行。

笔记 [总体结论] 通过合理控制假设空间的规模, 并利用概率不等式对训练误差与真实误差的差距进行界定, 我们能够以高概率选出在整体数据分布上表现良好的假设, 从而保证学习的可行性和泛化能力。

笔记 [精华弹幕] 我们很难学习到正确的结果, 但是当我们的样本量足够大时, 通过公式我们就知道样本与实际情况非常接近, 也就能学到正确的经验, 也就是说机器学习时有用的。

间章：机器何时能够学习？



笔记 [机器何时能够学习？]

“**When Can Machines Learn?**”（机器在何种条件下可以学习）是我们第一章所共同探讨的核心问题。

通过对学习的本质、假设空间的容量以及任务类型的系统分析，我们可以从以下四个方面给出较为严谨的回答：

1. 学习的理论可行性

学习的目标是从有限训练样本中学习到的能泛化的新样本的预测函数。这一过程是否可行，取决于：

- 是否存在一个假设函数能近似真实的目标函数（即 $f^* \in \mathcal{H}$ ）；
- 学习算法能否通过有限数据有效地找到这个假设；
- 换言之，当假设空间中确实存在“好”的函数，且我们能从数据中识别它时，学习才有可能成功。

2. 假设空间的容量控制

假设空间 $\mathcal{H}$ 的容量决定了其表达能力，学习是否能泛化取决于 $\mathcal{H}$ 是否“刚好足够”：

- 若容量过小，模型可能欠拟合，无法拟合目标函数；
- 若容量过大，容易过拟合训练数据，导致泛化能力差；
- 有效学习需在“表达能力”与“泛化误差”之间取得平衡。复杂度控制工具如 VC 维、Rademacher 复杂度、Hoeffding 不等式等，为我们提供了理论保证。

3. 任务形式与学习方式

学习能否实现，还取决于任务类型和数据获取方式是否适合建模：

- 学习任务可为分类（如图像识别）、回归（如房价预测）或结构化输出（如命名实体识别）；
- 数据类型决定学习方式：监督学习依赖大量标签，无监督学习探索结构，半监督、自监督和强化学习则结合不同类型信号；
- 适当建模任务、选择合适的学习范式，是实现学习的基础。

4. 结论：机器何时能够学习？

综合而言，当以下条件满足时，机器学习才真正可行：

- 存在一个好的目标函数，可被假设空间 $\mathcal{H}$ 表达；
- 假设空间容量适中，能保证泛化误差可控；
- 数据集具备代表性，学习算法在有限样本下能拟合目标；
- 学习方式与任务结构合理匹配。

结语：学习的可能性建立在函数表达能力、数据可获取性、模型可控性以及任务可建模性之上。

只有在这些条件协同满足时，机器才能真正实现学习。

第 2 章 机器为什么能够学习？

2.1 训练 vs 测试

2.1.1 回顾与展望

假设数量 M 的权衡

联合界给出

$$\mathbb{P}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon] \leq 2Me^{-2\varepsilon^2 N}.$$

	小 M	大 M
$E_{\text{in}} \approx E_{\text{out}}$	✓	✗ (上界失效)
E_{in} 足够小	✗ (选择少)	✓

结论 M 过小或过大都会使学习失效，必须选择合适的 M （或假设集 $\mathcal{H}$ ）。

预告：下一步工作

已知 对有限假设集 $\mathcal{H}$ 大小为 M 时，有

$$\mathbb{P}[|E_{\text{in}}(g) - E_{\text{out}}(g)| > \varepsilon] \leq 2M \exp(-2\varepsilon^2 N).$$

待办

- 用有限量 $m_{\mathcal{H}}$ 取代 M ，得到

$$\mathbb{P}[|E_{\text{in}}(g) - E_{\text{out}}(g)| > \varepsilon] \leq 2m_{\mathcal{H}} \exp(-2\varepsilon^2 N).$$

- 论证当 $|\mathcal{H}|$ 无限时学习仍可行。
- 研究 $m_{\mathcal{H}}$ 的性质，从而像调节 M 一样选择“正确”的 $\mathcal{H}$ 。
- 最终彻底揭开 PLA 的神秘面纱。

2.1.2 有效直线数

联合界为何失效？

已知上界

$$\mathbb{P}[|E_{\text{in}}(g) - E_{\text{out}}(g)| > \varepsilon] \leq 2M \exp(-2\varepsilon^2 N)$$

来自联合界 $\mathbb{P}[B_1 \cup \dots \cup B_M] \leq \sum_m \mathbb{P}[B_m]$ ，其中 B_m 表示事件 $\{|E_{\text{in}}(h_m) - E_{\text{out}}(h_m)| > \varepsilon\}$ 。

联合界的不足

- 最坏情形假设所有 B_m 互斥，实际却大量重叠；
- 当 $h_1 \approx h_2$ 时， $E_{\text{out}}(h_1) \approx E_{\text{out}}(h_2)$ ，且对大多数样本 $\mathcal{D}$ 有 $E_{\text{in}}(h_1) = E_{\text{in}}(h_2)$ ；
- 联合界严重高估真实概率。

下一步思路 将相似假设按“类别”合并，用有限量 $m_{\mathcal{H}}$ 取代 M ，从而得到更紧致的上界。

直线到底有多少种？（二维平面）

问题设定 假设集 $\mathcal{H}$ 为 $\mathbb{R}^2$ 中所有直线。

从输入点看种类数

- 若仅看单个输入 $\mathbf{x}_1$ ，直线可把 $\mathbf{x}_1$ 分成两类：


正类 $\circ$ 或 负类 $\times$ 。

故 2 种。


- 若看两个输入 $\mathbf{x}_1, \mathbf{x}_2$ ，直线可把 $(\mathbf{x}_1, \mathbf{x}_2)$ 分成

$(\circ, \circ), (\circ, \times), (\times, \circ), (\times, \times)$

共 4 种。



(a) 一个输入的分类



(b) 两个输入的分类

图 2.1.1: 二维平面输出的分类

三个输入时直线有多少种划分？

一般情形 当输入 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ 处于一般位置（不共线）时，平面中的直线最多可将这 3 个点分成

$$2^3 = 8$$

种标签组合，每种组合均可由某条直线实现。

退化情形 若三点共线或出现重复输入，则某些标签组合无法由直线实现，实际可实现的划分种类数 **少于 8 种**（例如只有 6 种）。即

$$m_{\mathcal{H}}(3) = 6.$$




图 2.1.2: 三个输入时直线的划分情况

四条输入时直线有多少种划分？

设定假设集 $\mathcal{H}$ 为二维平面 $\mathbb{R}^2$ 中的所有直线，给定任意四个输入点 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$ 。

最大可实现划分 无论四点如何摆放（一般位置或退化），平面直线最多可将这 4 个点分成 14 种不同的标签组合（而非 $2^4 = 16$ 种）。即

$$m_{\mathcal{H}}(4) = 14.$$




图 2.1.3: 四个输入时直线的划分情况

命题 2.1.1 (有效直线数)

令 $\mathcal{H}$ 为二维平面所有直线组成的假设集, $m_{\mathcal{H}}(N)$ 表示对任意 N 个输入点 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 的最大可实现划分类数, 则有

$$m_{\mathcal{H}}(N) \leq 2^N \quad \text{且} \quad \begin{cases} m_{\mathcal{H}}(1) = 2, \\ m_{\mathcal{H}}(2) = 4, \\ m_{\mathcal{H}}(3) = 8, \\ m_{\mathcal{H}}(4) = 14. \end{cases}$$

利用 $m_{\mathcal{H}}(N)$ 替代原先的 M , 可得

$$\mathbb{P}[|E_{\text{in}}(g) - E_{\text{out}}(g)| > \varepsilon] \leq 2 m_{\mathcal{H}}(N) \exp(-2\varepsilon^2 N).$$

由于 $m_{\mathcal{H}}(N) \ll 2^N$ 且随 N 多项式增长, 即使 $\mathcal{H}$ 包含无限多条直线, 学习仍然可行。



例题 2.1 五条输入的有效直线数 在二维平面 $\mathbb{R}^2$ 中, 给定五条输入点 $\mathbf{x}_1, \dots, \mathbf{x}_5$ 。问: 平面直线最多可把这五点分成多少种不同的标签组合?

选项 14 16 22 32

解答 将五条输入大致均匀摆放在一个圆周上。对圆周上任意一段“连续”的点, 可画一条直线使其落在同一侧, 其余点在另一侧。按此方式枚举, 可得 22 种不同的划分, 远小于理论上限 $2^5 = 32$ 。后续课程将给出形式化证明。 ■

2.1.3 有效假设数**二分法 (Dichotomies): 迷你假设**

定义 设假设集 $\mathcal{H} = \{h: \mathcal{X} \rightarrow \{\times, \circ\}\}$ 。给定 N 个输入点 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$, 定义

$$\mathcal{H}(\mathbf{x}_1, \dots, \mathbf{x}_N) = \{(h(\mathbf{x}_1), \dots, h(\mathbf{x}_N)) \mid h \in \mathcal{H}\}$$

为 $\mathcal{H}$ 在这些点上“实现”的所有二分法 (dichotomies)。

示例 $\mathcal{H}$ = 平面所有直线, 则

$$\mathcal{H}(\mathbf{x}_1, \dots, \mathbf{x}_N) = \{\circ \circ \circ \circ, \circ \circ \circ \times, \circ \circ \times \times, \dots\}$$

其大小可能无限, 但受限于 2^N 。

用途 $|\mathcal{H}(\mathbf{x}_1, \dots, \mathbf{x}_N)|$ 可作为有限量替代原先的 M , 用于建立 PAC 界。

定义 2.1.1 (增长函数 (Growth Function))

设假设集 $\mathcal{H} \subseteq \{h: \mathcal{X} \rightarrow \{\times, \circ\}\}$ 。定义其增长函数为

$$m_{\mathcal{H}}(N) \triangleq \max_{(\mathbf{x}_1, \dots, \mathbf{x}_N) \in \mathcal{X}^N} |\mathcal{H}(\mathbf{x}_1, \dots, \mathbf{x}_N)|,$$

其中 $\mathcal{H}(\mathbf{x}_1, \dots, \mathbf{x}_N)$ 表示 $\mathcal{H}$ 在 N 个输入点上可实现的所有二分法集合。 $m_{\mathcal{H}}(N)$ 满足:

- 有限且 $m_{\mathcal{H}}(N) \leq 2^N$;
- 用于 PAC 界: $\mathbb{P}[|E_{\text{in}} - E_{\text{out}}| > \varepsilon] \leq 2m_{\mathcal{H}}(N)e^{-2\varepsilon^2 N}$;

- 对二维直线, $m_{\mathcal{H}}(N)$ 的前几项为

$$m_{\mathcal{H}}(1) = 2, \quad m_{\mathcal{H}}(2) = 4, \quad m_{\mathcal{H}}(3) = 8, \quad m_{\mathcal{H}}(4) = 14.$$



正射线 (Positive Rays) 的增长函数

设定 设输入空间 $\mathcal{X} = \mathbb{R}$ (一维), 假设集

$$\mathcal{H} = \{h \mid h(x) = \text{sign}(x - a), a \in \mathbb{R}\},$$

即所有以阈值 a 为界的“正射线”, 输出左侧为 -1 , 右侧为 $+1$ 。

二分法计数 对任意 N 个有序输入 $x_1 < x_2 < \dots < x_N$, 阈值 a 只能在 $(-\infty, x_1], [x_1, x_2], \dots, [x_N, +\infty)$ 这 $N+1$ 个区间取值, 每个区间对应一种不同的二分法, 故

$$m_{\mathcal{H}}(N) = N + 1.$$

性质

$$N + 1 < 2^N \quad \text{当 } N \text{ 较大时成立.}$$

因此即使 $\mathcal{H}$ 无限, 仍可用 $m_{\mathcal{H}}(N) = N + 1$ 取代原先的 M , 保证 PAC 上界有效。

正区间 (Positive Intervals) 的增长函数

设定 输入空间 $\mathcal{X} = \mathbb{R}$ (一维), 假设集

$$\mathcal{H} = \{h \mid h(x) = \mathbb{I}(x \in [a, b))\}.$$

其中 $\mathbb{I}[\cdot]$ 为示性函数: 区间内输出 $+1$, 其余输出 -1 。

二分法计数 对任意 N 个有序输入 $x_1 < x_2 < \dots < x_N$, 区间端点 a, b 只能落在

$$(-\infty, x_1], [x_1, x_2], \dots, [x_N, +\infty)$$

共 $N+1$ 个位置。选取两个端点 (可重合) 决定区间, 因此

$$m_{\mathcal{H}}(N) = \binom{N+1}{2} + 1 = \frac{N(N+1)}{2} + 1 = \frac{N^2 + N + 2}{2}.$$

(常简记为 $\mathcal{O}(N^2)$)

性质

$$\frac{N^2 + N + 2}{2} < 2^N \quad \text{当 } N \text{ 较大时成立,}$$

故 $\mathcal{H}$ 虽无限, 仍可用多项式增长的 $m_{\mathcal{H}}(N)$ 替代原先的 M , PAC 学习可行。

凸集 (Convex Sets) 的增长函数

设定 输入空间 $\mathcal{X} = \mathbb{R}^2$, 假设集

$$\mathcal{H} = \{h \mid h(\mathbf{x}) = \mathbb{I}(\mathbf{x} \in C), C \subseteq \mathbb{R}^2 \text{ 为凸集}\},$$

其中 $\mathbb{I}(\cdot)$ 为示性函数: 在凸集 C 内输出 +1, 否则 -1。

增长函数把 N 个点均匀放在一个大圆周上, 则

$$m_{\mathcal{H}}(N) = 2^N,$$

并称这 N 个点被 $\mathcal{H}$ 打散 (shattered)。

结论 凸集假设集满足 $m_{\mathcal{H}}(N) = 2^N$, VC 维无限, 需额外技术 (如正则化) 控制复杂度。




图 2.1.4: 三种假设集的增长函数对比

2.1.4 断点

四种假设集的增长函数

假设集	增长函数 $m_{\mathcal{H}}(N)$
正射线 (positive rays)	$N + 1$
正区间 (positive intervals)	$\frac{N^2 + N + 2}{2}$
凸集 (convex sets)	2^N
二维感知机 (2D perceptrons)	多项式上界 $< 2^N$

PAC 界 用 $m_{\mathcal{H}}(N)$ 替代原先的 M 得

$$\mathbb{P}[|E_{\text{in}}(g) - E_{\text{out}}(g)| > \varepsilon] \leq 2 m_{\mathcal{H}}(N) \exp(-2\varepsilon^2 N).$$

结论 多项式 $m_{\mathcal{H}}(N)$: 好; 指数 $m_{\mathcal{H}}(N)$: 坏。

笔记 [断点分类与理论猜想 (The Four Break Points)]

四种典型的 Break Point 情况与理论猜想

- 正射线 (Positive Rays):
 - 断点出现在 2
 - 增长函数: $\mathcal{H}(N) = N + 1 = \mathcal{O}(N)$
- 正区间 (Positive Intervals):
 - 断点出现在 3
 - 增长函数: $\mathcal{H}(N) = \frac{1}{2}N^2 + \frac{1}{2}N + 1 = \mathcal{O}(N^2)$
- 凸集 (Convex Sets):
 - 无断点
 - 增长函数: $\mathcal{H}(N) = 2^N$
- 二维感知机 (2D Perceptrons):
 - 断点出现在 4
 - 增长函数: $\mathcal{H}(N) < 2^N$ (在某些情况下)

理论猜想 (Conjecture):

- 若没有断点, 则 $\mathcal{H}(N) = 2^N$
- 若存在断点 k , 则 $\mathcal{H}(N) = \mathcal{O}(N^{k-1})$

2.1.5 总结

笔记 [训练 vs 测试]

- 回顾与展望: 两个核心问题: $E_{\text{out}}(g) \approx E_{\text{in}}(g)$ 与 $E_{\text{in}}(g) \approx 0$ 。
- 有效直线数: 在 4 个输入点看来, 最多只有 14 条有效直线。
- 有效假设数: 在 N 个输入点看来, 有效假设数至多为增长函数 $m_{\mathcal{H}}(N)$ 。
- 断点 (break point): 当 $m_{\mathcal{H}}(N)$ 不再呈指数增长时的关键转折点。

笔记 [总体结论] 为了解决在假设集无限时原有联合界失效的问题, 引入了增长函数 $m_{\mathcal{H}}(N)$, 用于衡量在 N 个样本点上, 假设集 $\mathcal{H}$ 实际能实现的不同划分数 (即有效假设数)。尽管 $\mathcal{H}$ 可能是无限的, 但其在有限数据上能产生的划分是有限的, 例如二维平面中直线在 4 个点上最多只能划分出 14 种情况。增长函数提供了更精确的复杂度度量, 使我们能够用更紧致的泛化上界替代原有依赖假设数 M 的不等式, 从而在控制模型复杂度的同时, 确保学习的可行性。

2.2 泛化理论

2.2.1 断点的限制

定义 2.2.1 (打散 (Shatter))

设 $\mathcal{X}$ 为输入空间, $\mathcal{H} \subseteq \{h: \mathcal{X} \rightarrow \{-1, +1\}\}$ 为一假设类。给定有限子集 $S = \{x_1, \dots, x_N\} \subseteq \mathcal{X}$, 记

$$\mathcal{H}_S := \{(h(x_1), \dots, h(x_N)) \mid h \in \mathcal{H}\} \subseteq \{-1, +1\}^N.$$

若 $|\mathcal{H}_S| = 2^{|S|}$, 则称 $\mathcal{H}$ 打散 (shatters) 集合 S 。进一步, 若 $\mathcal{H}$ 对 $\mathcal{X}$ 中任意大小为 d 的子集皆可打散, 则称 $\mathcal{H}$ 能打散任意 d 个点。



命题 2.2.1 (断点 $k=2$ 时的打散 (shatter) 任意两个点的含义)

设假设类 $\mathcal{H}$ 的最小断点为 $k=2$, 则 $\mathcal{H}$ 不能打散任意两个点是指存在某两点 $x_1, x_2 \in \mathcal{X}$, 使得

$$|\{(h(x_1), h(x_2)) \mid h \in \mathcal{H}\}| < 4.$$

因而, 对任何含两个元素的子集 $S = \{x_i, x_j\} \subseteq \mathcal{X}$, 必有

$$|\mathcal{H}_S| \leq 3 < 2^{|S|} = 4,$$

即 $\mathcal{H}$ 至少缺失 $(\circ, \times)$ 或 $(\times, \circ)$ 或 $(\circ, \circ)$ 或 $(\times, \times)$ 中的一种标记组合。



命题 2.2.2 (最小断点 $k=2$ 的限制)

设假设集 $\mathcal{H}$ 的最小断点 (break point) 为 $k=2$ 。则对增长函数 $m_{\mathcal{H}}(N)$ 有

- 1) $N=1$: 由定义必有 $m_{\mathcal{H}}(1) = 2$;
- 2) $N=2$: 由定义必有 $m_{\mathcal{H}}(2) < 4$, 故最大可能值为 3;
- 3) $N=3$: 需满足假设空间 $\mathcal{H}$ 无法打散任意两点, 即对于给定的三个输入点 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$, 任意选取其中两点, 其对应的二分法组合数必须小于 4。换言之, 不存在两点能被 $\mathcal{H}$ 完全打散。根据这一限制, 增长函数的上界为:

$$m_{\mathcal{H}}(3) \leq 4.$$

且若存在 5 个二分法, 则必能打散某两点, 与 $k=2$ 矛盾。



$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$	$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$
○	○	○	○	○	○	○	○	○	○	○	○	○	○	○	○	○	○
○	○	×	○	○	×	○	○	×	○	○	×	○	○	×	○	○	×
○	×	○	○	×	○	○	×	○	○	×	○	○	×	○	○	×	○
○	×	×	×	○	○	×	×	○	×	×	○	×	×	○	×	×	○
×	×	×	×	○	○	×	×	○	×	×	○	×	×	○	×	×	○
×	×	×	×	○	○	×	×	○	×	×	○	×	×	○	×	×	○
×	×	×	×	○	○	×	×	○	×	×	○	×	×	○	×	×	○
×	×	×	×	○	○	×	×	○	×	×	○	×	×	○	×	×	○

图 2.2.1: 最小断点 $k=2$ 时二分法组合的示例图

命题 2.2.3 (断点限制 ($k=2$ 情形))

设假设集 $\mathcal{H}$ 的最小断点 (break point) 为 $k=2$, 则其增长函数 $m_{\mathcal{H}}(N)$ 必须满足

$$m_{\mathcal{H}}(1) = 2, \quad m_{\mathcal{H}}(2) \leq 3, \quad m_{\mathcal{H}}(3) \leq 4 < 2^3.$$

这表明，当 $N > k$ 时，断点 k 会显著限制 $m_{\mathcal{H}}(N)$ 的最大可能值，使其严格小于 2^N 。
由此产生一个待验证的猜想：若存在最小断点 k ，则对所有 N 有

$$m_{\mathcal{H}}(N) \leq \text{给定 } k \text{ 时的最大可能 } m_{\mathcal{H}}(N) \leq \text{多项式}(N).$$

从而 $m_{\mathcal{H}}(N)$ 由指数级降为多项式级，但尚需后续证明。



例题 2.2 设假设集 $\mathcal{H}$ 的最小断点 $k = 1$ 。问：当 $N = 3$ 时， $m_{\mathcal{H}}(3)$ 的最大可能值为多少？

选项 1 2 4 8

解答 由于 $k = 1$ ， $\mathcal{H}$ 连一个点都无法打散。因此，在 3 个输入的每一列中均不能同时出现 $\circ$ 与 $\times$ 。包含第一种二分法后，就无法再引入任何不同的二分法，故最大可能值为 1。 ■

2.2.2 界函数（基础情形）

定义 2.2.2 (界函数 (Bounding Function))

定义界函数

$$B(N, k) \triangleq \max_{\mathcal{H}: \text{break point}=k} m_{\mathcal{H}}(N),$$

即当最小断点为 k 时，任意假设集 $\mathcal{H}$ 在 N 个输入上所能达到的最大增长函数值。

组合意义 $B(N, k)$ 是满足下列条件的二进制向量（长度 N ，元素为 $\circ, \times$ ）的最大数量：不存在任何长度为 k 的子向量同时包含两种符号（即无法打散任意 k 个点）。

性质与用途

- $B(N, k)$ 仅由 N, k 决定，与 $\mathcal{H}$ 的具体形式无关。
- 例如： $B(N, 3)$ 同时给出正区间 ($k = 3$) 和 1D 感知机 ($k = 3$) 的统一上界。
- 新目标：证明 $B(N, k) \leq \text{多项式}(N)$ 。



表 2.2.1: 界函数 $B(N, k)$ 的已知值

$B(N, k)$	k						
	1	2	3	4	5	6	...
N	1	1	2	2	2	2	...
	2	1	3	4	4	4	...
	3	1	4	7	8	8	...
	4	1			15	16	...
	5	1				31	32
	6	1					63
	$\vdots$	$\vdots$					$\ddots$

已知规律

- 当 $N < k$ 时： $B(N, k) = 2^N$ （尚未触发断点条件）。
- 当 $N = k$ 时： $B(N, k) = 2^N - 1$ （去掉任一单个二分法即可满足断点）。
- 当 $N > k$ 时：数值继续按组合规律递减，且总体保持多项式增长。

例题 2.3 对二维感知机 (2D perceptrons), 以下哪一句话正确?

选项

- 1) 最小断点 $k = 2$;
- 2) $m_{\mathcal{H}}(4) = 15$;
- 3) 当 $N = k =$ 最小断点时, $m_{\mathcal{H}}(N) < B(N, k)$;
- 4) 当 $N = k =$ 最小断点时, $m_{\mathcal{H}}(N) > B(N, k)$ 。

解答 已知二维感知机的最小断点为 $k = 4$, 且 $m_{\mathcal{H}}(4) = 14$, 而界函数给出 $B(4, 4) = 15$ 。因此

$$m_{\mathcal{H}}(4) = 14 < 15 = B(4, 4),$$

即界函数在 $N = k$ 时可能“宽松”。正确选项为 [3]。 ■

2.2.3 界函数 (归纳情形)

在获得若干基础情形的界函数值后, 我们可借助归纳法推导其余取值。作为示例, 先通过组合分析求出 $B(4, 3)$ 的具体数值, 再对所得二分法进行重新归类与配对, 得到如下示意图。

	x_1	x_2	x_3	x_4
01	○	○	○	○
02	×	○	○	○
03	○	×	○	○
04	○	○	×	○
05	○	○	○	×
06	×	×	○	×
07	×	○	×	○
08	×	○	○	×
09	○	×	×	○
10	○	×	○	×
11	○	○	×	×

⇒

	x_1	x_2	x_3	x_4
01	○	○	○	○
05	○	○	○	×
02	×	○	○	○
08	×	○	○	×
03	○	×	○	○
10	○	×	○	×
04	○	○	×	○
11	○	○	×	×
06	×	×	○	×
07	×	○	×	○
09	○	×	×	○

图 2.2.2: $B(4, 3)$ 的排列组合形式

估计 $B(4, 3)$ 的两部分

第一部分 ($\alpha + \beta$ 的约束)


$$B(4, 3) = 11 = 2\alpha + \beta, \quad \alpha + \beta \leq B(3, 3).$$

其中 $\alpha + \beta$ 是在 (X_1, X_2, X_3) 上满足“不打散任意 3 点”的二分法数。

第二部分 (α 的约束)

$$\alpha \leq B(3, 2),$$

α 为在 (X_1, X_2, X_3) 上满足“不打散任意 2 点”的二分法数, 且每个二分法与 X_4 成对出现 (X_4 取相反符号)。

图 2.2.3: α 和 β 在 $B(4, 3)$ 上的约束

归纳上界

核心关系

$$B(4, 3) = 2\alpha + \beta, \quad \alpha \leq B(3, 2) = 4, \quad \alpha + \beta \leq B(3, 3) = 8.$$

由此得到

$$B(4, 3) \leq B(3, 3) + B(3, 2) = 8 + 4 = 12, \quad \text{精确值为11.}$$

一般递推

$$B(N, k) \leq B(N-1, k) + B(N-1, k-1), \quad \forall N, k \geq 1.$$

界函数上界（部分）

$B(N, k)$		k					
		1	2	3	4	5	6
N	1	1	2	2	2	2	2
	2	1	3	4	4	4	4
	3	1	4	7	8	8	8
	4	1	≤ 5	11	15	16	16
	5	1	≤ 6	≤ 16	≤ 26	31	32
	6	1	≤ 7	≤ 22	≤ 42	≤ 57	63

定理 2.2.1 (界函数定理)

对任意正整数 N, k , 界函数满足

$$B(N, k) \leq \sum_{i=0}^{k-1} \binom{N}{i},$$

其最高次项为 N^{k-1} 。对固定的 k , $B(N, k)$ 被 N 的多项式上界所控制。**注** 上式中的不等号“ $\leq$ ”事实上可取等号，读者可自行证明，下面给出一种证明思路。**证明** 设有 N 个元素的点集 C , 考虑所有 0-1 标签序列，其中最多只有 $k-1$ 个位置标记为 1，其可能的标签总数为

$$\sum_{i=0}^{k-1} \binom{N}{i}.$$

任何函数类若不能在大小为 k 的集合上构造出全部 2^k 种标记, 那么它在任意 N 个点上所能构造的标签数必然不超过上述数量, 因此 $B(N, k) \leq \sum_{i=0}^{k-1} \binom{N}{i}$ 。

我们构造函数类 $\mathcal{F} = \{f_A \mid A \subseteq C, |A| \leq k-1\}$, 其中 $f_A(x) = 1$ 当且仅当 $x \in A$ 。此类函数产生的标签正好是所有 0-1 向量中“1”的个数不超过 $k-1$ 的那些, 共计 $\sum_{i=0}^{k-1} \binom{N}{i}$ 种。即上界可达, 因此

$$B(N, k) \geq \sum_{i=0}^{k-1} \binom{N}{i}。$$

因此 $B(N, k) = \sum_{i=0}^{k-1} \binom{N}{i}$, 且其最高次项为 $\binom{N}{k-1} \sim \frac{N^{k-1}}{(k-1)!}$ 。 ■

推论 2.2.1

若假设集 $\mathcal{H}$ 存在断点 k , 则

$$m_{\mathcal{H}}(N) \leq B(N, k) \leq \text{多项式}(N).$$

2.2.4 图解证明

定理 2.2.2 (通用假设集的 PAC 上界 (BAD Bound))

对任意假设集 $\mathcal{H}$, 若存在最小断点 k , 则对充分大的样本量 N 和任意 $\varepsilon > 0$ 有

$$\mathbb{P}\left[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon\right] \leq 4 m_{\mathcal{H}}(2N) \exp\left(-\frac{\varepsilon^2 N}{8}\right).$$

为证明该定理, 我们先引入必要的定义和引理:

定义 2.2.3 (经验误差与泛化误差)

设假设空间为 $\mathcal{H}$, 训练集为 $S = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中每个样本 (x_i, y_i) 独立同分布于数据生成分布 D 。对任意假设 $h \in \mathcal{H}$, 定义:

- 经验误差 (in-sample error):

$$E_{\text{in}}(h) = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[h(x_i) \neq y_i]$$

表示假设 h 在训练集 S 上的平均错误率, 其中 $\mathbb{I}[\cdot]$ 为指示函数 (条件成立时取 1, 否则取 0)。

- 泛化误差 (out-of-sample error):

$$E_{\text{out}}(h) = \mathbb{E}_{(x,y) \sim D} [\mathbb{I}[h(x) \neq y]]$$

表示假设 h 在整个数据分布 D 上的期望错误率, $\mathbb{E}_{(x,y) \sim D}[\cdot]$ 表示对分布 D 的期望。 ♣

引理 2.2.1 (Symmetrization 不等式)

设 S 和 S' 是来自分布 D 的独立同分布样本集 (大小均为 N), 则对任意 $\epsilon > 0$:

$$\mathbb{P}_S \left[\sup_{h \in \mathcal{H}} |E_{\text{in}}(h) - E_{\text{out}}(h)| > \epsilon \right] \leq 2 \cdot \mathbb{P}_{S, S'} \left[\sup_{h \in \mathcal{H}} |E_{\text{in}}(h) - E'_{\text{in}}(h)| > \frac{\epsilon}{2} \right]$$

其中 $E'_{\text{in}}(h)$ 是 h 在 S' 上的经验误差。 ♥

证明 [定理的证明 (仅作参考, 读者有兴趣可自行证明)]

步骤 1: 固定假设的误差界

对任意固定假设 $h \in \mathcal{H}$, $E_{\text{in}}(h)$ 是 N 个独立 $[0, 1]$ 变量 $\mathbb{I}[h(x_i) \neq y_i]$ 的均值, 而 $E_{\text{out}}(h)$ 是其期望。由 Hoeffding 不等式:

$$\mathbb{P}(|E_{\text{in}}(h) - E_{\text{out}}(h)| > \epsilon) \leq 2 \exp(-2\epsilon^2 N)$$

步骤 2: 有限假设空间的联合界

若 $\mathcal{H}$ 含有限个假设, 对所有 $h \in \mathcal{H}$ 应用联合界:

$$\mathbb{P}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \epsilon] \leq \sum_{h \in \mathcal{H}} 2 \exp(-2\epsilon^2 N) = 2|\mathcal{H}| \exp(-2\epsilon^2 N)$$

步骤 3: 无限假设空间的处理

对于无限 $\mathcal{H}$, 利用增长函数限制可区分数目。考虑大小为 $2N$ 的样本集 $S \cup S'$, $\mathcal{H}$ 在其上的划分数目不超过 $m_{\mathcal{H}}(2N)$, 故:

$$|\{(h|_S, h|_{S'}) \mid h \in \mathcal{H}\}| \leq m_{\mathcal{H}}(2N)$$

其中 $h|_S$ 表示 h 在 S 上的预测标签。

步骤 4: 应用 Symmetrization 技巧

由 Symmetrization 不等式, 原概率可转化为两个经验误差差的概率:

$$\mathbb{P}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \epsilon] \leq 2 \cdot \mathbb{P}_{S, S'} \left[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E'_{\text{in}}(h)| > \frac{\epsilon}{2} \right]$$

给定含 $2N$ 样本的集合 (拆为 S, S' 各 N 样本), 有等价变形:

$$|E_{\text{in}} - E'_{\text{in}}| > \frac{\epsilon}{2} \iff \left| E_{\text{in}} - \frac{E_{\text{in}} + E'_{\text{in}}}{2} \right| > \frac{\epsilon}{4}$$

对 $S \cup S'$ 上假设诱导的划分, 结合增长函数 $m_{\mathcal{H}}(2N)$ 限制, 用 Hoeffding 松弛, 最终得:

$$\mathbb{P}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \epsilon] \leq 4 \cdot m_{\mathcal{H}}(2N) \cdot \exp\left(-\frac{\epsilon^2 N}{8}\right)$$

■

2.2.5 总结



笔记 [泛化理论]

- 断点的限制: 一旦存在断点 k , 其后的所有点都会被“截断”。
- 界函数 (基础情形): 定义 $B(N, k)$, 用来在断点为 k 时给出 $m_{\mathcal{H}}(N)$ 的上界。
- 界函数 (归纳情形): $B(N, k)$ 对 N 呈多项式增长, 即 $\text{poly}(N)$ 。
- 图解证明: 通过少量改动, 可将原先与 M 相关的界替换为与 $m_{\mathcal{H}}(N)$ 相关的界。

2.3 VC 维

2.3.1 VC 维的定义

命题 2.3.1 (VC 界回顾)

设假设集 $\mathcal{H}$ 具有最小断点 k 。对任意学习算法 $\mathcal{A}$ 输出的假设 $g = \mathcal{A}(\mathcal{D})$ ，当样本量 N 足够大时，对任意 $\varepsilon > 0$ 有

$$\mathbb{P}\left[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon\right] \leq 4(2N)^{k-1} \exp\left(-\frac{\varepsilon^2 N}{8}\right).$$

若同时满足：

- 1) 假设集存在断点 k ，即拥有好假设集；
- 2) 数据量 N 足够大，即拥有好数据；
- 3) 算法 $\mathcal{A}$ 选出具有较小 E_{in} 的假设 g ，即拥有好算法；

则大概率成立 $E_{\text{out}}(g) \approx E_{\text{in}}(g)$ ，即学习成功。



定义 2.3.1 (VC 维)

假设集 $\mathcal{H}$ 的 VC 维（记作 $d_{\text{VC}}(\mathcal{H})$ ）定义为

$$d_{\text{VC}}(\mathcal{H}) = \max\{N \in \mathbb{N} \mid m_{\mathcal{H}}(N) = 2^N\},$$

即能被打散的最多输入点数。等价地，

$$d_{\text{VC}}(\mathcal{H}) = \text{最小断点 } k - 1.$$

性质

- 若 $N \leq d_{\text{VC}}$ ，则 $\mathcal{H}$ 能够打散某 N 个输入；
- 若 $k > d_{\text{VC}}$ ，则 k 是 $\mathcal{H}$ 的断点；
- 当 $N \geq 2$ 且 $d_{\text{VC}} \geq 2$ 时， $m_{\mathcal{H}}(N) \leq N^{d_{\text{VC}}}$ 。



四种假设集的 VC 维及其学习保证

假设集	$m_{\mathcal{H}}(N)$	$d_{\text{VC}}(\mathcal{H})$
正射线 (positive rays)	$N + 1$	1
正区间 (positive intervals)	$\frac{N^2 + N + 2}{2}$	2
凸集 (Convex Sets)	2^N	∞
二维感知机 (2D perceptrons)	$\leq N^3 \ (N \geq 2)$	3

学习保证 只要 $d_{\text{VC}}(\mathcal{H}) < \infty$ ，学习所得假设 g 必以高概率满足 $E_{\text{out}}(g) \approx E_{\text{in}}(g)$ 且该结论

- 与具体学习算法 $\mathcal{A}$ 无关；
- 与输入分布 $\mathcal{P}$ 无关；
- 与真实目标函数 f 无关。

2.3.2 线性分类器的 VC 维

再探二维感知机学习算法 (PLA)

设定

- 数据集 $\mathcal{D}$ 线性可分, $X_n \sim \mathcal{P}$, $y_n = f(X_n)$;
- PLA 保证收敛。

VC 维保证

$$\mathbb{P}[|E_{\text{in}}(g) - E_{\text{out}}(g)| > \varepsilon] \leq 4(2N)^{d_{\text{VC}}} \exp\left(-\frac{\varepsilon^2 N}{8}\right) \quad (\text{由 } d_{\text{VC}} = 3 \text{ 控制}).$$

当迭代次数 T 与样本量 N 足够大时

$$E_{\text{in}}(g) = 0 \implies E_{\text{out}}(g) \approx E_{\text{in}}(g) \approx 0.$$

猜想 对于特征维度 $d > 2$ 的一般 PLA, 上述结论同样成立, 只需将 d_{VC} 替换为 $d + 1$ 。

例题 2.4 选择题: 证明 $d_{\text{VC}} \geq d + 1$ 下列哪一句话最能说明 $d_{\text{VC}} \geq d + 1$?

- 1) 存在一组 $d + 1$ 个输入可以被我们打散。
- 2) 任意一组 $d + 1$ 个输入都可以被我们打散。
- 3) 存在一组 $d + 2$ 个输入我们无法打散。
- 4) 任意一组 $d + 2$ 个输入我们都无法打散。

解答 正确选项为 [1]。根据 VC 维定义, d_{VC} 是使得 $m_{\mathcal{H}}(N) = 2^N$ 的最大 N 。

因此若存在一组 $d + 1$ 个输入可以被我们打散, 则能在某 $d + 1$ 个输入上构造出全部 2^{d+1} 种二分法, 则 $m_{\mathcal{H}}(d + 1) = 2^{d+1}$, 从而 $d_{\text{VC}} \geq d + 1$ 。 ■

命题 2.3.2 ($d_{\text{VC}} \geq d + 1$ (一般 d 维情形))

在 d 维空间 $\mathbb{R}^d$ (含偏置项) 中, 存在 $d + 1$ 个输入点可以被线性假设集打散。构造“平凡”输入矩阵

$$X = \begin{bmatrix} -x_1^T - \\ -x_2^T - \\ -x_3^T - \\ \vdots \\ -x_{d+1}^T - \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 1 & 1 & 0 & \cdots & 0 \\ 1 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 0 & \cdots & 1 \end{bmatrix}_{(d+1) \times (d+1)}$$

则 X 可逆。对任意标签向量 $\mathbf{y} \in \{-1, +1\}^{d+1}$, 令

$$\mathbf{w} = X^{-1}\mathbf{y} \Leftrightarrow X\mathbf{w} = \mathbf{y}$$

便有

$$\text{sign}(X\mathbf{w}) = \mathbf{y},$$

因而这 $d + 1$ 个点可以被线性分类器打散, 故

$$d_{\text{VC}} \geq d + 1.$$

例题 2.5 选择题: 证明 $d_{\text{VC}} < d + 2$ 下列哪一句话最能说明 $d_{\text{VC}} < d + 2$?

- 1) 存在一组 $d + 1$ 个输入可以被我们打散。

- 2) 任意一组 $d+1$ 个输入都可以被我们打散。
- 3) 存在一组 $d+2$ 个输入我们无法打散。
- 4) 任意一组 $d+2$ 个输入我们都无法打散。

解答 正确选项为 [4]。根据 VC 维定义, d_{VC} 为使得 $m_{\mathcal{H}}(N) = 2^N$ 的最大 N 。

若任意一组 $d+2$ 个输入我们都无法打散, 则对任意 $d+2$ 个输入都无法产生全部 2^{d+2} 种二分法, 即 $m_{\mathcal{H}}(d+2) < 2^{d+2}$, 则 $d+2$ 是一个断点, 从而 $d_{VC} < d+2$, 亦即 $d_{VC} \leq d+1$ 。 ■

命题 2.3.3 ($d_{VC} \leq d+1$ (一般 d 维情形))

设输入空间为 $\mathbb{R}^d$ (含偏置项), 令 $X = [\mathbf{x}_1, \dots, \mathbf{x}_{d+2}] \in \mathbb{R}^{(d+1) \times (d+2)}$ 为任意 $d+2$ 个输入组成的矩阵。由于列数多于行数, X 的列必然线性相关, 即存在不全为零的系数 $a_1, \dots, a_{d+1}$ 使得

$$\mathbf{x}_{d+2} = a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2 + \dots + a_{d+1} \mathbf{x}_{d+1}.$$

假设线性分类器能打散这 $d+2$ 个点, 则对任意标签分配 $y_1, \dots, y_{d+2} \in \{-1, +1\}$, 都存在 $\mathbf{w} \in \mathbb{R}^{d+1}$ 满足:

$$\text{sign}(\mathbf{w}^\top \mathbf{x}_i) = y_i \quad (\forall i = 1, \dots, d+2).$$

特别地, 取 $y_i = \text{sign}(a_i)$ (若 $a_i = 0$ 则 y_i 任意), 且 $y_{d+2} = -1$ 。此时:

$$\mathbf{w}^\top \mathbf{x}_{d+2} = \sum_{i=1}^{d+1} a_i (\mathbf{w}^\top \mathbf{x}_i) = \sum_{i=1}^{d+1} a_i y_i = \sum_{i=1}^{d+1} |a_i| > 0,$$

但根据标签定义要求 $\mathbf{w}^\top \mathbf{x}_{d+2} = y_{d+2} < 0$, 矛盾。因此, 任意 $d+2$ 个输入均无法被线性假设集打散, 从而

$$d_{VC} \leq d+1.$$

定理 2.3.1 (线性分类器的 VC 维)

设输入空间为 $\mathbb{R}^d$ (即包含偏置项的 $(d+1)$ 维增广空间), 则线性假设集

$$\mathcal{H} = \{h \mid h(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x}), \mathbf{w} \in \mathbb{R}^{d+1}\}$$

的 VC 维满足

$$d_{VC}(\mathcal{H}) = d+1.$$

2.3.3 VC 维的直观物理意义

自由度 (Degrees of Freedom)

参数自由度	$\mathbf{w} = (w_0, w_1, \dots, w_d) \in \mathbb{R}^{d+1}$
假设数量	$M = \mathcal{H} $ (“模拟” 自由度)
假设“威力”	$d_{VC}(\mathcal{H}) = d+1$ (“有效二进制” 自由度)
结论	$d_{VC}(\mathcal{H})$ 衡量假设集的表达能

VC 维与自由参数的例子

正射线 ($d_{VC} = 1$)

$$h(x) = \text{sign}(x - a), \quad \text{自由参数: 阈值 } a \in \mathbb{R}.$$

正区间 ($d_{VC} = 2$)

$$h(x) = \text{sign}[(x - l)(r - x)], \quad \text{自由参数: 左端 } l, \text{右端 } r \in \mathbb{R}.$$

经验法则

$$d_{VC} \approx \text{自由参数个数} \quad (\text{通常成立, 但并非绝对})$$

例题 2.6 过原点超平面的 VC 维 在 $\mathbb{R}^d$ 中, 仅考虑通过原点的超平面 (即固定偏置项 $w_0 = 0$ 的感知机), 其 VC 维为多少?

选项 1 d $d+1$ ∞

解答 证明思路与普通感知机几乎相同, 与普通感知机的区别在于通过原点的超平面的偏置项为 0, 即输入空间 $\mathbb{R}^d$ 的维度与 VC 维大小相同, 因此 $d_{VC} = d$ 。

但可直接利用 $d_{VC} \approx \text{自由参数个数}$ 这一直觉: 通过原点的超平面仅含 d 个自由参数 $(w_1, \dots, w_d)$, 因此 $d_{VC} = d$ 。 ■

2.3.4 VC 维的解读

命题 2.3.4 (VC 界的详细重述: 模型复杂度的惩罚项 (Penalty for Model Complexity))

设

- $\mathcal{H}$ 为任意假设集, 其 VC 维 $d_{VC} \geq 2$;
- $\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$ 为独立同分布样本, $N \geq 2$;
- $g = \mathcal{A}(\mathcal{D}) \in \mathcal{H}$ 为算法 $\mathcal{A}$ 输出的假设。

$$\mathbb{P}_{\mathcal{D}} \left[\underbrace{|E_{\text{in}}(g) - E_{\text{out}}(g)|}_{\text{BAD}} > \epsilon \right] \leq \underbrace{4(2N)^{d_{VC}} \exp\left(-\frac{1}{8}\epsilon^2 N\right)}_{\delta}$$

则对任意 $\delta > 0$, 以概率至少 $1 - \delta$ 成立

$$|E_{\text{in}}(g) - E_{\text{out}}(g)| \leq \underbrace{\sqrt{\frac{8}{N} \left(\frac{4(2N)^{d_{VC}}}{\delta} \right)}}_{\Omega(N, d_{VC}, \delta)}.$$

其中

$$\Omega(N, d_{VC}, \delta) = \sqrt{\frac{8}{N} \ln \left(\frac{4(2N)^{d_{VC}}}{\delta} \right)}$$

VC 维相关信息

以高概率成立

$$E_{\text{out}}(g) \leq E_{\text{in}}(g) + \underbrace{\sqrt{\frac{8}{N} \left(\frac{4(2N)^{d_{\text{VC}}}}{\delta} \right)}}_{\Omega(N, d_{\text{VC}}, \delta)}$$

- 模型复杂度 $d_{\text{VC}} \uparrow$
 $\Rightarrow$ 泛化界 $\Omega \uparrow$, 但训练误差 $E_{\text{in}} \downarrow$ 。
- 模型复杂度 $d_{\text{VC}} \downarrow$
 $\Rightarrow$ 泛化界 $\Omega \downarrow$, 但训练误差 $E_{\text{in}} \uparrow$ 。
- 最优 d_{VC}^* 位于中间地带。




图 2.3.1: 模型复杂度、样本内误差、样本外误差与 VC 维关系图

命题 2.3.5 (VC 界的重新表述: 样本复杂度 (Sample Complexity))

给定精度 $\varepsilon = 0.1$ 、置信参数 $\delta = 0.1$ 与 VC 维 $d_{\text{VC}} = 3$, 若要求

$$4(2N)^{d_{\text{VC}}} \exp\left(-\frac{\varepsilon^2 N}{8}\right) \leq \delta,$$

则最小样本量 N 的理论上界为

$$N \approx 29,300 \approx 10^4 d_{\text{VC}}.$$

实际经验法则常取

$$N \approx 10 d_{\text{VC}}$$

即可满足泛化需求。

命题 2.3.6 (VC 界的松弛性 (Looseness of the VC Bound))

$$\mathbb{P}[|E_{\text{in}}(g) - E_{\text{out}}(g)| > \varepsilon] \leq 4(2N)^{d_{\text{VC}}} \exp\left(-\frac{\varepsilon^2 N}{8}\right).$$

理论与实践的差距

理论要求： $N \sim 10^4 d_{VC}$ ；实际经验： $N \sim 10 d_{VC}$ 即够。为何如此松弛？

四大保守来源

- 1) 使用 Hoeffding 不等式处理未知 E_{out} ，需对任意分布、任意目标函数均成立；
- 2) 用增长函数 $m_{\mathcal{H}}(N)$ 代替条件集合 $\mathcal{H}(X_1, \dots, X_N)$ 的规模；
- 3) 进一步用 $N^{d_{VC}}$ 代替 $m_{\mathcal{H}}(N)$ ，对所有同 d_{VC} 的假设集通用；
- 4) 采用联合界（union bound）覆盖最坏情形，同时保护算法 $\mathcal{A}$ 的任意选择。

结论 虽然 VC 界在数值上非常宽松，但它对所有模型“同样宽松”，因此仍能有效指导机器学习改进方向——这正是 VC 界的重要哲学意义。



2.3.5 总结



笔记 [VC 维]

- VC 维的定义：最大的非突破点，即能够被完全打散（shatter）的最大点数。
- 线性分类器的 VC 维： $d_{VC}(\mathcal{H}) = d + 1$ 。
- VC 维的直观物理意义： d_{VC} 约等于模型中自由参数的个数。
- VC 维的解读：粗略地反映了模型复杂度与所需样本复杂度。



笔记 [总体结论] VC 维衡量的是假设集能打散的最大样本数，是模型复杂度的核心指标。它决定了在多大样本量下学习算法能有效泛化，即训练误差接近于测试误差。VC 界给出了泛化误差的概率上界，虽数值上偏保守，但为不同模型提供了统一的理论保障。整体上，VC 维帮助我们在模型复杂度与泛化能力之间取得平衡，是理解机器学习本质的重要工具。

2.4 噪声与误差

2.4.1 噪声与概率目标

定义 2.4.1 (机器学习中的噪声 (Noise in Machine Learning))

在监督学习中，噪声 (noise) 泛指任何使得观测数据无法被目标模型完美重现的现象。维基百科将其归纳为两大类：

- 1) 随机噪声 (**stochastic noise**)：由随机波动、测量误差或未建模的随机过程引起，表现为数据标签或特征值中的随机偏差。
- 2) 确定性噪声 (**deterministic noise**)：当真实现象的复杂度超出模型表达能力时，数据中包含的、无法被模型捕获的系统性结构误差。

无论来源如何，这两种噪声都会导致模型试图去拟合其本无法建模的部分，从而引发过拟合。通常需要正则化、数据清洗或鲁棒算法来减缓其负面影响。



定义 2.4.2 (概率弹珠模型 (Probabilistic Marbles))

在 VC 理论中，数据被比喻为一袋弹珠：

- 样本：单个弹珠 $x \sim P(x)$ 从总体中 i.i.d. 抽取。
- 标签：
 - 确定性弹珠：颜色固定为 $f(x)$ ；误差事件为 $f(x) \neq h(x)$ 。
 - 概率弹珠 (含噪声)：颜色随机， $y \sim P(y | x)$ ；误差事件为 $y \neq h(x)$ 。
- 共同点：无论 x 还是 (x, y) ，只要 i.i.d. 抽取，VC 界均可估计“橙色弹珠”（即泛化误差）的概率。



命题 2.4.1 (学习目标的形式化)

对任意输入 $x \in \mathcal{X}$ ，其目标分布 $P(y | x)$ 可分解为

$$P(y | x) = \begin{cases} P(f(x) | x) = 1 - \eta(x), \\ P(\bar{f}(x) | x) = \eta(x), \end{cases}$$

其中

- $f(x) \in \mathcal{Y}$ 为理想迷你目标，
- $\eta(x) \in [0, 1]$ 为翻转噪声水平。

则学习算法的目标可表述为：

$$\min_{h \in \mathcal{H}} \mathbb{E}_{x \sim P(x)} \left[\mathbb{P}_{y \sim P(y|x)} [h(x) \neq y] \right].$$

特别地，当 $\eta(x) \equiv 0$ 时，目标退化为

$$\min_{h \in \mathcal{H}} \mathbb{E}_{x \sim P(x)} [\mathbb{I}\{h(x) \neq f(x)\}].$$



2.4.2 误差度量

定义 2.4.3 (误差度量 (Error Measure))

最终假设 g 与目标函数 f 之间的误差度量 $E(g, f)$ 可按以下三种场景定义：

- 1) 样本外误差 (out-of-sample):

$$E_{\text{out}}(g) = \mathbb{E}_{x \sim P}[\mathbb{I}\{g(x) \neq f(x)\}].$$

- 2) 逐点误差 (pointwise): 对单个输入 x 计算

$$\text{err}(g, f, x) = \mathbb{I}\{g(x) \neq f(x)\}.$$

- 3) 分类误差 (classification): 通常直接记为

$$0/1 \text{ error} = \mathbb{I}\{\text{prediction} \neq \text{target}\},$$

也即逐点误差的特例。



定义 2.4.4 (逐点误差度量 (Pointwise Error Measure))

误差度量 $E(g, f)$ 常可写成逐点误差 $\text{err}(g(x), f(x))$ 的平均：

- 样本外误差

$$E_{\text{out}}(g) = \mathbb{E}_{x \sim P}[\text{err}(g(x), f(x))].$$

- 样本内误差

$$E_{\text{in}}(g) = \frac{1}{N} \sum_{n=1}^N \text{err}(g(x_n), f(x_n)).$$

两种常用的逐点误差

- 0/1 误差 (分类)

$$\text{err}(\hat{y}, y) = \mathbb{I}[\hat{y} \neq y] \quad \text{只关心“对”或“错”。}$$

- 平方误差 (回归)

$$\text{err}(\hat{y}, y) = (\hat{y} - y)^2 \quad \text{度量“偏离”程度。}$$

学习启示 不同 err 会给出不同的学习指引——分类器通常优化 0/1 误差或其凸代理，而回归器则优化平方误差或其变体。



例题 2.7 理想迷你目标：噪声与误差的相互作用

给定

$$P(y = 1 | x) = 0.2, \quad P(y = 2 | x) = 0.7, \quad P(y = 3 | x) = 0.1,$$

及两种逐点误差度量：

- 0/1 误差: $\text{err}(\hat{y}, y) = \mathbb{I}[\hat{y} \neq y]$;
- 平方误差: $\text{err}(\hat{y}, y) = (\hat{y} - y)^2$ 。

解答 计算各候选输出 $\hat{y}$ 的期望误差

$$\mathbb{E}_{y \sim P(y|x)}[\text{err}(\hat{y}, y)] :$$

$\hat{y}$	0/1 误差	平方误差
1	0.8	1.1
2	0.3*	0.3
3	0.9	1.5
1.9	1.0	0.29*

结论

- 0/1 误差下的理想迷你目标: $f(x) = \arg \max_{y \in \mathcal{Y}} P(y|x)$ 。
- 平方误差下的理想迷你目标: $f(x) = \sum_{y \in \mathcal{Y}} y \cdot P(y|x)$ 。

证明 设给定输入 x 的条件分布为 $P(y | x)$, $y \in \mathcal{Y}$ 。

(1) 0/1 误差要最小化期望 0/1 误差

$$\mathbb{E}_{y \sim P(y|x)}[\mathbb{I}[\hat{y} \neq y]] = 1 - P(\hat{y} | x).$$

显然, 当且仅当选择使 $P(y | x)$ 最大的标签作为预测值时上式最小, 故

$$f(x) = \arg \max_{y \in \mathcal{Y}} P(y | x).$$

(2) 平方误差要最小化期望平方误差

$$\mathbb{E}_{y \sim P(y|x)}[(\hat{y} - y)^2] = \sum_{y \in \mathcal{Y}} (y - \hat{y})^2 P(y | x).$$

对 $\hat{y}$ 求导并令导数为零:

$$\frac{\partial}{\partial \hat{y}} \sum_y (y - \hat{y})^2 P(y | x) = -2 \sum_y (y - \hat{y}) P(y | x) = 0.$$

解得

$$\hat{y} = \sum_{y \in \mathcal{Y}} y P(y | x),$$

即条件期望 $\mathbb{E}[y | x]$, 因此

$$f(x) = \sum_{y \in \mathcal{Y}} y P(y | x).$$

2.4.3 算法级误差度量

命题 2.4.2 (指纹验证中的误差度量选择)

设指纹系统的输出为 $g \in \{-1, +1\}$, 真实标签为 $y \in \{-1, +1\}$, 其中

$y = +1$: 真实用户, $y = -1$: 入侵者.

定义两种错误类型:

- 假接受 (**False Accept**): $g = +1, y = -1$;
- 假拒绝 (**False Reject**): $g = -1, y = +1$ 。

若采用 0/1 误差

$$\text{err}(g, y) = \mathbb{I}[g \neq y],$$

则假接受与假拒绝被同等惩罚；实际应用需引入代价敏感误差

$$\text{err}_{\text{FP}}(g, y) = \begin{cases} C_{\text{FA}}, & \text{假接受,} \\ C_{\text{FR}}, & \text{假拒绝,} \\ 0, & \text{正确决策.} \end{cases}$$

因此，指纹验证系统的误差度量必须根据业务需求选择 C_{FA} 与 C_{FR} ，而 0/1 误差通常不足以反映真实风险。

命题 2.4.3 (指纹验证：超市 vs. CIA)

下表给出两场景下假接受 (FA) 与假拒绝 (FR) 的代价矩阵，其中数值代表单位损失。

g	超市折扣系统		CIA 门禁系统	
	$y = +1$ (顾客)	$y = -1$ (入侵者)	$y = +1$ (员工)	$y = -1$ (入侵者)
+1	0	1 (小额折扣)	0	1 000 (严重泄密)
-1	10 (顾客流失)	0	1 (员工不悦)	0

结论 误差度量必须场景化：

- 超市： $C_{\text{FR}} \gg C_{\text{FA}}$ ，应优先降低假拒绝；
- CIA： $C_{\text{FA}} \gg C_{\text{FR}}$ ，应优先降低假接受。

2.4.4 加权分类

命题 2.4.4 (加权分类：CIA 代价矩阵)

给定二元分类问题，设类别标签 $y \in \{-1, +1\}$ ，模型输出 $h(x) \in \{-1, +1\}$ 。对 CIA 门禁场景，定义逐点代价（权重）如下：

$$\text{Cost}(h(x), y) = \begin{cases} 1, & \text{若 } y = +1, h(x) \neq +1 \text{ (假拒绝),} \\ 1000, & \text{若 } y = -1, h(x) \neq -1 \text{ (假接受),} \\ 0, & \text{其余情况.} \end{cases}$$

则加权误差度量为

$$E_{\text{out}}(h) = \mathbb{E}_{(x,y) \sim P} [\text{Cost}(h(x), y)],$$

$$E_{\text{in}}(h) = \frac{1}{N} \sum_{n=1}^N \text{Cost}(h(x_n), y_n).$$

此即为加权分类：对不同 (x, y) 赋予不同权重，以反映业务风险。

命题 2.4.5 (加权分类中最小化 E_{in})

给定加权误差

$$E_{\text{in}}^{\mathbf{w}}(h) = \sum_{n=1}^N w_n \mathbb{I}[y_n \neq h(x_n)], \quad \text{其中} \quad w_n = \begin{cases} 1, & y_n = +1, \\ 1000, & y_n = -1. \end{cases}$$

朴素想法

- 若数据线性可分, PLA 不受权重影响, 仍能收敛。
- Pocket 算法可把“替换规则”改为:
若 $E_{\text{in}}^{\mathbf{w}}(w_{t+1}) < E_{\text{in}}^{\mathbf{w}}(w)$, 则用 w_{t+1} 替换 w 。
- 经权重修改的 Pocket 算法在加权 $E_{\text{in}}^{\mathbf{w}}$ 上依旧保持类似收敛保证。

等价构造把每个负样本复制 1000 次, 得到新数据集

$$\mathcal{D}' : \underbrace{(x_1, +1)}_{1 \text{ 次}}, \underbrace{(x_2, -1), \dots, (x_2, -1)}_{1000 \text{ 次}}, \dots, \underbrace{(x_N, +1)}_{1 \text{ 次}}.$$

则

$$E_{\text{in}}^{\mathbf{w}}(h) (\text{原问题}) = E_{\text{in}}(h) (\text{复制后问题}),$$

两者最小化等价。

**算法 2.4.3:** Weighted Pocket Algorithm (加权口袋算法)**输入:** 数据集 $\mathcal{D} = \{(x_n, y_n, w_n)\}_{n=1}^N$, 其中 $w_n = 1$ 若 $y_n = +1$, $w_n = 1000$ 若 $y_n = -1$ **输出:** 权重向量 w_{best} 初始化 $w_0 \leftarrow \mathbf{0}$, $w_{\text{best}} \leftarrow w_0$;**repeat**

// 加权 PLA

 以概率正比于 w_n 随机选取样本 (x_n, y_n) ; 若 $y_n (w_t^\top x_n) \leq 0$, 则 $w_{t+1} \leftarrow w_t + y_n x_n$; 否则 $w_{t+1} \leftarrow w_t$;

// 加权口袋替换规则

if $E_{\text{in}}^{\mathbf{w}}(w_{t+1}) < E_{\text{in}}^{\mathbf{w}}(w_{\text{best}})$ **then** $w_{\text{best}} \leftarrow w_{t+1}$;**until** 达到预设迭代次数;**return** w_{best} ;**注**[系统化路径 (Reduction)] 利用“虚拟复制”思想, 可将上述加权策略推广到多数其他学习算法!**2.4.5 总结****笔记** [噪声与误差]

- 噪声与概率目标: 可用条件概率 $P(y|x)$ 取代确定性目标函数 $f(x)$ 。
- 误差度量: 决定“理想”目标函数的选取。
- 算法级误差度量: 由用户定义, 需兼顾“合理性”与“友好性”。
- 加权分类: 通过虚拟“样本复制”即可轻松实现。

间章：机器为什么能够学习？

笔记 [机器为什么能够学习？]

“**Why Can Machines Learn?**”（机器为什么能够学习）是我们第二章共同关注的基础性问题。通过对学习本质、容量控制与学习任务的深入探讨，我们可以从以下四个方面给出清晰的解释：

1. 泛化学习的理论依据

学习的本质是通过有限样本学习出能泛化到未见样本的预测函数。之所以可能实现，源于以下几个基本事实：

- 假设空间中存在一个近似目标函数的“好”假设（即 $f^* \in \mathcal{H}$ ）；
- Hoeffding 不等式为我们提供了从经验误差到泛化误差之间的概率上限；
- 当存在好假设，且我们有足够数据来估计其泛化性能时，学习便具备理论可行性。

2. 假设空间的容量可控

函数集合的容量决定了其表达能力与过拟合风险之间的平衡。学习之所以可能，是因为我们可以：

- 用有限有效划分数、Break point 或 VC 维等方式刻画容量；
- 证明当容量有限时，泛化误差可以被控制；
- 从而在保证表达能力的同时，实现良好的泛化性能。

3. 学习任务与监督结构的适配

学习的实现不仅取决于理论条件，也受制于任务结构与数据组织方式：

- 任务类型（分类、回归、结构化输出）决定学习目标；
- 数据类型（监督、无监督、强化等）决定信号形式；
- 当学习任务可形式化建模，且数据提供足够结构信息时，学习才能有效展开。

4. 总结：为何机器能够学习？

综合来看，机器学习之所以成为可能，依赖于以下几方面的协同成立：

- 存在一个目标函数可由假设空间 $\mathcal{H}$ 表达；
- 假设空间的容量可以通过理论手段加以控制；
- 样本数据包含足够结构信号支持泛化；
- 学习任务与监督机制能够准确描述问题。

结语：机器能够学习，源于存在可被建模的目标函数、受控的假设容量、可获取的有效样本，以及清晰定义的任务结构。

第3章 机器如何学习？

3.1 线性回归

3.1.1 线性回归问题

定义 3.1.1 (线性回归假设 (Linear Regression Hypothesis))

以顾客特征为例：

$$\mathbf{x} = (x_0, x_1, x_2, x_3, x_4) = (1, 23, 1,000,000, 0.5, 200,000),$$

其中

- $x_0 = 1$ ：偏置项；
- x_1 ：年龄（岁）；
- x_2 ：年薪（新台币）；
- x_3 ：在职年数；
- x_4 ：当前债务。


用加权线性组合近似理想信用额度

$$y \approx \sum_{i=0}^d w_i x_i = \mathbf{w}^\top \mathbf{x}.$$


线性回归假设

$$h(\mathbf{x}) = \mathbf{w}^\top \mathbf{x},$$

与感知机形式相同，但去掉了符号函数。



(a) 一维特征线性回归拟合示意图



(b) 二维特征线性回归拟合示意图

图 3.1.1: 线性回归拟合示意图

命题 3.1.1 (常用误差度量：平方误差)

在回归问题中，最流行（且历史最悠久）的误差度量为平方误差

$$\text{err}(\hat{y}, y) = (\hat{y} - y)^2.$$

对应的样本内与样本外误差分别为

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N (\mathbf{w}^\top \mathbf{x}_n - y_n)^2,$$

$$E_{\text{out}}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x}, y) \sim P} [(\mathbf{w}^\top \mathbf{x} - y)^2].$$

**3.1.2 线性回归算法****命题 3.1.2 (平方误差的矩阵形式与最优权)**

将设计矩阵与目标向量记为

$$\mathbf{X} = \begin{bmatrix} -\mathbf{x}_1^\top & - \\ \vdots & \\ -\mathbf{x}_N^\top & - \end{bmatrix}_{N \times (d+1)}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}_{N \times 1}, \quad \mathbf{w} \in \mathbb{R}^{d+1},$$

则样本内误差可写成简洁矩阵形式

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2.$$

性质

- $E_{\text{in}}(\mathbf{w})$ 连续、可微且凸。
- 最优权 $\mathbf{w}_{\text{LIN}}$ 的必要条件为梯度为零：

$$\nabla_{\mathbf{w}} E_{\text{in}}(\mathbf{w}) = \frac{2}{N} \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) = \mathbf{0}.$$

**命题 3.1.3 (线性回归的梯度)**

给定设计矩阵 $X \in \mathbb{R}^{N \times (d+1)}$ 与目标向量 $y \in \mathbb{R}^N$ ，样本内平方误差

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 = \frac{1}{N} (\mathbf{w}^\top X^\top X \mathbf{w} - 2\mathbf{w}^\top X^\top \mathbf{y} + \mathbf{y}^\top \mathbf{y}).$$

标量情形（单权 w ）

$$E_{\text{in}}(w) = \frac{1}{N} (aw^2 - 2bw + c) \implies \nabla E_{\text{in}}(w) = \frac{2}{N} (aw - b).$$

向量情形（多权 $\mathbf{w}$ ）

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{N} (\mathbf{w}^\top A \mathbf{w} - 2\mathbf{w}^\top \mathbf{b} + c) \quad \text{其中 } A = X^\top X, \mathbf{b} = X^\top \mathbf{y},$$

$$\nabla E_{\text{in}}(\mathbf{w}) = \frac{2}{N} (X^\top X \mathbf{w} - X^\top \mathbf{y}).$$

**定理 3.1.1 (最优线性回归权重)**

任务：寻找 $\mathbf{w}_{\text{LIN}}$ ，使得梯度为零

$$\nabla E_{\text{in}}(\mathbf{w}) = X^\top X \mathbf{w} - X^\top \mathbf{y} = \mathbf{0}.$$

- 若 $X^T X$ 可逆 ($\det(X^T X) \neq 0$)，则存在唯一解

$$\mathbf{w}_{\text{LIN}} = (X^T X)^{-1} X^T \mathbf{y}.$$

- 若 $X^T X$ 奇异，则最优解不唯一；可选取

$$\mathbf{w}_{\text{LIN}} = X^\dagger \mathbf{y},$$

其中 $X^\dagger$ 为伪逆 (pseudo-inverse)，通过不同定义方式给出，通常取

$$X^\dagger = (X^T X)^\dagger X^T.$$

这种情况常见于 $N \geq d+1$ 且特征近似线性相关。

实践建议 为实现数值稳定，推荐使用成熟库中的线性求解器（如 SVD 或 QR 分解）直接求 $\mathbf{w}_{\text{LIN}}$ ，而避免显式计算 $(X^T X)^{-1}$ ，尤其在 $X^T X$ 接近奇异时。



算法 3.1.4: 通过伪逆求解线性回归

输入: 数据集 $\mathcal{D} = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$ ，其中 $\mathbf{x}_n \in \mathbb{R}^{d+1}$, $y_n \in \mathbb{R}$

输出: 最优权重向量 $\mathbf{w}_{\text{LIN}} \in \mathbb{R}^{d+1}$

构造设计矩阵 $\mathbf{X} \leftarrow \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_N^T \end{bmatrix}_{N \times (d+1)}$ 和目标向量 $\mathbf{y} \leftarrow \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}_{N \times 1}$;

计算伪逆 $\mathbf{X}^\dagger \leftarrow (\mathbf{X}^T \mathbf{X})^\dagger \mathbf{X}^T$;

$\mathbf{w}_{\text{LIN}} \leftarrow \mathbf{X}^\dagger \mathbf{y}$;

return $\mathbf{w}_{\text{LIN}}$.

例题 3.1 选择题: 线性回归预测向量的矩阵公式

得到 $\mathbf{w}_{\text{LIN}}$ 后，我们可以计算预测值 $\hat{y}_n = \mathbf{w}_{\text{LIN}}^T \mathbf{x}_n$ 。如果将所有 $\hat{y}_n$ 收集到一个类似于我们构造 $\mathbf{y}$ 的向量 $\hat{\mathbf{y}}$ 中，那么 $\hat{\mathbf{y}}$ 的矩阵公式是什么？

- 1) $\mathbf{y}$
- 2) $\mathbf{X} \mathbf{X}^T \mathbf{y}$
- 3) $\mathbf{X} \mathbf{X}^\dagger \mathbf{y}$
- 4) $\mathbf{X} \mathbf{X}^\dagger \mathbf{X} \mathbf{X}^T \mathbf{y}$

解答 正确选项为 [3]。由于 $\hat{\mathbf{y}} = \mathbf{X} \mathbf{w}_{\text{LIN}}$ ，利用 $\mathbf{w}_{\text{LIN}} = \mathbf{X}^\dagger \mathbf{y}$ ，则 $\hat{\mathbf{y}} = \mathbf{X} \mathbf{X}^\dagger \mathbf{y}$ 。 ■

3.1.3 泛化问题

命题 3.1.4 (解析解的优势: 比 VC 界更简单的保证)

给定噪声水平 σ^2 ，记 $\hat{\mathbf{y}} = \mathbf{X} \mathbf{w}_{\text{LIN}}$ ，则

$$E_{\text{in}}(\mathbf{w}_{\text{LIN}}) = \frac{1}{N} \|\mathbf{y} - \hat{\mathbf{y}}\|^2 = \frac{1}{N} \|(I - H)\mathbf{y}\|^2, \quad \text{其中 } H = \mathbf{X} \mathbf{X}^\dagger.$$

几何解释 ($\mathbf{H}$ 矩阵)

- H 把任意 $\mathbf{y} \in \mathbb{R}^N$ 投影到 $\text{span}(\mathbf{X})$ ，故 $\hat{\mathbf{y}} = H\mathbf{y}$ 。
- $I - H$ 把 $\mathbf{y}$ 映射到其残差 $\mathbf{y} - \hat{\mathbf{y}} \perp \text{span}(\mathbf{X})$ 。
- 自由度: $\text{Tr}(I - H) = N - (d+1)$ 。(由于 $\text{Tr}(H) = d+1$ ，利用迹的可加性即得)






图 3.1.2: 线性回归中观测向量在列空间的投影与残差示意图

命题 3.1.5 (线性回归学习曲线)

设输入数据矩阵 $\mathbf{X} \in \mathbb{R}^{N \times (d+1)}$, 其列空间为 $\mathcal{S} = \text{span}(\mathbf{X}) \subseteq \mathbb{R}^N$, 观测目标为

$$\mathbf{y} = \mathbf{f} + \boldsymbol{\varepsilon}, \quad \text{其中 } \mathbf{f} \in \mathcal{S}, \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_N).$$

记投影矩阵为 $\mathbf{H} = \mathbf{X}\mathbf{X}^\top$, 则模型预测 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 是 $\mathbf{y}$ 在 $\mathcal{S}$ 上的正交投影, 残差为

$$\mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}.$$

于是有:

- 样本内误差的期望为

$$\mathbb{E}_{\mathcal{D}}[E_{\text{in}}(\mathbf{w}_{\text{LIN}})] = \frac{1}{N} \mathbb{E}[\|(\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}\|^2] = \sigma^2 \left(1 - \frac{d+1}{N}\right);$$

- 样本外误差的期望为 (推导更复杂, 但形式对称)

$$\mathbb{E}_{\mathcal{D}}[E_{\text{out}}(\mathbf{w}_{\text{LIN}})] = \sigma^2 \left(1 + \frac{d+1}{N}\right).$$

证明 由于 $\mathbf{f} \in \text{span}(\mathbf{X})$, 我们有 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y} = \mathbf{H}(\mathbf{f} + \boldsymbol{\varepsilon}) = \mathbf{f} + \mathbf{H}\boldsymbol{\varepsilon}$. 因此残差为

$$\mathbf{y} - \hat{\mathbf{y}} = (\mathbf{f} + \boldsymbol{\varepsilon}) - (\mathbf{f} + \mathbf{H}\boldsymbol{\varepsilon}) = (\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}.$$

因此, 样本内误差为

$$E_{\text{in}} = \frac{1}{N} \|\mathbf{y} - \hat{\mathbf{y}}\|^2 = \frac{1}{N} \|(\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}\|^2.$$

取期望得:

$$\mathbb{E}_{\mathcal{D}}[E_{\text{in}}] = \frac{1}{N} \mathbb{E}[\boldsymbol{\varepsilon}^\top (\mathbf{I} - \mathbf{H})^2 \boldsymbol{\varepsilon}].$$

由于 $\mathbf{H}$ 是正交投影矩阵, 满足 $\mathbf{H} = \mathbf{H}^\top = \mathbf{H}^2$, 因此 $(\mathbf{I} - \mathbf{H})^2 = \mathbf{I} - \mathbf{H}$. 于是

$$\mathbb{E}_{\mathcal{D}}[E_{\text{in}}] = \frac{1}{N} \mathbb{E}[\boldsymbol{\varepsilon}^\top (\mathbf{I} - \mathbf{H}) \boldsymbol{\varepsilon}] = \frac{1}{N} \text{Tr}((\mathbf{I} - \mathbf{H}) \mathbb{E}[\boldsymbol{\varepsilon} \boldsymbol{\varepsilon}^\top]).$$

由于 $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, 协方差为 $\sigma^2 \mathbf{I}$, 因此

$$\mathbb{E}_{\mathcal{D}}[E_{\text{in}}] = \frac{1}{N} \text{Tr}((\mathbf{I} - \mathbf{H}) \sigma^2 \mathbf{I}) = \frac{\sigma^2}{N} \text{Tr}(\mathbf{I} - \mathbf{H}) = \frac{\sigma^2}{N} (N - \text{Tr}(\mathbf{H})).$$

注意 $\text{Tr}(\mathbf{H}) = \text{rank}(\mathbf{H}) = d+1$, 因此

$$\mathbb{E}_{\mathcal{D}}[E_{\text{in}}] = \sigma^2 \left(1 - \frac{d+1}{N}\right).$$

对于样本外误差, 设新样本点为 $(\mathbf{x}_0, y_0)$, 其中

$$y_0 = \mathbf{x}_0^\top \mathbf{w}_f + \varepsilon_0, \quad \varepsilon_0 \sim \mathcal{N}(0, \sigma^2), \quad \text{且 } \mathbf{f} = \mathbf{X} \mathbf{w}_f.$$

最小二乘解为

$$\mathbf{w}_{\text{LIN}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{f} + \boldsymbol{\varepsilon}),$$

预测为

$$\hat{y}_0 = \mathbf{x}_0^\top \mathbf{w}_{\text{LIN}} = \mathbf{x}_0^\top \mathbf{w}_f + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}.$$

因此误差为

$$y_0 - \hat{y}_0 = \varepsilon_0 - \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}.$$

于是有

$$\mathbb{E}[(y_0 - \hat{y}_0)^2] = \mathbb{E}[\varepsilon_0^2] + \mathbb{E} \left[\left(\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon} \right)^2 \right].$$

第一项为 σ^2 。记 $A = \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ ，则第二项为

$$\mathbb{E}[(A\boldsymbol{\varepsilon})^2] = \mathbb{E}[\boldsymbol{\varepsilon}^\top A^\top A \boldsymbol{\varepsilon}] = \sigma^2 \text{Tr}(A^\top A).$$

在均匀采样假设下，有 $\mathbb{E}[\text{Tr}(A^\top A)] = \frac{d+1}{N}$ ，因此

$$\mathbb{E}_{\mathcal{D}}[E_{\text{out}}] = \sigma^2 + \sigma^2 \cdot \frac{d+1}{N} = \sigma^2 \left(1 + \frac{d+1}{N} \right).$$




图 3.1.3: 线性回归中观测向量的信号与噪声分解示意图

定理 3.1.2 (线性回归的学习曲线)

设噪声水平为 σ^2 ，特征维度为 d ，训练样本数为 N ，则线性回归的样本内与样本外误差的期望为：

$$\overline{E}_{\text{out}}(\mathbf{w}_{\text{LIN}}) = \sigma^2 \left(1 + \frac{d+1}{N} \right),$$

$$\overline{E}_{\text{in}}(\mathbf{w}_{\text{LIN}}) = \sigma^2 \left(1 - \frac{d+1}{N} \right).$$

推论：

- 当 $N \rightarrow \infty$ 时， $\overline{E}_{\text{in}}, \overline{E}_{\text{out}} \rightarrow \sigma^2$ ，误差收敛于噪声水平；
- 期望泛化误差为：

$$\overline{E}_{\text{out}} - \overline{E}_{\text{in}} = \frac{2(d+1)}{N} \cdot \sigma^2;$$

- 泛化误差与 VC 理论中的最坏情形上界同阶 $(d+1)$ ，说明“学习确实发生了”。




图 3.1.4: 数据点数量与期望误差关系示意图

3.1.4 线性回归用于二分类

命题 3.1.6 (线性分类 vs. 线性回归)

- 线性分类

输出空间 $\{-1, +1\}$, 假设 $h(x) = \text{sign}(w^\top x)$, 代价函数

$$\text{err}(\hat{y}, y) = \mathbb{I}[\hat{y} \neq y],$$

求解一般情形为 NP-hard。

- 线性回归

输出空间 $\mathbb{R}$, 假设 $h(x) = w^\top x$, 代价函数

$$\text{err}(\hat{y}, y) = (\hat{y} - y)^2,$$

存在解析解

$$w_{\text{LIN}} = (X^\top X)^{-1} X^\top y.$$

- 用线性回归做二分类的启发式

对二分类数据 $\mathcal{D}$ 直接运行线性回归 (高效), 然后取

$$g(x) = \text{sign}(w_{\text{LIN}}^\top x).$$

该启发式在实践中表现良好, 其理论解释见后文。



命题 3.1.7 (两种误差的关系与线性回归二分类近似)

设二分类标签 $y \in \{-1, +1\}$, 令

- 0/1 误差: $\text{err}_{0/1}(w) = \mathbb{I}[\text{sign}(w^\top x) \neq y]$;
- 平方误差: $\text{err}_{\text{sqr}}(w) = (w^\top x - y)^2$ 。

逐点误差上界对任意 (x, y) 有


$$\text{err}_{0/1}(w) \leq \text{err}_{\text{sqr}}(w).$$

VC 泛化界


$$E_{\text{out},0/1}(w) \leq E_{\text{in},0/1}(w) + \Omega\left(\frac{d+1}{N}\right) \leq E_{\text{in},\text{sqr}}(w) + \Omega\left(\frac{d+1}{N}\right),$$

其中右侧为宽松上界，但换来计算效率。

结论 w_{LIN} 既可作为高效的基线分类器，也可作为 PLA / Pocket 算法的初始化向量。



(a) 期望输出为 1 时平方误差与 0-1 误差对比图



(b) 期望输出为 -1 时平方误差与 0-1 误差对比图

图 3.1.5: 期望输出的平方误差与 0-1 误差对比图

3.1.5 总结



笔记 [线性回归]

- 线性回归问题：用超平面逼近实值输出。
- 线性回归算法：利用伪逆得到解析解。
- 泛化问题：平均而言 $E_{\text{out}} - E_{\text{in}} \approx \frac{2(d+1)}{N}$ 。
- 线性回归用于二分类：0/1 误差上界由平方误差控制。

3.2 逻辑回归

3.2.1 逻辑回归问题

定义 3.2.1 (软二分类 (Soft Binary Classification))

目标函数为条件概率

$$f(x) = P(+1 | x) \in [0, 1].$$

- 理想（无噪）数据：观测标签 $y^* = f(x)$ ，即直接给出真实概率。
- 实际（含噪）数据：观测标签 $y \sim P(y | x)$ ，其中

$$P(y = +1 | x) = f(x), \quad P(y = -1 | x) = 1 - f(x).$$

要点 输入数据 $\{(x_n, y_n)\}_{n=1}^N$ 与硬二分类完全相同，但目标函数不再是 $\{-1, +1\}$ 而是连续概率 $[0, 1]$ 。



定义 3.2.2 (逻辑假设 (Logistic Hypothesis))

给定病人特征向量

$$\mathbf{x} = (x_0, x_1, x_2, \dots, x_d)^\top = (\text{年龄, 性别, 血压, 胆固醇, } \dots)^\top,$$

首先计算加权“风险分数”

$$s = \mathbf{w}^\top \mathbf{x} = \sum_{i=0}^d w_i x_i.$$

再用逻辑函数 (logistic function) 将分数映射为概率估计

$$\sigma(s) = \frac{1}{1 + e^{-s}} \in (0, 1).$$

于是逻辑假设定义为

$$h(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x})},$$

用于逼近目标条件概率

$$f(\mathbf{x}) = P(y = +1 | \mathbf{x}).$$




图 3.2.1: sigmoid 函数图像

例题 3.2 Logistic 回归的二分类决策

设 Logistic 假设

$$h(\mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^\top \mathbf{x}}} \in (0, 1),$$

以阈值 0.5 将其转化为二分类预测：

$$\text{预测类别} = \text{sign}(h(\mathbf{x}) - 0.5).$$

选项 上述决策等价于下列哪个公式？

- 1) $\text{sign}(\mathbf{w}^\top \mathbf{x} - 0.5)$
- 2) $\text{sign}(\mathbf{w}^\top \mathbf{x})$
- 3) $\text{sign}(\mathbf{w}^\top \mathbf{x} + 0.5)$
- 4) 以上皆非

解答 正确选项为 [2]。由于当 $\mathbf{w}^\top \mathbf{x} = 0$ 时， $h(\mathbf{x}) = 0.5$ ，故在 0.5 处对 $h(\mathbf{x})$ 阈值化等价于在 0 处对 $\mathbf{w}^\top \mathbf{x}$ 阈值化。 ■

3.2.2 逻辑回归的误差**定义 3.2.3 (似然 (Likelihood))**

给定目标函数

$$f(x) = P(y = +1 | x), \quad P(y = -1 | x) = 1 - f(x),$$

及数据集

$$\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}, \quad y_n \in \{+1, -1\}.$$

目标函数生成数据的概率

$$\prod_{n=1}^N P(x_n) f(x_n)^{\frac{1+y_n}{2}} [1 - f(x_n)]^{\frac{1-y_n}{2}}.$$

模型假设 h 生成数据的似然

$$\text{likelihood}(h) = \prod_{n=1}^N P(x_n) h(x_n)^{\frac{1+y_n}{2}} [1 - h(x_n)]^{\frac{1-y_n}{2}}.$$

当 $h \approx f$ 时， $\text{likelihood}(h)$ 接近使用真实 f 的概率，而真实概率通常较大。 ♣

命题 3.2.1 (Logistic 假设的似然)

设 Logistic 假设

$$h(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^\top \mathbf{x}}}, \quad \text{满足} \quad 1 - h(\mathbf{x}) = h(-\mathbf{x}).$$

给定数据集 $\{(x_n, y_n)\}_{n=1}^N$ ，其中 $y_n \in \{+1, -1\}$ ，则似然函数

$$\begin{aligned} \text{likelihood}(h) &= P(\mathbf{x}_1)h(\mathbf{x}_1) \times P(\mathbf{x}_2)(1 - h(\mathbf{x}_2)) \times \dots \times P(\mathbf{x}_N)(1 - h(\mathbf{x}_N)) \\ &= P(\mathbf{x}_1)h(+\mathbf{x}_1) \times P(\mathbf{x}_2)h(-\mathbf{x}_2) \times \dots \times P(\mathbf{x}_N)h(-\mathbf{x}_N) \end{aligned}$$

可以看出似然函数正比于

$$\text{likelihood}(h) \propto \prod_{n=1}^N h(y_n x_n) = \prod_{n=1}^N \sigma(y_n \mathbf{w}^\top \mathbf{x}_n).$$

最优参数通过最大似然估计获得

$$\mathbf{w} = \arg \max_{\mathbf{w}} \prod_{n=1}^N \sigma(y_n \mathbf{w}^\top \mathbf{x}_n).$$



定义 3.2.4 (交叉熵误差 (Cross-Entropy Error))

给定数据集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, 其中 $y_n \in \{-1, +1\}$, 逻辑回归假设

$$h(x; w) = \sigma(w^\top x) = \frac{1}{1 + \exp(-w^\top x)}.$$

似然函数

$$\text{likelihood}(w) \propto \prod_{n=1}^N h(x_n; w)^{\frac{1+y_n}{2}} [1 - h(x_n; w)]^{\frac{1-y_n}{2}} = \prod_{n=1}^N \sigma(y_n w^\top x_n).$$

对数似然与交叉熵误差 最大化对数似然等价于最小化交叉熵误差

$$E_{\text{in}}(w) = \frac{1}{N} \sum_{n=1}^N \underbrace{\ln(1 + \exp(-y_n w^\top x_n))}_{\text{err}(w, x_n, y_n)}.$$



3.2.3 逻辑回归误差的梯度

命题 3.2.2 (最小化交叉熵误差 $E_{\text{in}}(w)$)

交叉熵误差

$$E_{\text{in}}(w) = \frac{1}{N} \sum_{n=1}^N \ln(1 + \exp(-y_n w^\top x_n))$$

连续、可微、二阶可微且凸。

梯度计算

$$\nabla E_{\text{in}}(w) = \frac{1}{N} \sum_{n=1}^N \underbrace{\sigma(-y_n w^\top x_n)}_{\theta_n} (-y_n x_n) = \frac{1}{N} \sum_{n=1}^N \theta_n (-y_n x_n),$$

其中 $\theta_n \in (0, 1)$ 为样本权重。

最优条件

$$\nabla E_{\text{in}}(w) = \mathbf{0} \implies \sum_{n=1}^N \theta_n y_n x_n = \mathbf{0}.$$

- 若数据线性可分, 则 $\forall n, y_n w^\top x_n > 0$, 所有 $\theta_n \rightarrow 0$, 梯度趋于零;
- 一般情形下上式为非线性方程, 无闭式解, 需数值迭代 (如梯度下降、Newton 法)。



算法 3.2.5: 感知机学习算法 (PLA): 迭代优化视角**输入:** 数据集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, 其中 $y_n \in \{-1, +1\}$ **输出:** 权重向量 w (作为最终假设 g)初始化 $w_0 \leftarrow \mathbf{0}$;**for** $t = 0, 1, 2, \dots$ **do** 任选一个误分类样本 $(x_{n(t)}, y_{n(t)})$ 满足

$$\text{sign}(w_t^\top x_{n(t)}) \neq y_{n(t)};$$

更新权重

$$w_{t+1} \leftarrow w_t + y_{n(t)} x_{n(t)};$$

if 所有样本被正确分类 **then break**;**return** $w \leftarrow w_t$;**3.2.4 梯度下降****算法 3.2.6:** 梯度下降法最小化 $E_{\text{in}}(w)$ **输入:** 初始权重 $w_0 \in \mathbb{R}^{d+1}$, 学习率 $\eta > 0$, 迭代次数 T **输出:** 最终权重 $g = w_T$ **for** $t = 0$ **to** $T - 1$ **do** 计算梯度: $\mathbf{g}_t = \nabla E_{\text{in}}(w_t)$; 更新权重: $w_{t+1} \leftarrow w_t - \eta \frac{\mathbf{g}_t}{\|\mathbf{g}_t\|}$;**return** w_T ;**命题 3.2.3 (梯度下降的原理)**

利用一阶泰勒近似

$$E_{\text{in}}(w_t + \eta v) \approx E_{\text{in}}(w_t) + \eta v^\top \nabla E_{\text{in}}(w_t), \quad \|v\| = 1,$$

当步长 η 足够小时, 最优方向为负梯度

$$v^* = -\frac{\nabla E_{\text{in}}(w_t)}{\|\nabla E_{\text{in}}(w_t)\|}.$$

因此迭代公式

$$w_{t+1} = w_t + \eta v^* = w_t - \eta \frac{\nabla E_{\text{in}}(w_t)}{\|\nabla E_{\text{in}}(w_t)\|}$$

保证了 E_{in} 沿“下坡”方向单调下降, 是简单且流行的优化工具。**命题 3.2.4 (固定学习率的梯度下降启发式)**设当前梯度为 $\mathbf{g}_t = \nabla E_{\text{in}}(w_t)$ 。若将学习率 η 设为与梯度范数单调相关的量 (例如 $\eta \propto \|\mathbf{g}_t\|$), 则步长

$$w_{t+1} = w_t - \eta \frac{\mathbf{g}_t}{\|\mathbf{g}_t\|}$$

退化为固定步长。实践中更常用的是固定学习率（fixed learning rate） $\eta > 0$ 的梯度下降：

$$w_{t+1} \leftarrow w_t - \eta \nabla E_{\text{in}}(w_t).$$




图 3.2.2: 学习率对优化过程影响示意图

算法 3.2.7: 逻辑回归 (梯度下降)

输入: 训练集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, 其中 $y_n \in \{-1, +1\}$; 学习率 $\eta > 0$; 最大迭代次数 T

输出: 最终权重向量 g

初始化 $w_0 \in \mathbb{R}^{d+1}$;

for $t = 0, 1, \dots, T - 1$ **do**

 计算梯度

$$\nabla E_{\text{in}}(w_t) = \frac{1}{N} \sum_{n=1}^N \sigma(-y_n w_t^\top x_n) (-y_n x_n);$$

 更新权重

$$w_{t+1} \leftarrow w_t - \eta \nabla E_{\text{in}}(w_t);$$

if $\|\nabla E_{\text{in}}(w_{t+1})\| < \varepsilon$ **then break;**

return $g \leftarrow w_{t+1}$;

注 每轮迭代时间复杂度与 Pocket 算法一轮相当。

3.2.5 总结

笔记 [逻辑回归]

- 逻辑回归问题: 以 $P(+1|x)$ 为目标, 用 $w^\top x$ 作为假设。
- 逻辑回归的误差: 交叉熵 (负对数似然)。
- 逻辑回归误差的梯度: 以权重 A 加权的样本向量之和。
- 梯度下降: 沿负梯度 $-\nabla E_{\text{in}}(w)$ 向“山下”滚动更新。

3.3 线性模型用于分类

3.3.1 二分类的线性模型

定义 3.3.1 (误差函数回顾)

给定线性评分函数 $s = w^\top x$ ，二分类标签 $y \in \{-1, +1\}$ ，三种线性模型的假设与误差函数如下：

模型	假设 $h(x)$	误差函数 $\text{err}(h, x, y)$	备注
线性分类	$\text{sign}(s)$	$\mathbb{I}[\text{sign}(s) \neq y]$	0/1 误差
线性回归	s	$(s - y)^2$	平方误差
逻辑回归	$\sigma(s) = \frac{1}{1 + e^{-s}}$	$-\ln \sigma(y s) = \ln(1 + e^{-y s})$	交叉熵误差

统一视角：所有误差均可写成关于“分类正确性得分” $z = ys$ 的函数

$$\text{err}_{0/1}(s, y) = \mathbb{I}[\text{sign}(s) \neq y] = \mathbb{I}[\text{sign}(ys) \neq 1] = \mathbb{I}[\text{sign}(z) \neq 1],$$

$$\text{err}_{\text{SQR}}(s, y) = (s - y)^2 = (ys - 1)^2 = (z - 1)^2,$$

$$\text{err}_{\text{CE}}(z) = \ln(1 + e^{-ys}) = \ln(1 + e^{-z}).$$




图 3.3.1: 线性分类、线性回归与逻辑回归对比示意图

定义 3.3.2 (误差函数可视化与上界性质)

令 $z = ys$ 为“分类正确性得分”，三种误差函数如下：

- **0/1**: $\text{err}_{0/1}(z) = \mathbb{I}[z \leq 0]$ ，仅在 $z \leq 0$ 时取 1。
- **SQR**: $\text{err}_{\text{SQR}}(z) = (z - 1)^2$ ，在 $z < 1$ 时较大；当 $z > 1$ 时过度惩罚。
- **CE**: $\text{err}_{\text{CE}}(z) = \ln(1 + e^{-z})$ ，较小的 err_{CE} 等价于较小的 $\text{err}_{0/1}$ ：
- **Scaled CE**: $\text{err}_{\text{SCE}}(z) = \log_2(1 + e^{-z})$ ，单调递减且为 0/1 误差的紧致上界：

$$\text{err}_{0/1}(z) \leq \text{err}_{\text{SCE}}(z), \quad \forall z \in \mathbb{R}.$$

因此，Scaled CE 可用于设计算法误差函数，保证“小的 Scaled CE $\Rightarrow$ 小的 0/1 误差”。






图 3.3.2: 二分类问题中不同误差度量对比图

命题 3.3.1 (上界的理论含义)

设 $s = w^\top x$ 。对任意 $y \in \{-1, +1\}$ 有逐点误差关系

$$\text{err}_{0/1}(s, y) \leq \text{err}_{\text{SCE}}(s, y) = \frac{1}{\ln 2} \cdot \text{err}_{\text{CE}}(s, y), \quad \text{err}_{\text{CE}}(s, y) = \ln(1 + e^{-ys}).$$

从而整体误差满足

$$E_{\text{in}}^{0/1}(w) \leq E_{\text{in}}^{\text{SCE}}(w) = \frac{1}{\ln 2} \cdot E_{\text{in}}^{\text{CE}}(w).$$

$$E_{\text{out}}^{0/1}(w) \leq E_{\text{out}}^{\text{SCE}}(w) = \frac{1}{\ln 2} \cdot E_{\text{out}}^{\text{CE}}(w),$$

泛化界结合

- 对 0/1 误差用 VC 界: $E_{\text{out}}^{0/1}(w) \leq E_{\text{in}}^{0/1}(w) + \Omega^{0/1} \leq \frac{1}{\ln 2} E_{\text{in}}^{\text{CE}}(w) + \Omega^{0/1}$;
- 对交叉熵误差用 VC-Reg 界: $E_{\text{out}}^{0/1}(w) \leq \frac{1}{\ln 2} E_{\text{out}}^{\text{CE}}(w) \leq \frac{1}{\ln 2} E_{\text{in}}^{\text{CE}}(w) + \frac{1}{\ln 2} \Omega^{0/1}$ 。

结论 当交叉熵误差 $E_{\text{in}}^{\text{CE}}(w)$ 足够小时, 0/1 误差 $E_{\text{out}}^{0/1}(w)$ 也必然小, 因此逻辑回归 / 线性回归可作为线性分类的高效近似方法。

命题 3.3.2 (回归用于分类: 比较与权衡)

给定二分类数据 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, $y_n \in \{-1, +1\}$ 。

- **线性回归 (Linear Regression)**

优点 解析解, 计算最快;

缺点 仅在数据线性可分时表现良好, 否则需借助 Pocket 等启发式;

用途 常作为 PLA / Pocket / Logistic 回归的初始权重 w_0 。

- **逻辑回归 (Logistic Regression)**

优点 凸优化, 有强理论保证 (交叉熵误差 $\Rightarrow$ 0/1 误差上界);

缺点 相比线性回归, 优化更耗时;

结论 实践中通常优于 Pocket, 是首选的线性分类器。

3.3.2 随机梯度下降

算法 3.3.8: 两种迭代优化方案

输入: 训练集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, 初值 w_0

输出: 权重向量 w

for $t = 0, 1, 2, \dots$ **do**

if *PLA* **then**

 // 每次只看一个样本

 随机选取误分类样本 (x_n, y_n) ;

 更新 $w_{t+1} \leftarrow w_t + y_n x_n$;

 单次迭代复杂度 $O(1)$;

else if *Logistic Regression* (批量) **then**

 // 每次遍历全部样本

 计算梯度 $\nabla E(w_t) = \frac{1}{N} \sum_{n=1}^N \sigma(-y_n w_t^\top x_n)(-y_n x_n)$;

 更新 $w_{t+1} \leftarrow w_t - \eta \nabla E(w_t)$;

 单次迭代复杂度 $O(N)$;

else if *Pocket* **then**

 与 PLA 类似, 但保留历史最佳权重, 复杂度 $O(N)$;

当满足停止准则时, 返回最终 w 作为 g ;

算法 3.3.9: 逻辑回归的随机梯度下降 (SGD)

输入: 数据集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, 学习率 $\eta > 0$

输出: 权重向量 w

初始化 w_0 ;

for $t = 0, 1, 2, \dots$ **do**

 从 $\{1, \dots, N\}$ 中均匀随机抽取一个下标 n ;

 计算单个样本的梯度

$$\nabla_{w \text{err}}(w_t, x_n, y_n) = \sigma(-y_n w_t^\top x_n)(-y_n x_n);$$

 更新权重

$$w_{t+1} \leftarrow w_t + \eta \underbrace{\sigma(-y_n w_t^\top x_n) y_n x_n}_{\text{随机梯度}};$$

if 满足停止准则 **then break**;

return 最终 w ;

注 随机梯度 $\nabla_{w \text{err}}(w, x_n, y_n)$ 是对真实梯度

$$\nabla_w E_{\text{in}}(w) = \frac{1}{N} \sum_{n=1}^N \nabla_{w \text{err}}(w, x_n, y_n)$$

的无偏估计且每迭代仅需 $O(1)$ 时间, 体现出了随机梯度的两个关键性质: 无偏性和高效性。

命题 3.3.3 (随机梯度下降 SGD)

设真实梯度

$$\nabla E_{\text{in}}(w) = \frac{1}{N} \sum_{n=1}^N \nabla \text{err}(w, x_n, y_n),$$

随机梯度

$$\nabla_{\text{SGD}}(w) = \nabla \text{err}(w, x_n, y_n) \quad (n \text{ 均匀随机}),$$

则

$$\nabla_{\text{SGD}}(w) = \nabla E_{\text{in}}(w) + \underbrace{\text{零均值噪声}}_{\text{零期望}}.$$

算法

$$w_{t+1} \leftarrow w_t - \eta_t \nabla_{\text{SGD}}(w_t).$$

优缺点

- 优点：计算简单、成本低廉，适合大数据或在线学习；
- 缺点：方向噪声大，收敛路径不稳定。

逻辑回归 **SGD** 更新

$$w_{t+1} \leftarrow w_t + \eta \underbrace{\sigma(-y_n w_t^\top x_n) y_n x_n}_{-\nabla \text{err}(w, x_n, y_n)}.$$



注 SGD 的更新规则是沿着负随机梯度方向更新参数 w 。

命题 3.3.4 (PLA 再探：与 SGD 逻辑回归的对应)

令 $s_n = w_t^\top x_n$ ，则两种算法的更新可写成统一形式：

- **SGD 逻辑回归**

$$w_{t+1} = w_t + \eta \sigma(-y_n s_n) (y_n x_n).$$

- **PLA**

$$w_{t+1} = w_t + \mathbb{I}[y_n \neq \text{sign}(s_n)] (y_n x_n).$$

关系

- SGD 逻辑回归可视为“软” PLA：权重 $\sigma(-y_n s_n) \in (0, 1)$ 随置信度连续变化；
- PLA 相当于 SGD 逻辑回归在 $|s_n|$ 很大时的极限特例，取 $\eta = 1$ 且仅当犯错才更新。

两条实用经验

- 停止条件：迭代次数 t 足够大即可；
- 学习率：若输入 x 已归一化到合理范围，取 $\eta \approx 0.1$ 。

**例题 3.3 选择题：大数据线性回归的 SGD 更新方向**

考虑在大数据场景下对线性回归应用随机梯度下降 (SGD)。当使用负随机梯度时，其更新方向是什么？

- 1) x_n
- 2) $y_n x_n$

$$3) 2(w_t^T x_n - y_n)x_n$$

$$4) 2(y_n - w_t^T x_n)x_n$$

解答 正确选项为 [4]。在线性回归中，平方误差函数为 $\text{err}(w, x_n, y_n) = (w^T x_n - y_n)^2$ 。对其关于 w 求梯度可得

$$\nabla_w \text{err}(w, x_n, y_n) = 2(w^T x_n - y_n)x_n.$$

SGD 的更新规则是沿着负随机梯度方向更新参数 w ，即 $w_{t+1} = w_t - \eta \cdot \nabla_w \text{err}(w_t, x_n, y_n)$ ，所以更新方向为负梯度： $-\nabla_w \text{err}(w_t, x_n, y_n) = 2(y_n - w_t^T x_n)x_n$ 。

该更新规则具有直观的物理解释：通过与残差 $(y_n - w_t^T x_n)$ 成比例地“修正”来改进 w_t 。 ■

3.3.3 逻辑回归的多分类

定义 3.3.3 (硬分类 (Hard Classification))

在多类或多标签预测任务中，若将每个样本唯一地（多类）或唯一地集合（多标签）分配到一个或多个确定的类别，而不输出任何概率或置信度，则称该过程为硬分类。在组合二元分类器（如一对多或一对一策略）的框架下，硬分类通过以下方式实现：

- 多类：各二元分类器输出 $\{-1, +1\}$ ，最终经投票或最大响应得到唯一类别标签。
- 多标签：各标签由独立的二元分类器给出 $\{0, 1\}$ 硬决策，组合后形成样本的标签集合。

硬分类的核心特征为：仅输出离散类别标签，不涉及概率估计或软决策。




图 3.3.3: 硬分类模型分类效果示例图

定义 3.3.4 (多类预测：组合软分类器 (Soft Classification))

在多类或多标签任务中，若将若干个二元概率分类器（如逻辑回归、软输出 SVM）的输出概率或置信度进行组合，以产生对每一类别（或标签）的后验概率估计，并据此做出最终预测，则称该过程为组合软分类器。

形式化地，给定 K 个类别，通过策略（一对多、一对一、纠错输出码等）训练 M 个二元分类器，每个分类器输出

$$h_m(x) \in [0, 1], \quad m = 1, \dots, M,$$

表示样本 x 属于某一子集的概率。组合函数

$$\hat{P}(y = k | x) = g(h_1(x), \dots, h_M(x)), \quad k = 1, \dots, K$$

将各分类器软输出映射为类别后验概率，最终预测取

$$\hat{y} = \arg \max_k \hat{P}(y = k | x).$$

由于整个过程保留并利用了概率输出，而非直接取硬标签，故称“软分类器组合”。




图 3.3.4: 软分类模型分类效果示例图

算法 3.3.10: One-Versus-All (OVA) 多类逻辑回归

输入: 训练集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, 类别数 K

输出: 预测函数 $g: \mathbb{R}^d \rightarrow \{1, \dots, K\}$

for $k = 1$ **to** K **do**

 构造二分类标签

$$y_n^{(k)} \leftarrow \begin{cases} +1, & y_n = k, \\ -1, & \text{otherwise;} \end{cases}$$

 在 $\{(x_n, y_n^{(k)})\}$ 上运行逻辑回归，得到权重 $w_{[k]}$;

定义最终预测

$$g(x) = \arg \max_{k \in \{1, \dots, K\}} w_{[k]}^\top x;$$

return g

优点: 高效、可复用任意逻辑回归类算法

缺点: K 大时子集极不平衡 (损失函数的权重倾斜: 负样本的损失贡献占比更高)

扩展: 多项逻辑回归可缓解不平衡

例题 3.4 选择题: OVA 分解的训练代价

考虑对大小为 N 的 K 类分类数据，基于逻辑回归进行 OVA 分解。下列哪一项最能描述其训练代价？

- 1) 学习 K 个逻辑回归假设，每个使用大小为 N/K 的数据
- 2) 学习 K 个逻辑回归假设，每个使用大小为 $N \ln K$ 的数据
- 3) 学习 K 个逻辑回归假设，每个使用大小为 N 的数据

4) 学习 K 个逻辑回归假设，每个使用大小为 NK 的数据

解答 正确选项为 [3]。OVA 分解将 K 类分类问题拆解为 K 个二分类子问题。对于第 k 个子问题，构造的数据集包含原始数据中所有属于类别 k 的样本（正样本）和所有不属于类别 k 的样本（负样本），即每个子问题的数据集大小为 N 。

因此，每个二分类子问题都需在完整的 N 个样本上训练逻辑回归模型，总需学习 K 个逻辑回归假设，每个对应的数据量为 N 。 ■

3.3.4 二元分解多分类

定义 3.3.5 (多类预测：组合成对分类器 (One-vs-One, OvO))

设类别集合 $\mathcal{Y} = \{1, 2, \dots, K\}$ 。成对分解 (One-vs-One) 通过以下两步将多类问题转化为多个二元问题：

1. 训练阶段对每一对类别 (i, j) , $1 \leq i < j \leq K$ ，仅保留类别 i 与 j 的样本，构造二元数据集

$$\mathcal{D}_{ij} = \{(x_n, y_n) \mid y_n \in \{i, j\}\}, \quad y_n^{(ij)} = \begin{cases} +1, & y_n = i, \\ -1, & y_n = j. \end{cases}$$

在此数据集上训练 $K(K-1)/2$ 个二元分类器

$$h_{ij} : \mathbb{R}^d \rightarrow \{-1, +1\}.$$

2. 预测阶段对测试样本 x ，将所有 $h_{ij}(x)$ 的预测结果进行投票：

$$g(x) = \arg \max_{k \in \mathcal{Y}} \sum_{i < j} \mathbb{I}[h_{ij}(x) = \text{sign}(k-i) \cdot \text{sign}(k-j)].$$

得票最多的类别即为最终输出。

性质

- 每个二元子集仅含两类别，通常样本更均衡；
- 需训练 $\binom{K}{2}$ 个分类器，预测时需 $\binom{K}{2}$ 次调用；
- 投票平局可用置信度或距离度量解决。




图 3.3.5: 组合成对分类器分类效果示例图

算法 3.3.11: 一对一成对分解 (OVO) 多类算法**输入:** 训练集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, 类别数 K **输出:** 预测函数 $g: \mathbb{R}^d \rightarrow \{1, \dots, K\}$ **for** 每对类别 $(k, \ell) \in \{1, \dots, K\} \times \{1, \dots, K\}, k < \ell$ **do**

构造二分类子集

$$\mathcal{D}_{k,\ell} = \{(x_n, \tilde{y}_n) \mid y_n = k \text{ 或 } y_n = \ell\}, \tilde{y}_n = +1 \text{ if } y_n = k, -1 \text{ if } y_n = \ell.$$

 在 $\mathcal{D}_{k,\ell}$ 上训练二元分类器 $w_{[k,\ell]}$;**预测阶段**对输入 x 执行所有 $w_{[k,\ell]}$ 并投票:

$$g(x) = \arg \max_k \sum_{i < j} \mathbb{I}[\text{sign}(w_{[i,j]}^\top x) = \text{vote for } k].$$

优点

- 每个子问题仅含两类, 通常更小、更均衡、更稳定;
- 可复用任意二元分类算法。

缺点

- 需存储及训练 $O(K^2)$ 个分类器;
- 预测时需 $O(K^2)$ 次调用, 空间与时间开销大。

OVO 是另一种简单实用的多类元算法, 值得放入工具箱。

例题 3.5 选择题: OVO 分解的总计算代价

考虑对包含 10 个类别的分类问题采用 OVO (One-Versus-One) 分解, 总样本数为 N 且各类别样本数均衡。若单个二分类器在大小为 M 的数据集上的 CPU 时间为 M^3 , 则 OVO 分解的总 CPU 时间为:

- 1) $\frac{9}{200} N^3$
- 2) $\frac{9}{25} N^3$
- 3) $\frac{4}{5} N^3$
- 4) N^3

解答 正确选项为 [2]。OVO 分解将 K 类问题拆解为 $\binom{K}{2} = \frac{K(K-1)}{2}$ 个二分类子问题。对于 10 类问题, 需训练 $\binom{10}{2} = 45$ 个分类器。

由于样本均衡, 每个类别含 $\frac{N}{10}$ 个样本, 每对子问题仅使用两个类别的样本, 故单个子问题的数据集大小为 $\frac{N}{10} + \frac{N}{10} = \frac{N}{5}$ 。

单个子问题的 CPU 时间为 $(\frac{N}{5})^3 = \frac{N^3}{125}$, 总 CPU 时间为 $45 \times \frac{N^3}{125} = \frac{9}{25} N^3$ 。 ■

注 使用相同算法的 OVA 分解将花费 $10N^3$ 的时间, 这比 OVO 差得多。

3.3.5 总结**笔记** [线性模型用于分类]

- 二分类的线性模型: 三种模型各有适用场景。
- 随机梯度下降: 沿负的随机梯度方向更新参数。
- 逻辑回归的多分类: 选取估计概率最大的类别 $\arg \max_k \hat{P}(k \mid x)$ 。
- 二元分解多分类: 通过锦标赛方式预测最终冠军类别。

3.4 非线性变换

3.4.1 二次假设

命题 3.4.1 (线性假设的局限与突破)

我们迄今讨论的线性假设

$$h(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x})$$

具有以下特征：

- 几何：决策边界为超平面（“直线”在高维推广）；
- 理论：对 d 维输入空间，VC 维恰为

$$d_{\text{VC}} = d + 1,$$

- 数学：线性于参数 $\mathbf{w}$ ；
- 实践：仅对近似线性可分的数据表现良好。

局限 线性假设的表达能受 VC 维限制，当数据分布非线性或特征维度不足时， E_{in} 往往较大，泛化性能受限。

突破路径 通过特征映射 $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^D$ ($D \gg d$) 或核技巧，将数据嵌入高维空间，使线性超平面在原始空间表现为非线性决策边界，从而显著提升模型容量。

命题 3.4.2 (圆可分 $\Leftrightarrow$ 线可分：二次特征映射视角)

令二次特征映射

$$\Phi: \mathbb{R}^2 \rightarrow \mathbb{R}^6, \quad \Phi(x) = (1, x_1, x_2, x_1^2, x_1x_2, x_2^2)^\top,$$

记 $z = \Phi(x)$ 。对任意数据集 $\{(x_n, y_n)\} \subset \mathbb{R}^2 \times \{-1, +1\}$ ，以下等价：

- 存在一条二次曲线（圆、椭圆、双曲线、抛物线或其退化形式）在 $\mathbb{R}^2$ 中完全分离该数据集；
- 存在向量 $w \in \mathbb{R}^6$ 使得在映射空间 $\mathbb{R}^6$ 中线性可分，即

$$y_n = \text{sign}(w^\top z_n), \quad \forall n.$$

此时，原始空间的决策边界由

$$h(x) = \text{sign}(w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_1x_2 + w_5x_2^2)$$

给出，其几何形状由系数 (w_3, w_4, w_5) 与二次型判别式共同决定。

定义 3.4.1 (通用二次假设集)

在二维输入空间 $\mathbb{R}^2$ 中，定义六维特征映射

$$\phi(x) = (1, x_1, x_2, x_1^2, x_1x_2, x_2^2) \in \mathbb{R}^6.$$

对应的二次假设集

$$\mathcal{H}_\phi = \{h: \mathbb{R}^2 \rightarrow \{-1, +1\} \mid h(x) = \text{sign}(w^\top \phi(x)), w \in \mathbb{R}^6\}$$

具备如下性质：

- 与特征空间 $\mathbb{R}^6$ 中的线性感知机等价；

- 在原始空间可生成任意二次曲线边界：圆、椭圆、双曲线、抛物线等；
- 直线与常值函数为其退化特例；
- 示例：椭圆 $(x_1 + x_2 - 3)^2 + (x_1 - x_2 - 4)^2 = 1$ 等价于

$$w^\top \phi(x) = 0, \quad w = [33, -20, -4, 3, 2, 3]^\top.$$



3.4.2 非线性变换

命题 3.4.3 (从好感知机到好二次假设)

设原始输入空间为 $\mathcal{X}$ ，特征映射 $\phi: \mathcal{X} \rightarrow \mathcal{Z}$ 定义为

$$z = \phi(x) = (1, x_1, x_2, x_1^2, x_1x_2, x_2^2)^\top.$$

已知

- 在 $\mathcal{X}$ 空间中，我们已能利用数据 $\{(x_n, y_n)\}$ 训练出好的线性感知机；
- 对应的 $\mathcal{Z}$ 空间中的数据为 $\{(z_n = \phi(x_n), y_n)\}$ 。

目标

- 在 $\mathcal{Z}$ 空间中训练一条好的线性感知机

$$h(z) = \text{sign}(w^\top z),$$

其在 $\mathcal{X}$ 空间即表现为一条优秀的二次分界线。



算法 3.4.12: 非线性变换三步法

输入：原始数据 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ ；特征映射 $\Phi: \mathcal{X} \rightarrow \mathcal{Z}$ ；线性分类算法 $\mathcal{A}$

输出：非线性分类器 $g: \mathcal{X} \rightarrow \{-1, +1\}$

Step 1 (非线性特征映射)

将原始数据映射到特征空间

$$\mathcal{D}_\Phi \leftarrow \{(z_n = \Phi(x_n), y_n)\}_{n=1}^N.$$

Step 2 (线性训练)

在 $\mathcal{D}_\Phi$ 上用算法 $\mathcal{A}$ 训练得到线性权重 w 。

Step 3 (返回分类器)

输出

$$g(x) = \text{sign}(w^\top \Phi(x)).$$

定义 3.4.2 (非线性模型：非线性变换 + 线性模型)

给定特征映射

$$\Phi: \mathcal{X} \rightarrow \mathcal{Z}, \quad z = \Phi(x),$$

以及任意线性模型 $\mathcal{A}$ (PLA、线性回归、逻辑回归等)，可构造非线性模型

$$g(x) = \mathcal{A}(\Phi(x)).$$

两自由度

- 选择非线性变换 Φ (二次、三次、多项式...);
- 选择线性模型 $\mathcal{A}$ (PLA、回归、分类...).

用途：二次 PLA、二次回归、三次回归、...、任意阶多项式回归皆可自由实现。




图 3.4.1: 特征变换与线性分类器结合的分类过程示意图




图 3.4.2: 特征变换在手写数字识别上的应用

例题 3.6 选择题：二次变换的维度计算

对于 d 维输入向量 $\mathbf{x} \in \mathbb{R}^d$ ，二次变换 $\phi_2(\mathbf{x})$ 包含所有二次项 $x_i x_j$ ($i \leq j$)、线性项 x_i 及常数项 1，则其维度为：

- 1) d
- 2) $\frac{d^2}{2} + \frac{3d}{2} + 1$
- 3) $d^2 + d + 1$
- 4) 2^d

解答 正确选项为 [2]。二次变换 $\phi_2(\mathbf{x})$ 的维度由三部分构成：

- 二次项：含 $x_i x_j$ ($i \leq j$)，共 $\binom{d+1}{2} = \frac{d(d+1)}{2}$ 项；
- 线性项：含 $x_1, x_2, \dots, x_d$ ，共 d 项；
- 常数项：1 项。

$$\text{总维度} = \frac{d(d+1)}{2} + d + 1 = \frac{d^2 + d + 2d + 2}{2} = \frac{d^2}{2} + \frac{3d}{2} + 1。$$

3.4.3 非线性变换的代价

引理 3.4.1 (Q 阶多项式映射的特征维度)

设输入维度为 d ， Q 阶多项式特征映射定义为

$$\phi_Q(\mathbf{x}) = (1, x_1, \dots, x_d, x_1^2, x_1 x_2, \dots, x_d^2, \dots, x_1^Q, \dots, x_d^Q),$$

则该映射后的特征维度为

$$D = \binom{Q+d}{d}.$$



证明 特征维度的计算等价于统计 $\phi_Q(\mathbf{x})$ 中所有单项式的总数。这些单项式均具有形式 $x_1^{k_1} x_2^{k_2} \dots x_d^{k_d}$ ，其中 $k_1, k_2, \dots, k_d$ 为非负整数，且满足总次数约束：

$$0 \leq k_1 + k_2 + \dots + k_d \leq Q.$$

为统一处理“总次数不超过 Q ”这一条件，引入虚拟变量 $k_{d+1} \geq 0$ ，令其满足：

$$k_1 + k_2 + \dots + k_d + k_{d+1} = Q.$$

此时，原问题中满足 $k_1 + \dots + k_d \leq Q$ 的非负整数组 $(k_1, \dots, k_d)$ 与新方程的非负整数解 $(k_1, \dots, k_d, k_{d+1})$ 形成一一对应关系。

根据组合数学中的“星号与竖线”原理：对于方程 $x_1 + x_2 + \dots + x_n = m$ （其中 $x_i \geq 0$ 且为整数），其非负整数解的个数为 $\binom{m+n-1}{n-1}$ 。

在此处，变量总数为 $n = d + 1$ ，总次数为 $m = Q$ ，代入上述原理可得解的个数为

$$\binom{Q + (d+1) - 1}{(d+1) - 1} = \binom{Q+d}{d},$$

因此特征维度 $D = \binom{Q+d}{d}$ 。

定义 3.4.3 (Q 阶多项式映射的代价)

设输入维度为 d ，定义 Q 阶多项式特征映射

$$\phi_Q(\mathbf{x}) = (1, x_1, \dots, x_d, x_1^2, x_1 x_2, \dots, x_d^2, \dots, x_1^Q, \dots, x_d^Q).$$

1. 计算与存储代价

映射后的特征维度

$$D = \binom{Q+d}{d} = O(Q^d).$$

需要 $O(D)$ 次运算与空间来存储 $\phi_Q(\mathbf{x})$ 和权重 w ；当 Q 增大时，代价迅速上升。

2. 模型复杂度代价

假设集 $\mathcal{H}_{\phi_Q}$ 的 VC 维满足

$$d_{VC}(\mathcal{H}_{\phi_Q}) \leq D + 1 = O(Q^d).$$

直观解释：在 ϕ_Q 空间中，任意 $D + 2$ 个输入无法被打散（已超出线性可分能力），回到原始 x 空间亦无法被打散。因此 Q 越大， d_{VC} 越大，模型复杂度随之升高。



命题 3.4.4 (泛化困境：如何选择多项式阶数 Q ?)

在特征空间

$$\Phi_Q(x) \in \mathbb{R}^D \quad \text{其中} \quad D = \binom{Q+d}{d}$$

中训练得到的假设 g 满足

$$E_{\text{out}}(g) \leq E_{\text{in}}(g) + \Omega\left(\frac{D \ln N}{N}\right).$$

直观权衡

- Q 过低： $E_{\text{in}}(g)$ 可能过大（欠拟合）
- Q 过高： $E_{\text{in}}(g) = 0$ 却造成 D 暴涨， $E_{\text{out}}(g)$ 远离 $E_{\text{in}}(g)$ （过拟合）

如何选 Q ? 凭经验“目测”往往选 $Q = 1$ （原始空间）；系统做法需交叉验证或正则化，以在偏差-方差之间取得最佳折中。



命题 3.4.5 (“肉眼选特征”的风险)

即便在二维空间 $\mathbb{R}^2$ 中能凭直观“看出”合适的特征，当输入空间扩展到 $X = \mathbb{R}^{10}$ 时，这种“目测法”显然不再可行。

同一问题的四种特征映射示例

$$\text{完整二阶映射 } \Phi_2: \quad z = (1, x_1, x_2, x_1^2, x_1x_2, x_2^2), d_{VC} = 6;$$

$$\text{视觉直观下的“简化”}: z = (1, x_1^2, x_2^2), \quad d_{VC} = 3;$$

$$\text{进一步“简化”}: \quad z = (1, x_1^2 + x_2^2), \quad d_{VC} = 2;$$

$$\text{极致简化}: \quad z = \text{sign}(0.6 - x_1^2 - x_2^2), \quad d_{VC} = 1.$$

核心警示 人脑自带的“模型复杂度直觉”极易导致过拟合。为保证 VC 维估计具备数据无关性 (data-independent)，特征映射 Φ 必须在未观测数据的前提下预先确定。



笔记 [非线性变换的代价]

非线性映射（如多项式映射）虽可提升表达能力，但会带来维度膨胀、模型复杂度升高与泛化风险；另外，特征映射的选择应避免主观臆断，需结合交叉验证等方法进行系统优化。

3.4.4 结构化假设集

定义 3.4.4 (多项式变换的层级结构)

对阶数 $Q = 0, 1, 2, \dots$ 定义嵌套特征映射

$$\begin{aligned}\Phi_0(x) &= (1), \\ \Phi_1(x) &= (\Phi_0(x), x_1, x_2, \dots, x_d), \\ \Phi_2(x) &= (\Phi_1(x), x_1^2, x_1x_2, \dots, x_d^2), \\ &\vdots \\ \Phi_Q(x) &= (\Phi_{Q-1}(x), \text{所有新增 } Q \text{ 阶单项式}).\end{aligned}$$

对应假设集合呈严格嵌套：

$$\mathcal{H}_0 \subset \mathcal{H}_1 \subset \mathcal{H}_2 \subset \dots \subset \mathcal{H}_Q.$$

层级属性

- **VC 维单调增：** $d_{VC}(\mathcal{H}_0) \leq d_{VC}(\mathcal{H}_1) \leq \dots \leq d_{VC}(\mathcal{H}_Q)$.
- **训练误差单调减：** $E_{in}(g_0) \geq E_{in}(g_1) \geq \dots \geq E_{in}(g_Q)$, 其中 $g_j = \arg \min_{h \in \mathcal{H}_j} E_{in}(h)$.
- **权衡启示：** 选用过高阶的 $\mathcal{H}_Q$ 虽能降低 E_{in} , 却因 d_{VC} 过大而升高 E_{out} (过拟合)。




图 3.4.3: 递增假设空间序列示意图

命题 3.4.6 (线性模型优先原则)

将假设集合按嵌套关系排列为

$$\mathcal{H}_0 \subset \mathcal{H}_1 \subset \mathcal{H}_2 \subset \dots \subset \mathcal{H}_Q,$$

其 VC 维与训练误差满足

$$d_{VC}(\mathcal{H}_j) \uparrow, \quad E_{in}(g_j) \downarrow, \quad \text{其中 } g_j = \arg \min_{h \in \mathcal{H}_j} E_{in}(h).$$

诱人的陷阱 选用 $\mathcal{H}_{1126}$ 这类高复杂度模型, 虽能将训练误差 $E_{in}(g_{1126})$ 降至极低以“蒙混过关”, 但会导致 VC 维急剧攀升、泛化误差 E_{out} 彻底失控, 最终陷入难以挽回的境地。

稳妥策略

- 1) 从最简单的 $\mathcal{H}_1$ (线性模型) 起步;
- 2) 若此时 $E_{in}(g_1)$ 已满足需求, 即可终止并高效收尾;
- 3) 否则再逐步提升模型复杂度 (沿假设集序列右移); 这种做法即便多耗费些许计算资源, 也不会造成实质性损失。

结论 线性模型应优先选用的原则：兼具简单、高效、安全的特性，且实践中往往行之有效！




图 3.4.4: 模型复杂度、样本内误差、样本外误差与 VC 维关系图

3.4.5 总结

笔记 [非线性变换]

- 二次假设：在二次变换后的数据上使用线性假设。
- 非线性变换：先做 $\mathbf{z} = \Phi(\mathbf{x})$ ，再愉快地线性建模。
- 非线性变换的代价：计算量、存储量与模型复杂度同步上升。
- 结构化假设集：优先使用线性或更简单的模型。

笔记 [总体结论] 非线性变换通过将输入映射到高维特征空间，使得原本非线性可分的问题转化为线性可分，从而显著提升模型的表达能力。这一策略保留了线性模型在计算与训练上的优势，但也带来了维度膨胀、计算代价上升和模型复杂度增加等问题，可能导致泛化能力下降。为此，我们需在提升拟合能力与控制复杂度之间进行权衡，避免依赖主观直觉设计特征，应借助交叉验证、正则化等方法系统选择变换阶数。整体而言，非线性变换是连接简单模型与复杂任务之间的重要桥梁，是实现有效学习的关键手段之一。

间章：机器如何学习？



笔记 [机器如何学习？]

“**How Can Machines Learn?**”（机器如何学习）是我们第三章所共同回答的问题。通过线性回归、逻辑回归、分类扩展及非线性变换的具体实现，可从四个关键环节解析机器学习的实操路径：

1. 模型假设的构建：从数据规律到数学表达

机器学习的起点是构建能刻画数据规律的假设空间。这一过程体现为：

- 针对回归任务，采用线性组合假设 $h(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}$ ，用加权求和捕捉输入与输出的线性关联；
- 针对分类任务，引入逻辑函数将线性得分映射为概率 $h(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x})$ ，用概率形式表达类别归属的不确定性；
- 面对非线性规律，通过特征映射 $\Phi(\mathbf{x})$ 将原始数据转化为高维特征，再复用线性假设框架，让线性模型在高维空间拟合原始空间的非线性模式。

这些假设通过数学形式将“数据规律”转化为可计算的参数化模型，为学习提供基础框架。

2. 误差函数的设计：量化偏差的学习信号

学习的核心是“从错误中改进”，误差函数则是量化错误的关键：

- 回归问题中，平方误差 $(\hat{y} - y)^2$ 直观反映预测值与真实值的偏离程度；
- 分类问题中，交叉熵误差 $\ln(1 + e^{-z})$ 精准衡量预测概率与标签的匹配度；
- 各类误差均需满足“可优化性”，即能通过数学运算引导模型参数向更优方向调整。

误差函数为机器提供了“学习的反馈信号”，使其知晓当前模型的优劣。

3. 优化算法的执行：从初始猜测到最优参数

有了目标（最小化误差），需通过算法求解最优参数：

- 部分简单问题可直接通过矩阵运算求得解析解，一步到位获取最优参数；
- 复杂问题需通过梯度下降等迭代算法，沿误差减小方向逐步更新参数，渐进逼近最优解；
- 随机梯度下降通过单样本更新提升效率，适配大数据场景下的高效学习。

优化算法是机器“主动学习”的核心动力，使其能从初始参数出发，逐步逼近最优解。

4. 泛化能力的保障：从训练数据到未知数据

学习的终极目标是对新数据有效，需通过以下机制保障：

- 控制模型复杂度（如选择合适阶数的特征变换），避免过拟合；
- 利用理论工具平衡模型表达能力与泛化风险，确保学到的规律不仅适配训练数据，更能推广到未知样本；
- 多分类任务中，通过合理拆解策略（如一对多、一对一）复用二分类的泛化机制，解决复杂场景下的学习问题。

结语：机器学习的过程是“假设建模 → 误差量化 → 优化求解 → 泛化控制”的闭环：通过数学工具将数据规律转化为可学习的参数模型，最终实现从已知数据到未知数据的有效预测。

第4章 机器如何学得更好？

4.1 过拟合的危害

4.1.1 什么是过拟合？

定义 4.1.1 (坏的泛化与过拟合)

当训练集大小 N 固定时，模型复杂度可用 VC 维 d_{VC} 表征。泛化能力由内外误差之差 $E_{out} - E_{in}$ 衡量，该差值应尽可能小。

1) 过拟合 (Overfitting): 当将 d_{VC} 从最优值 d_{VC}^* 提高到极高维度 (如 1126) 时,

$$E_{in} \downarrow, E_{out} \uparrow, \implies E_{out} - E_{in} \text{ 显著增大.}$$

模型对训练数据拟合更好，但泛化能力恶化。

2) 欠拟合 (Underfitting): 当将 d_{VC} 降至过低时，模型表达能力不足，难以捕捉数据规律，

$$E_{in} \uparrow, E_{out} \uparrow.$$

内外误差均增大，表现出整体性能低下。



命题 4.1.1 (过拟合的“驾驶”类比)


将机器学习过程类比为驾驶：

- 数据 $\leftrightarrow$ 观察到的路况；
- 目标函数 $\leftrightarrow$ 理想行驶路线；
- 模型容量 (d_{VC}) $\leftrightarrow$ 车速。


则

- (a) 车速过高 (d_{VC} 过大) $\Rightarrow$ 对路面微小起伏过度反应，即过拟合；
- (b) 路面颠簸 (数据噪声) $\Rightarrow$ 进一步放大失控风险；
- (c) 观察窗口有限 (样本量 N 小) $\Rightarrow$ 无法充分了解路况，同样导致偏离。

因此，噪声与数据规模共同决定了“失控”即过拟合发生的概率。



(a) 好拟合图像



(b) 过拟合图像

图 4.1.1: 机器学习拟合曲线图像

4.1.2 噪声与数据量的作用

命题 4.1.2 (过拟合的案例研究)

考虑两种不同的目标函数场景：


(a) 场景一：含噪声的 **10** 次目标函数 给定含噪声的 10 次目标函数，分别在 2 次多项式空间 $\mathcal{H}_2$ 中挑选假设 g_2 ，和在 10 次多项式空间 $\mathcal{H}_{10}$ 中挑选假设 g_{10} 。得到如下结果：

	$g_2 \in \mathcal{H}_2$	$g_{10} \in \mathcal{H}_{10}$
E_{in}	0.050	0.034
E_{out}	0.127	9.00


(b) 场景二：无噪声的 **50** 次目标函数 给定无噪声的 50 次目标函数，同样分别在 2 次多项式空间 $\mathcal{H}_2$ 中挑选假设 g_2 ，和在 10 次多项式空间 $\mathcal{H}_{10}$ 中挑选假设 g_{10} 。得到如下结果：

	$g_2 \in \mathcal{H}_2$	$g_{10} \in \mathcal{H}_{10}$
E_{in}	0.029	0.00001
E_{out}	0.120	7680

在这两种场景中，从 g_2 到 g_{10} 均出现了过拟合现象，即模型在训练集上的误差 E_{in} 减小，但在测试集上的误差 E_{out} 显著增大。



(a) 十阶目标函数（有噪声）



(b) 五十阶目标函数（无噪声）

图 4.1.2: 二阶拟合与十阶拟合对比图

命题 4.1.3 (过拟合与模型选择的“讽刺”)

给定同一组数据，真实目标函数为十次多项式。

- 学习者 **Overfit** (过拟合者)：在十次多项式假设空间 $\mathcal{H}_{10}$ 中选择假设函数 g_{10} ；
- 学习者 **Restrict** (受限者)：仅在二次多项式假设空间 $\mathcal{H}_2$ 中选择假设函数 g_2 。


虽然两者都知道目标是十次多项式，学习者 Restrict 却主动放弃高阶拟合能力，结果是：

$$E_{\text{out}}(g_2) \ll E_{\text{out}}(g_{10}).$$


这一现象可以从学习曲线中得到进一步验证：

- 对于 $\mathcal{H}_{10}$ ，当数据点数量 N 趋近于无穷大时，预期的 E_{out} 较低，但在 N 较小时，泛化误差会大得多。
- 在数据点数量 N 较小的灰色区域， $\mathcal{H}_{10}$ 会出现过拟合现象，表现为 E_{in} 下降而 E_{out} 上升。

即使在无噪声的情况下，学习者 Restrict 仍然能够在 E_{out} 上取得优势，这是因为目标函数的复杂性本身就起到了类似噪声的作用。



(a) 假设空间 $\mathcal{H}_2$ 下期望误差与数据点数量关系图



(b) 假设空间 $\mathcal{H}_{10}$ 下期望误差与数据点数量关系图

图 4.1.3: 不同假设空间下期望误差与数据点数量关系图

4.1.3 确定性噪声

命题 4.1.4 (过拟合度量实验)

设目标函数 $f \in \mathcal{H}_{Q_f}$ ，其形式为 $f(x) = \sum_{q=0}^{Q_f} \alpha_q x^q$ ，其中 α_q 为系数。观测样本由以下方式生成：

$$y_n = f(x_n) + \varepsilon_n, \quad \varepsilon_n \sim \mathcal{N}(0, \sigma^2)$$

其中 x_n 在定义域上均匀分布， ε_n 为独立同分布的高斯噪声，噪声水平为 σ^2 。

记 $g_2 \in \mathcal{H}_2$ 与 $g_{10} \in \mathcal{H}_{10}$ 分别为通过二次多项式拟合和十次多项式拟合得到的假设函数。过拟合程度可量化为：

$$\text{Overfit}(g_2, g_{10}) \triangleq E_{\text{out}}(g_{10}) - E_{\text{out}}(g_2)$$

并且恒有 $E_{\text{in}}(g_{10}) \leq E_{\text{in}}(g_2)$ 。

该过拟合度量值 $\text{Overfit}(g_2, g_{10})$ 随噪声水平 σ^2 的增大或样本量 N 的减小而单调上升。





(a) 固定 Q_f 时噪声水平与数据点数量关系热图(b) 固定 σ^2 时目标复杂度与数据点数量关系热图

图 4.1.4: 目标复杂度或噪声水平与数据点数量关系热图

命题 4.1.5 (噪声与数据量对过拟合的影响)

设目标函数 $f \in \mathcal{H}_{Q_f}$, 样本数为 N , 则过拟合程度满足:

$$\text{Overfit}(g) \propto \frac{\sigma^2}{N} + \frac{\text{DetNoise}}{N}$$

其中 σ^2 为随机噪声强度, DetNoise 为确定性噪声 (deterministic noise)。

经验规律

- 固定 Q_f : 数据量 N 减小或随机噪声 σ^2 增大 $\Rightarrow$ 过拟合程度上升;
- 固定 N : 真实复杂度 Q_f 增大 $\Rightarrow$ 确定性噪声增大 $\Rightarrow$ 过拟合程度上升。

确定性噪声定义 若 $f \notin \mathcal{H}$, 则存在:

$$\text{DetNoise}(x) = f(x) - h^*(x), \quad h^* = \arg \min_{h \in \mathcal{H}} E_{\text{out}}(h)$$

与随机噪声不同, 确定性噪声具有以下特点:

- 由假设空间 $\mathcal{H}$ 决定;
- 对给定的 x 固定不变。




图 4.1.5: 确定性噪声图片

例题 4.1 选择题：确定性噪声的计算

考虑目标函数为 $\sin(1126x)$, $x \in [0, 2\pi]$, 且 x 在该区间均匀采样。若用线性假设 $h(x) = w \cdot x$ 以平方误差近似目标函数, 则每个 x 处的确定性噪声为:

- 1) $|\sin(1126x)|$
- 2) $|\sin(1126x) - x|$
- 3) $|\sin(1126x) + x|$
- 4) $|\sin(1126x) - 1126x|$

解答 正确选项为 **[1]**。确定性噪声是目标函数与最优近似函数的差异。对线性假设 $h(x) = w \cdot x$, 通过尝试不同 w 值可知, 当 $w = 0$ 时, $h^*(x) = 0$ 是最优假设 (平方误差最小)。

因此, 确定性噪声为 $|\sin(1126x) - h^*(x)| = |\sin(1126x)|$ 。 ■

4.1.4 应对过拟合**命题 4.1.6 (驾驶类比再探：防治过拟合的实用技术)**

将机器学习过程类比为驾驶行为:

- 过拟合 $\leftrightarrow$ 发生车祸;
- 过度 VC 维 (d_{VC}) $\leftrightarrow$ 驾驶速度过快;
- 噪声 $\leftrightarrow$ 颠簸的路面;
- 数据量有限 (N) $\leftrightarrow$ 对路况的观察有限。

防治过拟合的对应策略如下:

机器学习	驾驶策略
从简单模型起步	低速驾驶
数据清洗/剪枝	使用更准确的路况信息
数据提示 (hinting)	利用更多的路况信息
正则化	踩刹车
验证	监控仪表盘

这些一一对应的实用技术, 都是防止“失控”——过拟合——的有效手段。 ♠

定义 4.1.2 (数据清洗 / 数据剪枝 (Data Cleaning / Data Pruning))

数据清洗 (Data Cleaning) 是从数据集、数据库表或记录集中检测、纠正或移除损坏、不准确、不完整、不相关或重复数据的过程, 旨在将“脏数据”转换为满足质量要求的高质量可用数据。

其核心任务包括:

- 一致性检查: 发现并修正逻辑冲突、越界值;
- 缺失值处理: 插补、删除或标记无效值;
- 异常值检测与修正: 识别并替换错误或离群样本;
- 重复记录去重: 合并或删除冗余条目;
- 数据类型与格式标准化: 确保变量类型、单位和命名一致。

数据剪枝 (Data Pruning) 是数据清洗的一个子过程, 专指在不损失关键信息的前提下, 删除冗

余、噪声或低质量样本，从而降低模型复杂度并减少过拟合风险。

清洗后的数据应满足准确性、完整性、一致性、唯一性和有效性等质量维度，为后续分析与建模奠定可靠基础。



定义 4.1.3 (数据提示 (Data Hinting))

数据提示 (Data Hinting) 是一种在不收集额外真实样本的前提下，通过“伪造”或“生成”虚拟样本 (virtual examples) 来扩充训练集规模的数据增强技术。其核心思想是：在保持标签不变的情况下，对已有数据进行合理的几何或语义变换，从而人为地引入更多有效信息，降低过拟合风险。

常见做法包括：

- 图像：平移、旋转、缩放、翻转、亮度/对比度调整；
- 文本：同义词替换、随机删除/插入词语、回译；
- 语音：加噪、变速、音高偏移；
- 数值特征：小幅随机扰动、线性插值。

注意事项

- 变换强度应受约束，避免引入错误标签；
- 对生成样本进行一致性检查，确保其符合真实数据分布。

数据提示与常规数据增强 (data augmentation) 在术语上常互换使用，但“hinting”更强调通过人工“提示”模型学习不变性或鲁棒性，而非单纯增加样本量。



4.1.5 总结



笔记 [过拟合的危害]

- 什么是过拟合?： E_{in} 降低， E_{out} 反而升高。
- 噪声与数据量的作用：过拟合“极易”发生！
- 确定性噪声：假设集 $\mathcal{H}$ 无法捕捉的部分表现为噪声。
- 应对过拟合：数据清洗/裁剪/提示等方法，以及其他策略。

4.2 正则化

4.2.1 正则化假设集

命题 4.2.1 (正则化)

设 Q 阶多项式特征映射为：

$$\phi_Q(x) = (1, x, x^2, \dots, x^Q) \in \mathbb{R}^{Q+1}$$

对应假设集为：

$$\mathcal{H}_Q = \{h(x) = w^\top \phi_Q(x) \mid w \in \mathbb{R}^{Q+1}\}$$

约束 从 $\mathcal{H}_{10}$ 退到 $\mathcal{H}_2$ 等价于在 $\mathcal{H}_{10}$ 中施加线性约束：

$$w_3 = w_4 = \dots = w_{10} = 0$$

带约束的回归

$$\mathcal{H}_{10} \text{ 回归 : } \min_{w \in \mathbb{R}^{11}} E_{\text{in}}(w)$$

$$\mathcal{H}_2 \text{ 回归 : } \min_{\substack{w \in \mathbb{R}^{11} \\ w_3 = \dots = w_{10} = 0}} E_{\text{in}}(w)$$



注 为何不直接令 $w \in \mathbb{R}^3$? 因为显式约束形式为后续更灵活的正则化（如 L_2 、 L_1 惩罚）奠定统一框架。

命题 4.2.2 (从硬约束到软约束的正则化)

设多项式特征映射后的权重维度为 $d = 10$ ，记

$$\phi(x) = (1, x, x^2, \dots, x^{10}), \quad w = (w_0, w_1, \dots, w_{10}) \in \mathbb{R}^{11}$$

(a) 稀疏硬约束：

$$\mathcal{H}_2^{\text{hard}} = \{w \in \mathbb{R}^{11} \mid w_3 = w_4 = \dots = w_{10} = 0\}$$

优化问题为：

$$\min_{w \in \mathbb{R}^{11}} E_{\text{in}}(w) \quad \text{s.t. } w_3 = \dots = w_{10} = 0$$

(b) 宽松稀疏约束：

$$\mathcal{H}_2^{\text{sparse}} = \{w \in \mathbb{R}^{11} \mid \|w\|_0 \leq 3\}$$

其中 $\|w\|_0$ 为非零权重个数。该约束更灵活： $\mathcal{H}_2^{\text{hard}} \subset \mathcal{H}_2^{\text{sparse}} \subset \mathcal{H}_{10}$ ，但求解 $\min E_{\text{in}}$ 在 $\mathcal{H}_2^{\text{sparse}}$ 下为 NP-hard。

(c) 软约束（ L_2 正则化）：

$$\mathcal{H}(C) = \{w \in \mathbb{R}^{11} \mid \|w\|_2^2 \leq C\}, \quad C \geq 0$$

优化问题为：

$$\min_{w \in \mathbb{R}^{11}} E_{\text{in}}(w) \quad \text{s.t. } \|w\|_2^2 \leq C$$

该集合对 C 连续嵌套：

$$\mathcal{H}(0) \subset \mathcal{H}(1.126) \subset \dots \subset \mathcal{H}(1126) \subset \dots \subset \mathcal{H}(\infty) = \mathcal{H}_{10}$$

结论：软约束 $\mathcal{H}(C)$ 既保留模型容量，又通过连续调节 C 实现平滑正则化，从而避免 NP-hard 求解，成为实际中最常用的正则化框架。



例题 4.2 选择题：正则化假设集的成员判定

对于 $Q \geq 1$ ，下列哪个假设（权重向量 $\mathbf{w} \in \mathbb{R}^{Q+1}$ ）不属于正则化假设集 $\mathcal{H}(1)$ ？

- 1) $\mathbf{w}^T = [0, 0, \dots, 0]$
- 2) $\mathbf{w}^T = [1, 0, \dots, 0]$
- 3) $\mathbf{w}^T = [1, 1, \dots, 1]$
- 4) $\mathbf{w}^T = \left[\sqrt{\frac{1}{Q+1}}, \sqrt{\frac{1}{Q+1}}, \dots, \sqrt{\frac{1}{Q+1}} \right]$

解答 正确选项为 [3]。正则化假设集 $\mathcal{H}(1)$ 要求权重向量的 L_2 范数满足 $\|\mathbf{w}\|_2 \leq 1$ 。

- 选项 1: $\|\mathbf{w}\|_2 = 0 \leq 1$ ，满足条件。
- 选项 2: $\|\mathbf{w}\|_2 = 1 \leq 1$ ，满足条件。
- 选项 3: $\|\mathbf{w}\|_2 = \sqrt{Q+1} > 1$ （因 $Q \geq 1$ ），不满足条件。
- 选项 4: $\|\mathbf{w}\|_2 = 1 \leq 1$ ，满足条件。



4.2.2 权重衰减正则化

命题 4.2.3 (正则化回归的矩阵形式与拉格朗日乘法)

矩阵形式给定特征矩阵 $Z \in \mathbb{R}^{N \times (Q+1)}$ 和标签向量 $y \in \mathbb{R}^N$ ，正则化回归问题可表示为：

$$\min_{\mathbf{w} \in \mathbb{R}^{Q+1}} E_{\text{in}}(\mathbf{w}) = \frac{1}{N} (Z\mathbf{w} - y)^\top (Z\mathbf{w} - y) \quad \text{s.t.} \quad \mathbf{w}^\top \mathbf{w} \leq C$$

其中 $\mathbf{w}^\top \mathbf{w} \leq C$ 表示可行域为半径 $\sqrt{C}$ 的超球面。

拉格朗日乘法构造拉格朗日函数：

$$\mathcal{L}(\mathbf{w}, \lambda) = \frac{1}{N} (Z\mathbf{w} - y)^\top (Z\mathbf{w} - y) + \lambda(\mathbf{w}^\top \mathbf{w} - C), \quad \lambda \geq 0$$

最优解 $\mathbf{w}_{\text{REG}}$ 满足 KKT 条件：

$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}, \lambda) = \frac{2}{N} Z^\top (Z\mathbf{w} - y) + 2\lambda \mathbf{w} = 0$$

解得：

$$\mathbf{w}_{\text{REG}} = (Z^\top Z + N\lambda I)^{-1} Z^\top y$$

且互补松弛条件给出：

$$\lambda(\mathbf{w}_{\text{REG}}^\top \mathbf{w}_{\text{REG}} - C) = 0$$

几何解读 在 $\mathbf{w}^\top \mathbf{w} = C$ 边界上，负梯度 $-\nabla E_{\text{in}}(\mathbf{w}_{\text{REG}})$ 与法向量 $\mathbf{w}_{\text{REG}}$ 平行，保证在不违反约束的前提下无法再降低 E_{in} 。






图 4.2.1: 带约束的样本内误差最小化几何解释图

命题 4.2.4 (增广误差与岭回归的等价性)

增广误差的定义设正则化参数 $\lambda > 0$ 已知 (可由先验知识或交叉验证确定), 定义增广误差:

$$E_{\text{aug}}(w) = \underbrace{\frac{1}{N} \|Zw - y\|_2^2}_{E_{\text{in}}(w)} + \underbrace{\frac{\lambda}{N} \|w\|_2^2}_{\text{正则化项}}$$

其中 $\|\cdot\|_2$ 表示欧几里得范数。

无约束优化解 对增广误差求导并令导数为零:

$$\nabla_w E_{\text{aug}}(w) = \frac{2}{N} (Z^\top Zw - Z^\top y) + \frac{2\lambda}{N} w = 0$$

解得:

$$w_{\text{REG}} = (Z^\top Z + \lambda I)^{-1} Z^\top y$$

该式即为统计学中的 岭回归 (ridge regression)。

与约束优化的等价性 最小化无约束增广误差 $E_{\text{aug}}(w)$ 等价于求解以下带约束优化问题:

$$\min_w \frac{1}{N} \|Zw - y\|_2^2 \quad \text{s.t.} \quad \|w\|_2^2 \leq C$$

其中 C 是与 λ 相关的常数, 二者通过拉格朗日对偶关系一一对应。

命题 4.2.5 (正则化效果)

固定特征映射与数据集, 仅改变正则化参数 λ :

- $\lambda = 0$: 无正则化, 易过拟合;
- $\lambda = 0.0001$: 轻微正则, 拟合与泛化平衡;
- $\lambda = 0.01$: 适中正则, 进一步抑制过拟合;
- $\lambda = 1$: 强正则, 可能欠拟合。

权重衰减 (weight-decay) 把 $\frac{\lambda}{N} \|w\|^2$ 加进损失函数, 等价于

$$\text{更大的 } \lambda \iff \text{偏好更短的 } w \iff \text{有效缩小约束半径 } C.$$

结论: 任意非线性变换 + 线性模型 + 权重衰减, 即可稳健地控制复杂度与泛化性能。




图 4.2.2: 不同的正则化参数值的权重衰减

定义 4.2.1 (多项式特征映射：从朴素到归一化)

给定输入变量 $x \in [-1, 1]$, 常用的两种多项式特征构造方式:

1) 朴素多项式映射

$$\phi_{\text{naive}}(x) = (1, x, x^2, \dots, x^Q).$$

当 $x \in [-1, 1]$ 时, $|x^q|$ 随阶数 q 增大而迅速减小, 导致需要极大的权重 w_q 才能产生显著影响。

2) 归一化多项式映射 (**Legendre 正交基**) 采用勒让德多项式 $\{L_q(x)\}_{q=0}^Q$ 作为正交归一基函数:

$$\phi_{\text{norm}}(x) = (L_0(x), L_1(x), \dots, L_Q(x)),$$

其中

$$L_0(x) = 1,$$

$$L_1(x) = x,$$

$$L_2(x) = \frac{1}{2}(3x^2 - 1),$$

$$L_3(x) = \frac{1}{2}(5x^3 - 3x),$$

$$L_4(x) = \frac{1}{8}(35x^4 - 30x^2 + 3),$$

$$L_5(x) = \frac{1}{8}(63x^5 - 70x^3 + 15x), \dots$$

由于 $\{L_q(x)\}$ 在区间 $[-1, 1]$ 上正交归一, 数值稳定性高, 可显著抑制所需权重 w_q 的幅度, 从而缓解数值病态与过拟合。




图 4.2.3: Legendre 正交基

例题 4.3 选择题: 正则化权重与普通权重的等价条件

在什么情况下正则化权重 w_{REG} 等于普通最小二乘权重 w_{LIN} ?

1) $\lambda = 0$

2) $C = \infty$

3) $C \geq \|w_{\text{LIN}}\|^2$

4) 以上所有情况

解答 正确选项为 [4]。正则化权重 w_{REG} 由目标函数 $\sum (y_n - w^T x_n)^2 + \lambda \|w\|^2$ 最小化得到，普通权重 w_{LIN} 是 $\lambda = 0$ 时的特例。

- 选项 1: $\lambda = 0$ 时，正则化退化为普通最小二乘， $w_{\text{REG}} = w_{\text{LIN}}$ 。
- 选项 2: $C = \infty$ 时，正则化约束被忽略，等价于 $\lambda = 0$ 。
- 选项 3: $C \geq \|w_{\text{LIN}}\|^2$ 时，正则化约束不限制 w_{LIN} 。

所有选项均满足条件。 ■

4.2.3 正则化与 VC 理论

命题 4.2.6 (正则化与 VC 理论的统一视角)

1. 受约束优化与 VC 界考虑权重范数约束下的经验风险最小化问题：

$$\min_w E_{\text{in}}(w) \quad \text{s.t.} \quad w^\top w \leq C$$

根据 VC 理论，其泛化误差满足：

$$E_{\text{out}}(w) \leq E_{\text{in}}(w) + \Omega(\mathcal{H}(C))$$

其中 $\mathcal{H}(C) = \{h \mid h(x) = w^\top \phi(x), w^\top w \leq C\}$ ，且约束半径 C 与某个拉格朗日乘子 λ 一一对应。

2. 增广误差的再阐释将约束转化为无约束正则化问题：

$$\min_w E_{\text{aug}}(w) = E_{\text{in}}(w) + \frac{\lambda}{N} w^\top w$$

此时：

- 正则项 $w^\top w$ ：度量单个假设的复杂度；
- $\Omega(\mathcal{H})$ ：度量整个假设集的复杂度。

若 $\frac{\lambda}{N} w^\top w$ 能良好地近似 $\Omega(\mathcal{H})$ ，则 E_{aug} 比 E_{in} 更接近 E_{out} ，从而在理论上享有整个假设集 $\mathcal{H}$ 的灵活性，同时实践中利用正则化避免过拟合。

3. 有效 VC 维

- 名义 VC 维: $d_{\text{VC}}(\mathcal{H}) = d + 1$ ，因优化时“理论上”遍历所有 w ；
- 有效 VC 维: $d_{\text{EFF}}(\mathcal{H}, \lambda)$ ，对应实际受正则化约束的假设子集 $\mathcal{H}(C)$ ；
- 当 λ 较大时， $d_{\text{EFF}}(\mathcal{H}, \lambda) \ll d_{\text{VC}}(\mathcal{H})$ ，从而解释正则化如何在高名义复杂度下保持低有效复杂度。

结论：

正则化 = 用较小的 d_{EFF} 控制较大的 d_{VC}



4.2.4 通用正则化项

定义 4.2.2 (通用正则项 $\Omega(w)$ 的设计准则)

正则项 $\Omega(w)$ 的选择应兼顾以下三类动机，并可与误差函数 E_{err} 共同构成增广误差

$$E_{\text{aug}}(w) = E_{\text{err}}(w) + \lambda \Omega(w).$$

1. 目标依赖型 (target-dependent)

对真实目标函数的先验已知，可构造指向该先验的约束方向。例如：

- 对称正则：当目标函数具有奇偶对称性时，强制对应奇/偶系数 w_q 为零；
- 平滑正则：鼓励高频系数 w_q 趋零，以逼近更平滑或更简单的真实函数。

2. 合理性型 (plausible)

对随机或确定性噪声均呈现非光滑特性时，选用

- 稀疏正则 (L_1): $\Omega(w) = \sum_q |w_q|$ ，诱导稀疏解；
- 权重衰减 (L_2): $\Omega(w) = \sum_q w_q^2$ ，抑制大权重。


3. 友好型 (friendly)

正则项本身需易于优化：


- L_2 正则：凸、可微、闭式解；
- L_1 正则：虽非光滑，但凸且可高效求解（如坐标下降、近端梯度）。

结论：

正则项 $\leftrightarrow$ 误差度量：均遵循“目标依赖 / 合理 / 友好”的相同设计哲学。



(a) L_2 正则化



(b) L_1 正则化


图 4.2.4: 正则化图像

命题 4.2.7 (最优正则化参数 λ 的选择)


给定真实目标复杂度 Q_f (多项式阶数) 与两类噪声：

- 随机噪声 (stochastic noise)；
- 确定性噪声 (deterministic noise)。

数值实验结果 (固定 N) 如图所示：



(a) 不同噪声水平下期望样本外误差与正则化参数关系图



(b) 不同目标复杂度下期望样本外误差与正则化参数关系图

图4.2.4: 正则化图像

结论

- 噪声越大 $\Leftrightarrow$ 需要更大的 λ ;
- 噪声未知时, 必须通过交叉验证等方法选择恰当 λ , 否则易过拟合或欠拟合。

4.2.5 总结

笔记 [正则化]

- 正则化假设集: 在原始假设空间 $\mathcal{H}$ 上施加约束。
- 权重衰减正则化: 在目标函数中增加 $\lambda \Omega(w)$, 得到增广误差 $E_{\text{aug}}(w) = E_{\text{in}}(w) + \lambda \Omega(w)$ 。
- 正则化与 VC 理论: 正则化通过减少有效参数降低复杂度 C , 从而减小有效 VC 维 d_{eff} 。
- 通用正则化项: 可依据“目标相关”“合理”或“算法友好”等原则构造。

4.3 验证

4.3.1 模型选择问题

命题 4.3.1 (模型选择的两大陷阱)

设共有 M 个候选模型 $\mathcal{H}_1, \mathcal{H}_2, \dots, \mathcal{H}_M$, 对应算法 $\mathcal{A}_1, \mathcal{A}_2, \dots, \mathcal{A}_M$ 。目标是选出 $\mathcal{H}_{m^*}$, 使得 $g_{m^*} = \mathcal{A}_{m^*}(\mathcal{D})$ 的 E_{out} 最小。

(a) 按最小 E_{in} 选择

$$m^* = \arg \min_{1 \leq m \leq M} E_{\text{in}}(\mathcal{A}_m(\mathcal{D}))$$

这种方法存在严重问题:

- 更复杂的模型 (如 Φ_{1126} 比 Φ_1) 总能获得更低的 E_{in}
- 无正则化的模型 ($\lambda = 0$ 比 $\lambda = 0.1$) 总能获得更低的 E_{in}
- 等价于在整个并集 $\bigcup_m \mathcal{H}_m$ 上最小化 E_{in}
- 导致过拟合和泛化性能下降

(b) 按最小 E_{test} 选择

$$m^* = \arg \min_{1 \leq m \leq M} E_{\text{test}}(\mathcal{A}_m(\mathcal{D}))$$

其中 $\mathcal{D}_{\text{test}}$ 为独立测试集。根据有限模型族的 Hoeffding 不等式:

$$E_{\text{out}}(g_{m^*}) \leq E_{\text{test}}(g_{m^*}) + O\left(\sqrt{\frac{\log M}{N_{\text{test}}}}\right)$$

但在实际应用中:

- 测试集 $\mathcal{D}_{\text{test}}$ 往往无法获取
- 这种方法虽然理论上完美, 但在实践中不可行
- 甚至可能被视为“作弊”行为

结论:

仅凭 E_{in} 选择模型 $\rightarrow$ 灾难; 仅凭 E_{test} 选择模型 $\rightarrow$ 不可能。



命题 4.3.2 (误差对比: E_{in} 、 E_{test} 与 E_{val})

	E_{in}	E_{test}	E_{val}
数据来源	训练集 $\mathcal{D}$	独立测试集 $\mathcal{D}_{\text{test}}$	验证集 $\mathcal{D}_{\text{val}} \subset \mathcal{D}$
可行性	随时可用	通常不可获取	随时可用
数据状态	被算法用于训练	从未被使用	未被算法使用
用途	训练/选择模型	最终泛化估计	模型选择
风险	过拟合 (已污染)	无偏估计	合法“作弊”

结论：

利用 E_{val} 进行模型选择，既可行又“合法作弊”。

例题 4.4 选择题：假设集的最小误差假设判定

对于 $\mathcal{X} = \mathbb{R}^d$ ，考虑两个假设集 $\mathcal{H}_+$ 和 $\mathcal{H}_-$ 。 $\mathcal{H}_+$ 包含所有 $w_1 \geq 0$ 的感知机， $\mathcal{H}_-$ 包含所有 $w_1 \leq 0$ 的感知机。记 g_+ 和 g_- 分别为各自假设集中最小 E_{in} 的假设。下列哪项陈述正确？

- 1) 若 $E_{\text{in}}(g_+) < E_{\text{in}}(g_-)$ ，则 g_+ 是所有感知机中的最小 E_{in} 假设。
- 2) 若 $E_{\text{test}}(g_+) < E_{\text{test}}(g_-)$ ，则 g_+ 是所有感知机中的最小 E_{test} 假设。
- 3) 两个假设集是不相交的。
- 4) 以上均不正确。

解答 正确选项为 [1]。两假设集的交集为 $w_1 = 0$ 的感知机，并集是所有感知机。

- 选项 1：因两假设集的并集是所有感知机，若 $E_{\text{in}}(g_+) < E_{\text{in}}(g_-)$ ，则 g_+ 是所有感知机中最小 E_{in} 的假设。
- 选项 2：测试误差与训练误差不同，无法据此判定 g_+ 是所有感知机中最小 E_{test} 的假设。
- 选项 3：两假设集有交集（ $w_1 = 0$ 的感知机），并非不相交。

4.3.2 验证

命题 4.3.3 (验证集模型选择法则)

1. 验证集划分 将数据集 $\mathcal{D}$ （大小为 N ）划分为两部分：

$$\mathcal{D}_{\text{train}} \quad (\text{大小 } N - K) \quad \mathcal{D}_{\text{val}} \quad (\text{大小 } K)$$

其中 $\mathcal{D}_{\text{val}} \subset \mathcal{D}$ 称为验证集，是手头用于模拟测试集的样本，满足：

$$\mathcal{D}_{\text{val}} \stackrel{\text{iid}}{\sim} P(\mathbf{x}, y)$$

为了保证验证集“干净”，只允许将 $\mathcal{D}_{\text{train}}$ 输入给学习算法 $\mathcal{A}_m$ 进行模型拟合。

2. 模型选择流程 对每个模型空间 $\mathcal{H}_m$ 及其算法 $\mathcal{A}_m$ （ $m = 1, \dots, M$ ）执行：

- 1) 使用训练集学习： $g_m^- = \mathcal{A}_m(\mathcal{D}_{\text{train}})$ ；
- 2) 计算其在验证集上的误差： $E_{\text{val}}(g_m^-)$ ；
- 3) 选择验证误差最小的模型：

$$m^* = \arg \min_{1 \leq m \leq M} (E_m = E_{\text{val}}(g_m^-))$$

3. 泛化误差界 对所有 m ，有如下 Hoeffding 泛化保证：

$$E_{\text{out}}(g_m^-) \leq E_{\text{val}}(g_m^-) + O\left(\sqrt{\frac{\log M}{K}}\right)$$

特别地，对模型选择结果 m^* 有：

$$E_{\text{out}}(g_{m^*}^-) \leq E_{\text{val}}(g_{m^*}^-) + O\left(\sqrt{\frac{\log M}{K}}\right)$$

4. 最终模型训练 选定 m^* 后，可在整个数据集 $\mathcal{D}$ 上重新训练得到最终模型：


$$g_{m^*} = \mathcal{A}_{m^*}(\mathcal{D})$$

基于学习曲线的启发式收益，有：


$$E_{\text{out}}(g_{m^*}) \leq E_{\text{out}}(g_{m^*}^-)$$

从而整体泛化误差满足：

$$E_{\text{out}}(g_{m^*}) \leq E_{\text{out}}(g_{m^*}^-) \leq E_{\text{val}}(g_{m^*}^-) + O\left(\sqrt{\frac{\log M}{K}}\right)$$



(a) 训练集与验证集划分示意图



(b) 基于验证集的模型选择

图 4.3.1: 模型选择流程示意图例

命题 4.3.4 (实践中的验证：子模型 vs 全模型，以及 K 的两难)

固定总数据量 N ，当验证集大小 K 从 5 增至 25 时，四种策略的 E_{out} 变化规律如下：

- **in-sample** (直接用 $\mathcal{D}$ 训练并选模型)
 - 对应模型为 $g_{\hat{m}}$ ，其泛化误差恒定为 $E_{\text{out}}(g_{\hat{m}}) \approx 0.56$
 - 误差偏高的原因是模型发生了过拟合
- **sub- g** (用 $\mathcal{D}_{\text{train}}$ 和 $\mathcal{D}_{\text{val}}$ 选模型，最终仍用 $\mathcal{D}_{\text{train}}$ 训练)
 - 对应模型为 $g_{m^*}^-$ ，其 E_{out} 曲线先降低后升高
 - 在某些 K 取值下表现甚至劣于 in-sample 策略
 - 核心原因：训练数据减少 $\Rightarrow$ 所有 g_m 变差
- **full- g** (用 $\mathcal{D}_{\text{train}}$ 和 $\mathcal{D}_{\text{val}}$ 选模型，最后用完整 $\mathcal{D}$ 重新训练)
 - 对应模型为 g_{m^*} ，其 E_{out} 曲线呈单调下降趋势，在 K 较大时会略微上升
 - 满足泛化误差关系： $E_{\text{out}}(g_{m^*}) \leq E_{\text{out}}(g_{m^*}^-)$
 - 经验取值： $K \approx \frac{N}{5}$ 时可接近最优泛化误差
- **optimal** (作弊选择，使用测试集误差 E_{test} 选择)
 - 理论上可达到最优性能，但实际不可行
 - 因测试集在模型训练阶段应保持不可见性

关于 K 选择的两难困境：

- K 偏大：评估准确性提高，但训练数据不足导致模型性能下降
- K 偏小：训练效果较好，但验证集对泛化误差的评估准确性降低

实战中建议取 $K \approx \frac{N}{5}$ ，以平衡评估精度与训练效果。




图 4.3.2: 不同模型期望样本外误差与验证集大小关系图

例题 4.5 选择题：验证过程的总计算代价

对于一个学习模型，使用 N 个样本的训练时间为 N^2 秒。当使用 $K = \frac{N}{5}$ 进行验证，并训练 25 个不同参数的模型以得到最终的 g_{m^*} 时，总时间为：

- 1) $6N^2$
- 2) $17N^2$
- 3) $25N^2$
- 4) $26N^2$

解答 正确选项为 [2]。验证过程分为两步：

1. 训练 25 个模型得到 g_m^- ：每个模型的有效训练样本为 $N - K = \frac{4N}{5}$ ，时间为 $(\frac{4N}{5})^2 = \frac{16}{25}N^2$ ，总时间为 $25 \times \frac{16}{25}N^2 = 16N^2$ 。

2. 训练最终模型 g_{m^*} ：时间为 N^2 。

总时间为 $16N^2 + N^2 = 17N^2$ 。 ■

4.3.3 留一交叉验证

命题 4.3.5 (极端情形： $K = 1$ 的留一交叉验证)

设总样本数为 N 。当验证集大小取 $K = 1$ 时，交叉验证过程如下：

1. 单次验证过程：每一轮从样本集中留出一个样本 $(\mathbf{x}_n, y_n)$ 作为验证点，利用剩余的 $N - 1$ 个样本训练模型 g_n^- 。

2. 单点验证误差定义：

$$E_{\text{val}}^{(n)}(g_n^-) = \text{err}(g_n^-(\mathbf{x}_n), y_n) = e_n$$

其中， $\text{err}(\cdot, \cdot)$ 表示模型预测值与真实值之间的误差度量函数。

3. LOOCV 估计量：留一交叉验证 (Leave-One-Out Cross Validation, LOOCV) 的误差估计量定义

为所有单点验证误差的平均值：

$$E_{\text{loocv}}(\mathcal{H}, \mathcal{A}) = \frac{1}{N} \sum_{n=1}^N e_n = \frac{1}{N} \sum_{n=1}^N \text{err}(g_n^-(\mathbf{x}_n), y_n)$$

4. 估计目标：我们期望该估计量能够近似反映最终模型的泛化误差：

$$E_{\text{loocv}}(\mathcal{H}, \mathcal{A}) \approx E_{\text{out}}(g)$$

其中 g 表示使用全部 N 个样本训练得到的最终模型， $E_{\text{out}}(g)$ 为其泛化误差。

核心思想：每次仅留一个样本用于验证，循环执行 N 次后取平均。

命题 4.3.6 (留一交叉验证 (LOOCV) 的示意与理论保证)

1. 示意图 假设存在两个候选模型，分别为线性模型 $\mathcal{H}_{\text{linear}}$ 和常数模型 $\mathcal{H}_{\text{constant}}$ 。当对 3 个样本分别执行 LOOCV 操作时，单点误差依次记为 e_1 、 e_2 、 e_3 ，则有：

$$E_{\text{loocv}}(\text{linear}) = \frac{e_1 + e_2 + e_3}{3},$$

$$E_{\text{loocv}}(\text{constant}) = \frac{e_1 + e_2 + e_3}{3} \text{ (对应常数模型).}$$

通过对这两个模型的 LOOCV 误差进行比较，我们可以选出：

$$m^* = \arg \min_{1 \leq m \leq M} E_{\text{loocv}}(\mathcal{H}_m, \mathcal{A}_m)$$

2. 理论保证 设 g_n^- 是在数据集 $\mathcal{D} \setminus \{(\mathbf{x}_n, y_n)\}$ (其样本数量为 $N-1$) 上训练得到的模型，那么：

$$E_{\text{loocv}}(\mathcal{H}, \mathcal{A}) = \frac{1}{N} \sum_{n=1}^N \text{err}(g_n^-(\mathbf{x}_n), y_n) = \frac{1}{N} \sum_{n=1}^N E_{\text{out}}(g_n^- | \mathcal{D}_n)$$

其中 $\mathcal{D}_n = \mathcal{D} \setminus \{(\mathbf{x}_n, y_n)\}$ 。对上述等式两边取期望可得：

$$\mathbb{E}_{\mathcal{D}}[E_{\text{loocv}}(\mathcal{H}, \mathcal{A})] = \mathbb{E}_{\mathcal{D}}[E_{\text{out}}(g^-)]$$

这里 g^- 表示在样本数量为 $N-1$ 的随机数据集上训练得到的模型。由此可见，LOOCV 被认为是 $E_{\text{out}}(g)$ 的“几乎无偏估计”。




图 4.3.3: 留一交叉验证示意图

定义 4.3.1 (留一交叉验证 (Leave-One-Out Cross-Validation, LOOCV))

留一交叉验证是一种穷尽式 (exhaustive) 交叉验证方法, 适用于样本量较小的数据集。其流程如下:

1. 设数据集含 N 个样本。
2. 对每一个样本 $i = 1, 2, \dots, N$:
 - 以样本 (x_i, y_i) 为验证集;
 - 其余 $N - 1$ 个样本构成训练集, 训练模型 g_i^- ;
 - 计算验证误差 $e_i = \text{err}(g_i^-(x_i), y_i)$ 。
3. 最终性能估计取所有轮次的平均值

$$\text{LOOCV 误差} \triangleq \frac{1}{N} \sum_{i=1}^N e_i.$$

特性

- 数据利用率高: 几乎利用全部数据进行训练。
- 无随机性: 每次划分唯一确定。
- 计算代价大: 需训练 N 次模型, N 较大时开销显著。
- 期望无偏: $\mathbb{E}[\text{LOOCV 误差}] = \mathbb{E}[E_{\text{out}}(g^-)]$, 其中 g^- 为在 $N - 1$ 个样本上训练的模型。

**例题 4.6 选择题: LOOCV 平方误差计算**

考虑三个样本 $(x_1, y_1), (x_2, y_2), (x_3, y_3)$, 其中 $y_1 = 1, y_2 = 5, y_3 = 7$ 。使用 LOOCV 估计最优常数预测 (平方误差最小) 的性能, 其 E_{loocv} 为:

- 1) 0
- 2) $\frac{56}{9}$
- 3) $\frac{60}{9}$
- 4) 14

解答 正确选项为 [4]。LOOCV 每次留下一个样本, 其余样本的平均为预测值:

- 留下 y_1 : 训练集平均为 6, 误差 $(6 - 1)^2 = 25$;
- 留下 y_2 : 训练集平均为 4, 误差 $(4 - 5)^2 = 1$;
- 留下 y_3 : 训练集平均为 3, 误差 $(3 - 7)^2 = 16$ 。

平均误差为 $\frac{25+1+16}{3} = 14$ 。

**4.3.4 V 折交叉验证****命题 4.3.7 (留一交叉验证 (LOOCV) 的缺点)**

1. 计算代价高 LOOCV 要求将每个样本依次留出作为验证集, 总共需要训练 N 次模型, 其计算公式为:

$$E_{\text{loocv}}(\mathcal{H}, \mathcal{A}) = \frac{1}{N} \sum_{n=1}^N \text{err}(g_n^-(x_n), y_n)$$

其中, g_n^- 表示第 n 次在 $N - 1$ 个样本上训练得到的模型。

在实际应用中, 只有当存在像线性回归的解析解这类特殊情况时, LOOCV 才有可能在较大的 N

下可行，否则其计算量会大到几乎无法处理。

2. 方差大、稳定性差 由于每次验证仅使用单个样本，这使得 LOOCV 的估计量对异常值极为敏感，从而导致：

$$\text{Var}(E_{\text{loocv}}) \gg \text{Var}(E_{\text{k-fold}})$$

命题 4.3.8 (V 折交叉验证 (V-Fold Cross Validation))

1. 计算量缩减思路

- 留一交叉验证：将 $\mathcal{D}$ 均分为 N 份，依次取 1 份验证、 $N-1$ 份训练，共训练 N 次
- V 折交叉验证改进：将 $\mathcal{D}$ 随机均分为 V 份

$$\mathcal{D} = \mathcal{D}_1 \cup \mathcal{D}_2 \cup \cdots \cup \mathcal{D}_V, \quad |\mathcal{D}_i| \approx \frac{N}{V}$$

- 循环验证过程：第 v 折用 $\mathcal{D}_v$ 验证，其余 $V-1$ 份训练得 g_v^-
- V 折误差计算公式：

$$E_{\text{CV}}(\mathcal{H}, \mathcal{A}) = \frac{1}{V} \sum_{v=1}^V \frac{1}{|\mathcal{D}_v|} \sum_{(x,y) \in \mathcal{D}_v} \text{err}(g_v^-(x), y)$$

2. 模型选择

- 通过交叉验证误差选择最优模型：

$$m^* = \arg \min_{1 \leq m \leq M} E_{\text{CV}}(\mathcal{H}_m, \mathcal{A}_m)$$

3. 实用经验

- 实际应用中，推荐选择以下参数：
- $V=10$ （十折交叉验证）或 $V=5$ （五折交叉验证），通常能取得良好效果

4. 验证的本质与报告规范

- 各阶段核心任务：
 - 训练阶段：在假设空间内挑选假设
 - 验证阶段：在候选模型中挑选最终模型
 - 测试阶段：仅作评估，不参与任何选择
- 结果报告原则：
 - 验证误差通常比测试误差乐观，因此应报告最终测试集结果，而非最佳验证结果

定义 4.3.2 (V 折交叉验证 (V-Fold Cross-Validation))

V 折交叉验证（又称 k 折交叉验证）是一种重抽样（resampling）模型验证技术，用于评估统计模型对未知数据的泛化能力。

操作步骤

1. 将含有 N 个样本的数据集随机划分为 V 个互不相交、大小大致相等的子集（称为“折”或“folds”）。
2. 依次取第 v 折（ $v=1, \dots, V$ ）作为验证集，其余 $V-1$ 折作为训练集。
3. 在训练集上训练模型，并在验证集上计算预测误差 e_v 。

4. 重复上述过程 V 次，最终交叉验证误差为

$$E_{cv} = \frac{1}{V} \sum_{v=1}^V e_v.$$

常用设置实践中常取 $V = 5$ 或 $V = 10$ ，分别称为 5 折或 10 折交叉验证。

特性

- 每个样本恰好被用作验证一次，有效利用数据；
- 通过取平均降低因单次划分带来的方差；
- 便于与留一法 ($V = N$) 或随机子抽样法比较，计算代价介于二者之间。



例题 4.7 选择题：10 折交叉验证的总训练时间

对于一个学习模型，使用 N 个样本的训练时间为 N^2 秒。当使用 10 折交叉验证训练 25 个不同参数的模型以得到最终的 g_{m^*} 时，总训练时间为：

- 1) $\frac{47}{2}N^2$
- 2) $47N^2$
- 3) $\frac{407}{2}N^2$
- 4) $407N^2$

解答 正确选项为 [3]。10 折交叉验证每次训练使用 $\frac{9N}{10}$ 个样本，时间为 $(\frac{9N}{10})^2$ 。25 个模型的总训练时间为：

$$25 \times 10 \times \left(\frac{9N}{10}\right)^2 = 25 \times \frac{81}{10}N^2 = 202.5N^2$$

最终模型训练时间为 N^2 ，总时间为：

$$202.5N^2 + N^2 = \frac{407}{2}N^2$$



4.3.5 总结



笔记 [验证]

- 模型选择问题：用 E_{in} 危险，用 E_{test} 又不诚实。
- 验证：在训练集 $\mathcal{D}_{train}$ 上训练模型 $\mathcal{A}_m$ ，用验证误差 E_{val} 选模型，最后把最佳模型 $\mathcal{A}_{m^*}$ 放回完整数据 $\mathcal{D}$ 再训练。
- 留一交叉验证：计算量巨大，但估计几乎无偏。
- V 折交叉验证：计算与性能之间的折中方案。

4.4 三大学习原则

4.4.1 奥卡姆剃刀

定义 4.4.1 (奥卡姆剃刀 (Occam's Razor))

奥卡姆剃刀，又称“简约原则”，是一条哲学与科学方法论原则，主张

“如无必要，勿增实体。”

具体而言，当存在多个能够同等程度解释观测现象的假设时，应当优先选择假设数目最少（或结构最简单）的那一个。该原则由 14 世纪英格兰逻辑学家、方济会修士威廉·奥卡姆 (William of Ockham) 提出，故以其名命名。

在机器学习语境中，奥卡姆剃刀常被转述为：“在训练误差相近的模型中，选择复杂度较低者，以降低过拟合风险并提高泛化性能。”

注意 奥卡姆剃刀并非断言简单假设必然正确，而是一种启发式策略：在缺乏进一步证据前，优先采纳简洁解释，以减少不必要的复杂性与潜在错误。



命题 4.4.1 (简单即更好：奥卡姆剃刀在机器学习中的阐释)

1. 简单的定义

- 简单假设 h ：由少量参数（比特）唯一确定，假设描述长度 $\ell(h)$ 较小。
- 简单模型 $\mathcal{H}$ ：所含假设总数 $|\mathcal{H}|$ 较小，即增长函数 $m_{\mathcal{H}}(N)$ 更小。
- 二者联系：
 - 若 h 由 ℓ 比特描述，则 $h \in \mathcal{H}$ 且 $|\mathcal{H}| \leq 2^\ell$ ；
 - 因此有 $\ell(h) \downarrow \implies |\mathcal{H}| \downarrow \implies m_{\mathcal{H}}(N) \downarrow$ 。

2. 哲学与实用理由

- 数学保证：对于相同的训练误差， $|\mathcal{H}|$ 越小， $\Omega(\mathcal{H}; N)$ 越小，泛化界越紧。
- 哲学直觉：
 - 简单模型“完美”拟合数据的概率更低；
 - 一旦拟合成功，其统计显著性更高。
- 实践建议：永远先尝试线性模型，再逐步增加复杂度，并自问“数据是否被过度建模？”



例题 4.8 选择题：决策树桩的可分性概率

考虑 $\mathbb{R}^1$ 中的决策树桩作为假设集 $\mathcal{H}$ ，其生长函数 $m_{\mathcal{H}}(N) = 2N$ 。对于 10 个独立同分布 (i.i.d.) 的样本，标签由公平硬币生成，数据 $\mathcal{D}$ 被 $\mathcal{H}$ 可分的概率为：

- 1) $\frac{1}{1024}$
- 2) $\frac{10}{1024}$
- 3) $\frac{20}{1024}$
- 4) $\frac{100}{1024}$

解答 正确选项为 [3]。决策树桩的生长函数 $m_{\mathcal{H}}(10) = 20$ ，表示最多可实现 20 种标签分配。总标签分配数为 $2^{10} = 1024$ ，因此可分概率为： $P(\text{可分}) = \frac{20}{1024}$ 。 ■

4.4.2 采样偏差

定义 4.4.2 (采样偏差 (Sampling Bias))

采样偏差，又称选择偏差 (Selection Bias)，是指在抽样过程中，由于抽样方案或执行方式不当，导致样本不能代表总体，从而对总体参数产生系统性偏离的误差。

特征与成因

- 系统性：与随机抽样误差不同，采样偏差不会随样本量增加而减小，必须通过改进抽样设计或校正方法消除。
- 常见类型：
 - 抽样框偏差：抽样框未能覆盖全部总体单位；
 - 非随机抽样：便利抽样、自愿者抽样等导致样本自选择；
 - 分层失衡：各层样本比例与总体比例不符。

量化与检测

$$\text{采样偏差} = \mathbb{E}[\hat{\theta}_{\text{sample}}] - \theta_{\text{population}},$$

其中 $\hat{\theta}_{\text{sample}}$ 为样本统计量， $\theta_{\text{population}}$ 为总体真值。

减少策略

- 使用概率抽样（简单随机、分层、整群、系统抽样）；
- 扩大或校正抽样框；
- 事后加权或校准估计。



命题 4.4.2 (应对采样偏差)

若训练数据存在采样偏差，则学到的模型也会继承同样的偏差。

实用经验法则

- 让训练/验证的数据分布尽可能贴近测试场景。
- 举例：若测试阶段的输入为“用户最近记录”（如 KDDCup 2011），则
 - 训练：应加重近期样本的权重；
 - 验证：使用“靠后”的用户记录。



4.4.3 数据偷窥

定义 4.4.3 (数据偷窥 (Data Snooping / Peeking))

数据偷窥是指在完成正式分析或建模之前，过早地查看数据或初步结果，并据此调整分析流程、特征选择、模型结构或超参数的行为。该行为会导致统计结论出现系统性偏差，通常表现为：

- I 类错误膨胀：假阳性率被人为提高，使原本不显著的结论看似显著。
- 泛化性能虚高：训练-验证误差被低估，模型在实际部署时表现远低于预期。
- 可重复性受损：由于分析路径受偷窥结果影响，他人难以复现相同结论。

常见表现

- 根据初步显著性水平事后删减变量或重选阈值；
- 反复调参直到验证指标“足够好”；

- 在训练集上观察分布后人为构造特征。

避免策略

- 预先注册分析计划，锁定特征、模型及评价指标；
- 引入独立测试集，仅在最终一次性评估；
- 采用交叉验证或嵌套交叉验证，确保每一次调参都在训练折上完成；
- 对多次比较进行多重检验校正（如 Bonferroni、FDR）。



命题 4.4.3 (应对数据偷窥)

完全避免数据偷窥几乎不可能，除非极端坦诚。

极端坦诚做法 把测试数据锁进保险箱，永不提前查看。

相对可行的折中做法

- 保留验证集，但谨慎使用：任何基于验证集的调参都需记录并自我审查。
- 保持“盲视”：在建模阶段避免用任何数据结果做决策。
- 保持“怀疑”：对所有研究结果（包括自己的）都假设已受污染，并用“污染感”去解读。

核心思想 在“数据驱动建模（必要偷窥）”与“验证无偷窥”之间取得精细平衡。



4.4.4 三的威力

命题 4.4.4 (三大相关领域)

- 数据挖掘（Data Mining） 利用海量数据发现其中有趣或有价值的模式与规律。
- 人工智能（AI） 构建能够表现出智能行为的系统或算法，以解决复杂任务。
- 统计学（Statistics） 基于数据对未知总体或过程进行推断、估计与假设检验。

相互关系

- 机器学习（ML）是连接三者的桥梁之一；
- 统计学为机器学习提供了大量有用工具；
- 数据挖掘与机器学习在实践中难以严格区分；
- 三者共同构成实现人工智能的一条可行路径。



命题 4.4.5 (三大理论边界)

- Hoeffding** 不等式（单假设）

$$\mathbb{P}[|E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon] \leq 2 \exp(-2\varepsilon^2 N).$$

适用于对 单个固定假设的误差验证或测试。

- 多箱 **Hoeffding** 不等式（有限假设集）

$$\mathbb{P}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon] \leq 2M \exp(-2\varepsilon^2 N),$$

其中 $M = |\mathcal{H}|$ 。适用于 验证（有限候选模型）场景。

- VC** 界（无限假设集）

$$\mathbb{P}[\exists h \in \mathcal{H}, |E_{\text{in}}(h) - E_{\text{out}}(h)| > \varepsilon] \leq 4 m_{\mathcal{H}}(2N) \exp(-\frac{1}{8}\varepsilon^2 N),$$

以增长函数 $m_{\mathcal{H}}(N)$ 代替 M ，适用于训练阶段对任意规模假设集 $\mathcal{H}$ 的泛化保证。

命题 4.4.6 (三大线性模型)

1. 感知机算法 / Pocket 算法

假设函数: $h(x) = \text{sign}(s)$, 其中 $s = w^\top x$

损失函数: 0/1 损失 (不可微)

优化特点: 对线性可分数据保证收敛; 对含噪数据可通过 Pocket 算法进行启发式改进

2. 线性回归

假设函数: $h(x) = s = w^\top x$

损失函数: 平方损失 (二次可微)

优化特点: 存在解析解 $w = (X^\top X)^{-1} X^\top y$, 计算简便, 适用于小翻转噪声场景

3. 逻辑回归

假设函数: $h(x) = \sigma(s) = \frac{1}{1 + e^{-s}}$, 输出概率值

损失函数: 交叉熵损失 (对应最大似然估计)

优化特点: 无闭式解, 需采用迭代算法 (如梯度下降、Newton 法等)

命题 4.4.7 (三大关键工具)

1. 特征变换 (Feature Transform)

通过复杂映射 ϕ 将原始特征提升到高维空间, 从而降低 E_{in} , 但会增大 $d_{\text{VC}}(\mathcal{H})$ 。

2. 正则化 (Regularization)

在损失函数中加入正则项 $\Omega(w)$, 把有效 VC 维 $d_{\text{EFF}}(\mathcal{H}, \lambda)$ 控制到较小值, 防止过拟合, 代价是 E_{in} 可能略升。

3. 验证 (Validation)

预留 K 个样本作验证集 $\mathcal{D}_{\text{val}}$, 用 E_{val} 从有限候选 $\{g_1, \dots, g_M\}$ 中选出最佳模型, 减少选择自由度, 换取可靠的泛化估计。

命题 4.4.8 (三大学习原则)

1. 奥卡姆剃刀 (Occam's Razor)

当不同假设的训练误差相近时, 应优先选择结构更简单的模型。这一原则的核心是通过控制模型复杂度降低过拟合风险, 在保证拟合能力的同时提升泛化性能。

2. 采样偏差 (Sampling Bias)

训练数据的分布必须与测试场景 (真实世界) 的分布保持一致。若违背此原则, 模型学到的将只是训练数据的特定模式, 而非问题的本质规律, 最终导致泛化能力低下。

3. 数据偷窥 (Data Snooping)

建模过程中任何对测试数据或未公开结果的提前窥探, 都会引入隐性偏差并污染最终结论。严谨的做法是将测试数据严格隔离, 仅在模型确定后进行一次评估, 避免反复利用测试信息调整模型。

命题 4.4.9 (三大未来方向)

1. 更多变换 (More Transform)

通过核技巧、深度网络、特征嵌入等手段，把数据映射到更丰富的高维空间，以捕捉复杂结构。

2. 更多正则 (More Regularization)

采用稀疏约束、最大间隔、集成平均、提前停止等策略，抑制过拟合并提升泛化性能。

3. 更少标签 (Less Label)

借助无监督学习、半监督学习、自编码器、主动学习等方法，在标签稀缺的场景下仍能学得有效模型。

代表性技术与工具

- 核方法：SVM、核逻辑回归、RBF 网络、高斯核、二次规划。
- 集成与提升：Bagging、AdaBoost、随机森林、GBDT、OOB 误差。
- 稀疏与降维：PCA、矩阵分解、坐标下降、L1 正则。
- 深度学习：自编码器、深度神经网络、原型学习、k-means。
- 大间隔理论：软间隔、支持向量回归 (SVR)、概率 SVM。



4.4.5 总结



笔记 [三大学习原则]

- 奥卡姆剃刀：如无必要，勿增实体——优先选择最简单的假设。
- 采样偏差：训练数据的采集方式必须与测试场景尽量匹配。
- 数据偷窥：任何对数据的“提前使用”都是污染。
- 三的威力：诸多概念（如上界、模型、工具、原则等）常以‘三’组合出现。

间章：机器如何学得更好？

笔记 [机器如何学得更好?]

“**How Can Machines Learn Better?**”（机器如何学得更好？）是我们第四章所聚焦的核心问题。通过系统性地规避风险、优化模型与规范流程，可从四个关键维度解析提升机器学习效果的路径：

1. 规避过拟合：筑牢学习的基础防线

过拟合是机器学习效果不佳的主要诱因，本质是模型过度捕捉训练数据中的噪声，应对策略体现为：

- 识别过拟合特征：当训练误差 E_{in} 显著降低而测试误差 E_{out} 反而升高时，模型已陷入过拟合；
- 数据层面优化：通过数据清洗剔除异常值、数据剪枝保留核心样本、数据提示扩充有效数据量；
- 模型选择原则：优先使用简单模型，避免盲目提升复杂度，在拟合能力与泛化风险间找到平衡。

规避过拟合的核心是让模型“专注于规律而非噪声”，为学习效果的提升奠定基础。

2. 正则化：主动调控模型复杂度

正则化通过引入约束机制，在保证模型拟合能力的同时抑制过度复杂，是提升泛化性能的核心技术：

- 核心思想：在误差函数中加入正则项（如 L_2 范数惩罚），构建增广误差 $E_{aug}(w) = E_{in}(w) + \lambda\Omega(w)$ ，使模型在最小化训练误差的同时偏好更简洁的参数配置；
- 作用机制：通过限制参数规模降低模型的有效 VC 维，缩小假设空间范围；
- 实践价值：正则化参数 λ 可灵活调节约束强度，实现“复杂度与拟合度”的精细化平衡，例如在岭回归中通过调整 λ 控制权重向量的大小。

正则化是机器主动控制学习过程的关键工具，使高复杂度模型在保持拟合能力的同时具备良好泛化性。

3. 验证：科学筛选最优模型

验证通过合理的数据划分与评估机制，确保选出的模型真正适配问题本质：

- 基础策略：将数据集划分为训练集（拟合模型）与验证集（评估泛化），通过验证误差（ E_{val} ）从候选模型中筛选最优者，避免仅依赖训练误差导致的选择偏差；
- 进阶方法：交叉验证（如 10 折交叉验证）通过多次划分数据取平均，减少单次评估的随机性，尤其适用于小样本场景；留一交叉验证（LOOCV）最大化数据利用率，提供更稳定的泛化估计；
- 最终训练：选定最优模型后，在完整数据集上重新训练，进一步提升模型性能。

验证是“客观评估模型泛化潜力”的科学方法，确保选出的模型不仅适配训练数据，更能推广到未知场景。

4. 遵循学习原则：保障学习的科学性

三大原则从方法论层面规范学习过程，避免策略性偏差：

- 奥卡姆剃刀：在训练误差相近时，优先选择结构更简单的模型，通过降低复杂度减少过拟合风险；
- 采样偏差：确保训练数据分布与测试场景一致，避免因数据代表性不足导致模型失效；
- 数据偷窥：严格隔离测试数据，避免在建模过程中提前使用测试信息调整策略，保证评估结果的客观性。

结语：机器学得更好的过程，是“规避过拟合 → 正则化调控 → 验证筛选 → 遵循原则”的系统优化：通过技术手段与方法论约束，实现从“能学习”到“学得精准、稳定、可靠”的跨越。

第 5 章 嵌入大量特征：核模型

5.1 线性支持向量机

5.1.1 大间隔分离超平面

命题 5.1.1 (线性分类的选择)

若未来输入 x 受（近似高斯）噪声扰动，则

- 噪声强度与 x 到分离超平面的距离呈正相关；
- 距离越大，对噪声的容忍度越高；
- 因此，噪声容忍度 $\propto$ 超平面到最近样本点 X_n 的距离。

结论 最右侧的超平面（即与最近样本点距离最大的超平面）具有最大的噪声容忍度，从而对过拟合更加鲁棒。




图 5.1.1: 线性分类示意图

定义 5.1.1 (最大间隔分离超平面 (Large-Margin Separating Hyperplane))

给定训练集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ ，其中 $y_n \in \{-1, +1\}$ 。

优化目标

$$\max_w \text{margin}(w) \quad \text{s.t.} \quad y_n w^\top x_n > 0, \quad n = 1, \dots, N$$

间隔定义

$$\text{margin}(w) = \min_{n=1, \dots, N} \text{distance}(x_n, w),$$

即超平面到最近样本点的距离，亦称“胖度”。

结论：寻找能够正确分类所有样本且间隔最大的分离超平面。



5.1.2 标准大间隔问题

命题 5.1.2 (点到超平面的距离：几何推导与最大间隔)

设超平面 $\mathcal{H}$ 由仿射方程

$$w^\top x + b = 0, \quad w \in \mathbb{R}^d, b \in \mathbb{R}$$

给出，其中 $w \neq 0$ 。对任意点 $x \in \mathbb{R}^d$ ，其到超平面 $\mathcal{H}$ 的欧几里得距离 $\text{distance}(x, b, w)$ 的推导如下：

几何推导

1. 取超平面 $\mathcal{H}$ 上任意一点 x' ，满足 $w^\top x' + b = 0$ 。
2. 向量 $x - x'$ 指向点 x ；将其投影到法向量 w 上即得垂直距离：

$$\text{distance}(x, b, w) = \frac{|w^\top (x - x')|}{\|w\|} = \frac{|w^\top x + b|}{\|w\|},$$

最大间隔 (maximal margin)

若 $\mathcal{H}$ 是分离超平面，即对所有训练样本 (x_n, y_n) 有

$$y_n(w^\top x_n + b) > 0, \quad n = 1, \dots, N,$$

则定义训练集到该平面的几何间隔 (functional margin 已归一化) 为

$$\text{margin}(b, w) \triangleq \min_{n=1, \dots, N} \frac{y_n(w^\top x_n + b)}{\|w\|}.$$

最大化 $\text{margin}(b, w)$ 的超平面 (b^*, w^*) 称为最大间隔分离超平面，满足

$$(b^*, w^*) = \arg \max_{b, w} \min_n \frac{y_n(w^\top x_n + b)}{\|w\|}.$$

该平面对所有样本具有最大鲁棒裕度，从而具备最优的泛化保证。



命题 5.1.3 (最大间隔超平面的归一化推导)

设训练集 $\{(x_n, y_n)\}_{n=1}^N$ 线性可分。最大间隔超平面可由以下等价优化刻画：

1. 原始几何间隔

对任意候选超平面 (b, w) ，定义

$$\text{margin}(b, w) = \min_n \frac{y_n(w^\top x_n + b)}{\|w\|},$$

其中约束为 $y_n(w^\top x_n + b) > 0, n = 1, \dots, N$ 。

2. 标度不变性

超平面方程 $w^\top x + b = 0$ 与 $\lambda w^\top x + \lambda b = 0$ ($\lambda > 0$) 描述同一平面，故几何间隔仅取决于方向 $(w/\|w\|)$ 与偏移 $b/\|w\|$ ，整体缩放不影响几何距离。

3. 特殊归一化

不失一般性，固定函数间隔为 1：令

$$\min_n y_n(w^\top x_n + b) = 1.$$

在此标度下，几何间隔简化为

$$\text{margin}(b, w) = \frac{1}{\|w\|}.$$

4. 最终优化形式

最大化间隔等价于最小化权重范数：

$$\min_{b,w} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_n(w^\top x_n + b) \geq 1, \quad n = 1, \dots, N.$$

该凸二次规划的唯一解 (b^*, w^*) 即为最大间隔分离超平面。



5.1.3 支持向量机

定义 5.1.2 (支持向量机 (Support Vector Machine, SVM))

支持向量机是一种监督式学习方法，用于分类与回归分析。其基本思想是在特征空间中构造一个（或一组）能够最大化类别之间间隔的超平面，使得不同类别的样本点被正确划分，并且离最近样本的距离尽可能远，从而提高模型的泛化能力。

更具体地，给定训练集

$$\{(x_i, y_i)\}_{i=1}^N \subset \mathbb{R}^d \times \{-1, +1\},$$

SVM 求解如下凸二次规划问题：

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i, \\ \text{s.t.} \quad & y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, N, \end{aligned}$$

其中 $w \in \mathbb{R}^d$ 为法向量， $b \in \mathbb{R}$ 为偏置， ξ_i 为松弛变量， $C \geq 0$ 为惩罚参数。

满足 $y_i(w^\top x_i + b) = 1$ 的训练样本称为支持向量，它们决定了最优超平面的位置与方向。

当数据线性不可分时，SVM 通过核函数 (Kernel trick) 将样本映射到高维（甚至无限维）特征空间，使得在高维空间中线性可分，并使用相同的二次规划框架求解。

因此，支持向量机可视为：

- 特征空间上的最大间隔线性分类器；
- 可借助核技巧推广为非线性分类器；
- 最终模型仅由支持向量决定，具有稀疏性和良好泛化能力。



命题 5.1.4 (SVM 的二次规划刻画)

对线性可分训练集 $\{(x_n, y_n)\}_{n=1}^N$ ，支持向量机等价于求解凸二次规划：

$$\min_{b,w} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_n(w^\top x_n + b) \geq 1, \quad n = 1, \dots, N$$

令 $u = \begin{pmatrix} b \\ w \end{pmatrix} \in \mathbb{R}^{d+1}$ ，可进一步写成标准 QP 形式：

$$\min_u \frac{1}{2} u^\top Q u + p^\top u \quad \text{s.t.} \quad A u \geq c$$

其中：

$$Q = \begin{pmatrix} 0 & 0_d^\top \\ 0_d & I_d \end{pmatrix}, \quad p = 0_{d+1}$$

$$A = \begin{bmatrix} y_1(1, x_1^\top) \\ y_2(1, x_2^\top) \\ \vdots \\ y_N(1, x_N^\top) \end{bmatrix}, \quad c = \mathbf{1}_N$$

该凸问题存在唯一全局最优解 (b^*, w^*) ，其对应的超平面即为最大间隔分离超平面。

算法 5.1.13: 线性硬间隔 SVM (QP 求解器实现)

输入: 训练集 $\{(x_n, y_n)\}_{n=1}^N \subset \mathbb{R}^d \times \{-1, +1\}$

输出: 超平面参数 (b, w) 与决策函数 g_{SVM}

1. 构造 QP 参数

$p \leftarrow 0_{d+1} \in \mathbb{R}^{d+1}$

对每个 $n = 1, \dots, N$:

$a_n \leftarrow y_n \begin{bmatrix} 1 \\ x_n \end{bmatrix} \in \mathbb{R}^{d+1}, \quad c_n \leftarrow 1$

$Q \leftarrow \begin{pmatrix} 0 & 0_d^\top \\ 0_d & I_d \end{pmatrix} \in \mathbb{R}^{(d+1) \times (d+1)}$

2. 调用 QP 求解器

$(b, w) \leftarrow \text{QP}(Q, p, [a_n]_{n=1}^N, [c_n]_{n=1}^N)$

3. 返回模型

$g_{\text{SVM}}(x) \leftarrow \text{sign}(w^\top x + b)$

性质: 硬间隔保证所有样本位于“胖边界”之外，无违反。

5.1.4 大间隔超平面的理由

命题 5.1.5 (大间隔限制二分法)

设“大间隔算法” $\mathcal{A}_\rho$ 满足:

- 若存在间隔 $\text{margin}(g) \geq \rho$ 的假设，则返回该假设;
- 否则返回 $\emptyset$ 。

对比示例

- $\mathcal{A}_0$ (等价于 PLA) 可打散“一般”三个输入;
- $\mathcal{A}_{1.126}$ (比 SVM 更严格) 可能无法打散任何三个输入。

结论 增大间隔 ρ 减少了可实现二分法 (dichotomies) 的数量，从而

$$d_{\text{VC}}(\mathcal{A}_\rho) \downarrow \Rightarrow \text{泛化性能提升。}$$

命题 5.1.6 (大间隔算法的 VC 维上界)

设大间隔算法 $\mathcal{A}_\rho$ 在半径为 R 的超球 $\mathcal{B}_R \subset \mathbb{R}^d$ 上运行，则其 VC 维满足:

$$d_{\text{VC}}(\mathcal{A}_\rho) \leq \min \left\{ \left\lceil \frac{R^2}{\rho^2} \right\rceil + 1, d + 1 \right\}$$

特例：二维单位圆当 $\mathcal{X}$ 为单位圆 $S^1 \subset \mathbb{R}^2$ 时：

- $\rho = 0$ （退化为感知器）： $d_{VC} = 3$ ，可打散任意三点；
- $\rho > \frac{\sqrt{3}}{2}$ ：因任意三点中必有两点弧距 $\leq \sqrt{3}$ ，故无法被打散， $d_{VC} < 3$ 。

结论 间隔 ρ 越大， $d_{VC}(\mathcal{A}_\rho)$ 越小，模型复杂度越低，泛化保证越强。

命题 5.1.7 (大间隔超平面的双重收益)

令 $\mathcal{H}_\rho$ 表示间隔至少为 ρ 的超平面集合。

1. 线性场景

$\mathcal{H}_\rho$ 本身可实现边界有限，VC 维 $d_{VC}(\mathcal{H}_\rho) \leq d + 1$ ；保持模型简单，对泛化有利。

2. 引入特征变换 Φ

通过映射 $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}^D$ 后， $\mathcal{H}_\rho$ 在高维空间可构造复杂决策边界，同时

$$d_{VC}(\mathcal{H}_\rho \circ \Phi) \leq \min\left\{\frac{R^2}{\rho^2} + 1, D + 1\right\}$$

仍受控；既降低 E_{in} ，又维持较低的模型复杂度。

结论 大间隔超平面 + 任意特征变换 Φ 产生“非线性 SVM”：边界可复杂，参数数量可庞大，但有效 VC 维依旧受限，在降低训练误差的同时保持优异泛化性能。

例题 5.1 选择题：大间隔算法的 VC 维上界

考虑在 $\mathcal{Z}$ -空间中运行大间隔算法 $\mathcal{A}_\rho$ ，其中 $\rho = \frac{1}{4}$ ，特征向量 $\mathbf{z} = \phi(\mathbf{x})$ 的维度为 1126（不包括 z_0 ），且 $\|\mathbf{z}\| \leq 1$ 。使用公式 $\min\left(\frac{R^2}{\rho^2}, d\right) + 1$ 计算 $d_{VC}(\mathcal{A}_\rho)$ 的上界：

- 1) 5
- 2) 17
- 3) 1126
- 4) 1127

解答 正确选项为 [2]。根据公式 $d_{VC}(\mathcal{A}_\rho) \leq \min\left(\frac{R^2}{\rho^2}, d\right) + 1$ ：

$R = 1$ ， $\rho = \frac{1}{4}$ ，故 $\frac{R^2}{\rho^2} = 16$ 。 $d = 1126$ ，因此 $\min(16, 1126) = 16$ 。最终上界为 $16 + 1 = 17$ 。 ■

5.1.5 总结



笔记 [线性支持向量机]

- 大间隔分离超平面：直观上对噪声更鲁棒。
- 标准大间隔问题：在特定分离尺度下最小化 $\|w\|$ 。
- 支持向量机：通过二次规划“轻松”求解。
- 大间隔超平面的理由：二分法数量更少，泛化性能更优。

5.2 对偶支持向量机

5.2.1 对偶 SVM 的动机

命题 5.2.1 (非线性硬间隔 SVM 的 QP 刻画)

给定训练集 $\{(x_n, y_n)\}_{n=1}^N$ 与特征映射 $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}^D$, 非线性硬间隔 SVM 等价于在 $D+1$ 维空间求解

$$\min_{b, w} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_n(w^\top \Phi(x_n) + b) \geq 1, \quad n = 1, \dots, N.$$

需求: 大间隔 (参数不多) 却能通过 Φ 产生复杂边界。

挑战: 当 D 很大甚至无限时, $D+1$ 个变量与 N 条约束的 QP 难以直接求解。

目标: 消除对维度 D 的显式依赖, 引出后续核技巧。

命题 5.2.2 (拉格朗日乘子: 约束转无约束)

令拉格朗日乘子 $\alpha_n \geq 0, n = 1, \dots, N$ 。对硬间隔 SVM 的原始问题

$$\min_{b, w} \frac{1}{2} w^\top w \quad \text{s.t.} \quad y_n(w^\top z_n + b) \geq 1,$$

构造拉格朗日函数

$$\mathcal{L}(b, w, \alpha) = \frac{1}{2} w^\top w + \sum_{n=1}^N \alpha_n [1 - y_n(w^\top z_n + b)].$$

等价刻画

$$\min_{b, w} \max_{\alpha \geq 0} \mathcal{L}(b, w, \alpha) = \begin{cases} +\infty, & \text{若存在约束被违反, 即存在 } k \text{ 使得 } y_k(w^\top z_k + b) \leq 1; \\ \frac{1}{2} w^\top w, & \text{若全部约束满足, 即对任意 } k \text{ 有 } y_k(w^\top z_k + b) \geq 1. \end{cases}$$

结果 所有显式约束被隐藏于 $\max_{\alpha \geq 0} \mathcal{L}(b, w, \alpha)$ 中, 实现“约束优化 $\rightarrow$ 无约束鞍点问题”的转化。

例题 5.2 选择题: 硬间隔 SVM 的拉格朗日函数

考虑两个变换后的样本 $(z_1, +1)$ 和 $(z_2, -1)$, 其中 $z_2 = -z_1 = -z$ 。硬间隔 SVM 的拉格朗日函数 $\mathcal{L}(b, w, \alpha)$ 为:

- 1) $\frac{1}{2} w^T w + \alpha_1(1 + w^T z + b) + \alpha_2(1 + w^T z + b)$
- 2) $\frac{1}{2} w^T w + \alpha_1(1 - w^T z - b) + \alpha_2(1 - w^T z + b)$
- 3) $\frac{1}{2} w^T w + \alpha_1(1 + w^T z + b) + \alpha_2(1 + w^T z - b)$
- 4) $\frac{1}{2} w^T w + \alpha_1(1 - w^T z - b) + \alpha_2(1 - w^T z - b)$

解答 正确选项为 [2]。硬间隔 SVM 的拉格朗日函数为:

$$\mathcal{L} = \frac{1}{2} w^T w + \alpha_1(1 - y_1(w^T z_1 + b)) + \alpha_2(1 - y_2(w^T z_2 + b))$$

代入 $y_1 = +1, y_2 = -1, z_2 = -z_1 = -z$, 化简得:

$$\mathcal{L} = \frac{1}{2} w^T w + \alpha_1(1 - w^T z - b) + \alpha_2(1 - w^T z + b)$$

5.2.2 拉格朗日对偶 SVM

命题 5.2.3 (拉格朗日对偶问题)

记拉格朗日函数：

$$\mathcal{L}(b, w, \alpha) = \frac{1}{2}w^\top w + \sum_{n=1}^N \alpha_n [1 - y_n(w^\top z_n + b)], \quad \alpha_n \geq 0$$

对任意固定的 $\alpha' \geq 0$, (由于 $\max \geq \text{any}$), 因此有：

$$\min_{b, w} \left(\max_{\alpha \geq 0} \mathcal{L}(b, w, \alpha) \right) \geq \min_{b, w} \mathcal{L}(b, w, \alpha')$$

取右侧对 α' 取最大, 可得：

$$\min_{b, w} \left(\max_{\alpha \geq 0} \mathcal{L}(b, w, \alpha) \right) \geq \max_{\alpha' \geq 0} \min_{b, w} \mathcal{L}(b, w, \alpha')$$

这是由于右侧是左侧的一个下界, 而最大化这个下界可以得到一个更紧的下界。

其中右侧即为拉格朗日对偶问题：

$$\max_{\alpha' \geq 0} \min_{b, w} \mathcal{L}(b, w, \alpha')$$

这表示在外层对 α 进行最大化, 等价于对原始问题下界的最大化。

强对偶性的条件：对于二次规划问题, 当满足以下条件时, 弱对偶性的不等式可以变为等式：

- 原问题是凸的
- 原问题可行 (如果数据 Φ 是可分的)
- 约束是线性的

这些条件被称为约束品性 (constraint qualification)。

当强对偶性成立时, 存在原问题和对偶问题的最优解 (b, w, α) 使得两者的最优值相等。

命题 5.2.4 (拉格朗日对偶的化简步骤)

记拉格朗日函数：

$$\mathcal{L}(b, w, \alpha) = \frac{1}{2}w^\top w + \sum_{n=1}^N \alpha_n [1 - y_n(w^\top z_n + b)], \quad \alpha_n \geq 0$$

1. 消去变量 b

对固定 α , 考虑内层无约束最小化问题：

$$\min_{b, w} \mathcal{L}(b, w, \alpha)$$

在最优解处满足偏导数为零的条件：

$$\frac{\partial \mathcal{L}(b, w, \alpha)}{\partial b} = 0 \implies \sum_{n=1}^N \alpha_n y_n = 0$$

这一条件使得 b 被消去, 目标函数仅依赖于 w 。

2. 消去变量 w

同样地, 对 w 求偏导并令其为零：

$$\frac{\partial \mathcal{L}(b, w, \alpha)}{\partial w} = 0 \implies w = \sum_{n=1}^N \alpha_n y_n z_n$$

将 w 代入拉格朗日函数，得到仅含 α 的目标函数：

$$\mathcal{L}(\alpha) = \sum_{n=1}^N \alpha_n - \frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n z_n \right\|^2$$

最终对偶问题 通过上述消元过程，原问题转化为仅含 α 的二次规划：

$$\max_{\alpha} \left\{ \sum_{n=1}^N \alpha_n - \frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n z_n \right\|^2 \right\} \quad \text{s.t.} \quad \sum_{n=1}^N \alpha_n y_n = 0, \alpha_n \geq 0.$$



命题 5.2.5 (KKT 最优性条件)

设原始问题为

$$\min_{b, w} \frac{1}{2} w^\top w \quad \text{s.t.} \quad y_n (w^\top z_n + b) \geq 1$$

化简后的对偶问题为

$$\max_{\alpha} \left\{ \sum_{n=1}^N \alpha_n - \frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n z_n \right\|^2 \right\} \quad \text{s.t.} \quad \sum_{n=1}^N \alpha_n y_n = 0, \alpha_n \geq 0$$

设 (b, w, α) 为原始-对偶最优解，则下列 Karush-Kuhn-Tucker (KKT) 条件成立，且在凸 QP 中既是必要也是充分条件：

1. 原始可行性

$$y_n (w^\top z_n + b) \geq 1, \quad n = 1, \dots, N.$$

2. 对偶可行性

$$\alpha_n \geq 0, \quad n = 1, \dots, N.$$

3. 对偶-内点最优性

$$\sum_{n=1}^N \alpha_n y_n = 0, \quad w = \sum_{n=1}^N \alpha_n y_n z_n.$$

4. 原始-内点最优性（互补松弛）

$$\alpha_n [1 - y_n (w^\top z_n + b)] = 0, \quad n = 1, \dots, N.$$

用途 利用上述 KKT 条件，可从最优 α 直接反演得到 (b, w) ，从而完成 SVM 求解。



例题 5.3 选择题：KKT 条件的验证

对于单变量 w ，考虑最小化 $\frac{1}{2}w^2$ ，约束为 $w \geq 1$ 和 $w \leq 3$ 。拉格朗日函数为 $\mathcal{L}(w, \alpha) = \frac{1}{2}w^2 + \alpha_1(1 - w) + \alpha_2(w - 3)$ 。下列哪些方程属于该优化问题的 KKT 条件？

- 1) $\alpha_1 \geq 0$ 且 $\alpha_2 \geq 0$
- 2) $w = \alpha_1 - \alpha_2$
- 3) $\alpha_1(1 - w) = 0$ 且 $\alpha_2(w - 3) = 0$
- 4) 以上所有

解答 正确选项为 [4]。KKT 条件包括：

- 拉格朗日乘子非负性： $\alpha_1 \geq 0, \alpha_2 \geq 0$ ；
- 梯度条件： $w = \alpha_1 - \alpha_2$ ；
- 互补松弛条件： $\alpha_1(1 - w) = 0, \alpha_2(w - 3) = 0$ 。

所有选项均满足 KKT 条件。 ■

5.2.3 求解对偶 SVM

命题 5.2.6 (支持向量机的对偶形式与 QP 形式)

硬间隔支持向量机 (SVM) 的对偶问题可以表示为以下凸二次规划 (Quadratic Programming, QP) 问题：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m (z_n^\top z_m) - \sum_{n=1}^N \alpha_n \\ \text{s.t.} \quad & \sum_{n=1}^N \alpha_n y_n = 0, \quad \alpha_n \geq 0, \quad n = 1, \dots, N. \end{aligned}$$

这是一个包含 N 个变量与 $N+1$ 条线性约束的凸二次规划问题，目标函数关于 α 严格凸，故存在唯一的全局最优解。

为方便使用标准 QP 求解器，上述问题可转写为通用 QP 形式：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^\top Q \alpha + p^\top \alpha \\ \text{s.t.} \quad & A \alpha \geq c, \end{aligned}$$

其中各项定义如下：

$$\begin{aligned} Q_{nm} &= y_n y_m z_n^\top z_m, \quad p = -\mathbf{1}_N, \\ A &= \begin{bmatrix} \mathbf{y}^\top \\ -\mathbf{y}^\top \\ I_N \end{bmatrix}, \quad c = \begin{bmatrix} 0 \\ 0 \\ \mathbf{0}_N \end{bmatrix}. \end{aligned}$$

注 其中第一行是等式约束 $\sum \alpha_n y_n = 0$ ，写作两条不等式 $\mathbf{y}^\top \alpha \geq 0$ 与 $-\mathbf{y}^\top \alpha \geq 0$ ；第三部分 I_N 实现 $\alpha_n \geq 0$ 的约束。许多数值求解器（如 CVXOPT、quadprog）对等式与边界条件会做特殊处理以保证数值稳定性。 💧

命题 5.2.7 (由最优 α 恢复最优 (b, w) 的 KKT 公式)

设 (b, w, α) 为原始-对偶最优解，则下列 KKT 条件成立：

1. 原始可行性

$$y_n (w^\top z_n + b) \geq 1, \quad n = 1, \dots, N.$$

2. 对偶可行性

$$\alpha_n \geq 0, \quad n = 1, \dots, N.$$

3. 对偶-内点最优性

$$\sum_{n=1}^N \alpha_n y_n = 0, \quad w = \sum_{n=1}^N \alpha_n y_n z_n.$$

4. 互补松弛性

$$\alpha_n [1 - y_n(w^\top z_n + b)] = 0, \quad n = 1, \dots, N.$$

恢复公式

1. 最优 w : 由对偶-内点最优性直接给出

$$w = \sum_{n=1}^N \alpha_n y_n z_n.$$

2. 最优 b : 任取一个 $\alpha_k > 0$ (支撑向量), 利用互补松弛得

$$1 - y_k(w^\top z_k + b) = 0 \implies b = y_k - w^\top z_k.$$

3. 最终的分类决策函数为:

$$g_{\text{SVM}}(x) = \text{sign} \left(\sum_{n=1}^N \alpha_n y_n (z_n^\top x) + b \right).$$

结论 $\alpha_n > 0$ 对应的样本即为支撑向量, 位于“胖边界”上。



例题 5.4 选择题: 硬间隔 SVM 的最优偏置 b

考虑两个变换后的样本 $(z_1, +1)$ 和 $(z_2, -1)$, 其中 $z_2 = -z_1 = -z$ 。假设硬间隔 SVM 的对偶问题最优解满足 $\alpha_1, \alpha_2 > 0$, 则最优偏置 b 为:

- 1) -1
- 2) 0
- 3) 1
- 4) 无法确定

解答 正确选项为 [2]。根据 KKT 条件, 最优解满足:

$$b = 1 - w^\top z \quad \text{和} \quad b = -1 + w^\top z$$

联立得 $b = 0$ 。



5.2.4 对偶 SVM 的启示

命题 5.2.8 (“最胖”超平面的数据表示)

设训练集 $\{(x_n, y_n)\}_{n=1}^N$, 经特征映射 $z_n = \Phi(x_n)$, 则支持向量机

$$w_{\text{SVM}} = \sum_{n=1}^N \alpha_n y_n z_n, \quad \alpha_n \text{ 来自对偶最优解, 且仅支撑向量对应的 } \alpha_n > 0.$$

PLA (感知器)

$$w_{\text{PLA}} = \sum_{n=1}^N \beta_n y_n z_n, \quad \beta_n \text{ 为样本 } x_n \text{ 被误分类并用于修正的次数.}$$

共性结论 所有基于梯度下降 / 随机梯度下降的 LogReg、LinReg (初值 $w_0 = 0$) 同样满足

$$w = \sum_{n=1}^N \gamma_n y_n z_n, \quad \gamma_n \in \mathbb{R}.$$

术语 称 w 由数据 $\{z_n\}$ “线性表示”；SVM 仅用支撑向量 (SVs) 即可表示 w ，实现稀疏数据依赖。

命题 5.2.9 (硬间隔 SVM 的两种等价形式)

1. 原始硬间隔 SVM

$$\min_{b,w} \quad \frac{1}{2} w^\top w \quad \text{s.t.} \quad y_n(w^\top z_n + b) \geq 1, \quad n = 1, \dots, N.$$

2. 对偶硬间隔 SVM

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^\top Q \alpha - \mathbf{1}^\top \alpha \\ \text{s.t.} \quad & y^\top \alpha = 0, \quad \alpha_n \geq 0, \quad n = 1, \dots, N, \end{aligned}$$

其中 $Q_{n,m} = y_n y_m z_n^\top z_m$ 。

规模与适用场景

- 原始形式： $d+1$ 个变量， N 条约束；适合 $d \ll N$ 。
- 对偶形式： N 个变量， $N+1$ 条简单约束；适合 $N \ll d$ 。

物理含义

- 原始：直接寻找经特殊尺度化后的 (b, w) 。
- 对偶：识别支撑向量 (z_n, y_n) 及其系数 α_n 。

最终输出 两种形式均给出同一最优 (b, w) ，对应最胖超平面；决策函数为

$$g_{\text{SVM}}(x) = \text{sign}(w^\top \Phi(x) + b).$$

例题 5.5 选择题：支持向量候选的数量

考虑在 5566 个样本上应用对偶硬间隔 SVM，得到 1126 个支持向量 (SVs)。下列哪个可能是“胖边界”样本 (SV 候选) 的数量？

- 1) 0
- 2) 1024
- 3) 1234
- 4) 9999

解答 正确选项为 [3]。支持向量候选数量需满足：

- 大于或等于实际支持向量数量 (1126)；
- 小于或等于总样本数 (5566)。

选项 3 (1234) 符合条件。

5.2.5 总结



笔记 [对偶支持向量机]

- 对偶 SVM 的动机：去除对维度 d 的依赖。
- 拉格朗日对偶 SVM：KKT 条件连接原始问题与对偶问题。
- 求解对偶 SVM：仍是二次规划，但可用专用求解器更高效地计算。
- 对偶 SVM 的启示：支持向量 (SVs) 刻画了“最胖”的超平面。

5.3 核支持向量机

5.3.1 核技巧

命题 5.3.1 (对偶 SVM 再审视：脱离维度依赖的关键)

当前已将偶 SVM 化为

$$\min_{\alpha} \frac{1}{2} \alpha^{\top} Q \alpha - \mathbf{1}^{\top} \alpha \quad \text{s.t.} \quad y^{\top} \alpha = 0, \alpha_n \geq 0,$$

其中

$$Q_{n,m} = y_n y_m \Phi(x_n)^{\top} \Phi(x_m).$$

目标 避免显式依赖维度 d ，需快速计算内积 $\Phi(x_n)^{\top} \Phi(x_m)$ 。

示例：二阶多项式核定义

$$\Phi_2(x) = \left(1, x_1, \dots, x_d, x_1^2, x_1 x_2, \dots, x_d x_1, x_d^2\right)^{\top} \in \mathbb{R}^{\frac{(d+1)(d+2)}{2}}.$$

对任意 $x, x' \in \mathbb{R}^d$ ，其内积可化简为

$$\Phi_2(x)^{\top} \Phi_2(x') = 1 + \sum_{i=1}^d x_i x'_i + \sum_{i=1}^d \sum_{j=1}^d x_i x_j x'_i x'_j = 1 + x^{\top} x' + (x^{\top} x')^2,$$

计算复杂度仅 $O(d)$ 。



命题 5.3.2 (核技巧：变换 + 内积一步完成)

定义核函数

$$K(x, x') \triangleq \Phi(x)^{\top} \Phi(x').$$

示例核：二阶多项式

$$K_2(x, x') = 1 + x^{\top} x' + (x^{\top} x')^2.$$

1. 二次规划矩阵

$$Q_{n,m} = y_n y_m K(x_n, x_m).$$

2. 最优偏置 b 任取支撑向量 (x_s, y_s) ($\alpha_s > 0$)，则

$$b = y_s - \sum_{n=1}^N \alpha_n y_n K(x_n, x_s).$$

3. 最优假设 g_{SVM} 对测试点 x ，

$$g_{\text{SVM}}(x) = \text{sign}\left(\sum_{n=1}^N \alpha_n y_n K(x_n, x) + b\right).$$

核技巧 用高效核函数 $K(\cdot, \cdot)$ 代替显式 $\Phi(\cdot)$ ，彻底摆脱对维度 $\tilde{d}$ 的依赖。



算法 5.3.14: 核硬间隔支持向量机 (Kernel Hard-Margin SVM)

输入: 训练集 $\{(x_n, y_n)\}_{n=1}^N \subset \mathbb{R}^d \times \{-1, +1\}$; 核函数 $K(\cdot, \cdot)$

输出: 支撑向量 $\{(x_n, y_n)\}_{n \in \mathcal{I}_{SV}}$, 对应 α_n , 偏置 b , 决策函数 g_{SVM}

1. 构造 QP 参数:

$$Q_{n,m} \leftarrow y_n y_m K(x_n, x_m), \quad \text{for } n, m = 1, \dots, N$$

$$p \leftarrow -\mathbf{1}_N, \quad A \leftarrow y^\top, \quad c \leftarrow 0$$

$$\text{下界 lb} \leftarrow \mathbf{0}_N, \quad \text{上界 ub} \leftarrow +\infty$$

2. 求解 QP:

$$\alpha \leftarrow \text{QP}(Q, p, A, c)$$

3. 提取支撑向量与偏置:

$$\mathcal{I}_{SV} \leftarrow \{n \mid \alpha_n > \varepsilon\}, \quad \varepsilon = 10^{-6}$$

$$b \leftarrow y_s - \sum_{n \in \mathcal{I}_{SV}} \alpha_n y_n K(x_n, x_s), \quad \text{for any } s \in \mathcal{I}_{SV}$$

4. 定义决策函数:

$$g_{SVM}(x) = \text{sign} \left(\sum_{n \in \mathcal{I}_{SV}} \alpha_n y_n K(x_n, x) + b \right)$$

时间复杂度说明

- $\mathcal{O}(N^2)$: 计算核矩阵 Q (N^2 次核函数计算);
- 二次规划变量数为 N , 等式约束 1 个, N 个不等式;
- $\mathcal{O}(\#\text{SV})$: 预测阶段仅依赖支撑向量核值。

备注 核 SVM 利用核技巧 (kernel trick) 避免显式映射到高维特征空间, 训练和预测均仅依赖于支撑向量。

例题 5.6 选择题: 二次核函数的计算

考虑两个样本 $\mathbf{x}$ 和 $\mathbf{x}'$, 满足 $\mathbf{x}^T \mathbf{x}' = 10$ 。则二次核函数 $K_{\Phi_2}(\mathbf{x}, \mathbf{x}')$ 的值为:

- 1) 1
- 2) 11
- 3) 111
- 4) 1111

解答 正确选项为 [3]。根据二次核函数公式 $K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$, 代入 $\mathbf{x}^T \mathbf{x}' = 10$ 得:

$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = 1 + 10 + 10^2 = 111$$

■

5.3.2 多项式核

命题 5.3.3 (通用二阶多项式核的三种等价形式)

对任意输入 $x, x' \in \mathbb{R}^d$, 二阶多项式核可写成三种等价但几何意义不同的形式:

形式一: 带常数项与交叉项

$$\Phi_2(x) = (1, x_1, \dots, x_d, x_1^2, \dots, x_d^2), \quad K_2(x, x') = 1 + x^\top x' + (x^\top x')^2.$$

形式二: 带缩放系数

$$\Phi_2(x) = (1, \sqrt{2}x_1, \dots, \sqrt{2}x_d, x_1^2, \dots, x_d^2), \quad K_2(x, x') = 1 + 2x^\top x' + (x^\top x')^2.$$

形式三: 带额外缩放与平方项

$$\Phi_2(x) = (1, \sqrt{2\gamma}x_1, \dots, \sqrt{2\gamma}x_d, \gamma x_1^2, \dots, \gamma x_d^2), \quad K_2(x, x') = 1 + 2\gamma x^\top x' + \gamma^2 (x^\top x')^2.$$

最常用紧凑形式

$$K_2(x, x') = (1 + x^\top x')^2, \quad \text{其中隐含系数 } \gamma = 1.$$

几何差异 三种 Φ_2 的幂次相同, 但内积缩放不同, 导致特征空间中的距离与角度各异; 而在 SVM 中, 常用

$$K_2(x, x') = (1 + x^\top x')^2$$

以获得简洁表达与数值稳定。

命题 5.3.4 (通用多项式核与线性核)

1. 通用多项式核 对阶次 $Q \geq 1$ 、参数 $\gamma > 0, \zeta \geq 0$, 定义

$$K_Q(x, x') = (\zeta + \gamma x^\top x')^Q.$$

该核隐式地将样本嵌入到度为 Q 的多项式特征空间 Φ_Q , 使 SVM 可在高维空间实现大间隔多项式分类, 而计算复杂度与原始维度 d 无关。

2. 线性核 (特殊情形) 取 $Q = 1, \gamma = 1, \zeta = 0$ 得

$$K_{\text{linear}}(x, x') = x^\top x',$$

即为标准内积核, 对应原始线性 SVM, 可直接在原始空间高效求解。

5.3.3 高斯核

命题 5.3.5 (无限维特征变换的核函数)

若存在高效可计算的核函数 $K(x, x')$, 则即使特征映射 $\Phi(x)$ 为无限维, 仍可实际应用。

1. 高斯核的无限维展开对一维输入 $x \in \mathbb{R}$, 令

$$K(x, x') = \exp(-(x - x')^2) = \exp(-x^2) \exp(-x'^2) \exp(2xx').$$

利用泰勒级数

$$\exp(2xx') = \sum_{i=0}^{\infty} \frac{(2xx')^i}{i!},$$

可得

$$K(x, x') = \exp(-x^2) \exp(-x'^2) \sum_{i=0}^{\infty} \frac{2^i}{i!} x^i x'^i = \Phi(x)^\top \Phi(x'),$$

其中

$$\Phi(x) = \exp(-x^2) \left(1, \sqrt{2}x, \sqrt{\frac{2^2}{2!}}x^2, \dots, \sqrt{\frac{2^i}{i!}}x^i, \dots \right)^\top$$

为无限维向量。

2. 一般高斯核（RBF 核）对任意维度 d ，定义

$$K(x, x') = \exp(-\gamma \|x - x'\|^2), \quad \gamma > 0.$$

该核对应无限维特征空间，但仅需 $O(d)$ 时间即可计算核值，实现“无限维变换 + 内积”一步完成。

命题 5.3.6 (高斯核 SVM 的假设与机制)

给定核函数

$$K(x, x') = \exp(-\gamma \|x - x'\|^2), \quad \gamma > 0,$$

高斯核（又称 RBF 核）SVM 的最终假设为

$$g_{\text{SVM}}(x) = \text{sign} \left(\sum_{n \in \mathcal{I}_{\text{SV}}} \alpha_n y_n \exp(-\gamma \|x - x_n\|^2) + b \right).$$

该式可视作以各支撑向量 x_n 为中心、系数为 $\alpha_n y_n$ 的高斯径向基函数的线性组合。

支撑向量机制

- 通过核技巧，将高阶甚至无限维特征变换 $\Phi(x)$ 简化为高效核值 $K(x, x')$ 。
- 无需显式存储 w ，仅需保留少量支撑向量及其 α_n 。
- 高斯 SVM 实现“无限维线性分类”，泛化性能由大间隔理论保证。




图 5.3.1: 硬间隔高斯核函数拟合图像

命题 5.3.7 (高斯核 SVM 的实际表现与过拟合风险)

高斯核

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

随参数 γ 增大呈如下行为：

- γ 较小：高斯函数平坦，决策边界平滑，欠拟合风险；

- γ 中等：边界与数据分布匹配良好；
- γ 较大：高斯函数尖锐，决策边界剧烈波动，存在过拟合风险。

重要提醒 即使采用大间隔框架，高斯 SVM 仍可能因 γ 过大而 过拟合。因此需通过交叉验证或验证集对 γ （以及软间隔参数 C ）进行 谨慎选择。



例题 5.7 选择题：高斯核函数的极限行为

考虑高斯核函数 $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$ 。当 $\gamma \rightarrow \infty$ 时，该核函数收敛到：

- 1) $K_{\lim}(\mathbf{x}, \mathbf{x}') = 0$
- 2) $K_{\lim}(\mathbf{x}, \mathbf{x}') = \mathbb{I}[\mathbf{x} = \mathbf{x}']$
- 3) $K_{\lim}(\mathbf{x}, \mathbf{x}') = \mathbb{I}[\mathbf{x} \neq \mathbf{x}']$
- 4) $K_{\lim}(\mathbf{x}, \mathbf{x}') = 1$

解答 正确选项为 2。当 $\gamma \rightarrow \infty$ 时：

- 若 $\mathbf{x} = \mathbf{x}'$ ，则 $K(\mathbf{x}, \mathbf{x}') \rightarrow 1$ ；
- 若 $\mathbf{x} \neq \mathbf{x}'$ ，则 $K(\mathbf{x}, \mathbf{x}') \rightarrow 0$ 。

这等价于指示函数 $\mathbb{I}[\mathbf{x} = \mathbf{x}']$ 。



5.3.4 核函数比较

命题 5.3.8 (线性核的优缺点)

核函数

$$K(x, x') = x^\top x'$$

缺点

- 表达能力受限——并非所有数据都能被线性分离。

优点

- 计算高效：可利用专门的原始 QP 求解器快速求解。
- 可解释性强：权重 w 与支撑向量均具有直观含义。
- 基本原则：先尝试线性模型，必要时再引入非线性核。

结论 线性核是 SVM 工具箱中不可或缺的基础利器。



命题 5.3.9 (多项式核的优缺点)

核函数

$$K(x, x') = (\zeta + \gamma x^\top x')^Q, \quad \gamma > 0, \zeta \geq 0, Q \in \mathbb{N}.$$

缺点

- 当阶次 Q 较大时易出现数值不稳定。
- 若 $|\zeta + \gamma x^\top x'| < 1$ ，则核值趋近 0；若大于 1，则迅速放大，导致数值尺度失衡。
- 含 γ, ζ, Q 三个超参数，调参复杂。

优点

- 表达能力优于线性核，可处理非线性可分数据。

- 明确控制多项式阶次 Q ，便于解释模型复杂度。
- 对低阶 Q （如 $Q = 2, 3$ ）往往足够有效。

建议 多项式核通常仅在 Q 较小时实用；高阶时可考虑先在显式高维特征 $\Phi(x)$ 上做线性 SVM，以规避数值与调参难题。

命题 5.3.10 (高斯核的优缺点)

核函数

$$K(x, x') = \exp(-\gamma \|x - x'\|^2), \quad \gamma > 0.$$

缺点

- 模型“黑箱”化：无限维特征空间导致 w 不可解释。
- 计算速度慢于线性核。
- 表达能力过强，易过拟合。

优点

- 比线性/多项式核更强大，能刻画复杂决策边界。
- 数值稳定，不会出现多项式核的极端放大或缩小。
- 仅一个超参数 γ ，调参相对简单。

结论 高斯核是实践中使用最广的核之一，但需通过交叉验证谨慎选择 γ 与软间隔参数 C ，以防过拟合。

命题 5.3.11 (其他有效核函数与 Mercer 条件)

核函数 $K(x, x')$ 体现特定相似度 $\Phi(x)^\top \Phi(x')$ ；“任意相似度 $\Rightarrow$ 有效核”并不成立。

Mercer 充要条件 设 $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ 为候选核，记

$$K_{ij} = K(x_i, x_j), \quad \mathbf{K} = [K_{ij}] \in \mathbb{R}^{N \times N}.$$

则 K 为有效核当且仅当

- 对称性： $K(x, x') = K(x', x)$ ；
- 半正定性：对任意有限点集 $\{x_n\}_{n=1}^N$ ，Gram 矩阵

$$\mathbf{K} = \begin{bmatrix} \Phi(x_1)^\top \Phi(x_1) & \cdots & \Phi(x_1)^\top \Phi(x_N) \\ \vdots & \ddots & \vdots \\ \Phi(x_N)^\top \Phi(x_1) & \cdots & \Phi(x_N)^\top \Phi(x_N) \end{bmatrix}$$

半正定，即 $\mathbf{K} \geq 0$ 。

自定义核 任意满足上述 Mercer 条件的对称半正定函数均可作为新核；然而构造与验证通常较为困难。

例题 5.8 选择题：无效核函数的识别

下列哪个不是有效的核函数？（提示：考虑两个 1 维向量 $\mathbf{x}_1 = (1)$ 和 $\mathbf{x}_2 = (-1)$ ，验证 Mercer 条件。）

- 1) $K(\mathbf{x}, \mathbf{x}') = (-1 + \mathbf{x}^T \mathbf{x}')^2$
- 2) $K(\mathbf{x}, \mathbf{x}') = (0 + \mathbf{x}^T \mathbf{x}')^2$
- 3) $K(\mathbf{x}, \mathbf{x}') = (1 + \mathbf{x}^T \mathbf{x}')^2$

4) $K(\mathbf{x}, \mathbf{x}') = (-1 - \mathbf{x}^T \mathbf{x}')^2$

解答 正确选项为 [1]。构造核矩阵并验证半正定性：

- 选项 1 的核矩阵为 $\begin{pmatrix} 0 & 4 \\ 4 & 0 \end{pmatrix}$ ，行列式为 $-16 < 0$ ，不满足 Mercer 条件。
- 其他选项的核矩阵均半正定。

■

5.3.5 总结



笔记 [核支持向量机]

- 核技巧：核函数充当“变换 + 内积”的快捷方式。
- 多项式核：嵌入经过特殊缩放的多项式特征变换。
- 高斯核：隐式嵌入无限维特征变换。
- 核函数比较：线性核追求效率，高斯核追求表达能力。

5.4 软间隔支持向量机

5.4.1 动机与原问题

命题 5.4.1 (硬间隔 SVM 的缺点与软间隔的引入)

1. 硬间隔过拟合风险

即使采用大间隔，硬间隔 SVM 仍可能过拟合，主要原因：

- 高维/无限维特征映射 Φ 带来强大表达能力；
- 强制要求“完全可分”——若数据含噪声，则模型会强行拟合异常点。

2. 放弃部分样本：软间隔思想

引入松弛变量 $\xi_n \geq 0$ ，将硬间隔约束

$$y_n(w^\top z_n + b) \geq 1, \quad \forall n$$

放宽为

$$y_n(w^\top z_n + b) \geq 1 - \xi_n, \quad \forall n,$$

并优化目标

$$\min_{b, w, \xi} \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n,$$

其中 $C > 0$ 权衡“大间隔”与“噪声容忍”：

- C 大：近似硬间隔，对误分类惩罚高；
- C 小：允许更多误分类或边界违规，提升鲁棒性。

命题 5.4.2 (软间隔 SVM 的完整表述)

引入松弛变量 $\xi_n \geq 0$ 记录第 n 个样本的“间隔违规”程度，软间隔 SVM 可统一写成如下凸二次规划：

原始问题

$$\begin{aligned} \min_{b, w, \xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s.t.} \quad & y_n(w^\top z_n + b) \geq 1 - \xi_n, \quad n = 1, \dots, N, \\ & \xi_n \geq 0, \quad n = 1, \dots, N. \end{aligned}$$

超参数 $C > 0$ 的作用

- C 大：惩罚间隔违规，近似硬间隔；
- C 小：容忍较大 ξ_n ，换取更大间隔与鲁棒性。

规模 该 QP 含 $\tilde{d} + 1 + N$ 个变量 (b, w, ξ) 与 $2N$ 条线性约束。

下一步目标 将原始问题导出对偶形式，从而再次利用核技巧彻底消除对维度 $\tilde{d}$ 的显式依赖。

5.4.2 对偶问题

命题 5.4.3 (软间隔 SVM 的拉格朗日对偶推导)

1. 原始问题

$$\min_{b, w, \xi} \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \quad \text{s.t.} \quad \begin{cases} y_n(w^\top z_n + b) \geq 1 - \xi_n, \\ \xi_n \geq 0, \quad n = 1, \dots, N. \end{cases}$$

2. 拉格朗日函数

引入乘子 $\alpha_n \geq 0, \beta_n \geq 0$,

$$\mathcal{L}(b, w, \xi, \alpha, \beta) = \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n + \sum_{n=1}^N \alpha_n [1 - \xi_n - y_n(w^\top z_n + b)] - \sum_{n=1}^N \beta_n \xi_n.$$

3. 消去 ξ_n 与 β_n

对 ξ_n 求导并令为零得

$$\frac{\partial \mathcal{L}(b, w, \xi, \alpha, \beta)}{\partial \xi_n} = C - \alpha_n - \beta_n = 0 \implies \beta_n = C - \alpha_n.$$

于是 β_n 可被隐式约束 $0 \leq \alpha_n \leq C$ 取代, 且

$$\mathcal{L}(b, w, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{n=1}^N \alpha_n [1 - y_n(w^\top z_n + b)].$$

4. 消去 b 与 w

与硬间隔 SVM 相同, 有

$$\sum_{n=1}^N \alpha_n y_n = 0, \quad w = \sum_{n=1}^N \alpha_n y_n z_n.$$

5. 标准软间隔对偶

代入化简后得到

$$\max_{\alpha} \left(\sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n, m} \alpha_n \alpha_m y_n y_m z_n^\top z_m \right) \quad \text{s.t.} \quad \sum_{n=1}^N \alpha_n y_n = 0, \quad 0 \leq \alpha_n \leq C.$$



命题 5.4.4 (标准软间隔 SVM 的对偶形式)

软间隔 SVM 的对偶问题可表示为以下凸二次规划:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m z_n^\top z_m - \sum_{n=1}^N \alpha_n \\ \text{s.t.} \quad & \sum_{n=1}^N y_n \alpha_n = 0, \quad 0 \leq \alpha_n \leq C, \quad n = 1, \dots, N. \end{aligned}$$

变量与约束规模

- 变量: N 个 α_n 。
- 约束: 1 条等式约束 + N 条下界约束 + N 条上界约束, 共 $2N + 1$ 条。

与硬间隔 SVM 的差异: 硬间隔 SVM 对 α_n 仅有非负约束, 软间隔 SVM 额外引入上界 $\alpha_n \leq C$ 。

隐式恢复

$$w = \sum_{n=1}^N \alpha_n y_n z_n, \quad \beta_n = C - \alpha_n, \quad n = 1, \dots, N.$$



5.4.3 软间隔 SVM 的启示

算法 5.4.15: 核软间隔 SVM (Kernel Soft-Margin SVM)

输入: 训练集 $\{(x_n, y_n)\}_{n=1}^N$; 核函数 $K(\cdot, \cdot)$; 惩罚参数 $C > 0$

输出: 支撑向量索引集 $\mathcal{I}_{\text{SV}}$, 对应 α_n , 偏置 b , 决策函数 g_{SVM}

1. 构造 QP 参数

$$\begin{aligned} Q_{n,m} &\leftarrow y_n y_m K(x_n, x_m), \quad n, m = 1, \dots, N, \\ p &\leftarrow -\mathbf{1}_N, \quad A_{\text{eq}} \leftarrow y^\top, \quad c_{\text{eq}} \leftarrow 0, \\ \text{lb} &\leftarrow 0_N, \quad \text{ub} \leftarrow C \mathbf{1}_N. \end{aligned}$$

2. 求解二次规划

$$\alpha \leftarrow \text{QP}(Q, p, A_{\text{eq}}, c_{\text{eq}}, \text{lb}, \text{ub}).$$

3. 提取支撑向量

$$\mathcal{I}_{\text{SV}} \leftarrow \{n \mid \alpha_n > 0\}, \quad \mathcal{I}_{\text{free}} \leftarrow \{n \mid 0 < \alpha_n < C\}.$$

若 $s \in \mathcal{I}_{\text{free}}$, 由于 $(C - \alpha_s)\xi_s = 0$, 则 $\xi_s = 0 \quad \forall s$, 得出 $b = y_s - y_s \xi_s - w^\top z_s = y_s - w^\top z_s$.

4. 计算偏置 任取 $s \in \mathcal{I}_{\text{free}}$ (自由支撑向量), 则

$$b \leftarrow y_s - \sum_{n \in \mathcal{I}_{\text{SV}}} \alpha_n y_n K(x_n, x_s).$$

5. 决策函数 对任意新样本 x ,

$$g_{\text{SVM}}(x) = \text{sign}\left(\sum_{n \in \mathcal{I}_{\text{SV}}} \alpha_n y_n K(x_n, x) + b\right).$$

复杂度

- 训练: $\mathcal{O}(N^3)$ (QP) + $\mathcal{O}(N^2)$ (核矩阵)。
- 预测: $\mathcal{O}(|\mathcal{I}_{\text{SV}}|)$ (仅支撑向量)。

性质

- 与硬间隔 SVM 步骤几乎一致, 仅增加上界约束 $\alpha_n \leq C$ 。
- 原始/对偶问题恒有解, 更灵活地容忍噪声。

命题 5.4.5 (软间隔高斯核 SVM 的实际表现与调参)

高斯核

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

与软间隔参数 C 共同决定决策边界形状:

- $C = 1$: 较大容忍度, 边界光滑, 欠拟合风险;
- $C = 10$: 中等容忍度, 边界与数据分布基本匹配;

- $C = 100$: 几乎不容忍违规, 边界尖锐, 过拟合风险上升。

重要提醒 即使采用软间隔, 高斯 SVM 仍可能因 (γ, C) 选择不当而过拟合。

实践要求 必须通过交叉验证或验证集, 对 (γ, C) 进行谨慎联合调参。




图 5.4.1: 软间隔高斯核函数拟合图像

命题 5.4.6 (α_n 的物理意义)

由互补松弛条件

$$\alpha_n [1 - y_n(w^\top z_n + b)] = 0, \quad (C - \alpha_n)\xi_n = 0,$$

可将样本按 α_n 分为三类:

- 非支持向量 ($\alpha_n = 0$)

$\xi_n = 0$, 样本落在“胖边界”之外或之上, 对决策边界无影响。

- $\square$ 自由支撑向量 ($0 < \alpha_n < C$)

$\xi_n = 0$, 样本恰好落在“胖边界”上, 用于唯一确定偏置 b 。

- $\triangle$ 边界支撑向量 ($\alpha_n = C$)

$\xi_n > 0$ 记录违规量, 样本已越过“胖边界”, 但仍在容忍范围内。

结论 系数 α_n 不仅决定支撑向量, 还能用于后续数据分析, 如异常检测、样本重要性评估等。




图 5.4.2: α_n 的物理意义

例题 5.9 选择题：SVM 训练误差的范围

对于大小为 10000 的数据集,假设 SVM 的支持向量数为 1126,其中 1000 个支持向量被“有界”(bounded)。则 0/1 误差下 $E_{\text{in}}(g_{\text{SVM}})$ 的可能范围是:

- 1) $0.0000 \leq E_{\text{in}}(g_{\text{SVM}}) \leq 0.1000$
- 2) $0.1000 \leq E_{\text{in}}(g_{\text{SVM}}) \leq 0.1126$
- 3) $0.1126 \leq E_{\text{in}}(g_{\text{SVM}}) \leq 0.5000$
- 4) $0.1126 \leq E_{\text{in}}(g_{\text{SVM}}) \leq 1.0000$

解答 正确选项为 [1]。有界支持向量是唯一可能违反“胖边界”的样本。当 $\xi_n \geq 1$ 时,违反会导致 0/1 错误;当 $\xi_n < 1$ 时,违反不导致 0/1 错误。因此,训练误差范围为 $0.0000 \leq E_{\text{in}}(g_{\text{SVM}}) \leq 0.1000$ 。■

5.4.4 模型选择**命题 5.4.7 (SVM 的留一交叉验证误差与支撑向量数的关系)****1. 留一交叉验证误差上界**

对含 N 个样本的训练集,留一交叉验证误差满足

$$E_{\text{LOOCV}} \leq \frac{|\mathcal{I}_{\text{SV}}|}{N},$$

其中 $\mathcal{I}_{\text{SV}}$ 为全部支撑向量的索引集。

直观解释 若最优解中 $\alpha_N = 0$ (即第 N 个样本为非支撑向量),则去掉该样本后剩余的最优 $\alpha_1, \dots, \alpha_{N-1}$ 仍保持不变,因此预测误差为 0;唯有支撑向量才可能导致留一误差。

2. 用支撑向量数调参

- $n_{\text{SV}}(C, \gamma)$ 是 (C, γ) 的非光滑函数,直接优化困难;
- 可作为计算 E_{CV} 过于耗时时的“安全检查”:在少量网格点上排除 n_{SV} 过大的危险模型;
- 仅为上界,实际误差可能远低于该比例。

5.4.5 总结**笔记 [软间隔支持向量机]**

- 动机与原问题:引入松弛变量 ξ_n 以允许间隔违规。
- 对偶问题:拉格朗日乘子 α_n 被常数 C 上界约束。
- 软间隔 SVM 的启示:通过“有界/自由”支持向量进行数据分析。
- 模型选择:使用交叉验证,或近似地依据支持向量数目 n_{SV} 。

5.5 核逻辑回归

5.5.1 软间隔 SVM 的正则化视角

命题 5.5.1

1. 软间隔 SVM 的无约束优化形式

$$\min_{b,w} \underbrace{\frac{1}{2}\|w\|^2}_{\text{L2 正则项}} + C \underbrace{\sum_{n=1}^N \max(1 - y_n(w^\top z_n + b), 0)}_{\text{合页损失 (hinge loss)}}$$

该目标函数由 L2 正则项与合页损失项组成，可简记为：

$$\min_{b,w} \frac{1}{2}\|w\|^2 + C \mathcal{L}_{\text{hinge}}(b, w),$$

即最小化带 L2 正则的 hinge loss，常被称为软间隔支持向量机的无约束形式。

2. 与经典正则化框架的对应关系

模型	正则方式	误差控制或损失
硬间隔 SVM	约束 $\ w\ ^2 \leq \text{const.}$	$E_{\text{in}} = 0$ （完全可分）
软间隔 SVM	$\frac{1}{2}\ w\ ^2$ (L2 正则)	$\sum \max(0, 1 - y_n f(x_n))$ (hinge loss)
L2 正则化模型	$\frac{\lambda}{N}\ w\ ^2$	$\frac{1}{N} \sum \text{err}$ (一般损失)

3. 统一视角下的理解

- 大间隔 $\iff$ 较少可分超平面 $\iff \|w\|$ 小 $\iff$ 强 L2 正则化；
- 软间隔 $\iff$ 使用 hinge loss 对误差进行容忍，允许一定程度的误分；
- 正则强度由超参数 C 控制，等价地，也可使用 $\lambda = \frac{1}{2C}$ ：

较大 $C \Rightarrow$ 小正则，间隔小，拟合更强 较小 $C \Rightarrow$ 大正则，间隔大，泛化更强

4. 拓展意义与建模连接

- 从正则化的角度理解 SVM，有助于与其他学习模型（如逻辑回归、岭回归）建立统一框架；
- 该视角也便于推广到核方法、稀疏学习、随机特征等更复杂场景；
- 尽管该无约束形式易于理解，但由于 $\max(\cdot, 0)$ 不可导，故优化上比标准 SVM 更难处理，不能直接使用核技巧。



5.5.2 SVM vs 逻辑回归

命题 5.5.2 (SVM 与逻辑回归的算法误差及关联)

1. 线性评分与误差度量

定义线性评分

$$s = w^\top z_n + b.$$

- 0/1 误差: $\text{err}_{0/1}(s, y) = \mathbb{I}[ys \leq 0]$ 。
- SVM (合页误差): $\text{err}_{\text{SVM}}(s, y) = \max(1 - ys, 0)$, 为 $\text{err}_{0/1}$ 的凸上界, 常称 **hinge loss**。
- 逻辑回归 (缩放交叉熵): $\text{err}_{\text{SCE}}(s, y) = \log_2(1 + \exp(-ys))$, 亦为 $\text{err}_{0/1}$ 的凸上界。




图 5.5.1: 二分类问题中不同误差度量对比图

2. SVM 与逻辑回归的近似关系

当 ys 远离 0 时,

$$\text{err}_{\text{SVM}}(s, y) \approx \ln 2 \cdot \text{err}_{\text{SCE}}(s, y),$$

因此 SVM 可视为带 **L2** 正则的逻辑回归的近似。

表 5.5.1: 二分类线性模型对比

	PLA	软间隔 SVM	正则化逻辑回归
优化目标	最小化 0/1 误差 $\min_{w,b} \sum_n \mathbb{I}[y_n(w^\top z_n + b) \leq 0]$	最小化正则化合页误差 $\min_{w,b} \frac{1}{2} \ w\ ^2 + C \sum_n \max(0, 1 - y_n f(x_n))$	最小化正则化交叉熵 $\min_{w,b} \frac{\lambda}{N} \ w\ ^2 + \frac{1}{N} \sum_n \log(1 + e^{-y_n f(x_n)})$
求解方法	逐点修正	二次规划 (QP)	梯度下降 / SGD 等
优点	线性可分时高效	优化简单, 理论保证	优化简单, 正则化自然
缺点	仅线性可分时收敛; 否则需 pocket	合页误差对极负样本宽松	交叉熵对极负样本宽松

注 正则化逻辑回归 $\approx$ SVM; 反之, SVM 也可视为带合页误差的逻辑回归近似。

5.5.3 软二分类的 SVM

命题 5.5.3 (两层学习: SVM 变换后再用逻辑回归微调)

定义最终模型

$$g(x) = \sigma(A(w_{\text{SVM}}^\top \Phi(x) + b_{\text{SVM}}) + B), \quad \sigma(z) = \frac{1}{1 + e^{-z}},$$

其中

- **SVM 变体**: 固定超平面方向与位置 $(w_{\text{SVM}}, b_{\text{SVM}})$, 由核方法给出;
- **逻辑回归变体**: 仅用两个标量参数 $A > 0, B \approx 0$ 对超平面进行缩放与平移, 使其更接近最大似然。

第二层的逻辑回归优化

将 SVM 输出

$$\psi_{\text{SVM}}(x_n) = w_{\text{SVM}}^\top \Phi(x_n) + b_{\text{SVM}}$$

作为新特征, 求解

$$\min_{A, B} \frac{1}{N} \sum_{n=1}^N \log(1 + \exp[-y_n(A \psi_{\text{SVM}}(x_n) + B)]).$$

总结 此“两层学习”策略把 SVM 的非线性变换结果当作逻辑回归的新输入, 实现 SVM 变换后的逻辑回归微调, 兼具 SVM 的结构性与逻辑回归的概率校准优势。



算法 5.5.16: Platt 概率 SVM (Platt's Probabilistic SVM)

输入: 训练数据 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$; 核函数 $K(\cdot, \cdot)$; 惩罚参数 C

输出: 概率输出软二分类器 $g(x) = \sigma(A \cdot f_{\text{SVM}}(x) + B)$, 其中 $\sigma(z) = \frac{1}{1 + e^{-z}}$

步骤 1: 训练核软间隔 SVM

$$f_{\text{SVM}}(x) = w_{\text{SVM}}^\top \Phi(x) + b_{\text{SVM}} = \sum_{n \in \mathcal{I}_{\text{SV}}} \alpha_n y_n K(x_n, x) + b_{\text{SVM}}.$$

步骤 2: 构造新特征

$$z_n = f_{\text{SVM}}(x_n), \quad n = 1, \dots, N.$$

步骤 3: 逻辑回归微调

在新特征空间 $\{(z_n, y_n)\}_{n=1}^N$ 上求解带特殊正则化的逻辑回归

$$\min_{A, B} \sum_{n=1}^N \log(1 + \exp[-y_n(A z_n + B)]) + \text{正则项}.$$

(实际实现中采用梯度下降、SGD 或其他高效方法, 因仅含两个变量)

输出

$$g(x) = \sigma(A f_{\text{SVM}}(x) + B), \quad \text{提供概率而非硬标签。}$$

备注

- 概率边界可能与纯 SVM 边界不同, 主要受偏置 B 影响;
- 若直接在 z 空间做精确逻辑回归, 则等价于核化逻辑回归 (下一节给出)。

5.5.4 核逻辑回归

命题 5.5.4 (核技巧的核心：统一表示定理)

设最优权重向量可写成训练样本的线性组合

$$w^* = \sum_{n=1}^N \beta_n z_n, \quad z_n = \Phi(x_n).$$

则对任意输入 x ,

$$w^{*\top} z = \sum_{n=1}^N \beta_n z_n^\top z = \sum_{n=1}^N \beta_n K(x_n, x),$$

其中 $K(x_n, x) = \Phi(x_n)^\top \Phi(x)$ 为核函数。因此无需显式计算高维特征 $\Phi(x)$ ，只需核值即可预测。三种经典算法的统一形式

$$w = \sum_{n=1}^N \alpha_n y_n z_n$$

系数来源：

- SVM: α_n 来自对偶最优解；
- PLA: α_n 为样本被误分并用于修正的次数；
- 逻辑回归 (SGD): α_n 为历次梯度更新中该样本的贡献累积。

结论 核技巧的本质是权重由数据线性表示，使所有线性模型在高维特征空间中统一且高效。

定理 5.5.1 (表示定理 Representer Theorem)

对任意带 L2 正则的线性模型

$$\min_w \frac{\lambda}{N} \|w\|^2 + \frac{1}{N} \sum_{n=1}^N \text{err}(y_n, w^\top z_n),$$

其最优解 w^* 必落在训练样本张成的子空间中，即存在 $\{\beta_n\}_{n=1}^N \subset \mathbb{R}$ ，使得

$$w^* = \sum_{n=1}^N \alpha_n z_n, \quad z_n = \Phi(x_n).$$

证明要点

设 $w^* = w_{\parallel} + w_{\perp}$ ，其中 $w_{\parallel} \in \text{span}\{z_n\}$ ， $w_{\perp} \perp \text{span}\{z_n\}$ 。

- 误差项只与 $w_{\parallel}$ 有关: $\text{err}(y_n, w^{*\top} z_n) = \text{err}(y_n, w_{\parallel}^\top z_n)$ ；
- 正则项满足 $\|w^*\|^2 = \|w_{\parallel}\|^2 + \|w_{\perp}\|^2 \geq \|w_{\parallel}\|^2$ ；
- 若 $w_{\perp} \neq 0$ ，则 $w_{\parallel}$ 更优，矛盾！故 $w_{\perp} = 0$ 。

推论 任意 L2 正则线性模型均可核化：

$$f(x) = w^{*\top} \Phi(x) = \sum_{n=1}^N \beta_n K(x_n, x).$$

算法 5.5.17: 核逻辑回归 (Kernel Logistic Regression)

目标函数 利用表示定理, 将 L2 正则化逻辑回归写成仅与系数 β_n 相关的核化形式:

$$\min_{\beta \in \mathbb{R}^N} \frac{\lambda}{N} \sum_{n=1}^N \sum_{m=1}^N \beta_n \beta_m K(x_n, x_m) + \frac{1}{N} \sum_{n=1}^N \log \left(1 + \exp \left[-y_n \sum_{m=1}^N \beta_m K(x_m, x_n) \right] \right)$$

算法步骤

1. 构造核矩阵 $\mathbf{K} \in \mathbb{R}^{N \times N}$, 其中 $K_{n,m} = K(x_n, x_m)$;
2. 任选优化算法 (GD、SGD、LBFGS 等) 对无约束目标

$$J(\beta) = \frac{\lambda}{N} \beta^\top \mathbf{K} \beta + \frac{1}{N} \sum_{n=1}^N \log \left(1 + \exp \left[-y_n (\mathbf{K} \beta)_n \right] \right)$$

求解最优 β^* ;

3. 预测函数

$$g(x) = \sigma \left(\sum_{n=1}^N \beta_n^* K(x_n, x) \right), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

复杂度

- 训练: $\mathcal{O}(N^3)$ (核矩阵) + 迭代优化开销;
- 预测: $\mathcal{O}(N)$ (全部样本) 或稀疏近似。

命题 5.5.5 (核逻辑回归的另一种视角: 核特征空间中的线性模型)

核逻辑回归 (KLR) 可等价地视为在两种不同空间中的线性模型:

1. 核特征空间中的线性模型

目标函数

$$\min_{\beta \in \mathbb{R}^N} \frac{\lambda}{N} \sum_{n=1}^N \sum_{m=1}^N \beta_n \beta_m K(x_n, x_m) + \frac{1}{N} \sum_{n=1}^N \log \left(1 + \exp \left[-y_n \sum_{m=1}^N \beta_m K(x_m, x_n) \right] \right)$$

等价于在变换后的特征空间

$$(K(x_1, x_n), K(x_2, x_n), \dots, K(x_N, x_n)) \in \mathbb{R}^N$$

上学习线性模型

$$f(x) = \beta^\top \Phi_{\mathbf{K}}(x),$$

其中 $\Phi_{\mathbf{K}}(x) = (K(x_1, x), \dots, K(x_N, x))^\top$, 并采用核正则化项 $\frac{\lambda}{N} \beta^\top \mathbf{K} \beta$ 。

2. 嵌入核的原始空间中的线性模型

同样可视为在无限维或高维嵌入特征空间 $\Phi(x)$ 中学习线性模型

$$f(x) = w^\top \Phi(x),$$

并施加 L2 正则化 $\frac{\lambda}{N} \|w\|^2$ 。

与 SVM 的对比

- SVM: α_n 稀疏, 仅支撑向量非零;
- KLR: β_n 通常非零, 整体稠密, 预测需全部核值。

**例题 5.10 选择题: KLR 线性模型的空间维度**

当将核逻辑回归 (KLR) 视为具有嵌入核变换和核正则化的 β 线性模型时, 该线性模型操作的 $\mathcal{Z}$ 空间

的维度是：

- 1) d (原始空间 $\mathcal{X}$ 的维度)
- 2) N (训练样本数)
- 3) $\tilde{d}$ (核函数隐式定义的特征变换维度)
- 4) λ (正则化参数)

解答 正确选项为 [2]。对于任意样本 $\mathbf{x}$ ，核变换后的数据为 $(K(\mathbf{x}_1, \mathbf{x}), K(\mathbf{x}_2, \mathbf{x}), \dots, K(\mathbf{x}_N, \mathbf{x}))$ ，其维度为 N 。 ■

5.5.5 总结



笔记 [核逻辑回归]

- 软间隔 SVM 的正则化视角：带 L2 正则项的合页误差 (hinge loss)。
- SVM vs 逻辑回归：SVM 近似于带 L2 正则的逻辑回归。
- 软二分类的 SVM：常用“两层学习”流程。
- 核逻辑回归：利用表示定理，将 L2 正则化逻辑回归推广到核空间。

5.6 支持向量回归

5.6.1 核岭回归

算法 5.6.18: 核岭回归 (Kernel Ridge Regression, KRR)

问题表述 利用表示定理, 将 L2 正则岭回归写成仅与系数 β 相关的核化形式:

$$\min_{\beta \in \mathbb{R}^N} \frac{\lambda}{N} \sum_{n=1}^N \sum_{m=1}^N \beta_n \beta_m K(x_n, x_m) + \frac{1}{N} \sum_{n=1}^N \left(y_n - \sum_{m=1}^N \beta_m K(x_n, x_m) \right)^2$$

矩阵形式 令 $\mathbf{K} \in \mathbb{R}^{N \times N}$ 为核矩阵, $\mathbf{y} = (y_1, \dots, y_N)^\top$, 则目标函数为

$$E_{\text{aug}}(\beta) = \frac{\lambda}{N} \beta^\top \mathbf{K} \beta + \frac{1}{N} \|\mathbf{y} - \mathbf{K} \beta\|^2 = \frac{\lambda}{N} \beta^\top \mathbf{K} \beta + \frac{1}{N} (\beta^\top \mathbf{K}^\top \mathbf{K} \beta - 2\beta^\top \mathbf{K}^\top \mathbf{y} + \mathbf{y}^\top \mathbf{y}).$$

解析解 对目标函数求梯度并令其为零:

$$\nabla E_{\text{aug}}(\beta) = \frac{2}{N} (\lambda \mathbf{K}^\top \mathbf{I} \beta + \mathbf{K}^\top \mathbf{K} \beta - \mathbf{K}^\top \mathbf{y}) = 0 \Rightarrow (\lambda \mathbf{I} + \mathbf{K}) \beta = \mathbf{y}.$$

由于 $\lambda > 0$ 且 $\mathbf{K}$ 为半正定矩阵 (满足 Mercer 条件), 因此矩阵 $\lambda \mathbf{I} + \mathbf{K}$ 可逆, 解为:

$$\beta = (\lambda \mathbf{I} + \mathbf{K})^{-1} \mathbf{y}.$$

预测函数 对任意新样本 x , 其预测值为:

$$f(x) = \sum_{n=1}^N \beta_n K(x_n, x).$$

复杂度

- 训练复杂度: $\mathcal{O}(N^3)$ (核矩阵求逆);
- 预测复杂度: $\mathcal{O}(N)$ (对每个测试样本计算 N 个核值)。

表 5.6.1: 线性岭回归 vs. 核岭回归

	线性岭回归	核岭回归
解析解	$(\lambda \mathbf{I} + \mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$	$(\lambda \mathbf{I} + \mathbf{K})^{-1} \mathbf{y}$
模型能力	受限 (线性假设)	灵活 (由核函数决定)
训练复杂度	$\mathcal{O}(d^3 + d^2 N)$	$\mathcal{O}(N^3)$
预测复杂度	$\mathcal{O}(d)$	$\mathcal{O}(N)$
适用场景	$N \gg d$ 时高效	大数据时困难

注 线性 vs. 核岭回归: 在计算效率与模型灵活性之间权衡。

5.6.2 支持向量回归原问题

定义 5.6.1 (最小二乘支持向量机 (Least-Squares SVM))

最小二乘支持向量机 (LS-SVM) 是由 Suykens 和 Vandewalle 提出的一类监督学习方法，可视为传统支持向量机 (SVM) 的最小二乘版本。其核心特点包括：

- 优化目标：在正则化框架下最小化平方误差与权重范数的加权和

$$\min_{w,b,e} \frac{1}{2} w^\top w + \frac{\gamma}{2} \sum_{n=1}^N e_n^2,$$

其中松弛变量 e_n 满足等式约束

$$y_n(w^\top \Phi(x_n) + b) = 1 - e_n, \quad n = 1, \dots, N.$$

- 线性系统求解：通过引入拉格朗日乘子 α_n ，最终转化为线性 Karush-Kuhn-Tucker (KKT) 方程组

$$\begin{bmatrix} 0 & \mathbf{1}^\top \\ \mathbf{1} & K + \gamma^{-1}I \end{bmatrix} \begin{bmatrix} b \\ \alpha \end{bmatrix} = \begin{bmatrix} 0 \\ y \end{bmatrix},$$

其中 $K_{n,m} = y_n y_m k(x_n, x_m)$ 为核矩阵。

- 与传统 SVM 的区别：
 - 1) 使用等式约束代替不等式约束，避免二次规划；
 - 2) 解由线性方程组给出，计算速度快；
 - 3) 失去解的稀疏性（所有样本均贡献）；
 - 4) 对误差分布假设更敏感，需额外正则化或加权处理。
- 适用场景：回归、分类、函数估计及非线性系统建模，尤其适用于样本量中等但对计算效率要求较高的任务。



表 5.6.2: 软间隔 SVM vs. 最小二乘 SVM (LS-SVM)

	软间隔 SVM	最小二乘 SVM (LS-SVM)
本质	最大间隔分类器	核岭回归用于分类
决策边界	稀疏支撑向量决定	与软间隔 SVM 近似
支撑向量	稀疏 α (少量 SV)	稠密 β (所有样本)
预测复杂度	$O(I_{SV})$	$O(N)$
实际影响	预测快	预测慢，内存占用大
稀疏性	期望稀疏 α	期望稀疏 β (难点)

注 LS-SVM 与核逻辑回归一样产生稠密系数；标准 SVM 的稀疏性仍是高效预测的关键。

命题 5.6.1 (Tube 回归 (ε -不敏感回归))

误差定义 给定容忍宽度 $\varepsilon > 0$, 定义 ε -不敏感误差

$$\text{err}(y, s) = \max(0, |s - y| - \varepsilon) = \begin{cases} 0, & |s - y| \leq \varepsilon, \\ |s - y| - \varepsilon, & |s - y| > \varepsilon. \end{cases}$$

几何意义

- 在 $|s - y| \leq \varepsilon$ 的“管”内：误差为 0；
- 在管外：误差为到管边界的垂直距离。

与平方误差对比

$$\text{err}_{\text{sq}}(y, s) = (s - y)^2.$$

- 当 $|s - y| \ll \varepsilon$ 时, $\text{err}(y, s) \approx 0$ 而平方误差仍较小；
- 当 $|s - y| \gg \varepsilon$ 时, 管误差线性增长, 对离群点更不敏感；
- 当 $|s - y|$ 较小时, $\text{err}_{\text{tube}} \approx \text{err}_{\text{sq}}$, 且受异常值的影响较小。




图 5.6.1: 平方误差与管误差对比图

命题 5.6.2 (L2 正则化 Tube 回归与 SVR 的统一视角)

原始无约束问题

$$\min_w \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \max(0, |w^\top z_n + b - y_n| - \varepsilon)$$

因含不可微的 $\max(\cdot)$ 而难以直接优化。借鉴标准 SVM 的做法, 引入松弛变量并转化为二次规划:

支持向量回归 (SVR) 的原始形式

$$\begin{aligned} \min_{b, w, \xi^\wedge, \xi^\vee} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s. t.} \quad & |y_n - w^\top z_n - b| \leq \varepsilon + \xi_n, \quad \xi_n \geq 0. \end{aligned}$$

化简支持向量回归 (SVR) 的原始形式

$$\begin{aligned} \min_{b, w, \xi^\wedge, \xi^\vee} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N (\xi_n^\wedge + \xi_n^\vee) \\ \text{s. t.} \quad & y_n - w^\top z_n - b \leq \varepsilon + \xi_n^\wedge, \\ & w^\top z_n + b - y_n \leq \varepsilon + \xi_n^\vee, \\ & \xi_n^\wedge, \xi_n^\vee \geq 0, \quad n = 1, \dots, N. \end{aligned}$$

后续步骤

- 利用表示定理将 w 表示为核函数的线性组合，实现核化；
- 构造拉格朗日对偶，导出仅含对偶变量 α_n 的 QP；
- KKT 条件将自动给出稀疏解：仅 $|w^\top z_n + b - y_n| \geq \varepsilon$ 的样本成为支撑向量。



算法 5.6.19: 支持向量回归 (Support Vector Regression, SVR)

原始问题 (Primal) 引入松弛变量 $\xi_n^+, \xi_n^- \geq 0$ 分别表示上、下管外违规量，SVR 的原始优化问题为

$$\begin{aligned} \min_{b, w, \xi^\wedge, \xi^\vee} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N (\xi_n^\wedge + \xi_n^\vee) \\ \text{s. t.} \quad & y_n - w^\top z_n - b \leq \varepsilon + \xi_n^\wedge, \\ & w^\top z_n + b - y_n \leq \varepsilon + \xi_n^\vee, \\ & \xi_n^\wedge \geq 0, \quad \xi_n^\vee \geq 0, \quad n = 1, \dots, N. \end{aligned}$$

参数解释

- $C > 0$: 正则化与管外违规的权衡；
- $\varepsilon > 0$: 垂直管宽度 (容忍误差范围)。

二次规划规模

- 变量: $\tilde{d} + 1 + 2N$ ($b, w, \xi^\wedge, \xi^\vee$);
- 约束: $4N$ 条线性不等式。

下一步 通过拉格朗日对偶消除对维度 $\tilde{d}$ 的依赖，实现核技巧。

例题 5.11 选择题: SVR 松弛变量的计算

考虑使用 $\varepsilon = 0.05$ 求解支持向量回归 (SVR)。在最优解处，已知 $\mathbf{w}^T \mathbf{z}_1 + b = 1.234$ 和 $y_1 = 1.126$ 。则松弛变量 $\xi_1^\vee$ 和 $\xi_1^\wedge$ 的值为：

- 1) $\xi_1^\vee = 0.108, \xi_1^\wedge = 0.000$
- 2) $\xi_1^\vee = 0.000, \xi_1^\wedge = 0.108$
- 3) $\xi_1^\vee = 0.058, \xi_1^\wedge = 0.000$
- 4) $\xi_1^\vee = 0.000, \xi_1^\wedge = 0.058$

解答 正确选项为 [3]。计算偏差 $y_1 - (\mathbf{w}^T \mathbf{z}_1 + b) - \varepsilon = -0.158$ ，由于小于 0，故 $\xi_1^\vee = 0.000$ ；计算偏差 $(\mathbf{w}^T \mathbf{z}_1 + b) - y_1 - \varepsilon = 0.058$ ，故 $\xi_1^\wedge = 0.058$ 。 ■

5.6.3 支持向量回归对偶

命题 5.6.3 (SVR 的对偶推导与解的稀疏性)

1. 拉格朗日函数与对偶变量 引入两组拉格朗日乘子

$$\alpha_n^\wedge \geq 0 \quad \text{对应} \quad y_n - (w^\top z_n + b) \leq \varepsilon + \xi_n^\wedge, \quad \alpha_n^\vee \geq 0 \quad \text{对应} \quad (w^\top z_n + b) - y_n \leq \varepsilon + \xi_n^\vee.$$

原始拉格朗日函数 (已消去松弛变量 $\xi_n^\wedge$ 和 $\xi_n^\vee$ [利用求导求极值的方式]):

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + \sum_{n=1}^N \left[\alpha_n^\wedge (-\varepsilon + y_n - w^\top z_n - b) + \alpha_n^\vee (-\varepsilon - y_n + w^\top z_n + b) \right].$$

2. 对偶问题 通过标准推导得到

$$\begin{aligned} \min_{\alpha_n^\wedge, \alpha_n^\vee} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N (\alpha_n^\wedge - \alpha_n^\vee)(\alpha_m^\wedge - \alpha_m^\vee) K(x_n, x_m) + \varepsilon \sum_{n=1}^N (\alpha_n^\wedge + \alpha_n^\vee) - \sum_{n=1}^N y_n (\alpha_n^\wedge - \alpha_n^\vee) \\ \text{s.t.} \quad & \sum_{n=1}^N (\alpha_n^\wedge - \alpha_n^\vee) = 0, \quad 0 \leq \alpha_n^\wedge, \alpha_n^\vee \leq C, \quad n = 1, \dots, N. \end{aligned}$$

3. 稀疏性 令 $\beta_n = \alpha_n^\wedge - \alpha_n^\vee$, 则

$$w = \sum_{n=1}^N (\alpha_n^\wedge - \alpha_n^\vee) z_n = \sum_{n=1}^N \beta_n z_n \quad \text{且} \quad f(x) = w^\top z + b = \sum_{n=1}^N \beta_n K(x_n, x) + b.$$

由互补松弛条件

$$\alpha_n^\wedge (\varepsilon + \xi_n^\wedge - y_n + w^\top z_n + b) = 0, \quad \alpha_n^\vee (\varepsilon + \xi_n^\vee + y_n - w^\top z_n - b) = 0,$$

可得

- 严格位于管内 $|f(x_n) - y_n| < \varepsilon$ 时 $\xi_n^\wedge = \xi_n^\vee = 0 \Rightarrow \alpha_n^\wedge = \alpha_n^\vee = 0 \Rightarrow \beta_n = 0$;
- 仅位于管边界或管外的样本才成为支撑向量, $\beta_n \neq 0$ 。

故 SVR 同样具有稀疏解。



例题 5.12 选择题: SVR 对偶问题的变量数量

支持向量回归 (SVR) 对偶问题的二次规划 (QP) 变量数量为:

- 1) $\tilde{d} + 1$
- 2) $\tilde{d} + 1 + 2N$
- 3) N
- 4) $2N$

解答 正确选项为 [4]。SVR 对偶问题的变量为拉格朗日乘数 $\alpha_i^\vee$ 和 $\alpha_i^\wedge$ (各 N 个), 总数量为 $2N$ 。■

5.6.4 核模型小结

表 5.6.3: 线性模型一览 (Map of Linear Models)

	优化目标	求解方式	说明
PLA / Pocket	直接最小化 0/1 误差	迭代修正	仅线性可分时有效
线性软间隔 SVM	正则化合页损失	QP (二次规划)	大间隔, 稀疏解
线性岭回归	正则化平方损失	解析解	稠密系数, 无稀疏性
正则化逻辑回归	正则化交叉熵	GD/SGD 等	概率输出, 稠密系数
线性 SVR (Tube 回归)	正则化 ε -不敏感损失	QP	稀疏支撑向量

注 线性软间隔 SVM、线性岭回归、正则化逻辑回归、线性 SVR 均为 LIBLINEAR 库中的常用算法。

表 5.6.4: 线性 / 核模型综合一览 (Comprehensive Map of Linear / Kernel Models)

类别	模型	求解方式	稀疏性	使用情况	说明
线性	PLA / Pocket	迭代修正	稀疏 (误分修正)	性能较差, 较少使用	仅线性可分时有效
	线性软间隔 SVM	QP (二次规划)	稀疏 α	中等规模常用	大间隔, 稀疏 α
	线性岭回归	解析解	稠密	小数据常用	稠密系数
	正则化逻辑回归	GD / SGD	稠密	概率输出常用	概率输出, 稠密系数
	线性 SVR	QP	稀疏 α	回归任务常用	ε -不敏感损失, 稀疏 α
核化	核岭回归	解析解	稠密 β (所有样本)	因稠密 β , 大数据少用	非线性映射
	核逻辑回归	无约束优化	稠密 β	因稠密 β , 大数据少用	概率输出
	核 SVM	对偶 QP	稀疏 α	LIBSVM 主力模型	非线性边界
	核 SVR	对偶 QP	稀疏 α	LIBSVM 主力模型	非线性回归
	概率 SVM	SVM-变换后逻辑回归	稀疏 α	LIBSVM 扩展模型	概率校准

注 1. 核 SVM、核 SVR、核岭回归、核逻辑回归、概率 SVM 均为 LIBSVM 库中的常用核化算法。
2. 线性模型因性能受限而较少采用; 核化稠密模型 (核岭回归、核逻辑回归) 因预测时需全部核值, 计算代价高, 大数据场景下使用受限。

5.6.5 总结

笔记 [支持向量回归]

- 核岭回归: 在岭回归上应用表示定理, 实现核化。
- 支持向量回归原问题: 最小化带正则的 ε -tube 误差。
- 支持向量回归对偶: 与 SVM 对偶类似, 仍为二次规划 (QP)。
- 核模型小结: 力量越大, 责任越大 (使用高表达能力核函数需谨慎)。

间章：嵌入大量特征：核模型

笔记 [嵌入大量特征：核模型]

“Embedding Numerous Features: Kernel Models”（嵌入大量特征：核模型）是我们第五章的核心主题。通过核技巧的巧妙设计与对偶优化的高效实现，核模型为高维特征嵌入提供了一套完整解决方案，可从四个关键维度解析其核心逻辑：

1. 高维特征的隐式表达：规避显式维度灾难

核模型突破高维特征处理瓶颈的核心在于“隐式嵌入”：

- 定义核函数 $K(x, x') = \Phi(x)^\top \Phi(x')$ ，将原始空间样本映射到高维特征空间，却无需显式构造或存储高维特征 $\Phi(x)$ ；
- 多项式核 $(\zeta + \gamma x^\top x')^Q$ 隐式对应度为 Q 的多项式特征，高斯核 $\exp(-\gamma \|x - x'\|^2)$ 则对应无限维特征空间，均通过核值计算替代高维内积；
- “映射-内积”的机制，从根本上解决了高维特征显式处理带来的计算复杂度与存储成本问题。

2. 模型假设的灵活扩展：从线性到非线性的统一

核模型通过高维嵌入实现了模型能力的飞跃：

- 在高维特征空间复用线性模型框架（如线性超平面分类、线性回归），借助特征映射的非线性特性，在原始空间实现复杂的非线性决策边界；
- 支持向量机（SVM）通过最大化间隔确保模型泛化能力，核岭回归、核逻辑回归则分别将正则化回归与概率分类扩展到高维场景；
- 不同核函数对应不同特征空间结构，使模型可适配从多项式关系到局部相似性的多样数据模式。

高维嵌入让简单的线性模型具备了处理复杂问题的能力。

3. 优化问题的维度缩减：对偶变换的关键作用

对偶优化是核模型处理高维特征的核心技术支撑：

- 通过拉格朗日对偶变换，将以高维参数 w 为变量的原始优化问题，转化为以样本级变量 α_n 为核心的对偶问题，变量维度从特征数降至样本数 N ；
- 对偶问题的目标函数与约束条件仅依赖核矩阵 $\mathbf{K}(x_n, x_m)$ ，彻底摆脱对特征维度的依赖；
- 求解对偶问题后，通过 $w = \sum \alpha_n y_n \Phi(x_n)$ 与核函数重构高维模型参数，实现从低维优化到高维模型的无缝衔接。

对偶变换让高维特征嵌入从“不可解”变为“可高效求解”。

4. 实用化的关键保障：稀疏性与泛化控制

核模型通过多重机制确保高维嵌入的实用性：

- 稀疏性：支持向量机中，仅少量支撑向量参与模型构建，大幅降低预测阶段的计算成本；
- 泛化控制：通过正则化参数（如软间隔 SVM 中的 C 、核岭回归中的 λ ）平衡模型复杂度与拟合能力，结合大间隔理论与 VC 维上界保证泛化性能；
- 工程适配：通过交叉验证选择核函数类型与参数，避免过拟合或欠拟合。

结语：核模型通过“隐式嵌入-对偶优化-稀疏泛化”机制，解决了大量特征嵌入的核心难题：既利用高维特征捕捉复杂规律，又避免了显式高维处理的弊端，成为连接低维输入与高维建模的经典方案。

第 6 章 组合预测特征：聚合模型

6.1 混合与袋装

6.1.1 集成的动机

命题 6.1.1 (基于数学符号的预测融合框架)

设你有 T 位“朋友”模型 $g_1, \dots, g_T$ ，每个模型对输入 x 给出股价涨跌预测 $g_t(x) \in \{-1, +1\}$ 。

1. 选择最可信的朋友

$$G(x) = g_{t^*}(x), \quad t^* = \arg \min_{t \in \{1, \dots, T\}} \text{Eval}(g_t^-).$$

2. 均匀融合

$$G(x) = \text{sign}\left(\sum_{t=1}^T 1 \cdot g_t(x)\right).$$

3. 非均匀加权融合

$$G(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t g_t(x)\right), \quad \alpha_t \geq 0.$$

- 仅选最优： $\alpha_t = \mathbb{I}[t = \arg \min_s \text{Eval}(g_s^-)]$ ；
- 均匀权重： $\alpha_t = 1$ ；
- 任意非负权重：例如 α_t 与 $\text{Eval}(g_t^-)$ 成反比。

4. 条件融合

$$G(x) = \text{sign}\left(\sum_{t=1}^T q_t(x) g_t(x)\right), \quad q_t(x) \geq 0,$$

其中 $q_t(x)$ 可按 α_t 或任意非负函数设定。

总结 上述框架构成丰富的融合模型族 (**aggregation models**)，从简单选择到复杂条件加权，灵活权衡偏差与方差。



命题 6.1.2 (验证选模 vs. 融合：动机与优势)

1. 验证选模 (Selection by Validation)

$$G(x) = g_{t^*}(x), \quad t^* = \arg \min_{t \in \{1, \dots, T\}} \text{Eval}(g_t^-).$$

- 简单、常用；
- 若以 $E_{\text{in}}(g_t^-)$ 代替 $\text{Eval}(g_t^-)$ ，则因模型复杂度惩罚不足而需付出“复杂度代价”；
- 依赖 单个强假设保证 E_{val} (从而 E_{out}) 小。

2. 融合 (Aggregation) 的动机

- 不必强求单个强模型，可利用 多个 (可能较弱) 假设；
- 通过均匀或非均匀加权，融合效果可优于任何单一成员；
- 可视为隐式 特征变换或 正则化；
- 适当融合 $\Rightarrow$ 性能提升。

结论 融合策略将“选最优”升级为“组合众长”，在偏差-方差权衡中获得更优泛化。



例题 6.1 选择题：决策树桩的均匀混合

考虑三个决策树桩假设 $g_1(x) = \text{sign}(1 - x)$ 、 $g_2(x) = \text{sign}(1 + x)$ 和 $g_3(x) = -1$ 。均匀混合这三个假设后的结果 $G(x)$ 为：

- 1) $2\mathbb{I}[|x| \leq 1] - 1$
- 2) $2\mathbb{I}[|x| \geq 1] - 1$
- 3) $2\mathbb{I}[x \leq -1] - 1$
- 4) $2\mathbb{I}[x \geq +1] - 1$

解答 正确选项为 **1**。分析各区间的预测值，其中 $G(x) = \frac{g_1(x) + g_2(x) + g_3(x)}{3}$ ：

- $x < -1$ 时， $G(x) = -\frac{1}{3}$ ；
- $-1 \leq x \leq 1$ 时， $G(x) = \frac{1}{3}$ ；
- $x > 1$ 时， $G(x) = -\frac{1}{3}$ 。

结果对应 $2\mathbb{I}[|x| \leq 1] - 1$ 。



6.1.2 均匀混合 (Uniform Blending)

命题 6.1.3 (均匀融合 (Uniform Blending))

分类情形

给定已知模型 $g_1, \dots, g_T$ ，每人一票：

$$G(x) = \text{sign}\left(\sum_{t=1}^T 1 \cdot g_t(x)\right).$$

- 若所有 g_t 相同 (独裁)：效果与单个 g_t 无异；
- 若 g_t 差异显著 (多样性 + 民主)：多数票可纠正少数错误。

多类推广

$$G(x) = \arg \max_{k \in \{1, \dots, K\}} \sum_{t=1}^T \mathbb{I}[g_t(x) = k].$$

回归情形

$$G(x) = \frac{1}{T} \sum_{t=1}^T g_t(x).$$

- 若所有 g_t 相同：效果等同单个模型；
- 若 g_t 差异显著：某些高估，某些低估 $\rightarrow$ 平均反而更准确。

结论 即使最简单的均匀融合，在模型多样性充足时，也能优于任意单一假设。



定理 6.1.1 (均匀融合的偏差-方差分解定理)

设均匀融合后的平均模型为

$$G(x) = \frac{1}{T} \sum_{t=1}^T g_t(x),$$

并记对 $t = 1, \dots, T$ 的算术平均为 $\text{avg}[\cdot]$ 。则对任意输入点 x 有如下均方误差分解：

$$\text{avg}[(g_t(x) - f(x))^2] = \text{avg}[(g_t(x) - G(x))^2] + (G(x) - f(x))^2$$

对整个输入分布取期望（即取 E_{out} ）后，得到

$$\frac{1}{T} \sum_{t=1}^T E_{\text{out}}(g_t) = \text{avg}[E_{\text{out}}(g_t)] = \text{avg}[E_{\text{out}}((g_t - G)^2)] + E_{\text{out}}(G) \geq E_{\text{out}}(G).$$

即融合后的误差不超过单个模型的平均误差。



证明 为便于书写，在固定的输入点 x 处，去掉显式的 x 依赖写作 g_t, f, G 。从代数展开开始：

$$\begin{aligned} \text{avg}[(g_t - f)^2] &= \text{avg}[g_t^2 - 2g_t f + f^2] \\ &= \text{avg}(g_t^2) - 2 \text{avg}(g_t) f + f^2. \end{aligned}$$

由定义 $\text{avg}(g_t) = G$ ，因此

$$\text{avg}[(g_t - f)^2] = \text{avg}(g_t^2) - 2Gf + f^2.$$

将 $\text{avg}(g_t^2)$ 写为关于 G 的展开：

$$\text{avg}(g_t^2) = \text{avg}[(g_t - G + G)^2] = \text{avg}[(g_t - G)^2 + 2(g_t - G)G + G^2].$$

利用线性算子与 $\text{avg}(g_t - G) = \text{avg}(g_t) - G = 0$ ，可得

$$\text{avg}(g_t^2) = \text{avg}[(g_t - G)^2] + G^2.$$

把此式代回前式：

$$\begin{aligned} \text{avg}[(g_t - f)^2] &= (\text{avg}[(g_t - G)^2] + G^2) - 2Gf + f^2 \\ &= \text{avg}[(g_t - G)^2] + (G^2 - 2Gf + f^2) \\ &= \text{avg}[(g_t - G)^2] + (G - f)^2, \end{aligned}$$

得到点态（fixed- x ）分解：

$$\text{avg}[(g_t - f)^2] = \text{avg}[(g_t - G)^2] + (G - f)^2.$$

对输入 x 按数据分布取期望（即对整个样本空间取 $E_x[\cdot]$ 或记为 $E_{\text{out}}(\cdot)$ ），并用线性性交换 avg 与 E_x 的顺序：

$$\begin{aligned} \text{avg}[E_{\text{out}}(g_t)] &= \text{avg}[E_x[(g_t(x) - f(x))^2]] \\ &= E_x[\text{avg}[(g_t(x) - f(x))^2]] \\ &= E_x[\text{avg}[(g_t(x) - G(x))^2] + E_x[(G(x) - f(x))^2]] \\ &= \text{avg}[E_{\text{out}}((g_t - G)^2)] + E_{\text{out}}(G). \end{aligned}$$

由于 $\text{avg}[E_{\text{out}}((g_t - G)^2)] \geq 0$ ，于是

$$\text{avg}[E_{\text{out}}(g_t)] \geq E_{\text{out}}(G).$$



命题 6.1.4 (特殊 g_t ：虚拟迭代过程的偏差-方差分解)

考虑虚拟迭代过程：对 $t = 1, 2, \dots, T$,

- 从分布 $\mathcal{P}^N$ 独立同分布抽取大小为 N 的数据集 $\mathcal{D}_t$ ；

- 以算法 $\mathcal{A}$ 得到模型 $g_t = \mathcal{A}(\mathcal{D}_t)$ 。

令平均模型

$$G = \frac{1}{T} \sum_{t=1}^T g_t, \quad \bar{g} = \lim_{T \rightarrow \infty} G = \mathbb{E}_{\mathcal{D} \sim \mathcal{P}^N}[\mathcal{A}(\mathcal{D})].$$

则任意 g_t 的期望风险（泛化误差）可分解为

$$\mathbb{E}_{\mathcal{D}}[\text{E}_{\text{out}}(g_t)] = \underbrace{\text{Bias}^2(\bar{g})}_{\text{共识模型的偏差}} + \underbrace{\mathbb{E}_{\mathcal{D}}[\text{Var}(g_t)]}_{\text{对共识的期望方差}}.$$

结论 均匀混合（uniform blending）通过降低方差项，提高整体性能的稳定性。



例题 6.2 选择题：线性回归假设的均匀混合

设 $g_1(\mathbf{x}), g_2(\mathbf{x}), \dots, g_T(\mathbf{x})$ 是 T 个线性回归假设，其中 $g_t(\mathbf{x}) = \mathbf{w}_t^T \mathbf{x}$ 。对这些假设进行均匀混合得到 $G(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^T g_t(\mathbf{x})$ ，则 $G(\mathbf{x})$ 是：

- 1) 常数函数
- 2) 线性函数
- 3) 二次函数
- 4) 无正确选项

解答 正确选项为 [2]。将线性回归假设代入均匀混合公式： $G(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^T \mathbf{w}_t^T \mathbf{x} = \left(\frac{1}{T} \sum_{t=1}^T \mathbf{w}_t \right)^T \mathbf{x}$ ，令

$\mathbf{w} = \frac{1}{T} \sum_{t=1}^T \mathbf{w}_t$ ，则 $G(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ ，仍为线性函数。 ■

6.1.3 线性/任意混合

算法 6.1.20: 线性混合（Linear Blending）

设定 已知 T 个基预测器 $g_t(x)$ ，给每个 g_t 赋予权重 $\alpha_t \geq 0$ （投票/票数），构造最终分类器

$$G(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t g_t(x)\right).$$

回归情形 将线性混合视为线性回归 + 特征变换：

$$\min_{\alpha_t \geq 0} \sum_{n=1}^N \left(y_n - \sum_{t=1}^T \alpha_t g_t(x_n) \right)^2,$$

等价于

$$\min_{\mathbf{w} \geq 0} \sum_{n=1}^N \left(y_n - \mathbf{w}^T \Phi(x_n) \right)^2, \quad \Phi_t(x) = g_t(x) \text{ (把 } g_t \text{ 当作新特征)}.$$

符号约束的讨论

- 若允许 $\alpha_t < 0$ ，则 $\alpha_t g_t(x) = |\alpha_t| (-g_t(x))$ ，即反向投票——对错误率极高的基模型（如 99% 错误的涨跌分类器）直接取反即可。
- 实践中常放宽到 $\alpha_t \in \mathbb{R}$ ，再经正则化控制。

总结 线性混合 = 线性模型 + 以 g_t 为特征变换 + 权重约束（非负或正则化）。

命题 6.1.5 (线性混合 vs. 选择 (Selection) 及任意混合 (Any Blending))

1. 线性混合 vs. 选择

- 选择 (Selection): 从 T 个假设类 $\mathcal{H}_t$ 中各自训练出 g_t , 然后再选择 $g_{\hat{t}}$:

$$\hat{t} = \arg \min_t E_{\text{in}}(g_t).$$

复杂度代价为

$$d_{\text{VC}}\left(\bigcup_{t=1}^T \mathcal{H}_t\right) \text{ (表示在所有候选模型的并集中支付的 VC 维成本)}$$

- 线性混合 (Linear Blending): 将选择视为特例如下:

$$\text{令 } \alpha_t = \begin{cases} 1, & \text{if } t = \hat{t}, \\ 0, & \text{otherwise.} \end{cases}$$

因此线性混合的复杂度代价

$$\geq d_{\text{VC}}\left(\bigcup_{t=1}^T \mathcal{H}_t\right).$$

2. 任意混合 (Any Blending / Stacking)

给定 $g_1^-, g_2^-, \dots, g_T^-$ (在训练集 $\mathcal{D}_{\text{train}}$ 上训练), 构造新特征

$$\Phi(x) = (g_1^-(x), g_2^-(x), \dots, g_T^-(x))^{\top}.$$

将验证集 $\mathcal{D}_{\text{val}}$ 映射为

$$\{(z_n = \Phi(x_n), y_n)\}_{n=1}^{N_{\text{val}}}.$$

- 线性混合: 在新特征上求解

$$\alpha = \arg \min_{\alpha} \sum_{(z,y) \in \mathcal{D}_{\text{val}}} \ell(y, \alpha^{\top} z) \implies G_{\text{LinB}}(x) = \alpha^{\top} \Phi(x).$$

- 任意混合 (Stacking): 允许在特征 $\Phi(x)$ 上使用任意元学习器 $\mathcal{A}$:

$$\tilde{g} = \mathcal{A}(\{(z_n, y_n)\}), \quad G_{\text{AnyB}}(x) = \tilde{g}(\Phi(x)).$$

注意事项:

- 任意混合灵活且强大, 可实现“条件混合”(conditional blending);
- 但如同所有模型组合一样, 存在过拟合风险, 需结合交叉验证与正则化方法使用。



6.1.4 袋装 (Bagging)

命题 6.1.6 (为均匀聚合而构造多样性)

要获得有效的均匀聚合, 需要保证 g_t 之间的差异。常见策略:

- 不同模型: $g_1 \in \mathcal{H}_1, g_2 \in \mathcal{H}_2, \dots, g_T \in \mathcal{H}_T$;
- 不同超参: 如 GD 的学习率 $\eta \in \{0.001, 0.01, \dots, 10\}$;
- 算法随机性: 随机 PLA 配合不同随机种子;
- 数据随机性: 交叉验证内部产生的子模型 g_v^- 。



命题 6.1.7 (重访偏差-方差与自助法)

设共识模型

$$\bar{g} = \mathbb{E}_{\mathcal{D} \sim P^N}[\mathcal{A}(\mathcal{D})].$$

其期望性能满足

$$\mathbb{E}_{\mathcal{D}}[\text{E}_{\text{out}}(g)] = \underbrace{\text{Bias}^2(\bar{g})}_{\text{共识偏差}} + \underbrace{\mathbb{E}_{\mathcal{D}}[(g - \bar{g})^2]}_{\text{方差}}.$$

但 $\bar{g}$ 需无穷多 $\mathcal{D}_t \sim P^N$ 才能精确获得。

自助法 (**Bootstrapping**): 从手头的 D 中重采样生成 $D_t \stackrel{\text{i.i.d.}}{\approx} P^N$, 从而

$$\bar{g} \approx \frac{1}{T} \sum_{t=1}^T \mathcal{A}(D_t), \quad D_t \leftarrow \text{Bootstrap}(D).$$

**算法 6.1.21: 自助聚合 Bootstrap Aggregation (装袋法 bagging)**

虚拟迭代过程 (理想不可行)

1. 对 $t = 1, 2, \dots, T$: 从总体分布 P^N 独立同分布抽取大小为 N 的数据集 $\mathcal{D}_t$;
2. 由基算法 $\mathcal{A}$ 得到模型 $g_t = \mathcal{A}(\mathcal{D}_t)$;
3. 均匀聚合: $G = \frac{1}{T} \sum_{t=1}^T g_t$.

实际迭代过程 (**Bootstrap** 近似)

1. 对 $t = 1, 2, \dots, T$: 从手头的数据集 D 中有放回地重采样大小为 N' (通常 $N' = N$) 的数据集 $\tilde{\mathcal{D}}_t$;
2. 由基算法 $\mathcal{A}$ 得到模型 $g_t = \mathcal{A}(\tilde{\mathcal{D}}_t)$;
3. 均匀聚合: $G = \frac{1}{T} \sum_{t=1}^T g_t$.

总结 Bagging 是一种简单的元算法 (meta-algorithm), 在任意基算法 $\mathcal{A}$ 之上, 通过 Bootstrap 重采样构造多样性, 从而降低方差、提升稳定性。

例题 6.3 选择题: 自助法重采样的概率

使用自助法从包含 N 个样本的数据集 $\mathcal{D}$ 中有放回地抽取 N 个样本组成新数据集 $\tilde{\mathcal{D}}_t$, 则 $\tilde{\mathcal{D}}_t$ 与 $\mathcal{D}$ 完全相同的概率为:

- 1) 0
- 2) $\frac{1}{N^N}$
- 3) $\frac{N!}{N^N}$
- 4) 1

解答 正确选项为 [3]。自助法的重采样规则是有放回地抽取 N 个样本。要使 $\tilde{\mathcal{D}}_t$ 与 $\mathcal{D}$ 完全相同, 需满足两个条件:

1. 每个样本被选中一次: 每次抽样的概率为 $\frac{1}{N}$, 独立抽样 N 次的概率为 $(\frac{1}{N})^N$ 。
2. 排列组合: N 个样本的全排列数为 $N!$, 即所有可能的顺序都需被考虑。

因此, 概率为: $(\frac{1}{N})^N \times N! = \frac{N!}{N^N}$



6.1.5 总结



笔记 [混合与袋装]

- 集成的动机：聚合得到的 G 可以兼具强性能与稳健性。
- 均匀混合 (Uniform Blending)：多样假设各投一票，输出平均值。
- 线性/任意混合：将假设视为特征变换进行两层学习。
- 袋装 (Bagging)：通过自助采样构造多样假设，实现 Bootstrap Aggregation。



笔记 [总体结论] 混合与袋装通过融合多个模型的预测结果，借助多样性弥补单一模型的不足，在降低方差、提升泛化性能上效果显著。这一策略保留了基模型的特性，却也可能增加计算成本与过拟合风险。因此，需通过合理设计融合规则（如均匀、加权）和构造多样模型（如自助采样）平衡性能与复杂度，是增强模型稳健性的重要集成学习手段。

6.2 自适应提升

6.2.1 提升的动机

命题 6.2.1 (动机: AdaBoost 的比喻)

- 学生 (弱学习器): 简单的假设 g_t , 例如垂直或水平直线。
- 班级 (强学习器): 复杂的最终假设 G , 例如图中的黑色曲线。
- 教师 (AdaBoost): 一种巧妙的算法, 通过对样本权重的动态调整, 引导学生把注意力集中在当前最困难、最关键的例子上, 从而逐步提升整体性能。




图 6.2.1: AdaBoost 的示意图

6.2.2 重加权带来多样性

命题 6.2.2 (Bootstrap 等价于样本重加权)

设原始训练集为 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ 。

1. 重加权视角

一次 Bootstrap 抽样可视为给每个样本 (x_n, y_n) 赋予一个非负权重 u_n , 表示该样本在此次抽样中被选中的次数。例如, 若抽样结果为

$$\mathcal{D}_t = \{(x_1, y_1), (x_1, y_1), (x_2, y_2), (x_4, y_4)\},$$

则对应权重为

$$u_1 = 2, \quad u_2 = 1, \quad u_3 = 0, \quad u_4 = 1.$$

2. 加权经验误差

任意假设 h 的加权误差为

$$E_{in}^u(h) = \sum_{n=1}^N u_n \cdot \mathbb{I}[y_n \neq h(x_n)].$$

3. 加权基学习算法

- 加权 SVM (通过求解对偶二次规划问题 $E_{in}^u \propto C \sum_{n=1}^N u_n \text{err}_{\hat{SVM}}$): 将软间隔约束调整为 $0 \leq \alpha_n \leq C u_n$.

- 加权逻辑回归（通过 SGD 求解 $E_{in}^u \propto u_n \text{err}_{CE}$ ）：在 SGD 步骤中，按权重 u_n 对样本进行概率采样，等价于最小化加权交叉熵

$$\sum_{n=1}^N u_n \cdot \ell_{CE}(y_n, h(x_n)).$$

结论 Bootstrap 抽样等价于样本重加权学习，这一视角统一了 Bagging 与加权基学习算法，并可自然推广至类别加权学习。

命题 6.2.3 (通过重加权提升 Bagging 多样性)

设第 t 轮基学习器为 g_t ，样本权重为 $u_n^{(t)}$ ，定义加权误差

$$\epsilon_t = \frac{\sum_{n=1}^N u_n^{(t)} \mathbb{I}[y_n \neq g_t(x_n)]}{\sum_{n=1}^N u_n^{(t)}}.$$

目标 构造下一轮权重 $u_n^{(t+1)}$ ，使新基学习器 g_{t+1} 与 g_t 足够多样。

最优重加权策略

为实现多样性，需使 g_t 在新权重 $u_n^{(t+1)}$ 下的加权正确率与错误率相等（即 $\sum_{\text{正确}} u_n^{(t+1)} = \sum_{\text{错误}} u_n^{(t+1)}$ ），令

$$u_n^{(t+1)} = u_n^{(t)} \cdot \begin{cases} \sqrt{\frac{\epsilon_t}{1-\epsilon_t}}, & y_n = g_t(x_n) \text{ (正确样本)}, \\ \sqrt{\frac{1-\epsilon_t}{\epsilon_t}}, & y_n \neq g_t(x_n) \text{ (错误样本)}. \end{cases}$$

等价地，可统一写为

$$u_n^{(t+1)} = u_n^{(t)} \cdot \exp(-\alpha_t y_n g_t(x_n)), \quad \alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right).$$

性质

- 加权正确率与错误率相等： $\sum_{\text{正确}} u_n^{(t+1)} = \sum_{\text{错误}} u_n^{(t+1)}$ ；
- g_t 在新的权重下不再是加权误差最小的假设，从而强制 g_{t+1} 与之不同，实现多样性。

例题 6.4 选择题：AdaBoost 的样本权重更新

在 AdaBoost 算法中，初始样本权重均为 $u_n^{(1)} = \frac{1}{4}$ （共 4 个样本）。第一个分类器 g_1 错误分类了样本 1，正确分类了其他 3 个样本。则更新后 $\frac{u_1^{(2)}}{u_2^{(2)}}$ 的值为：

- 1) 4
- 2) 3
- 3) $\frac{1}{3}$
- 4) $\frac{1}{4}$

解答 正确选项为 [2]。

1. 计算错误率：分类器 g_1 错误分类 1 个样本，总样本数为 4，因此错误率： $\epsilon_1 = \frac{1}{4}$ 。
2. 根据 AdaBoost 公式，分类器权重 α_1 为：

$$\alpha_1 = \frac{1}{2} \ln \left(\frac{1-\epsilon_1}{\epsilon_1} \right) = \frac{1}{2} \ln 3$$

3. 权重更新公式：

- 错误样本: $u_1^{(2)} = u_1^{(1)} \cdot \exp(-\alpha_1 \cdot (-1) \cdot (+1)) = \frac{1}{4} \cdot \exp(\alpha_1)$
 - 正确样本: $u_2^{(2)} = u_2^{(1)} \cdot \exp(-\alpha_1 \cdot (+1) \cdot (+1)) = \frac{1}{4} \cdot \exp(-\alpha_1)$
4. 权重比: $\frac{u_1^{(2)}}{u_2^{(2)}} = \frac{\exp(\alpha_1)}{\exp(-\alpha_1)} = \exp(2\alpha_1) = \exp(\ln 3) = 3$. ■

6.2.3 自适应提升算法

命题 6.2.4 (最优重加权因子: 提升多样性的缩放机制)

设当前基学习器 g_t 的加权错误率为

$$\epsilon_t = \frac{\sum_{n=1}^N u_n^{(t)} \mathbb{I}[y_n \neq g_t(x_n)]}{\sum_{n=1}^N u_n^{(t)}}.$$

最优缩放因子定义缩放因子

$$\diamond_t = \sqrt{\frac{1 - \epsilon_t}{\epsilon_t}},$$

并对样本权重进行如下缩放:

$$u_n^{(t+1)} = u_n^{(t)} \cdot \begin{cases} \frac{1}{\diamond_t}, & y_n = g_t(x_n) \text{ (正确样本)}, \\ \diamond_t, & y_n \neq g_t(x_n) \text{ (错误样本)}. \end{cases}$$

物理意义

- 错误样本权重 放大 $\diamond_t$ 倍;
- 正确样本权重 缩小 $\frac{1}{\diamond_t}$ 倍;
- 当 $\epsilon_t \leq \frac{1}{2}$ 时, $\diamond_t \geq 1$, 即错误样本权重被放大, 正确样本权重被缩小, 使下一轮基学习器聚焦于先前错误区域, 获得多样性。

等价性 该缩放机制等价于“最优重加权”(optimal re-weighting), 即:

- 错误样本的权重更新与 $(1 - \epsilon_t)$ 成正比;
- 正确样本的权重更新与 ϵ_t 成正比。

结论 通过“放大错误、缩小正确”的缩放因子, Bagging 可进化出更丰富的假设空间, 提升集成性能。 ♠

算法 6.2.22: 自适应提升算法 (AdaBoost)

输入: 训练集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$; 基学习算法 $\mathcal{A}$; 迭代轮数 T

输出: 最终分类器 $G(x)$

初始化权重

$$u_n^{(1)} = \frac{1}{N}, \quad n = 1, \dots, N.$$

for $t = 1$ **to** T **do**

训练弱分类器

 调用 $\mathcal{A}$ 在加权数据 $(\mathcal{D}, u^{(t)})$ 上学习, 得到

$$g_t = \mathcal{A}(\mathcal{D}, u^{(t)}),$$

 其中 $\mathcal{A}$ 最小化 $u^{(t)}$ -加权 0/1 误差。

计算加权错误率

$$\varepsilon_t = \frac{\sum_{n: y_n \neq g_t(x_n)} u_n^{(t)}}{\sum_{n=1}^N u_n^{(t)}}.$$

更新样本权重

$$u_n^{(t+1)} = u_n^{(t)} \cdot \begin{cases} \sqrt{\frac{1-\varepsilon_t}{\varepsilon_t}}, & y_n \neq g_t(x_n), \\ \sqrt{\frac{\varepsilon_t}{1-\varepsilon_t}}, & y_n = g_t(x_n). \end{cases}$$

 再归一化使 $\sum_n u_n^{(t+1)} = 1$ 。

计算投票权重

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1-\varepsilon_t}{\varepsilon_t} \right).$$

返回最终分类器

$$G(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t g_t(x) \right).$$

角色形象化

- 弱学习器 (weak base learning algorithm) $\mathcal{A}$: **Student**;
- 重加权机制 (optimal re-weighting factor $\diamond_t = \sqrt{\frac{1-\varepsilon_t}{\varepsilon_t}}$): **Teacher**;
- 线性聚合权重 (linear aggregation) α_t : **Class**。

命题 6.2.5 (AdaBoost 的理论保证)

由 VC 界可得

$$E_{\text{out}}(G) \leq E_{\text{in}}(G) + O \left(\sqrt{\underbrace{O(d_{\text{vc}}(\mathcal{H}) \cdot T \log T)}_{d_{\text{vc}} \text{ of all possible } G} \cdot \frac{\log N}{N}} \right),$$

其中 $d_{\text{vc}}(\mathcal{H})$ 为弱假设空间 $\mathcal{H}$ 的 VC 维, T 为迭代次数。

两项可控

- 第一项为 $E_{\text{in}}(G)$: 若每轮弱学习器满足 $\varepsilon_t \leq \varepsilon < \frac{1}{2}$ (略优于随机猜测), 则经 $T = O(\log N)$ 轮迭代后, $E_{\text{in}}(G) = 0$ 。
- 第二项为复杂度: 所有可能 G 对应的整体 d_{vc} 随迭代次数 T “缓慢”增长。

Boosting 视角总结 若弱学习器 $\mathcal{A}$ 始终“略优于随机”(即 $\varepsilon_t \leq \varepsilon < \frac{1}{2}$), 则 AdaBoost 结合 $\mathcal{A}$ 可将其“强化”为强学习器, 最终实现:

$$E_{\text{in}}(G) = 0 \quad \text{且} \quad E_{\text{out}}(G) \text{ 很小}$$



6.2.4 AdaBoost 实战




图 6.2.2: AdaBoost 实际应用

命题 6.2.6 (AdaBoost-Stump 的实际应用: 全球首个实时人脸检测系统)

核心模型 采用 **AdaBoost-Stump**: 在 24×24 像素图像中, 从 162,336 种候选特征里, 通过 AdaBoost-Stump 选出关键 patch, 并进行线性聚合。

两大贡献

- **特征选择**: AdaBoost-Stump 自动挑选最具判别力的 Haar-like 特征 (决策桩), 极大降低特征维度。
- **效率优化**: 对线性聚合器 G 进行改造, 可在早期阶段快速排除非人脸区域, 实现实时检测。

结论 AdaBoost-Stump 同时具备高效的特征选择与聚合能力, 成为首个可在实际场景中运行的实时人脸检测算法。



例题 6.5 选择题: AdaBoost - Stump 特征使用数量

现有一个规模为 9876 的数据集, 其中样本的特征向量 $\mathbf{x}_n \in \mathbb{R}^{5566}$ (即每个样本有 5566 维特征)。运行 AdaBoost - Stump 算法进行 1126 次迭代后, 集成分类器 G 实际有效使用的 $\mathbf{x}$ 中不同特征的数量范围是?

- 1) $0 \leq \text{数量} \leq 1126$
- 2) $1126 < \text{数量} \leq 5566$
- 3) $5566 < \text{数量} \leq 9876$
- 4) $9876 < \text{数量}$

解答 正确选项为 **[1]**。AdaBoost - Stump (AdaBoost 树桩) 作为弱分类器, 每次迭代构建时仅依据一个特征做决策。进行 1126 次迭代, 每次最多用 1 个不同特征 (也可能重复选同个特征), 所以有效使用的不同特征数最多 1126, 最少 0, 满足 $0 \leq \text{数量} \leq 1126$ 。■

6.2.5 总结



笔记 [自适应提升]

- 提升的动机：将多个弱假设集成为强假设。
- 重加权带来多样性：放大错分样本权重，缩小正确样本权重。
- 自适应提升算法：理论保证“两人智慧胜一人”。
- AdaBoost 实战：AdaBoost-Stump 既实用又高效。



笔记 [总体结论] 自适应提升 (AdaBoost) 通过动态调整样本权重引导弱学习器聚焦关键样本，将多个弱假设集成为强假设。其核心机制是重加权带来多样性——放大错分样本权重、缩小正确样本权重，使新基学习器与先前模型形成差异。算法具备理论保证，若弱学习器略优于随机猜测，经迭代可实现训练误差为 0 且泛化误差较小。实战中，AdaBoost-Stump 展现出高效的特征选择与聚合能力（如实时人脸检测），但需注意迭代次数对复杂度的影响。作为集成学习的重要手段，它通过巧妙的加权与聚合策略，有效提升了模型性能，是增强学习效果的实用方法。

6.3 决策树

6.3.1 决策树假设

表 6.3.1: 集成策略: Blending vs. Learning

聚合类型	Blending	Learning
Uniform (均匀)	投票 / 平均	Bagging
Non-uniform (非均匀)	线性加权	AdaBoost
Conditional (条件)	Stacking	决策树

注 决策树可视为一种传统的“条件聚合”学习模型：在每个节点根据输入特征动态决定子模型的权重。

命题 6.3.1 (决策树的递归视角与路径表达)

可把决策树看作一个递归定义的函数

$$G(x) = \sum_{t=1}^{\text{叶数}} \mathbb{I}[x \text{ 落在路径 } t] \cdot \text{leaf}_t(x),$$

也可递归地写成

$$G(x) = \sum_c \mathbb{I}[b(x) = c] \cdot G_c(x),$$

其中

- $b(x)$ 为当前节点的分支准则 (branching criteria);
- $G_c(x)$ 为第 c 个子树的预测函数;
- 整棵树即“(根节点, 子树)”——正如数据结构课所言。

注[关于决策树的声明]

- 可解释性强：在商业、医疗等领域广泛使用。
- 启发式为主：理论分析有限，常用启发式选择分裂。
- 实现简单：实现轻松。
- 预测与训练高效：但无单一“标准”算法。

结论：决策树主要依赖启发式，却因其直观与高效而自成一类实用模型。



6.3.2 决策树算法

算法 6.3.23: 基本决策树算法**输入:** 数据集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ **输出:** 决策树模型 $G(x)$ **Function** DecisionTree($\mathcal{D}$): **if** 终止条件满足 **then** **return** 基假设 $g_t(x)$; **else** 学习分支准则 $b(x)$; 将 $\mathcal{D}$ 按 $b(x)$ 的值划分为 C 个子集

$$\mathcal{D}_c = \{(x_n, y_n) \mid b(x_n) = c\}, \quad c = 1, \dots, C;$$

递归构建子树

$$G_c \leftarrow \text{DecisionTree}(\mathcal{D}_c);$$

return 组合函数

$$G(x) = \sum_{c=1}^C \mathbb{I}[b(x) = c] \cdot G_c(x).$$

四个关键选择

- 分支数 C (二叉或多叉);
- 分支准则 $b(x)$ (信息增益、基尼指数等);
- 终止条件 (最大深度、最小样本数、纯度阈值等);
- 基假设 $g_t(x)$ (常数、线性模型等)。

算法 6.3.24: Classification and Regression Tree (C&RT) 算法

输入: 数据集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, 其中 x_n 为样本特征, y_n 为对应标签/输出值, N 为样本总量

输出: 训练好的决策树模型 $G(x)$, 可依据输入特征 x 输出预测结果 (分类或回归值)

DecisionTree($\mathcal{D}$) **if** 满足终止条件 **then**

return 基假设 $g_t(x)$, 即基于当前数据集 $\mathcal{D}$ 的 E_{in} -最优常数; 分类任务常用多数投票, 回归任务常用均值;

else

 // 1. 选择分支准则 (二分支 + 决策桩)

 采用二分支策略 ($C = 2$, 将数据集划分为 2 个子集), 借助“决策桩 (decision stump, 简单的单特征判别规则)”确定划分方式:

$$b(x) = \underset{\substack{h \in \{\text{所有可能的决策桩}\} \\ (\text{单特征、简单阈值/类别划分规则})}}{\operatorname{argmin}} \sum_{c=1}^2 |\mathcal{D}_c| \cdot \operatorname{impurity}(\mathcal{D}_c)$$

 其中, $\mathcal{D}_c = \{(x_n, y_n) \mid b(x_n) = c\}$ 表示依据分支准则 $b(x)$ 划分后, 第 c 个子集的样本集合; $|\mathcal{D}_c|$ 是该子集的样本数量; $\operatorname{impurity}(\cdot)$ 为衡量数据集“纯度/杂质度”的函数。

 // 2. 杂质度 (Impurity) 计算规则

 杂质度用于量化数据集的“混乱程度”, 分类与回归任务采用不同计算逻辑:

$$\operatorname{impurity}(\mathcal{D}) = \begin{cases} \frac{1}{N} \sum_{n=1}^N (y_n - \bar{y})^2, & \text{回归任务 (预测连续值)} \\ \frac{1}{N} \sum_{n=1}^N \mathbb{I}[y_n \neq y^*], & \text{分类任务 (多数类占比)} \\ 1 - \sum_{k=1}^K \left(\frac{\sum_{n=1}^N \mathbb{I}[y_n = k]}{N} \right)^2, & \text{分类任务 (Gini 指数)} \\ 1 - \max_{1 \leq k \leq K} \frac{\sum_{n=1}^N \mathbb{I}[y_n = k]}{N}, & \text{分类任务 (最优类别)} \end{cases}$$

 实际应用中, 回归常选均方误差, 分类常选 Gini 指数。

 // 3. 终止条件细化说明

 所有样本标签/输出值相同: $\operatorname{impurity}(\mathcal{D}) = 0$, 无需再分裂, 直接以该值作为叶节点预测结果;

 所有样本特征完全相同 (但标签可能不同, 即存在杂质): 无法再用决策桩划分, 强制终止分裂;

 // 4. 递归构建子树与组合

 对划分得到的 2 个子集 $\mathcal{D}_1$ 、 $\mathcal{D}_2$, 分别递归调用 **DecisionTree($\mathcal{D}_c$)**, 生成子树 $G_1(x)$ 、 $G_2(x)$ 。最终:

$$G(x) = \sum_{c=1}^2 \mathbb{I}[b(x) = c] \cdot G_c(x)$$

 其中, $\mathbb{I}[\cdot]$ 是指示函数, 条件满足时为 1, 否则为 0。

例题 6.6 选择题：基尼指数（二分类场景）

已知基尼指数公式为 $G = 1 - \sum_{k=1}^K \left(\frac{\sum_{n=1}^N \mathbb{I}[y_n=k]}{N} \right)^2$ 。当 $K = 2$ （二分类）时，设 $\mu = \frac{N_1}{N}$ （ N_1 是标签 $y_n = 1$ 的样本数量， N 是总样本数），则此时基尼指数用 μ 表示的公式为？

- 1) $2\mu(1 - \mu)$
- 2) $2\mu^2(1 - \mu)$
- 3) $2\mu(1 - \mu)^2$
- 4) $2\mu^2(1 - \mu)^2$

解答 正确选项为 [1]。基尼指数定义为：

$$G = 1 - \sum_{k=1}^K \left(\frac{\text{标签为 } k \text{ 的样本数}}{\text{总样本数}} \right)^2$$

当 $K = 2$ 时，设标签为 1 的样本比例为 μ ，则标签为 2 的样本比例为 $1 - \mu$ 。代入公式得：

$$G = 1 - \mu^2 - (1 - \mu)^2$$

展开并化简：

$$G = 1 - \mu^2 - (1 - 2\mu + \mu^2) = 1 - \mu^2 - 1 + 2\mu - \mu^2 = 2\mu - 2\mu^2 = 2\mu(1 - \mu)$$

■

6.3.3 C&RT 决策树启发式**命题 6.3.2 (通过剪枝的正则化)**

完全生长的决策树满足 $E_{\text{in}}(G) = 0$ （若所有 x_n 互不相同），却因在极小子集 $\mathcal{D}_c$ 上继续分裂而严重过拟合（ E_{out} 很大）。

正则化目标 引入正则项 $\Omega(G) = \text{NumberOfLeaves}(G)$ ，求解

$$G^* = \arg \min_G [E_{\text{in}}(G) + \lambda \Omega(G)].$$

所得 G^* 称为 剪枝决策树 (pruned decision tree)。

计算策略 枚举全部子树不可行。通常采用 后剪枝：

1. 令 $G^{(0)}$ 为完全生长树；
2. 对 $i = 1, 2, \dots$ ，令 $G^{(i)} = \arg \min_G E_{\text{in}}(G)$ 其中 G 仅比 $G^{(i-1)}$ 少一片叶子；
3. 在验证集上选择最优剪枝序列 $\{G^{(i)}\}$ 。

♠

命题 6.3.3 (C&RT 对类别特征与缺失值的处理)**1. 类别特征的分支**

- 数值特征：使用决策桩

$$b(x) = \mathbb{I}[x_i \leq \theta] + 1, \quad \theta \in \mathbb{R}.$$

- 类别特征：使用决策子集

$$b(x) = \mathbb{I}[x_i \in S] + 1, \quad S \subseteq \{1, 2, \dots, K\}.$$

C&RT（及一般决策树）天然支持类别特征，无需额外编码。

2. 缺失值的代理分支

假设主分支为

$$b(x) = \mathbb{I}[\text{weight} \leq 50 \text{ kg}] + 1.$$

若预测时 `weight` 缺失：

- 人类做法：用 `height` 阈值近似 `weight` 阈值；
- 算法做法：训练时为 $b(x)$ 预先学习 代理分支

$$b_1(x), b_2(x), \dots \text{ (按与主分支一致性排序) ;}$$

预测时缺失即用最佳代理分支替代。

C&RT 通过代理机制轻松处理缺失特征。



6.3.4 决策树实践




图 6.3.1: C&RT 实际应用




图 6.3.2: C&RT 与 AdaBoost-Stump 的对比图

命题 6.3.4 (C&RT 的实用特性)

分类与回归树 (C&RT) 具有以下独特优势：

- 易于解释：决策树的结构直观，易于人类理解；
- 多分类友好：天然支持多分类任务，无需额外调整；
- 类别特征友好：直接处理类别特征，无需编码；
- 缺失值友好：通过代理分支处理缺失特征，无需丢弃样本；
- 高效非线性建模：训练与测试均高效，能自动捕捉非线性关系。

总结 几乎无其他单一学习模型具备上述全部特性，唯有其他决策树算法（即除了基础决策树之外的其他决策树相关算法）与之类似。



例题 6.7 选择题：未剪枝 CART 树的特性

以下哪项不是未剪枝（without pruning）的 CART（分类与回归树）的特性？

- 1) 易于处理缺失特征
- 2) 生成可解释的假设
- 3) 达到低训练误差 E_{in}
- 4) 达到低泛化误差 E_{out}

解答 正确选项为 [4]。未剪枝的 CART 树具有以下特性：

- 可通过替代分裂等方法轻松处理缺失特征（对应选项 1）；
- 树结构决策逻辑直观，生成的假设可解释（对应选项 2）；
- 会完全拟合训练数据，因此训练误差 E_{in} 低（对应选项 3）。

未剪枝的 CART 树因过度拟合训练数据，泛化误差 E_{out} 通常较高，无法保证低 E_{out} （选项 4 不符合）。 ■

6.3.5 总结

笔记 [决策树]

- 决策树假设：以路径条件方式表达的聚合模型。
- 决策树算法：递归地分裂节点，直至满足终止条件并返回叶节点（基预测）。
- C&RT 决策树启发式：剪枝、类别型特征分支、代理分裂。
- 决策树实践：模型可解释且计算高效。

6.4 随机森林

6.4.1 随机森林算法

算法 6.4.25: 随机森林 (Random Forest, RF) 算法

输入: 训练数据集 $\mathcal{D}$

输出: 随机森林模型 G

函数 RandomForest($\mathcal{D}$);

for $t = 1, 2, \dots, T$ **do**

 步骤 1: 通过自助采样从 $\mathcal{D}$ 中获取大小为 N' 的数据 $\tilde{\mathcal{D}}_t$;

 步骤 2: 利用 $\tilde{\mathcal{D}}_t$ 通过 DTree 函数获得树 g_t ;

返回 $G = \text{Uniform}(\{g_t\})$;

函数 DTree($\mathcal{D}$);

if 达到终止条件 **then**

 返回基学习器 g_t ;

else

 步骤 1: 学习最佳划分 $b(x)$ 并将 $\mathcal{D}$ 分割为 $\mathcal{D}_c$;

 步骤 2: 递归构建子树 $G_c \leftarrow \text{DTree}(\mathcal{D}_c)$;

 步骤 3: 返回 $G(x) = \sum_{c=1}^C \mathbb{I}[b(x) = c] \cdot G_c(x)$;

随机森林的优点:

- 高度并行/高效学习;
- 继承了 C&RT 的优点;
- 消除了完全生长树的缺点。

命题 6.4.1 (通过特征变换实现多样性)

1. 特征子空间采样 (Random Subspace)

从原始特征空间 $\mathbb{R}^d$ 中随机抽取 $d' < d$ 个特征索引 $i_1, \dots, i_{d'}$, 构造映射

$$\Phi(x) = (x_{i_1}, x_{i_2}, \dots, x_{i_{d'}}) \in \mathbb{R}^{d'}.$$

此做法

- 等价于在标准正交基中随机选择 d' 个坐标;
- 特别适用于 $d \gg N$ 的高维场景, 计算高效;
- 最早用于随机森林 (RF) 中每棵树的节点分裂。

2. 特征随机线性组合 (Random Combination)

更一般地, 取随机矩阵 $P \in \mathbb{R}^{d' \times d}$, 其每一行 p_i 从某分布 (如高斯或稀疏分布) 独立采样, 定义

$$\Phi(x) = Px, \quad \Phi_i(x) = p_i^\top x.$$

- 当 p_i 仅含 $d'' \ll d$ 个非零元素且取值为 $\{0, 1\}$ 时, 退化为随机子空间;
- 低维随机投影可减少方差, 同时保留足够表达能力;
- 现代 RF 可在每棵树、甚至每个节点重新采样 P , 实现“无处不在的随机性”。

结论 Bagging + 随机特征变换（子空间或线性组合）构成了随机森林的核心机制，在效率与多样性之间取得平衡。



例题 6.8 选择题：随机森林中 CART 树分支函数的等价模型

在由随机组合 CART 树构成的随机森林（RF）里，树中每个分支函数 $b(\mathbf{x})$ 等价于以下哪种模型？

- 1) 常数
- 2) 决策树桩（decision stump）
- 3) 感知机（perceptron）
- 4) 以上都不是

解答 正确选项为 [3]。在随机森林的随机组合 CART 树场景中，对于每个分支函数 $b(\mathbf{x})$ ，其工作逻辑是：输入向量 $\mathbf{x}$ 先通过一个随机向量 $\mathbf{v}$ 进行投影操作，之后再经阈值化处理来做出二元决策。而感知机的工作方式就是先对输入做线性组合（这里的投影可看作一种特殊的线性组合形式），再依据阈值进行判断，所以分支函数 $b(\mathbf{x})$ 等价于感知机。



6.4.2 袋外估计（OOB）

定义 6.4.1 (袋外样本 Out-of-Bag (OOB) Examples)

在自助抽样（bootstrap sampling）框架下，给定原始训练数据集

$$\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\},$$

通过有放回地抽取 N 个样本构成自助训练集 $\mathcal{D}^{(b)}$ 。由于抽样是有放回的，每个样本被抽中的概率为

$$1 - \left(1 - \frac{1}{N}\right)^N \xrightarrow{N \rightarrow \infty} 1 - e^{-1} \approx 63.2\%.$$

因此，对任意基学习器 h_b （如随机森林中的一棵树）：

- **In-bag samples**: 出现在 $\mathcal{D}^{(b)}$ 中并被用于训练 h_b 的样本；
- **Out-of-Bag (OOB) samples**: 未出现在 $\mathcal{D}^{(b)}$ 中的样本，占比约 36.8%。

对于整个集成模型（如包含 B 棵树的随机森林），每个训练样本 (x_n, y_n) 对部分树是 out-of-bag，对其余树是 in-bag。把这些袋外（OOB）预测聚合起来，即可得到该样本的袋外预测值（Out-of-Bag Prediction），进而计算袋外误差（Out-of-Bag Error）作为无需额外验证集的泛化误差估计。



命题 6.4.2 (利用 OOB 误差的模型选择)

设候选模型族为 $\{\mathcal{H}_m\}_{m=1}^M$ ，对应算法 $\mathcal{A}_m$ 。

传统做法（依赖验证集）

$$m^* = \arg \min_{1 \leq m \leq M} E_{\text{val}}(\mathcal{A}_m(\mathcal{D}_{\text{train}})), \quad \text{需额外划分验证集并重新训练。}$$

随机森林的 OOB 自验证

$$m^* = \arg \min_{1 \leq m \leq M} E_{\text{OOB}}(\text{RF}_m(\mathcal{D})),$$

其中

- E_{OOB} 由每棵树的袋外样本即时计算，无需重新训练；

- 可直接用于调节随机森林超参数（如子特征数 d' 、树数等）；
- 实践中 E_{OOB} 通常与真实误差高度一致。

结论 随机森林利用 OOB 误差实现“训练-验证一体化”，既节省计算又提升模型选择效率。

6.4.3 特征选择

命题 6.4.3 (特征选择 (Feature Selection))

对于原始特征向量 $x = (X_1, \dots, X_d)$ ，特征选择通过学习子集映射

$$\Phi(x) = (X_{i_1}, \dots, X_{i_{d'}}), \quad d' < d$$

保留有用维度、剔除冗余或无关维度。

优势

- 计算：训练与预测复杂度降低；
- 泛化：减少特征噪声，抑制过拟合；
- 解释：保留特征易于理解。

劣势

- 组合爆炸：最优子集搜索 NP-hard；
- 过拟合：小样本易选噪声特征；
- 误解释：被丢弃特征可能带来错误因果推断。

特例 决策树是少数自带特征选择的模型：每次分裂只挑一个最优特征，天然执行子集搜索。

命题 6.4.4 (随机森林中的特征重要性：线性模型、置换检验与 OOB 加速)

1. 线性模型的直观思路

若模型为线性形式

$$\text{score} = w^\top x = \sum_{i=1}^d w_i x_i,$$

则定义

$$\text{importance}(i) = |w_i|$$

作为特征 i 的重要性；权重 w 由数据学习得到，简单且可解释。

2. 非线性模型的置换检验 (Permutation Test)

对任意非线性模型（如随机森林），评估特征 i 的重要性步骤如下：

1. 记录原始性能 $\mathcal{P}(D)$ （如精度、 R^2 等）；
2. 构造置换数据集 $D^{(p)}$ ：仅对特征 i 做随机重排，保持其余特征与标签不变；
3. 计算置换后性能 $\mathcal{P}(D^{(p)})$ ；
4. 定义

$$\text{importance}(i) = \mathcal{P}(D) - \mathcal{P}(D^{(p)}).$$

置换破坏特征 i 与标签的关联，性能下降越显著，该特征越重要。

3. 随机森林的 OOB 加速实现

传统置换检验需重新训练与验证；随机森林天然拥有 OOB 样本，可直接使用：

1. 对每个样本 (x_n, y_n) ，仅收集其 OOB 树集合 G_{OOB} ；
2. 在 G_{OOB} 上计算 OOB 误差 $E_{\text{OOB}}(G)$ ；
3. 对特征 i 做重排后计算 $E_{\text{OOB}}^{(p)}(G)$ ；
4. 定义

$$\text{importance}(i) = E_{\text{OOB}}^{(p)}(G) - E_{\text{OOB}}(G).$$

无需额外划分验证集，一步到位，实际效果显著。



例题 6.9 选择题：随机森林中常数特征的重要性

在随机森林（RF）中，若数据集中第 1126 个特征是常数 5566，该特征的重要性 $\text{importance}(i)$ 是多少？

- 1) 0
- 2) 1
- 3) 1126
- 4) 5566

解答 正确选项为 **1**。在随机森林里，特征重要性用于衡量特征对模型区分样本的贡献价值。对于本题中第 1126 个这样的常数特征（所有样本在该特征上取值都是 5566），由于它无法为区分不同样本提供有效信息，对构建决策树、辅助模型做决策没有帮助。按照随机森林计算特征重要性的逻辑，这类常数特征的重要性就是 0。

6.4.4 随机森林实战




图 6.4.1: 少样本情况下决策树、bagging 与随机森林应用对比




图 6.4.2: 大量样本情况下 bagging 与随机森林应用对比




图 6.4.3: 含噪声的大量样本情况下 bagging 与随机森林应用对比

定理 6.4.1 (随机森林一致性：树数趋于无穷时误差收敛)

设随机森林

$$G_T(x) = \frac{1}{T} \sum_{t=1}^T g_t(x)$$

由 T 棵基学习器（决策树）构成，每棵树 g_t 通过以下随机机制独立生成：

- 对训练集 $\mathcal{D}$ 做自助抽样 $\mathcal{D}_t$ ；
- 在每个节点随机选取 m_{try} 个候选特征并选择最优分裂；
- 树生长至终端节点最小样本数 $s_{\min}$ 或最大深度。

记单棵树的条件期望

$$g(x) = \mathbb{E}_{\mathcal{D}_t}[g_t(x) \mid \mathcal{D}],$$

则当 $T \rightarrow \infty$ 时，随机森林的泛化误差满足

$$\lim_{T \rightarrow \infty} \mathbb{E}_{\mathcal{D}} \left[\mathbb{E}_{(x,y)} [\ell(y, G_T(x))] \right] = \mathbb{E}_{\mathcal{D}} \left[\mathbb{E}_{(x,y)} [\ell(y, g(x))] \right],$$

即集成误差收敛到单棵树的期望误差下界。



证明 [证明思路]（证明思路仅供参考，有兴趣的读者可自行查看资料）

1. 条件独立同分布：

给定训练集 $\mathcal{D}$ ，每棵树 g_t 的条件分布相同，且独立。

2. 大数定律：

对于任意固定 (x, y) ，随机变量 $\ell(y, g_t(x))$ 独立同分布，具有有限方差，故

$$\frac{1}{T} \sum_{t=1}^T \ell(y, g_t(x)) \xrightarrow{T \rightarrow \infty} \mathbb{E}_{g_t}[\ell(y, g_t(x))] = \mathbb{E}[\ell(y, g(x))] \quad \text{a.s.}$$

3. 一致可积：

损失 ℓ 有界（例如 0/1 损失或平方损失在有限域上），由控制收敛定理可交换期望与极限，得到

$$\mathbb{E}_{\mathcal{D}} \mathbb{E}_{(x,y)} \left[\ell \left(y, \frac{1}{T} \sum_{t=1}^T g_t(x) \right) \right] \xrightarrow{T \rightarrow \infty} \mathbb{E}_{\mathcal{D}} \mathbb{E}_{(x,y)} [\ell(y, g(x))].$$

4. 结论：当树数 $T \rightarrow \infty$ 时，随机森林的泛化误差收敛到单棵树条件期望误差的极限，因此“树越多越好”在统计意义上成立。 ■

注 收敛速度：由 Hoeffding 不等式，对任意 $\varepsilon > 0$,

$$\mathbb{P}(|G_T(x) - g(x)| > \varepsilon) \leq 2 \exp(-2T\varepsilon^2),$$

表明误差随 $\mathcal{O}(1/\sqrt{T})$ 速度下降；实践中需通过交叉验证或稳定性检查确定足够大的 T 。

6.4.5 总结



笔记 [随机森林]

- 随机森林算法：在随机投影的子空间上构建多棵决策树，再进行袋外集成。
- 袋外估计（OOB）：利用未参与训练的 OOB 样本进行自我验证。
- 特征选择：通过置换检验评估各特征的重要性。
- 随机森林实战：依靠大量树生成“平滑”的决策边界。

6.5 梯度提升决策树

6.5.1 自适应提升决策树

算法 6.5.26: 自适应提升决策树 (AdaBoost-DTree)

输入: 数据集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$; 迭代轮数 T

输出: 最终分类器 $G(x)$

初始化权重

$$u_n^{(1)} = \frac{1}{N}, \quad n = 1, \dots, N.$$

for $t = 1$ **to** T **do**

 重加权数据 依据当前权重 $u^{(t)}$;

 训练加权树

$$g_t = \text{DTree}(\mathcal{D}, u^{(t)});$$

 计算投票权重

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right), \quad \text{其中 } \varepsilon_t = \frac{\sum_{n: y_n \neq g_t(x_n)} u_n^{(t)}}{\sum_{n=1}^N u_n^{(t)}}.$$

返回 最终分类器

$$G(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t g_t(x) \right).$$

命题 6.5.1 (加权决策树的黑箱化实现逻辑)

针对无法直接接入样本权重的 C&RT 决策树, 可通过随机采样机制间接实现加权学习, 具体模式如下:

1. Bagging-DTree 模式

样本权重 u_n 依托 **Bootstrap** 重采样传递:

- 重采样逻辑: 样本 (x_n, y_n) 出现在重采样数据集 $\tilde{\mathcal{D}}_t$ 的概率, 与权重 u_n 正相关;
- 执行流程: 通过 Bootstrap 生成重采样集 $\tilde{\mathcal{D}}_t$ 后, 调用 $\text{DTree}(\tilde{\mathcal{D}}_t)$ 训练基学习器 g_t 。

2. AdaBoost-DTree 模式

第 t 轮样本权重 $u_n^{(t)}$ 借助比例采样 (按 $u_n^{(t)} / \sum u_k^{(t)}$ 概率) 传递:

- 黑箱兼容: 无需修改 DTree 内部逻辑, 仅通过采样生成加权分布 $\tilde{\mathcal{D}}_t$;
- 执行流程: $u^{(t)} \xrightarrow{\text{按权采样}} \tilde{\mathcal{D}}_t \xrightarrow{\text{DTree 训练}} g_t$ (权重驱动采样构建数据集, 再用决策树训练基学习器)。

结论 无论 Bagging 还是 AdaBoost 框架, 只要 C&RT 决策树保持“黑箱”(不改动算法内部), 均可通过随机采样策略桥接“权重信息”与“决策树训练”, 让黑箱模型间接支持加权学习逻辑。

命题 6.5.2 (弱决策树与 AdaBoost-Stump 机制)

1. 过强树的失效风险

在 AdaBoost 框架中, 若每棵决策树都以完全生长 (不剪枝、不限高) 的方式, 在全部训练样本 $\{x_n\}$ 上学习, 会引发关键问题:

由于完全生长的树可对训练样本实现“完美拟合”(若样本无重复标签), 此时训练误差 $E_{\text{in}}(g_t) = 0$, 其加权误差率 ε_t (衡量样本权重下的分类错误) 也会趋近于 0。代入 AdaBoost 为单树设计的投票权重公式:

$$\alpha_t = \ln \sqrt{\frac{1 - \varepsilon_t}{\varepsilon_t}}$$

当 $\varepsilon_t \rightarrow 0$ 时, $\alpha_t \rightarrow \infty$ 。这意味着单个强树会垄断整个集成的投票权, 彻底破坏 AdaBoost “多弱学习器协作互补”的核心逻辑, 失去集成学习的意义。

2. 弱树的构造策略

为避免强树“独裁”, 需主动构造弱决策树 (单树性能弱于随机猜测, 但多树可通过 AdaBoost 协作), 核心手段包含两方面:

- 限制模型复杂度:

- 对完全生长的树进行后剪枝 (post-pruning), 通过合并/删除节点精简结构;
- 或直接限制树高 (如强制树高 ≤ 1), 从根源降低单树拟合能力。

- 控制训练数据:

训练每棵树前, 按样本权重 $\mathbf{u}^{(t)}$ 进行加权采样, 让单树仅学习部分样本 (而非全部数据)。此举进一步削弱单树对全局规律的拟合, 强化“多树协作”的必要性。

3. 极限特例: AdaBoost-Stump

当树高被严格限制为 1 (极端剪枝, 仅保留一个分裂节点), 且以 0/1 分类误差 (最简单的“杂质度”指标, 直接统计分类错误数) 作为优化目标时, 决策树会退化为决策桩 (decision stump)——结构极简, 仅通过一个特征的阈值划分样本。

此时,

$$\text{AdaBoost-Stump} = \text{AdaBoost 框架} + (\text{树高} \leq 1 \text{ 的 C\&RT 决策树})$$

是 AdaBoost-DTree (基于决策树的 AdaBoost 通用框架) 的典型特殊实例。其本质是用“决策桩”这类极致弱学习器, 验证 AdaBoost 从“多弱协作”到“强集成”的核心逻辑。

例题 6.10 选择题: AdaBoost - DTree 中 α_t 的可能性分析

运行带采样的 AdaBoost - DTree 算法时, 得到决策树 g_t , 且 g_t 在采样数据集 $\tilde{\mathcal{D}}_t$ 上实现零误差。关于 g_t 对应的权重 α_t , 以下哪种情况可能发生?

- 1) $\alpha_t < 0$
- 2) $\alpha_t = 0$
- 3) $\alpha_t > 0$
- 4) 以上所有情况

解答 正确选项为 [4]。在 AdaBoost 中, 弱学习器权重 α_t 由误差率 ε_t 决定, 公式为 $\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right)$ 。

虽 g_t 在采样集 $\tilde{\mathcal{D}}_t$ 上零误差, 但在带权数据集 $(\mathcal{D}, \mathbf{u}^{(t)})$ 中, 加权误差不一定为 0。

- 若加权误差 $\varepsilon_t \rightarrow 0$, 则 $\alpha_t > 0$;
- 若加权误差 $\varepsilon_t = 0.5$, 则 $\alpha_t = 0$;

- 若加权误差 $\epsilon_t > 0.5$, 则 $\alpha_t < 0$ 。

因此 α_t 可小于、等于、大于 0, 所有情况都可能发生。 ■

6.5.2 AdaBoost 的优化视角

命题 6.5.3 (AdaBoost 的样本权重与投票得分)

在第 t 轮迭代中, 样本权重的更新规则如下:

$$u_n^{(t+1)} = u_n^{(t)} \cdot \begin{cases} \exp(\alpha_t), & \text{若分类错误 (即 } y_n \neq g_t(x_n) \text{)} \\ \exp(-\alpha_t), & \text{若分类正确 (即 } y_n = g_t(x_n) \text{)} \end{cases}$$

其中, $\alpha_t = \frac{1}{2} \ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$, ϵ_t 为第 t 轮基分类器 g_t 的分类误差率。

多轮迭代后权重的累积更新从初始权重 $u_n^{(1)}$ 开始, 经过 T 轮迭代, 样本 (x_n, y_n) 的权重 $u_n^{(T+1)}$ 可通过逐轮指数更新累积推导:

$$u_n^{(T+1)} = u_n^{(1)} \cdot \prod_{t=1}^T \exp(-y_n \alpha_t g_t(x_n))$$

若初始时所有样本权重均匀分布 (即 $u_n^{(1)} = \frac{1}{N}$, N 为样本总数), 则上式可简化为:

$$u_n^{(T+1)} = \frac{1}{N} \cdot \exp\left(-y_n \sum_{t=1}^T \alpha_t g_t(x_n)\right)$$

定义累积投票得分为 $\text{voting score}(x_n) = \sum_{t=1}^T \alpha_t g_t(x_n)$, 权重最终形式可统一关联为:

$$u_n^{(T+1)} \propto \exp(-y_n \cdot \text{voting score}(x_n))$$

投票得分与最终输出 AdaBoost 最终的强分类器由基分类器加权投票决定:

$$G(x) = \text{sign}\left(\underbrace{\sum_{t=1}^T \alpha_t g_t(x)}_{\text{投票得分 (voting score)}}\right)$$

其中, $\sum_{t=1}^T \alpha_t g_t(x)$ 是基分类器集合 $\{g_t\}$ 在样本 x 上的投票得分, 符号函数 $\text{sign}(\cdot)$ 依据投票得分正负输出最终分类标签。 ♠

命题 6.5.4 (投票得分与间隔的 AdaBoost 视角)

将最终分类器写成线性混合模型

$$G(x) = \text{sign}\left(\underbrace{\sum_{t=1}^T \alpha_t g_t(x)}_{\text{投票得分 (voting score)}}\right) = \text{sign}\left(\underbrace{\sum_{i=1}^d \omega_i \phi_i(x)}_{\text{投票得分 (voting score)}}\right)$$

带符号的未归一化间隔 对训练样本 (x_n, y_n) 定义

$$\text{margin}_n = \frac{y_n \cdot (w^\top \phi(x_n) + b)}{\|w\|} \propto y_n \cdot (\text{voting score}),$$

目标: $\text{margin}_n > 0$ 且越大越好 $\Leftrightarrow y_n (\text{voting score})$ 越大越好 $\Leftrightarrow \exp(-y_n (\text{voting score}))$ 越小越好 $\Leftrightarrow u_n^{(T+1)}$ 越小越好。

结论 AdaBoost 的权重更新使得

$$\sum_{n=1}^N u_n^{(t)} \propto \sum_{n=1}^N \exp(-y_n \cdot \text{voting score}(x_n))$$

在迭代中单调下降, 从而保证间隔持续增大, 最终获得强分类器。

命题 6.5.5 (AdaBoost 的指数误差函数)

AdaBoost 的迭代过程单调递减

$$\sum_{n=1}^N \exp\left(-y_n \sum_{t=1}^T \alpha_t g_t(x_n)\right),$$

从而近似最小化该目标。

指数误差 (算法误差度量) 给定线性得分 $s = \sum_{t=1}^T \alpha_t g_t(x)$, 定义

$$\text{err}_{\text{ADA}}(s, y) = \exp(-ys),$$

它是 0/1 误差的凸上界:

$$\text{err}_{0/1}(s, y) = \mathbb{I}[ys \leq 0] \leq \exp(-ys).$$




图 6.5.1: AdaBoost 的指数误差函数

结论 AdaBoost 通过最小化凸上界 $\exp(-ys)$ 来间接优化原本难以处理的 0/1 误差, 实现高效的 boosting 过程。

命题 6.5.6 (AdaBoost 的梯度下降视角)

1. 函数空间梯度下降基础

梯度下降的核心是在迭代第 t 步时, 通过一阶泰勒展开近似误差函数的局部更新:

$$\min_{\|v\|=1} E_{\text{in}}(\mathbf{w}_t + \eta \mathbf{v}) \approx E_{\text{in}}(\mathbf{w}_t) + \eta \cdot \mathbf{v}^\top \nabla E_{\text{in}}(\mathbf{w}_t),$$

其中 $\mathbf{v}$ 为搜索方向, η 为步长, $\nabla E_{\text{in}}(\mathbf{w}_t)$ 为当前点梯度。

2. AdaBoost 误差的泰勒展开 (函数空间梯度)

AdaBoost 的整体指数误差定义为：

$$E_{\text{ADA}} = \frac{1}{N} \sum_{n=1}^N \exp\left(-y_n(f_{t-1}(\mathbf{x}_n) + \eta h(\mathbf{x}_n))\right),$$

其中：

- $f_{t-1}(\mathbf{x}) = \sum_{\tau=1}^{t-1} \alpha_{\tau} g_{\tau}(\mathbf{x})$ 是前 $t-1$ 轮弱学习器的加权组合（函数空间“当前点”）；
- $h(\mathbf{x})$ 是第 t 轮待选弱学习器（搜索方向候选）；
- η 是步长（后续对应投票权重 α_t ）。

引入样本权重 $u_n^{(t)} = \frac{1}{N} \exp(-y_n f_{t-1}(\mathbf{x}_n))$ （由历史模型 f_{t-1} 决定），对 η 做一阶泰勒展开（保留线性项 $\exp(-z) \approx 1 - z$ ），误差简化为：

$$E_{\text{ADA}} \approx \sum_{n=1}^N u_n^{(t)} \cdot \exp(-y_n \eta h(\mathbf{x}_n)) \approx \sum_{n=1}^N u_n^{(t)} (1 - y_n \eta h(\mathbf{x}_n)).$$

3. 弱学习器：梯度方向的求解（加权 0/1 误差）

优化弱学习器 h 需最小化近似误差的线性项：

$$\min_h \sum_{n=1}^N u_n^{(t)} (-y_n h(\mathbf{x}_n)).$$

由于二分类中 $y_n, h(\mathbf{x}_n) \in \{-1, +1\}$ ，符号分析可得：

- 若 $y_n = h(\mathbf{x}_n)$ ，则 $-y_n h(\mathbf{x}_n) = -1$ ；
- 若 $y_n \neq h(\mathbf{x}_n)$ ，则 $-y_n h(\mathbf{x}_n) = +1$ 。

因此，目标等价于加权 0/1 误差最小化：

$$\sum_{n=1}^N u_n^{(t)} (-y_n h(\mathbf{x}_n)) = \sum_{n=1}^N u_n^{(t)} \cdot \mathbb{I}[y_n \neq h(\mathbf{x}_n)] \cdot 2 - \sum_{n=1}^N u_n^{(t)} = - \sum_{n=1}^N u_n^{(t)} + 2E_{\text{in}}^{u^{(t)}} \cdot N,$$

这正是 AdaBoost 中弱学习算法 $\mathcal{A}$ 的目标——找到 g_t 最小化加权 0/1 误差，即 g_t 提供了函数空间梯度下降的近似方向。

4. 步长 α_t ：最速下降的解析解

确定 g_t 后，误差简化为二分类形式（区分 g_t 正确/错误样本）：

$$E_{\text{ADA}}(\eta) = \sum_{\substack{n \\ y_n = g_t(\mathbf{x}_n)}} u_n^{(t)} e^{-\eta} + \sum_{\substack{n \\ y_n \neq g_t(\mathbf{x}_n)}} u_n^{(t)} e^{\eta} = \left(\sum_{n=1}^N u_n^{(t)} \right) ((1 - \varepsilon_t) e^{-\eta} + \varepsilon_t e^{\eta}),$$

其中 $\varepsilon_t = \sum_{\substack{n \\ y_n \neq g_t(\mathbf{x}_n)}} u_n^{(t)}$ 是 g_t 的加权分类误差。

对 η 求导并令导数为 0（最速下降条件）：

$$\frac{dE_{\text{ADA}}}{d\eta} = -(1 - \varepsilon_t) e^{-\eta} + \varepsilon_t e^{\eta} = 0,$$

解得最优步长：

$$\eta_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right) = \alpha_t.$$

即 AdaBoost 的投票权重 α_t 是函数空间梯度下降的最优步长。

结论 AdaBoost 等价于函数空间的最速下降算法，迭代中：

1. 弱学习器 $\mathcal{A}$ 寻找梯度方向（最小化加权 0/1 误差的 g_t ）；

2. 投票权重 α_t 是解析求解的最优步长，驱动模型沿梯度方向更新。

简言之，AdaBoost 通过“弱学习器定方向 + 解析步长定更新”，在函数空间逐步优化指数误差，最终构建强分类器。



6.5.3 梯度提升

命题 6.5.7 (Gradient Boosting: 任意误差函数的推广)

AdaBoost (仅二元输出假设)

$$\min_{\eta} \min_h \frac{1}{N} \sum_{n=1}^N \exp(-y_n(f_{t-1}(x_n) + \eta h(x_n))), \quad \text{其中 } h(x_n) \in \{-1, +1\}.$$

Gradient Boosting (任意假设, 实值输出) 将指数误差替换为任意可微损失 $\ell(\cdot, \cdot)$:

$$\min_{\eta} \min_h \frac{1}{N} \sum_{n=1}^N \ell(f_{t-1}(x_n) + \eta h(x_n), y_n), \quad \text{其中 } h(x_n) \in \mathbb{R}.$$

关键差异

- AdaBoost 限定 h 为二元输出，损失固定为指数；
- Gradient Boosting 允许 h 为实值输出，并可选用任意损失（平方误差、Huber、logistic 等），从而自然扩展到回归、软分类等任务。

结论 Gradient Boosting 通过“函数空间梯度下降 + 任意损失”框架，成为 AdaBoost 在任意误差函数下的通用推广。



命题 6.5.8 (Gradient Boost 回归的残差拟合机制)

1. 目标设定：平方误差优化框架

在第 t 轮迭代中，当前加法模型为：

$$f_{t-1}(\mathbf{x}) = \sum_{\tau=1}^{t-1} \alpha_{\tau} g_{\tau}(\mathbf{x})$$

对样本 $\mathbf{x}_n$ ，记前 $t-1$ 轮模型的预测值为 $s_n = f_{t-1}(\mathbf{x}_n)$ ，需最小化的平方损失目标为：

$$\min_{\eta, h} \frac{1}{N} \sum_{n=1}^N \text{err}(s_n + \eta \cdot h(\mathbf{x}_n), y_n), \quad \text{其中 } \text{err}(s, y) = (s - y)^2$$

2. 一阶泰勒近似：简化优化路径

对平方损失 $\text{err}(s, y)$ 做一阶泰勒展开（保留线性项与常数项），损失近似为：

$$\frac{1}{N} \sum_{n=1}^N \text{err}(s_n + \eta \cdot h(\mathbf{x}_n), y_n) \approx \underbrace{\frac{1}{N} \sum_{n=1}^N \text{err}(s_n, y_n)}_{\text{常数项}} + \frac{\eta}{N} \sum_{n=1}^N 2h(\mathbf{x}_n) \cdot (s_n - y_n)$$

若不约束 h ，理论上 $h(\mathbf{x}_n) = -\infty \cdot (s_n - y_n)$ 可使线性项最小化，但此时 h 的幅度无界，导致模型发散。

3. 正则化约束：残差拟合的本质

为避免 h 幅度失控，引入正则化后等价优化目标：

$$\min_h \frac{1}{N} \sum_{n=1}^N (2h(\mathbf{x}_n)(s_n - y_n) + (h(\mathbf{x}_n))^2) = \min_h \frac{1}{N} \sum_{n=1}^N \left(\underbrace{-(y_n - s_n)^2}_{\text{常数项}} + (h(\mathbf{x}_n) - (y_n - s_n))^2 \right)$$

定义残差 $r_n = y_n - s_n$ ，则弱学习器 h 的训练目标为：

$$g_t \leftarrow \arg \min_h \frac{1}{N} \sum_{n=1}^N (h(\mathbf{x}_n) - r_n)^2$$

即 g_t 需拟合当前残差 r_n ，弥补前 $t-1$ 轮模型的预测偏差。

4. 步长优化：单变量线性回归解

得到弱学习器 g_t 后，优化其在加法模型中的贡献步长 $\alpha_t = \eta$ ，需最小化：

$$\min_{\eta} \frac{1}{N} \sum_{n=1}^N (s_n + \eta \cdot g_t(\mathbf{x}_n) - y_n)^2$$

这等价于单变量线性回归问题（仅优化 η ），解析解为：

$$\alpha_t = \eta = \frac{\sum_{n=1}^N (y_n - s_n) \cdot g_t(\mathbf{x}_n)}{\sum_{n=1}^N (g_t(\mathbf{x}_n))^2}$$

5. 总结 Gradient Boost 回归的迭代过程：

- 残差拟合：用当前残差 $r_n = y_n - s_n$ 训练弱回归器 g_t ($s_n = \sum_{\tau=1}^{t-1} \alpha_{\tau} g_{\tau}(\mathbf{x}_n)$)；
- 步长优化：通过单变量线性回归计算 g_t 的最优贡献权重 α_t ；
- 迭代更新 $f_t(\mathbf{x}) = f_{t-1}(\mathbf{x}) + \alpha_t g_t(\mathbf{x})$ ，逐步降低平方损失。



算法 6.5.27: 梯度提升决策树 Gradient Boosted Decision Tree (GBDT)

输入：训练集 $\mathcal{D} = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$ ；迭代轮数 T

输出：最终回归器 $G(x)$

初始化残差 $s_n^{(0)} = 0, \quad n = 1, \dots, N.$

for $t = 1$ **to** T **do**

1. 拟合残差 使用平方误差回归算法 $\mathcal{A}$ （如采样 + 剪枝的 C&RT）训练弱学习器

$$g_t = \mathcal{A}(\{(\mathbf{x}_n, y_n - s_n^{(t-1)})\}_{n=1}^N).$$

2. 计算步长 对 $\{(g_t(\mathbf{x}_n), y_n - s_n^{(t-1)})\}_{n=1}^N$ 做单变量线性回归，得

$$\alpha_t = \frac{\sum_{n=1}^N (y_n - s_n^{(t-1)}) g_t(\mathbf{x}_n)}{\sum_{n=1}^N g_t(\mathbf{x}_n)^2}.$$

3. 更新残差

$$s_n^{(t)} \leftarrow s_n^{(t-1)} + \alpha_t g_t(\mathbf{x}_n), \quad n = 1, \dots, N.$$

返回最终模型

$$G(x) = \sum_{t=1}^T \alpha_t g_t(x).$$

6.5.4 集成模型小结

命题 6.5.9 (Blending 映射)

设已获得多样基模型 $\{g_t\}_{t=1}^T$ ，按聚合方式可将 Blending 映射为三类：

- **Uniform**：简单投票/平均

$$G(x) = \frac{1}{T} \sum_{t=1}^T g_t(x).$$

- **Non-uniform**：对 g_t 做线性加权

$$G(x) = \sum_{t=1}^T \alpha_t g_t(x), \quad \alpha_t \in \mathbb{R}.$$

- **Conditional**：在 g_t 变换后的特征上建立非线性模型

$$G(x) = \varphi(g_1(x), \dots, g_T(x)), \quad \varphi \text{ 非线性}.$$

实用准则

- 均匀聚合用于 稳定性；
- 非均匀或条件聚合需谨慎设计，以控制 复杂度。

命题 6.5.10 (Aggregation-Learning 模型映射)

设在学习过程中同时获得多样基模型 $\{g_t\}_{t=1}^T$ ，各类方法的多样性来源与聚合方式如下：

- **Bagging**：通过 自助采样 产生多样 g_t ，采用 均匀投票。
- **AdaBoost**：通过 重加权样本 产生多样 g_t ，采用 线性投票。
- **决策树**：通过 数据分裂 产生多样 g_t ，采用 条件投票（分支路径）。
- **Gradient Boost**：通过 残差拟合 产生多样 g_t ，采用 线性投票，并以 最速下降更新。

结论 Boosting 类算法（AdaBoost、Gradient Boost 等）因兼具多样性与高效聚合，成为最受欢迎的集成方法。

命题 6.5.11 (Aggregation-of-Aggregation 模型映射)

三大基础集成策略及其常见组合：

- **Bagging**
 - Random Forest：Bagging + 完全生长的决策树（强基模型）。
 - Randomized Bagging：在 Bagging 中进一步引入随机性。
- **AdaBoost**
 - AdaBoost-DTree（强）：AdaBoost + 深度较大的决策树（强基模型）。
 - AdaBoost-DTree（弱）：AdaBoost + 决策树桩（弱基模型）。
- **Gradient Boost**
 - GBDT：Gradient Boost + 决策树桩（弱基模型）。

结论 Bagging、AdaBoost 与 Gradient Boost 及其树增强版本均为实践中高频使用的集成方法。

6.5.5 总结



笔记 [梯度提升决策树]

- 自适应提升决策树：通过抽样与剪枝构造“弱”树。
- AdaBoost 的优化视角：在指数误差上执行函数梯度下降。
- 梯度提升：迭代地沿最陡残差方向拟合。
- 集成模型小结：有的专治欠拟合，有的专治过拟合。



笔记 [总体结论] 梯度提升决策树作为集成学习的重要分支，通过迭代优化弱决策树的协作机制，实现了从“弱模型集成”到“强模型”的跨越。其核心在于利用权重调整（AdaBoost）或残差拟合（Gradient Boosting）构建具有多样性的基模型，并通过线性加权整合输出，在降低偏差、提升预测精度上表现卓越。这一框架既保留了决策树处理非线性数据的优势，又通过梯度下降等优化逻辑增强了模型的灵活性（支持多任务与任意损失函数），但也可能因迭代深度过深导致过拟合或计算成本上升。因此，需通过控制树的复杂度（如剪枝、限制深度）和迭代轮数，平衡性能与效率，是解决复杂预测问题的高效集成学习工具。

间章：组合预测特征：聚合模型

笔记 [组合预测特征：聚合模型]

“Combining Predictive Features: Aggregation Models”（组合预测特征：聚合模型）的核心是通过整合多个预测特征或基模型输出，构建更全面、稳健的预测系统。通过构建多样化的基模型并设计高效的聚合策略，集成学习为提升预测性能提供了系统性解决方案，可从四个关键维度解析其核心逻辑：

1. 集成学习的核心理念：群体智慧的协同效应

集成学习突破单一模型局限的核心在于“群体决策”：

- 通过组合多个独立或弱相关的基模型 ($g_1, g_2, \dots, g_T$)，抵消单个模型的偏差或随机误差；
- 数学上通过偏差-方差分解验证：当基模型存在多样性时，集成模型的期望误差可显著低于单个模型的平均误差，尤其能降低高方差模型（如未剪枝决策树）的过拟合风险；
- 核心前提是“多样性”与“个体能力”的平衡：基模型需具备一定性能（略优于随机猜测），且预测误差应相互独立或负相关。

2. 多样性的构建策略：主动创造差异化基模型

多样性是集成学习有效的关键，主要通过以下途径实现：

- 数据层面：通过 Bootstrap 抽样 (Bagging)、样本重加权 (AdaBoost) 或特征子空间采样 (随机森林) 生成不同训练数据，迫使基模型关注数据的不同子集；
- 模型层面：采用不同算法、不同超参数或不同初始化（如随机梯度下降的不同种子）；
- 任务层面：对多分类问题采用 One-vs-Rest 分解，或对回归问题引入噪声扰动目标值，构建互补的预测任务。

3. 聚合策略的设计：从简单投票到自适应加权

根据基模型特性选择合适的聚合方式，常见策略包括：

- 简单聚合：均匀投票（分类）或平均（回归），如随机森林的多数表决，实现少数服从多数的决策；
- 加权聚合：基于基模型性能分配权重，如 AdaBoost 中误差越小的模型权重越大；
- 高阶聚合：通过元模型学习基模型输出与真实标签的映射关系 (Stacking)，实现非线性组合。

聚合策略需在“偏差-方差”与“计算复杂度”间权衡，例如均匀聚合简单高效，而 Stacking 虽灵活但易过拟合。

4. 典型集成方法：从 Bagging 到 Boosting 的演进

主流集成算法体现了多样性与聚合策略的不同组合：

- **Bagging**：通过 Bootstrap 抽样构建多样训练集，配合均匀聚合，代表算法为随机森林（额外引入特征随机选择），擅长降低方差；
- **Boosting**：通过迭代重加权聚焦难样本，配合加权聚合，代表算法为 AdaBoost（分类）与 GBDT（回归），擅长降低偏差；
- 混合策略：如 XGBoost/LightGBM 结合了 Boosting 的序列学习与随机森林的特征采样，进一步提升效率与泛化能力。

结语：集成学习通过“多样性构建-策略性聚合”的双轮驱动，将多个模型的优势进行融合，既保留了单一模型的简洁性，又能处理复杂数据模式。

第 7 章 蒸馏隐含特征：提取模型

7.1 神经网络

7.1.1 动机

命题 7.1.1 (感知器线性聚合的图示视角)

将 T 个感知器 $\{g_t\}_{t=1}^T$ 以线性方式聚合，可写成两层权重与两层符号函数的网络：

1. 第一层：每个 g_t 为

$$g_t(x) = \text{sign}(w_t^\top x),$$

其中 $x_0 \equiv 1$ (偏置项), $w_t \in \mathbb{R}^{d+1}$ 为第 t 个感知器的权重。

2. 第二层：线性聚合

$$G(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t g_t(x)\right),$$

其中 α_t 为第二层的投票权重。

结论 两层权重 $\{w_t\}$ 与 $\{\alpha_t\}$ ，以及两层符号函数 $\text{sign}(\cdot)$ ，共同构成“感知器线性聚合”的紧凑网络结构。




图 7.1.1: 单层神经网络示意图

命题 7.1.2 (感知器的强大力量与局限性)

考虑感知器的线性组合，其表达能力取决于基函数的数量和复杂性。

1. 强大力量

- 使用 8 个感知器可以实现复杂的决策边界。
- 使用 16 个感知器可以实现更平滑的决策边界。
- 对于“凸集”假设，感知器的 VC 维是有限的，但随着感知器数量的增加，可以逼近任意复杂的边界。

2. 局限性

- XOR 问题不能通过简单的线性组合解决。

$$\text{XOR}(g_1, g_2) = \text{OR}(\text{AND}(-g_1, g_2), \text{AND}(g_1, -g_2))$$

这表明 XOR 问题在特征空间 $\Phi(x) = (g_1(x), g_2(x))$ 下不是线性可分的。

结论 感知器的线性组合虽然强大，但不能解决所有问题。对于非线性可分问题，需要更复杂的特征变换或更深层次的网络结构。




图 7.1.2: 感知机实现复杂决策边界

命题 7.1.3 (逻辑运算的线性聚合实现)

利用感知器的线性聚合，可精确实现任意布尔函数。

1. AND 门示例

设两输入感知器

$$g_1(x) = \text{sign}(w_1^\top x), \quad g_2(x) = \text{sign}(w_2^\top x).$$

构造

$$G(x) = \text{sign}(-1 + g_1(x) + g_2(x)),$$

则

$$G(x) = +1 \iff g_1(x) = g_2(x) = +1 \text{ (TRUE); 否则 } G(x) = -1 \text{ (FALSE).}$$

2. OR、NOT 的类似实现

$$\text{OR}(g_1, g_2) = \text{sign}(+1 + g_1(x) + g_2(x)),$$

$$\text{NOT}(g) = \text{sign}(-g(x)).$$

3. XOR 的层级实现

$$\text{XOR}(g_1, g_2) = \text{OR}(\text{AND}(-g_1, g_2), \text{AND}(g_1, -g_2)),$$

需再加一层 AND+OR 变换。

结论 单层感知器 $\rightarrow$ 线性聚合 $\rightarrow$ 多层感知器 (MLP)，逐步增强表达能力，可解决非线性可分问题。

例题 7.1 选择题：AdaBoost 中实现逻辑或 (OR) 的权重组合

已知基学习器 $g_0(\mathbf{x}) = +1$ ，需找到权重 $(\alpha_0, \alpha_1, \alpha_2)$ ，使得集成模型 $G(\mathbf{x}) = \text{sign}\left(\sum_{t=0}^2 \alpha_t g_t(\mathbf{x})\right)$ 实现逻辑或运算 $\text{OR}(g_1, g_2)$ (即 g_1 或 g_2 为 $+1$ 时 G 输出 $+1$ ，仅当 g_1, g_2 全为 -1 时输出 -1)。

- 1) $(-3, +1, +1)$
- 2) $(-1, +1, +1)$

3) (+1, +1, +1)

4) (+3, +1, +1)

解答 正确选项为 [3]。逻辑或要求：全假 ($g_1, g_2 = -1$) 时 $G = -1$ ，否则 $G = +1$ 。

验证选项 3 ($\alpha_0, \alpha_1, \alpha_2$) = (+1, +1, +1):

- 全假场景： $1 \cdot 1 + 1 \cdot (-1) + 1 \cdot (-1) = -1 < 0$ ， $G = -1$ (符合)。
- 有真场景 (如 $g_2 = +1$)： $1 \cdot 1 + 1 \cdot (-1) + 1 \cdot (+1) = 1 > 0$ ， $G = +1$ (符合)。

综上，选项 3 满足逻辑或规则。 ■

7.1.2 神经网络假设

命题 7.1.4 (神经网络假设：特征变换)

神经网络通过逐层变换实现复杂的特征映射，其核心在于选择合适的变换函数。

1. 变换函数的选择

- 线性变换：整个网络退化为线性模型，表达能力受限。
- 离散变换 (如符号函数)：优化困难，难以对权重 w 进行梯度下降。
- 连续变换 (如 $\tanh$)：

$$\tanh(s) = \frac{e^s - e^{-s}}{e^s + e^{-s}} = 2\sigma(2s) - 1,$$

其中 $\sigma(s)$ 为 Sigmoid 函数。 $\tanh$ 函数是符号函数的连续近似，优化更易实现。




图 7.1.3: 连续变换函数

2. 神经网络结构

神经网络由多层组成，每层的输出是下一层的输入。

输入层： $x^{(0)} = x$,

隐藏层： $x^{(l)} = \tanh(W^{(l)}x^{(l-1)})$, $l = 1, \dots, L-1$,

输出层： $G(x) = \tanh(W^{(L)}x^{(L-1)})$.

结论 神经网络通过逐层变换实现复杂的特征映射， $\tanh$ 等连续变换函数因其优化友好性而被广泛使用。 ♠

命题 7.1.5 (神经网络的物理解释)

每一隐藏层都可视为对输入 x 的“模式匹配”变换：

- 第 ℓ 层输出

$$\Phi^{(\ell)}(x) = \tanh(W^{(\ell)}\Phi^{(\ell-1)}(x)), \quad \Phi^{(0)}(x) = x,$$

其中 $W^{(\ell)} \in \mathbb{R}^{d^{(\ell)} \times d^{(\ell-1)}}$ 的每一行对应一条“权重模式”。

- $\tanh(\cdot)$ 的符号与大小反映 x 与该模式的匹配程度：正值表示“匹配”，负值表示“不匹配”，

绝对值越大越显著。

整体视角 神经网络通过多层连接权重逐层提取并组合局部模式，最终实现复杂决策边界。




图 7.1.4: 多层神经网络示意图

例题 7.2 选择题：3 - 5 - 1 神经网络的权重数量

一个 3 - 5 - 1 神经网络（3 - 5 - 1 NNet）中，权重 $\{w_{ij}^{(\ell)}\}$ 的数量是多少？

- 1) 9
- 2) 15
- 3) 20
- 4) 26

解答 正确选项为 [4]。“3 - 5 - 1 神经网络”指输入层 3 个神经元、隐藏层 5 个神经元、输出层 1 个神经元的网络结构。

计算权重数量需考虑层间连接：

- 输入层 → 隐藏层：3×5=15 个连接权重 + 5 个偏置 = 20 个
- 隐藏层 → 输出层：5×1=5 个连接权重 + 1 个偏置 = 6 个

总权重数：20+6=26 个。

7.1.3 神经网络学习

命题 7.1.6 (神经网络权重学习：梯度计算与反向传播)

1. 网络结构与符号适配

设多层前馈神经网络，遵循以下符号与传播规则：

- 输入层： $\mathbf{x} = [x_0, x_1, \dots, x_d]^\top$ （其中 $x_0 = 1$ 为偏置输入）。
- 层间传播：第 ℓ 层第 j 个神经元的加权输入为 $s_j^{(\ell)}$ ，经 tanh 激活后输出 $x_j^{(\ell)} = \tanh(s_j^{(\ell)})$ ；第 ℓ 层到 $\ell + 1$ 层的权重记为 $w_{jk}^{(\ell+1)}$ （即第 ℓ 层第 j 个神经元连接到 $\ell + 1$ 层第 k 个神经元的权重）。

以含隐藏层的网络为例，前向传播关系可表示为：

$$s_j^{(\ell)} = \sum_{i=0}^{d^{(\ell-1)}} w_{ij}^{(\ell)} x_i^{(\ell-1)}, \quad x_j^{(\ell)} = \tanh(s_j^{(\ell)})$$

输出层误差定义为平方误差：

$$e_n = (y_n - \text{NNet}(\mathbf{x}_n))^2$$

2. 输出层梯度推导

对输出层（记总层数为 L ，输出层为第 L 层），第 1 个神经元的加权输入满足：

$$s_1^{(L)} = \sum_{i=0}^{d^{(L-1)}} w_{i1}^{(L)} x_i^{(L-1)}$$

根据链式法则，输出层权重 $w_{i1}^{(L)}$ 的梯度为：

$$\frac{\partial e_n}{\partial w_{i1}^{(L)}} = \frac{\partial e_n}{\partial s_1^{(L)}} \cdot \frac{\partial s_1^{(L)}}{\partial w_{i1}^{(L)}} = -2(y_n - s_1^{(L)}) \cdot x_i^{(L-1)}$$

定义输出层误差项 $\delta_1^{(L)} = -2(y_n - s_1^{(L)})$ ，则梯度可简化为：

$$\frac{\partial e_n}{\partial w_{i1}^{(L)}} = \delta_1^{(L)} \cdot x_i^{(L-1)}$$

3. 隐藏层梯度与反向传播递推

对一般层 ℓ ($1 \leq \ell < L$)，第 j 个神经元的加权输入为 $s_j^{(\ell)}$ ，激活输出为 $x_j^{(\ell)} = \tanh(s_j^{(\ell)})$ 。

定义误差项 $\delta_j^{(\ell)} = \frac{\partial e_n}{\partial s_j^{(\ell)}}$ ，通过链式法则推导递推关系：

由于第 ℓ 层激活 $x_j^{(\ell)}$ 会参与第 $\ell+1$ 层多个神经元的加权输入（即 $s_k^{(\ell+1)} = \sum_j w_{jk}^{(\ell+1)} x_j^{(\ell)}$ ），因此：

$$\delta_j^{(\ell)} = \frac{\partial e_n}{\partial s_j^{(\ell)}} = \sum_{k=1}^{d^{(\ell+1)}} \frac{\partial e_n}{\partial s_k^{(\ell+1)}} \cdot \frac{\partial s_k^{(\ell+1)}}{\partial x_j^{(\ell)}} \cdot \frac{\partial x_j^{(\ell)}}{\partial s_j^{(\ell)}}$$

代入激活函数导数 $\frac{\partial x_j^{(\ell)}}{\partial s_j^{(\ell)}} = \tanh'(s_j^{(\ell)})$ ，以及权重关系 $\frac{\partial s_k^{(\ell+1)}}{\partial x_j^{(\ell)}} = w_{jk}^{(\ell+1)}$ ，最终得反向传播递推公式：

$$\delta_j^{(\ell)} = \left(\sum_k \delta_k^{(\ell+1)} w_{jk}^{(\ell+1)} \right) \cdot \tanh'(s_j^{(\ell)})$$

利用 $\delta_j^{(\ell)}$ ，第 ℓ 层第 j 个神经元对第 i 个输入权重 $w_{ji}^{(\ell)}$ 的梯度为（输入来自前层激活 $x_i^{(\ell-1)}$ ）：

$$\frac{\partial e_n}{\partial w_{ji}^{(\ell)}} = \delta_j^{(\ell)} \cdot x_i^{(\ell-1)}$$

4. 计算流程与算法核心

神经网络权重学习遵循以下流程：

1. 前向传播：从输入层开始，逐层计算 $s_j^{(\ell)}$ 和 $x_j^{(\ell)}$ ，直至输出层得到预测值并计算误差 e_n 。
2. 反向传播：从输出层出发，利用上述递推公式反向逐层计算 $\delta_j^{(\ell)}$ ，结合前层激活 $x_i^{(\ell-1)}$ 求解所有权重梯度 $\frac{\partial e_n}{\partial w_{ji}^{(\ell)}}$ 。
3. 权重更新：通过（随机）梯度下降（SGD），依据梯度 $\frac{\partial e_n}{\partial w_{ji}^{(\ell)}}$ 迭代更新权重 $w_{ji}^{(\ell)}$ ，逐步最小化训练误差 E_{in} 。



算法 7.1.28: 反向传播 (Backpropagation) 算法

输入: 训练集 $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$; 网络结构层数及各层维度 $d^{(0)}, \dots, d^{(L)}$

输出: 训练完成的神经网络 $g_{\text{NN}}(\mathbf{x})$

初始化阶段

随机初始化神经网络各层权重 $w_{ij}^{(\ell)}$, 其中 ℓ 表示网络层数 ($\ell = 1, \dots, L$), i, j 为对应层神经元索引。

for $t = 0, 1, \dots, T$ **do**

随机样本选取: 从训练集里随机挑选一个样本 n , 即 $n \in \{1, 2, \dots, N\}$ (支持 mini-batch 时可多选);

前向传播计算

 以选中样本 $\mathbf{x}^{(0)} = x_n$ 为输入, 逐层计算神经元激活值: 对第 ℓ 层 ($\ell = 1, \dots, L$), 先算线性组合

$$s_j^{(\ell)} = \sum_i w_{ij}^{(\ell)} x_i^{(\ell-1)}$$

 再通过 tanh 激活函数得到激活值

$$x_j^{(\ell)} = \tanh(s_j^{(\ell)})$$

反向传播: 误差梯度计算

 从输出层 ($\ell = L$) 开始, 反向推导各层误差项 $\delta_j^{(\ell)}$:

- 输出层误差: 结合真实标签 y_n 与激活函数导数:

$$\delta_j^{(L)} = (y_{nj} - x_j^{(L)}) \odot \tanh'(s_j^{(L)})$$

- 隐藏层误差 ($\ell = L-1, \dots, 1$): 利用上层误差与权重, 反向传递计算:

$$\delta_j^{(\ell)} = \left(\sum_k w_{jk}^{(\ell+1)} \delta_k^{(\ell+1)} \right) \odot \tanh'(s_j^{(\ell)})$$

权重更新: 梯度下降

 依据误差项, 用梯度下降规则更新各层权重, 学习率 η 控制更新步长:

$$w_{ij}^{(\ell)} \leftarrow w_{ij}^{(\ell)} - \eta x_i^{(\ell-1)} \delta_j^{(\ell)}$$

输出神经网络模型

训练后, 神经网络可表示为多层 tanh 激活嵌套的形式 (以两层隐藏逻辑示例, 适配实际网络深度):

$$g_{\text{NN}}(\mathbf{x}) = \tanh \left(\sum_j w_{jk}^{(2)} \tanh \left(\sum_i w_{ij}^{(1)} x_i \right) \right)$$

注 实际训练中, 常采用 **mini-batch** 策略: 多次并行执行“样本选取 - 前向传播 - 反向传播”流程, 将多组样本的梯度平均后再更新权重, 平衡计算效率与收敛稳定性。反向传播核心价值是高效推导梯度, 让权重更新精准指向“降低预测误差”方向, 支撑神经网络学习复杂映射关系。

7.1.4 优化与正则化

命题 7.1.7 (神经网络的优化特性)

当网络包含多个隐藏层时，目标函数

$$\text{err}(W) = \sum_{n=1}^N \ell(y_n, \text{NNet}(x_n; W))$$

整体非凸，故难以保证全局最优。

关键现象

- GD/SGD 仅收敛到局部极小，其位置对初始权重敏感；
- 权重过大 $\rightarrow$ tanh 饱和 $\rightarrow$ 梯度趋零，训练停滞；
- 实用建议：采用随机小权重初始化并多组尝试。

结论 神经网络优化困难，但在实践中通过随机初始化与足够迭代通常可获良好局部解。

命题 7.1.8 (神经网络模型的 VC 维)

对采用 tanh 类激活函数的前馈网络，其 VC 维大致满足

$$d_{\text{vc}} = \mathcal{O}(VD)$$

其中 V 为神经元总数， D 为权重总数。

解读

- 优势：若 V 足够大，网络可逼近任意函数；
- 劣势：过大的 V 使 d_{vc} 急剧上升，易导致过拟合。

实践提示 使用神经网络时务必监控模型复杂度，防止因 V 过大而失控地过拟合。

命题 7.1.9 (神经网络的两种常用正则化)

1. 权重正则化

- L2 (权重衰减)

$$\Omega_{\text{L2}}(w) = \lambda \|w\|_2^2 \implies \text{大权重} \rightarrow \text{大收缩}, \text{小权重} \rightarrow \text{小收缩}.$$

- L1 (稀疏化)

$$\Omega_{\text{L1}}(w) = \lambda \|w\|_1 \implies \text{部分权重直接置零, 有效降低 } d_{\text{vc}}.$$

- 权重消除 **weight-elimination (Scaled L2)**

$$\Omega_{\text{WE}}(w) = \lambda \sum_i \frac{w_i^2}{1 + w_i^2} \implies \text{大权重} \rightarrow \text{中等收缩}, \text{小权重} \rightarrow \text{中等收缩}.$$

2. 早停 (Early Stopping)

随着迭代次数 t 增加：

- 训练误差 E_{in} 单调下降；
- 测试误差 E_{test} 先降后升，呈“过拟合”拐点；
- 较小 t 等价于“较低 VC 维”模型。

策略 在验证集监控 E_{test} ，选择其最低点的迭代次数 t^* 停止训练，从而有效防止过拟合。




图 7.1.5: 早停 (Early Stopping) 示意图

7.1.5 总结

笔记 [神经网络]

- 动机：借鉴生物神经结构，通过多层非线性映射获得强大表达能力。
- 神经网络假设：逐层提取模式，最终输出线性可分的表示。
- 神经网络学习：反向传播高效计算梯度。
- 优化与正则化：初始化技巧、正则项及早停等实用策略。

7.2 深度学习

7.2.1 深度神经网络

命题 7.2.1 (浅层与深层神经网络对比)

设隐藏层数为 L ，记 浅层网络 Shallow NNet: L 较小, 深层网络 Deep NNet: L 较大.

	浅层网络	深层网络
训练效率	高 (✓)	训练困难 (✗)
结构设计	简单 (✓)	复杂 (✗)
理论表达能力	已足够 (✓)	任意强大 (✓)
特征抽象	有限	更具“语义”层次

结论 深层神经网络（深度学习）虽训练更复杂，却因更强的表达能力与层次特征而近年备受关
注。

定义 7.2.1 (深度学习)

深度学习 (Deep learning)，又称深度结构化学习 (deep structured learning) 或层次式学习 (hierarchical learning)，是机器学习算法的一个子类，其核心特征如下：

1. 采用多层非线性处理单元级联 (cascade) 对原始输入进行特征提取与变换，每一层都以紧邻前一层输出作为输入；
2. 支持有监督、半监督或无监督的学习范式；
3. 学习多层次数据表征，对应不同抽象层级，形成概念的层次结构。

命题 7.2.2 (深度学习的主要挑战与关键技术)

深度网络在实践中面临四大难题，同时发展出相应的解决技术。

1. 结构决策困难
网络拓扑依赖主观领域知识，如图像任务常用卷积神经网络 (CNN)。
2. 模型复杂度高
数据量足够时复杂度并非主要瓶颈：通过噪声鲁棒的正则化手段抑制过拟合
 - Dropout：对网络内部随机失活保持鲁棒；
 - Denoising：对输入扰动保持鲁棒。
3. 优化困难
非凸目标易陷坏局部极小：采用 预训练 (pre-training) 进行谨慎初始化，避开劣质局部解。
4. 计算开销巨大
大数据放大计算需求：借助新型硬件/架构
 - GPU 并行计算；
 - Mini-batch 策略降低每次迭代成本。

结论 精心的正则化设计与权重初始化是当前深度学习成功的两大核心技术。

命题 7.2.3 (两步式深度学习框架)

将深度网络的训练解耦为两个阶段，既能缓解优化困难，又能提升最终性能。

Step 1: 预训练 (Pre-training)

逐层贪婪预训练：固定已训练层权重 $W^{(\ell-1)}$ ，仅更新当前层 $W^{(\ell)}$ ， $\ell = 1, \dots, L$ 。该过程为网络提供良好的初始权重，避免陷入劣质局部极小。

Step 2: 微调 (Fine-tuning)

在预训练所得权重基础上，使用反向传播 (Backprop) 对整个网络进行端到端微调，联合更新所有 $W^{(\ell)}$ 。

结论 “预训练 + 微调” 构成当前最简洁有效的深度学习方法，后续可进一步结合正则化（如 Dropout）以控制过拟合。




图 7.2.1: 深度学习预训练过程

例题 7.3 选择题：深度神经网络第一层隐藏层提取的特征

对于从原始像素进行手写字符识别的深度神经网络 (deep NNet)，在第一个隐藏层之后，更可能提取出以下哪种类型的特征？

- 1) pixels (像素)
- 2) strokes (笔画)
- 3) parts (部件)
- 4) digits (数字)

解答 正确选项为 [2]。深度神经网络 (deep NNet) 处理手写字符识别时，特征提取是“逐步抽象”的：

- 输入是原始像素 (pixels)，第一层隐藏层会学习基础的局部组合特征。对于手写字符，这些基础特征对应笔画 (strokes) (如横竖撇捺等简单结构)。
- 后续层会基于笔画进一步组合，提取更复杂的“部件 (parts)”，最终识别出完整“数字 (digits)”。

因此，第一个隐藏层后更可能提取出笔画 (strokes) 特征。 ■

7.2.2 自编码器

命题 7.2.4 (自编码器：信息保持的表示学习)

设网络权重集合 W 定义编码-解码映射 Φ ，其工作流程为：先通过编码权重 $W^{(1)}$ 将输入 x （如图片、文本等数据）转换为隐藏表示（可理解为数据的压缩版特征），再经解码权重 $W^{(2)}$ 还原输入本身，形成闭环映射。

1. 信息保持准则

理想权重需满足重建误差极小化约束：

$$\Phi(x) \approx x$$

该约束确保编码后信息可通过不同表示形式复用，且解码过程能近似还原原始输入。

2. 自编码器 (autoencoder) 结构与目标

自编码器是典型的 $d \rightarrow \tilde{d} \rightarrow d$ 结构神经网络，包含：

- 编码阶段：通过权重 $W_{ij}^{(1)}$ 将含偏置项的输入 $x = [x_0, x_1, \dots, x_d]^\top$ 映射到隐藏层（常用 tanh 激活函数）；
- 解码阶段：通过权重 $W_{ji}^{(2)}$ 映射回输出 $g(x)$ ，目标是逼近恒等函数 $g_i(x) \approx x_i$ 。




图 7.2.2: 自编码器 (autoencoder) 结构

核心用途

- 监督学习：隐藏表示 $\Phi(x)$ 作为信息浓缩特征，可提升下游任务性能；
- 无监督学习
 - 密度估计： $\|\Phi(x) - x\|$ 越小，样本符合典型分布的概率越高；
 - 异常检测： $\|\Phi(x) - x\|$ 显著偏大时判定为异常样本。

结论 自编码器通过近似恒等映射挖掘数据的紧凑可解释表示，由于其无需依赖大量标签，却能有效提取数据核心信息，是深度学习中预训练与特征提取的核心工具。

定义 7.2.2 (基本自编码器 (Basic Autoencoder))

设输入维度为 d ，隐藏层维度为 $\tilde{d}$ ，则基本自编码器为以下前馈网络：

$$d \xrightarrow{\text{编码}} \tilde{d} \xrightarrow{\text{解码}} d.$$

训练目标 给定数据集

$$\mathcal{D} = \left\{ (x_1, y_1 = x_1), (x_2, y_2 = x_2), \dots, (x_N, y_N = x_N) \right\},$$

最小化重建误差

$$E(W) = \sum_{n=1}^N \sum_{i=1}^d (g_i(x_n) - x_{n,i})^2.$$

特点

- 网络浅层，易于训练，可直接使用反向传播；
- 若 $\tilde{d} < d$ ，则隐藏层提供压缩（降维）表示；
- 常被视为无监督学习方法；
- 可附加权重共享或正则化约束（如 $W^{(2)} = W^{(1)\top}$ ）以进一步控制模型复杂度。

用途 作为深度学习中的浅层预训练手段，为基本网络提供良好的初始权重。



命题 7.2.5 (利用自编码器的预训练流程)

将深度网络逐层解耦为若干浅层自编码器，实现稳定且高效的预训练：

1. 逐层预训练

对 $\ell = 1, 2, \dots, L$ ：

1. 固定已训练层权重 $W^{(\ell-1)}$ ；
2. 以第 $\ell - 1$ 层输出作为输入，构造维度为 $d^{(\ell)}$ 的基本自编码器

$$d^{(\ell-1)} \rightarrow d^{(\ell)} \rightarrow d^{(\ell-1)};$$

3. 通过最小化重建误差训练该自编码器，得到 $W^{(\ell)}$ 。




图 7.2.3: 逐层预训练示意图

2. 微调

完成逐层预训练后，以所得权重为初始值，对整个网络执行端到端的反向传播微调。

进阶方案 成功案例常采用结构或正则化更复杂的自编码器，如

- 稀疏自编码器 (Sparse Autoencoder)，
- 去噪自编码器 (Denoising Autoencoder)，
- 收缩自编码器 (Contractive Autoencoder)。



例题 7.4 选择题：深度神经网络预训练时间计算

假设训练一个 $d - \tilde{d} - d$ 的自动编码器 (autoencoder)，使用反向传播 (backprop) 大约需要 $c \cdot d \cdot \tilde{d}$ 秒。那么，预训练一个 $d - d^{(1)} - d^{(2)} - d^{(3)} - 1$ 的深度神经网络 (deep NNet)，总共需要多少秒？

- 1) $c(d + d^{(1)} + d^{(2)} + d^{(3)} + 1)$
- 2) $c(d \cdot d^{(1)} \cdot d^{(2)} \cdot d^{(3)} \cdot 1)$
- 3) $c(dd^{(1)} + d^{(1)}d^{(2)} + d^{(2)}d^{(3)} + d^{(3)})$
- 4) $c(dd^{(1)} \cdot d^{(1)}d^{(2)} \cdot d^{(2)}d^{(3)} \cdot d^{(3)})$

解答 正确选项为 [3]。自动编码器训练时间与层间连接权重数量相关（如 $d - \tilde{d} - d$ 模型中，时间为 $c \cdot d \cdot \tilde{d}$ ，对应 $d \times \tilde{d}$ 个连接权重）。

对于 $d - d^{(1)} - d^{(2)} - d^{(3)} - 1$ 深度神经网络预训练，需分解为多个自动编码器步骤：

- $d \rightarrow d^{(1)}$: 连接权重数 $d \times d^{(1)}$, 时间约 $c \cdot dd^{(1)}$;
- $d^{(1)} \rightarrow d^{(2)}$: 连接权重数 $d^{(1)} \times d^{(2)}$, 时间约 $c \cdot d^{(1)}d^{(2)}$;
- $d^{(2)} \rightarrow d^{(3)}$: 连接权重数 $d^{(2)} \times d^{(3)}$, 时间约 $c \cdot d^{(2)}d^{(3)}$;
- $d^{(3)} \rightarrow 1$: 连接权重数 $d^{(3)} \times 1$, 时间约 $c \cdot d^{(3)}$ 。

总时间为各步骤时间之和, 即 $c(dd^{(1)} + d^{(1)}d^{(2)} + d^{(2)}d^{(3)} + d^{(3)})$ 。

7.2.3 去噪自编码器

命题 7.2.6 (深度学习的正则化与过拟合再审视)

深度网络因高模型复杂度极易过拟合, 需在结构与优化环节双重正则化。

1. 正则化手段

- 结构约束: 人为设计网络拓扑 (如 CNN) 以限制参数量;
- 权重正则化:
 - 权重衰减 Weight Decay: $\Omega(w) = \lambda \|w\|_2^2$,
 - 权重消除 Weight Elimination: $\Omega(w) = \lambda \sum_i \frac{w_i^2}{1+w_i^2}$;
- 早停 (Early Stopping): 在验证误差最低时终止训练。

2. 过拟合成因回顾

设数据量 N 、噪声水平 σ 、模型能力 P (如参数量), 则

$$\text{过拟合风险} \propto \frac{\sigma}{N} \cdot P.$$

因此:

- 噪声 $\uparrow \rightarrow$ 过拟合 $\uparrow$;
- 数据量 $\downarrow \rightarrow$ 过拟合 $\uparrow$;
- 模型能力 $\uparrow \rightarrow$ 过拟合 $\uparrow$ 。

结论深度网络必须结合结构约束、权重正则化与早停, 才能在高复杂度场景下抑制过拟合。

命题 7.2.7 (噪声处理: 去噪自编码器)

面对数据中的噪声, 可将“人工添加噪声”本身作为一种正则化手段。

去噪自编码器 (Denoising Autoencoder)

1. 构造含噪输入

$$\tilde{x}_n = x_n + \varepsilon_n, \quad \varepsilon_n \sim \text{人工噪声}.$$

2. 训练目标

$$\min_W \sum_{n=1}^N \|g(\tilde{x}_n) - x_n\|^2,$$

即网络不仅要还原原始 x_n , 还需在 $\tilde{x}_n$ 扰动下保持稳健。

3. 效果

- 在数据/图像处理中, $g(x)$ 成为去噪后的版本;
- 强制网络学习噪声不变特征, 等价于在损失中引入正则项;
- 人工噪声作为“提示 (hint)”, 可推广到其他神经网络或模型。

结论 去噪自编码器用“加噪 $\rightarrow$ 去噪”代替传统人工清洗, 既提升鲁棒性又充当正则化, 是深

度学习中的常用预处理与正则策略。



例题 7.5 选择题：正则化技术判断

以下哪一项不能被视为正则化技术？

- 1) 使用人工生成的含噪声数据训练模型
- 2) 提前停止梯度下降
- 3) 添加权重消除正则项
- 4) 以上都是正则化技术

解答 正确选项为 [4]。正则化技术用于限制模型复杂度、避免过拟合：

- 选项 1：添加噪声数据，增加数据多样性，迫使模型学习通用特征，属于正则化。
- 选项 2：提前停止梯度下降，防止模型在训练集过度拟合，属于正则化。
- 选项 3：权重消除正则项（如 L1/L2 正则），直接约束权重大小，限制模型复杂度，属于正则化。

因此，以上方法均为正则化技术。 ■

7.2.4 主成分分析

定义 7.2.3 (线性自编码器假设)

设输入 $\mathbf{x} \in \mathbb{R}^d$ （不含偏置项 x_0 ），为保证解的非平凡性，令隐藏层维度 $\tilde{d} < d$ 。

对第 k 个隐藏分量，采用线性假设：

$$h_k(\mathbf{x}) = \sum_{j=0}^{\tilde{d}} w_{kj} \left(\sum_{i=1}^d w_{ij} x_i \right), \quad 1 \leq k \leq \tilde{d}$$

通过以下约束简化模型（正则化与非平凡解保证）：

- 排除冗余偏置：若忽略 x_0 ，可令 i 的取值范围与 k 一致（即 $i \in [1, \tilde{d}]$ 或按需调整）；
- 权重对称约束：令 $w_{ij}^{(1)} = w_{ji}^{(2)} = w_{ij}$ ，记权重矩阵 $\mathbf{W} = [w_{ij}] \in \mathbb{R}^{d \times \tilde{d}}$ ，则线性自编码器的整体映射可推导为：

$$\mathbf{h}(\mathbf{x}) = \mathbf{W}\mathbf{W}^\top \mathbf{x}$$

- 非平凡解保证： $\tilde{d} < d$ 确保模型不是“恒等映射”，强制学习低维特征表示。

核心特性

1. 高效与稳健性：线性结构简单，训练计算高效； $\tilde{d} < d$ 限制复杂度，降低过拟合风险，契合“先线性、再拓展非线性”的建模思路；
2. 与 PCA 的关联：当权重对称且 $\tilde{d} < d$ 时， $\mathbf{W}\mathbf{W}^\top$ 可对应低秩重构矩阵，与主成分分析（PCA）的子空间投影逻辑等价，实现输入数据的低维主子空间提取。 ♣

命题 7.2.8 (线性自编码器的最优解)

给定中心化数据矩阵

$$\mathbf{X} = [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \dots \quad \mathbf{x}_N] \in \mathbb{R}^{d \times N},$$

线性自编码器通过优化权重矩阵 $\mathbf{W} \in \mathbb{R}^{\tilde{d} \times d}$ ($\tilde{d} < d$) 最小化重构误差:

$$E_{\text{in}}(\mathbf{W}) = \frac{1}{N} \sum_{n=1}^N \|\mathbf{x}_n - \mathbf{W}^\top \mathbf{W} \mathbf{x}_n\|^2.$$

求解过程如下:

1. 谱分解: 矩阵 $\rightarrow$ 正交变换 + 缩放

由于 $\mathbf{W}^\top \mathbf{W} \in \mathbb{R}^{d \times d}$ 是对称半正定矩阵, 可做特征分解:

$$\mathbf{W}^\top \mathbf{W} = \mathbf{V} \mathbf{\Gamma} \mathbf{V}^\top,$$

其中:

- $\mathbf{V} \in \mathbb{R}^{d \times d}$ 是正交矩阵 (满足 $\mathbf{V}^\top \mathbf{V} = \mathbf{V} \mathbf{V}^\top = \mathbf{I}_d$), 其列构成 $\mathbb{R}^d$ 的标准正交基;
- $\mathbf{\Gamma}$ 是对角矩阵, 秩为 $\tilde{d}$ (即恰好 $\tilde{d}$ 个非零对角元)。

对任意样本 $\mathbf{x}_n$, $\mathbf{W}^\top \mathbf{W} \mathbf{x}_n$ 可拆解为三步几何操作:

$$\mathbf{W}^\top \mathbf{W} \mathbf{x}_n = \mathbf{V} \mathbf{\Gamma} \mathbf{V}^\top \mathbf{x}_n$$

- (1) $\mathbf{V}^\top \mathbf{x}_n$: 将 $\mathbf{x}_n$ 投影到正交基 $\{\mathbf{v}_1, \dots, \mathbf{v}_d\}$ 上 (正交基变换, 等价于旋转/反射, 不改变向量长度);
- (2) $\mathbf{\Gamma}(\mathbf{V}^\top \mathbf{x}_n)$: 对投影后的坐标做维度缩放, 需将 $\geq d - \tilde{d}$ 个分量置 0 (压缩冗余维度), 剩余 $\tilde{d}$ 个分量保留并缩放;
- (3) $\mathbf{V}(\mathbf{\Gamma} \mathbf{V}^\top \mathbf{x}_n)$: 将缩放后的坐标映射回原空间 (逆正交基变换, 等价于逆旋转/逆反射, 重构数据)。

2. 最优 $\mathbf{\Gamma}$: 二值化缩放因子

代入误差函数后, 利用正交变换的保范性 ($\|\mathbf{V} \mathbf{z}\| = \|\mathbf{z}\|$), 重构误差等价于:

$$\min_{\mathbf{V}} \min_{\mathbf{\Gamma}} \frac{1}{N} \sum_{n=1}^N \|\mathbf{V}^\top \mathbf{x}_n - \mathbf{\Gamma} \mathbf{V}^\top \mathbf{x}_n\|^2$$

最小化该误差要求 $\mathbf{\Gamma}$ 的对角元满足二值化选择:

$$\gamma_i = \begin{cases} 1, & 1 \leq i \leq \tilde{d}, \\ 0, & \tilde{d} < i \leq d, \end{cases}$$

即 $\mathbf{\Gamma} = \begin{bmatrix} \mathbf{I}_{\tilde{d}} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$, 表示保留前 $\tilde{d}$ 维主成分信息、压缩其余 $d - \tilde{d}$ 维冗余信息。

3. 最优 $\mathbf{V}$: 主特征向量选择

将最优 $\mathbf{\Gamma}$ 代入后, 误差最小化等价于最大化目标函数:

$$\min_{\mathbf{V}} \sum_{n=1}^N \left\| \begin{bmatrix} \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_{d-\tilde{d}} \end{bmatrix} \mathbf{V}^\top \mathbf{x}_n \right\|^2 \equiv \max_{\mathbf{V}} \sum_{n=1}^N \left\| \begin{bmatrix} \mathbf{I}_{\tilde{d}} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \mathbf{V}^\top \mathbf{x}_n \right\|^2$$

根据瑞利商 (Rayleigh Quotient) 的极值性质, 其解由 $\mathbf{X}^\top \mathbf{X}$ 的前 $\tilde{d}$ 个最大特征值对应的主特征向量构成:

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_{\tilde{d}}],$$

其中 $\mathbf{X}^\top \mathbf{X} \mathbf{v}_j = \lambda_j \mathbf{v}_j$ 且 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{\tilde{d}}$ 。

4. 特殊验证：恒等变换的抵消

当 $\Gamma = I_d$ (即不压缩维度, $\tilde{d} = d$) 时, $W^\top W = V I_d V^\top = I_d$, 此时:

$$W^\top W x_n = V I_d V^\top x_n = x_n$$

结论 最优权重矩阵为 $W_{\text{opt}} = [v_1 \ v_2 \ \dots \ v_{\tilde{d}}]^\top$, 线性自编码器的编码过程等价于主成分分析 (PCA) —— 通过正交基变换 + 维度缩放, 提取数据方差最大的 $\tilde{d}$ 个主成分。



定义 7.2.4 (主成分分析 (PCA) 与线性自编码器)

给定中心化数据矩阵 $X = [x_1 \ \dots \ x_N] \in \mathbb{R}^{d \times N}$, 计算协方差矩阵 $XX^\top$ 的前 $\tilde{d}$ 个最大特征值对应的特征向量

$$W = [w_1 \ w_2 \ \dots \ w_{\tilde{d}}] \in \mathbb{R}^{d \times \tilde{d}}.$$

两种等价视角

- 线性自编码器: 最大化投影后幅值平方和

$$\max_W \sum_{n=1}^N \|W^\top x_n\|^2, \quad W^\top W = I_{\tilde{d}}.$$

- 统计 PCA: 最大化投影后样本方差

$$\max_W \text{Var}(W^\top x), \quad W^\top W = I_{\tilde{d}}.$$

统一结果 特征变换

$$\Phi(x) = W^\top (x - \bar{x}), \quad \bar{x} = \frac{1}{N} \sum_{n=1}^N x_n$$

完成线性降维, 其中 PCA 在统计与工程实践中更为常用。



例题 7.6 选择题: 优化问题的最优目标值

在求解优化问题 $\max_{\mathbf{v}} \sum_{n=1}^N \mathbf{v}^T \mathbf{x}_n \mathbf{x}_n^T \mathbf{v}$ (约束为 $\mathbf{v}^T \mathbf{v} = 1$) 时, 已知最优 $\mathbf{v}$ 是矩阵 $X^T X$ 对应最大特征值 λ 的特征向量。那么该优化问题的最优目标值是多少?

- 1) λ^1
- 2) λ^2
- 3) λ^3
- 4) λ^4

解答 正确选项为 1。

1. 目标函数变形:

利用矩阵求和性质, $\sum_{n=1}^N \mathbf{x}_n \mathbf{x}_n^T = X^T X$ (X 是以 $\mathbf{x}_n$ 为列的矩阵), 因此目标函数可写为:

$$\mathbf{v}^T \left(\sum_{n=1}^N \mathbf{x}_n \mathbf{x}_n^T \right) \mathbf{v} = \mathbf{v}^T (X^T X) \mathbf{v}$$

2. 特征值与特征向量的性质:

若 $\mathbf{v}$ 是 $X^T X$ 对应特征值 λ 的特征向量, 则 $(X^T X) \mathbf{v} = \lambda \mathbf{v}$ 。

3. 代入约束计算目标值:

结合约束 $\mathbf{v}^T \mathbf{v} = 1$ ，有：

$$\mathbf{v}^T (X^T X) \mathbf{v} = \mathbf{v}^T (\lambda \mathbf{v}) = \lambda \cdot (\mathbf{v}^T \mathbf{v}) = \lambda$$

由于 $\lambda^1 = \lambda$ ，因此最优目标值为 λ^1 ，对应选项 1。 ■

7.2.5 总结



笔记 [深度学习]

- 深度神经网络：解决困难的层级特征提取问题。
- 自编码器：无监督神经网络，用于学习数据表示。
- 去噪自编码器：将噪声作为“提示”，实现正则化。
- 主成分分析：线性自编码器的变体，用于数据处理。



笔记 [总体结论] 深度学习作为机器学习的重要分支，通过多层非线性处理单元构建层次化特征表示，实现对复杂数据的高效建模。其核心在于利用深度神经网络的层级结构，从原始输入中逐层提取抽象特征，并通过“预训练 + 微调”等策略缓解优化难题。自编码器作为无监督学习工具，通过编码-解码的闭环映射挖掘数据的紧凑表示，为深度网络提供有效的预训练初始化；去噪自编码器则将噪声引入训练过程，兼具特征学习与正则化功能，增强模型鲁棒性。主成分分析作为线性自编码器的特例，通过特征分解实现数据降维，为理解深度网络的线性基础提供了桥梁。尽管深度学习面临结构设计复杂、计算成本高、易过拟合等挑战，但凭借强大的表达能力与层次化特征提取优势，已成为处理图像、文本等复杂数据的核心技术，其发展依赖于正则化设计、优化算法与硬件算力的协同进步。

7.3 径向基函数网络

7.3.1 RBF 网络假设

定义 7.3.1 (径向基函数 (Radial Basis Function, RBF))

径向基函数 (Radial Basis Function, RBF) 是一类实值函数, 其函数值仅依赖于输入向量与某一固定中心点之间的欧氏距离, 而与方向无关。数学上, 存在一元函数 $\varphi: [0, \infty) \rightarrow \mathbb{R}$, 使得

$$\Phi(x) = \varphi(\|x - c\|),$$

其中 c 为中心向量, $\|\cdot\|$ 为欧几里得范数。

常见实例

- 高斯径向基函数

$$\varphi(r) = \exp\left(-\frac{r^2}{2\sigma^2}\right), \quad \sigma > 0.$$

- 多二次径向基函数

$$\varphi(r) = \sqrt{r^2 + c^2}, \quad c > 0.$$

- 逆多二次径向基函数

$$\varphi(r) = \frac{1}{\sqrt{r^2 + c^2}}, \quad c > 0.$$

- 薄板样条径向基函数

$$\varphi(r) = r^2 \log r.$$

主要特性

- 径向对称, 便于高维推广;
- 局部作用: 远离中心时函数值迅速衰减;
- 根据 Stone-Weierstrass 定理, RBF 组合可在紧集上任意精度逼近任意连续函数。

应用领域 函数插值、曲面重建、支持向量机核函数、RBF 神经网络隐层激活函数等。



命题 7.3.1 (从神经网络到 RBF 网络)

RBF (径向基函数) 网络可视为神经网络的一种特殊结构, 二者仅在隐藏层计算方式不同。

1. 隐藏层对比

- 神经网络: 内积 + 非线性

$$h_j(x) = \tanh(w_j^\top x + b_j).$$

- RBF 网络: 距离 + 径向基

$$RBF(x, \mu_m) = h_m(x) = \exp\left(-\gamma \|x - \mu_m\|^2\right).$$

2. 输出层统一 均为线性聚合

$$g(x) = \sum_{m=1}^M \beta_m h_m(x) + b.$$

3. RBF 网络假设

给定中心 μ_m 与权重 β_m ，RBF 网络定义为

$$g(x) = \sum_{m=1}^M \beta_m \exp(-\gamma \|x - \mu_m\|^2) + b.$$

其中

- μ_m : 中心 (可随机选、K-means 或 SVM 支持向量);
- β_m : 带符号的投票权重 (可最小二乘或 SVM 对偶系数 $\alpha_m y_m$)。

4. 与 SVM 的联系

高斯核 SVM 可视为

$$M = \#SV, \quad \mu_m = \text{支持向量}, \quad \beta_m = \alpha_m y_m.$$

结论 RBF 网络以距离度量替代内积，兼具神经网络与核方法的优点，历史上被视为神经网络的重要分支。




图 7.3.1: RBF 网络

命题 7.3.2 (RBF 与相似性)

RBF 网络通过“空间距离”度量输入 x 与中心 μ_m 的相似度，从而构造特征变换。

常见相似度函数

- 神经网络神经元

$$\text{Neuron}(x, x') = \tanh(\gamma x^\top x' + 1).$$

- 字符串相似度

$$\text{DNASim}(x, x') = \text{EditDistance}(x, x').$$

- 核函数 (Mercer 条件)

$$\text{Poly}(x, x') = (1 + x^\top x')^2, \quad \text{Gaussian}(x, x') = \exp(-\gamma \|x - x'\|^2).$$

- 截断相似度

$$\text{Truncated}(x, x') = \max(0, 1 - \|x - x'\|)^2.$$

RBF 视角

RBF 网络将“距离到中心”的单调不减函数作为相似度，进而

$$\Phi(x) = [\text{Gaussian}(x, \mu_1), \dots, \text{Gaussian}(x, \mu_M)]^\top$$

完成特征变换，随后线性组合即可。

结论 RBF 网络把“距离 $\rightarrow$ 相似度 $\rightarrow$ 特征”作为统一框架，兼容核方法与神经网络思想。



例题 7.7 选择题：径向基函数的判定

以下哪一项不是径向基函数（radial basis function）？

- 1) $\phi(\mathbf{x}, \boldsymbol{\mu}) = \exp(-\gamma \|\mathbf{x} - \boldsymbol{\mu}\|^2)$
- 2) $\phi(\mathbf{x}, \boldsymbol{\mu}) = -\sqrt{\mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \boldsymbol{\mu} + \boldsymbol{\mu}^T \boldsymbol{\mu}}$
- 3) $\phi(\mathbf{x}, \boldsymbol{\mu}) = \|\mathbf{x} - \boldsymbol{\mu}\|$
- 4) $\phi(\mathbf{x}, \boldsymbol{\mu}) = \mathbf{x}^T \mathbf{x} + \boldsymbol{\mu}^T \boldsymbol{\mu}$

解答 正确选项为 [4]。径向基函数的核心是函数值仅依赖于输入 $\mathbf{x}$ 与中心 $\boldsymbol{\mu}$ 的距离（即 $\phi(\mathbf{x}, \boldsymbol{\mu}) = \phi(\|\mathbf{x} - \boldsymbol{\mu}\|)$ ）。

- 选项 1 是高斯径向基函数，依赖 $\|\mathbf{x} - \boldsymbol{\mu}\|^2$ ；
- 选项 2 化简后依赖 $\|\mathbf{x} - \boldsymbol{\mu}\|$ ；
- 选项 3 是指示函数，依赖 $\|\mathbf{x} - \boldsymbol{\mu}\| = 0$ 的条件；
- 选项 4 $\mathbf{x}^T \mathbf{x} + \boldsymbol{\mu}^T \boldsymbol{\mu}$ 与 $\mathbf{x}$ 和 $\boldsymbol{\mu}$ 的距离无关，不满足径向基函数的定义。

因此，选项 4 不是径向基函数。



7.3.2 RBF 网络学习

命题 7.3.3 (Full RBF 网络与最近邻)

当 RBF 网络将全部训练样本设为基函数中心时，可导出两种经典模型。

1. Full RBF 网络

令中心数 $M = N$ 且 $\mu_m = x_m$ ，则

$$g_{\text{uniform}}(x) = \text{sign}\left(\sum_{m=1}^N y_m \exp(-\gamma \|x - x_m\|^2)\right).$$

物理意义：每个样本 x_m 依据相似度 $\exp(-\gamma \|x - x_m\|^2)$ 对 x 投出带符号的“一票”。

2. 最近邻 (1-NN)

若仅保留相似度最大的一项，则投票退化为选择：

$$\text{nbtor}(x) = y_m, \quad \text{其中 } m = \arg \min_i \|x - x_i\|.$$

进一步推广到 k 个最近邻可得到 k -NN 模型：

$$g_{k\text{-NN}}(x) = \text{sign}\left(\sum_{x_i \in \mathcal{N}_k(x)} y_i\right), \quad \mathcal{N}_k(x) \text{ 为 } x \text{ 的 } k \text{ 个最近邻}.$$

结论 Full RBF 网络由“全体投票”演变为“最近邻选择”，揭示了 RBF、核方法与实例学习之间的内在联系。



命题 7.3.4 (全连接 RBF 网络的插值性质)

考虑平方误差意义下的回归任务，采用全连接 RBF 网络

$$h(x) = \sum_{m=1}^N \beta_m \underbrace{\text{RBF}(x, x_m)}_{\text{Gaussian}}, \quad \text{其中中心 } \mu_m = x_m, M = N.$$

线性回归视角

将输入 x 通过径向基变换映射为

$$z_n = [\text{RBF}(x_n, x_1), \text{RBF}(x_n, x_2), \dots, \text{RBF}(x_n, x_N)]^\top \in \mathbb{R}^N, \quad Z = [z_1, \dots, z_N]^\top \in \mathbb{R}^{N \times N}.$$

最优系数由最小二乘给出

$$\beta = (Z^\top Z)^{-1} Z^\top y, \quad y = [y_1, \dots, y_N]^\top.$$

插值定理

若所有样本 $\{x_n\}_{n=1}^N$ 互不相同，则采用高斯 RBF 的矩阵 Z 正定、可逆，于是

$$\beta = Z^{-1} y, \quad \text{网络恰好插值所有训练点: } h(x_n) = y_n, \forall n.$$

结论 全连接 RBF 网络在高斯核下天然具备插值能力，其系数可通过一次性求解线性方程组获得。

命题 7.3.5 (正则化全连接 RBF 网络与中心剪枝)

全连接高斯 RBF 网络在插值情形下满足

$$g_{\text{RBF}}(x_n) = y_n, \quad \forall n = 1, \dots, N, \implies E_{\text{in}} = 0,$$

称为精确插值，但易导致过拟合。

1. 正则化系数估计

采用岭回归 (ridge regression) 代替最小二乘，得

$$\beta = (Z^\top Z + \lambda I)^{-1} Z^\top y,$$

其中

$$Z^\top Z = [\text{Gaussian}(x_n, x_m)]_{n,m=1}^N = K$$

即高斯核矩阵，于是

$$\beta = (K + \lambda I)^{-1} y,$$

等价于核岭回归。

2. 中心剪枝正则化

用 $M < N$ 个中心 $\{\mu_m\}_{m=1}^M$ 替代全部 N 个样本中心：

$$g(x) = \sum_{m=1}^M \beta_m \text{Gaussian}(x, \mu_m) + b, \quad \mu_m \text{ 为原型/质心}.$$

- 降低参数数量，抑制过拟合；
- 物理意义： μ_m 作为数据的代表性“原型”；
- 与 SVM 类比：支持向量仅为一组有效中心。

结论 通过正则化或中心剪枝，全连接 RBF 网络从“精确插值”过渡到“稳健学习”，兼顾拟合

与泛化。



例题 7.8 选择题：全高斯 RBF 网络 Z 矩阵变化

若 $\mathbf{x}_1 = \mathbf{x}_2$ ，全高斯径向基函数（RBF）网络的 Z 矩阵会发生什么变化？

- 1) 矩阵的前两行相同
- 2) 矩阵的前两列不同
- 3) 矩阵可逆
- 4) 前两行和前两列交叉处的子矩阵包含常数 0

解答 正确选项为 **1**。全高斯 RBF 网络中， Z 矩阵元素定义为 $Z_{ij} = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$ （以训练样本为中心）。

当 $\mathbf{x}_1 = \mathbf{x}_2$ 时，对任意 j ，有：

$$Z_{1j} = \exp(-\gamma \|\mathbf{x}_1 - \mathbf{x}_j\|^2), \quad Z_{2j} = \exp(-\gamma \|\mathbf{x}_2 - \mathbf{x}_j\|^2) = \exp(-\gamma \|\mathbf{x}_1 - \mathbf{x}_j\|^2)$$

因此， Z 矩阵的第一行与第二行元素完全相同。 ■

7.3.3 k -均值算法

命题 7.3.6 (聚类原型：K-means 交替优化)

给定数据集 $\{\mathbf{x}_n\}_{n=1}^N$ ，通过聚类选取 M 个原型 $\{\boldsymbol{\mu}_m\}_{m=1}^M$ ，用于构造正则化 RBF 网络。其核心逻辑与步骤如下：

1. 聚类误差定义

定义由 $\{S_1, \dots, S_M\}$ （数据集的不交并划分，满足样本无重叠、全覆盖）和原型 $\{\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_M\}$ 共同决定的平方误差：

$$E_{\text{in}}(S_1, \dots, S_M; \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_M) = \frac{1}{N} \sum_{n=1}^N \sum_{m=1}^M \mathbb{I}[\mathbf{x}_n \in S_m] \|\mathbf{x}_n - \boldsymbol{\mu}_m\|^2$$

该误差刻画“样本到所属簇原型的距离总和”，越小代表原型对簇内样本的代表性越强。

2. K-means 交替最小化算法

因直接联合优化划分 S_m 与原型 $\boldsymbol{\mu}_m$ 计算复杂，采用交替优化策略，分两步迭代逼近最小误差：

1. 固定原型，优化划分（样本指派）

若原型 $\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_M$ 已确定，对每个样本 $\mathbf{x}_n$ ，将其指派到距离最近原型对应的簇：

$$S_m = \{\mathbf{x}_n \mid \|\mathbf{x}_n - \boldsymbol{\mu}_m\| \leq \|\mathbf{x}_n - \boldsymbol{\mu}_j\|, \forall j \in \{1, \dots, M\}\}$$

此操作保证样本“唯一归属”到当前最匹配簇，最小化距离误差。

2. 固定划分，优化原型（均值更新的数学推导）

若划分 $S_1, \dots, S_M$ 已确定，需更新每个簇的原型 $\boldsymbol{\mu}_m$ 。此时对单个原型 $\boldsymbol{\mu}_m$ ，可通过无约束优化推导其最优解：

(1) 梯度计算：

对聚类误差 E_{in} 中与 $\boldsymbol{\mu}_m$ 相关的项求偏导（仅 S_m 内样本贡献非零项）：

$$\nabla_{\boldsymbol{\mu}_m} E_{\text{in}} = -2 \sum_{n=1}^N \mathbb{I}[\mathbf{x}_n \in S_m] (\mathbf{x}_n - \boldsymbol{\mu}_m)$$

利用指示函数筛选性，简化为：

$$\nabla_{\mu_m} E_{\text{in}} = -2 \left(\sum_{x_n \in S_m} x_n - |S_m| \mu_m \right)$$

(2) 最优原型求解：

令梯度为 $\mathbf{0}$ （无约束优化极值条件），解得：

$$\mu_m = \frac{1}{|S_m|} \sum_{x_n \in S_m} x_n$$

即最优原型是簇内样本均值，数学上可证明这是当前划分下平方误差最小的唯一解。

结论 K-means 交替优化通过迭代执行“样本指派 $\rightarrow$ 原型更新”，同时达成：

- 聚类紧凑性：数据被划分为内部距离紧凑的簇；
- 原型实用性： μ_m 作为簇的“共识中心”，可直接用于正则化 RBF 网络的中心构造，简化模型同时保留数据簇特征。



算法 7.3.29: k-Means 聚类算法

输入：数据集 $\{x_n\}_{n=1}^N$ ；聚类数 k ；最大迭代次数 $T_{\max}$

输出：簇划分 $\{S_1, \dots, S_k\}$ ；聚类中心 $\{\mu_1, \dots, \mu_k\}$

初始化

随机选取 k 个样本作为初始中心 $\mu_1^{(0)}, \dots, \mu_k^{(0)}$.

repeat

分配步骤

对每个样本 x_n 执行

$$S_j \leftarrow \{x_n \mid \|x_n - \mu_j\| \leq \|x_n - \mu_i\|, \forall i\}.$$

更新步骤

对每个簇 $j = 1, \dots, k$ 重新计算中心

$$\mu_j \leftarrow \frac{1}{|S_j|} \sum_{x_n \in S_j} x_n.$$

until 簇划分不再变化;

收敛性 由于目标函数

$$E_{\text{in}} = \sum_{j=1}^k \sum_{x_n \in S_j} \|x_n - \mu_j\|^2$$

在每一步交替优化中单调不增，算法必在有限步内收敛。

注 k-Means 是最流行的聚类算法之一；注意与 k-最近邻（k-NN）区分，二者同名但目的不同。

算法 7.3.30: RBF 网络结合 k-Means 的完整训练流程

输入: 训练集 $\{(x_n, y_n)\}_{n=1}^N$; 原型数 M ; RBF 类型 (如高斯)

输出: 预测函数 $g_{\text{RBF}}(x)$

1. 无监督原型获取

运行 k-Means 算法簇数设为 $k = M$, 得到原型中心

$$\mu_1, \mu_2, \dots, \mu_M.$$

2. 构造特征变换

构建径向基特征映射

$$\Phi(x) = [\text{RBF}(x, \mu_1), \text{RBF}(x, \mu_2), \dots, \text{RBF}(x, \mu_M)]^T \in \mathbb{R}^M.$$

3. 监督线性模型训练

对变换后的数据

$$\{(\Phi(x_n), y_n)\}_{n=1}^N$$

执行线性模型 (例如线性回归或逻辑回归), 得到权重

$$\beta \in \mathbb{R}^M.$$

4. 返回模型

$$g_{\text{RBF}}(x) = \text{LinearHypothesis}(\beta, \Phi(x)).$$

注

- 步骤 1 利用无监督聚类 (k-Means) 完成特征提取, 与自编码器思想类似;
- 典型超参数: 原型数 M 、RBF 带宽 γ (高斯核 γ)。


7.3.4 k -均值与 RBF 网络实践

图 7.3.2: k-means 算法示例





图 7.3.3: k-means 种类不同时的示例

(a) 使用 k 均值算法的径向基函数网络

(b) 全径向基函数网络

图 7.3.4: 径向基函数网络示例

例题 7.9 选择题: RBF 网络与岭回归结合的正则化程度

当与岭线性回归结合时, 以下哪种 RBF 网络的“正则化程度最高 (most regularized)”?

- 1) 小 M 且小 λ
- 2) 小 M 且大 λ
- 3) 大 M 且小 λ
- 4) 大 M 且大 λ

解答 正确选项为 [2]。正则化程度由模型复杂度和正则化强度共同决定:

- M (RBF 隐藏层神经元数) 越小, 模型基础复杂度越低;
- λ (岭回归正则化参数) 越大, 对参数的惩罚越强, 正则化效果越显著。

“最正则化”要求低复杂度模型 + 强正则化惩罚, 即小 M 且大 λ 。 ■

7.3.5 总结

 笔记 [径向基函数网络]

- RBF 网络假设: 以一组原型 (prototypes) 而非神经元作为非线性变换。
- RBF 网络学习: 对原型“假设”进行线性组合。
- k -均值算法: 通过交替优化实现聚类。
- k -均值与 RBF 网络实践: 原型数量的恰当选择至关重要。

7.4 矩阵分解

7.4.1 线性网络假设

定义 7.4.1 (类别特征的独热编码与线性网络推荐模型)

1. 类别特征的二进制向量编码 (One-Hot Encoding)

对含有限取值集合的类别特征，建立维度等于类别总数的二进制向量：

$$\text{血型 } \{A, B, AB, O\} \Rightarrow \begin{cases} A = [1, 0, 0, 0]^\top, \\ B = [0, 1, 0, 0]^\top, \\ AB = [0, 0, 1, 0]^\top, \\ O = [0, 0, 0, 1]^\top. \end{cases}$$

2. 特征提取与推荐模型

给定第 m 部电影的数据

$$\mathcal{D}_m = \{(x_n, y_n)\}_{n=1}^N, \quad x_n = \text{OneHot}(n) \in \mathbb{R}^N, \quad y_n = r_{nm} (\text{用户 } n \text{ 对电影 } m \text{ 的评分}),$$

构建线性网络（无隐藏层激活）

$$h(x_n) = w^\top V^\top x_n,$$

其中

- $V \in \mathbb{R}^{N \times k}$ ：所有用户共享的隐因子矩阵；
- $w \in \mathbb{R}^k$ ：电影 m 的隐因子权重向量；
- k ：隐因子维度（远小于 N ）。




图 7.4.1: 线性网络模型

3. 模型参数

联合学习

$$\min_{V, W} \sum_m \sum_n (r_{nm} - w_m^\top V^\top x_n)^2,$$

其中 $W = [w_1, \dots, w_M]$ 为所有电影的权重矩阵。

结论 线性网络（即矩阵分解）通过低秩隐因子 V, W 将高维稀疏的独热编码映射为用户-电影交互的稠密表示，是推荐系统的经典模型。



例题 7.10 选择题：线性网络假设的变量数量

对于 N 个用户、 M 部电影和 $\tilde{d}$ 个特征，要指定线性网络假设 $h(\mathbf{x}) = \mathbf{w}^\top \mathbf{V} \mathbf{x}$ ，需要使用多少个变量？

- 1) $N + M + \tilde{d}$
- 2) $N \cdot M \cdot \tilde{d}$
- 3) $(N + M) \cdot \tilde{d}$

4) $(N \cdot M) + \tilde{d}$

解答 正确选项为 [3]。线性网络假设 $h(\mathbf{x}) = \mathbf{w}^T \mathbf{V} \mathbf{x}$ 中，变量由矩阵 $\mathbf{V}$ 的元素决定（维度适配用户、电影与特征的关系）：

- $\mathbf{V}$ 需覆盖 N 个用户 + M 部电影的特征表示，维度为 $(N + M) \times \tilde{d}$ ；
- 变量数量为矩阵元素总数，即 $(N + M) \cdot \tilde{d}$ 。

因此，选项 3 正确。 ■

7.4.2 基础矩阵分解

定义 7.4.2 (矩阵分解 (Matrix Factorization) 模型)

问题设定

设用户-电影评分矩阵为

$$R = [r_{nm}] \in \mathbb{R}^{N \times M}, \quad \text{仅部分元素已知.}$$

引入

- 用户隐因子矩阵 $V = [v_1, \dots, v_N]^T \in \mathbb{R}^{N \times k}$ ；
- 电影隐因子矩阵 $W = [w_1, \dots, w_M]^T \in \mathbb{R}^{M \times k}$ ；
- 共同隐因子维度 $k \ll \min(N, M)$ 。

预测模型

对已知评分 $(n, m) \in \Omega$ 最小化平方误差

$$\min_{\{v_n\}, \{w_m\}} \sum_{(n, m) \in \Omega} (r_{nm} - v_n^\top w_m)^2.$$

交替最小二乘 (ALS) 算法

固定 V ，优化 W

对每个电影 m ，独立求解

$$w_m = \left(\sum_{n: (n, m) \in \Omega} v_n v_n^\top \right)^{-1} \left(\sum_{n: (n, m) \in \Omega} r_{nm} v_n \right).$$

固定 W ，优化 V

对称地，对每个用户 n ，

$$v_n = \left(\sum_{m: (n, m) \in \Omega} w_m w_m^\top \right)^{-1} \left(\sum_{m: (n, m) \in \Omega} r_{nm} w_m \right).$$

结论 矩阵分解通过低秩隐因子 V, W 将高维稀疏评分矩阵压缩为稠密表示，ALS 交替优化可高效求解，广泛应用于推荐系统、文本主题建模等领域。 ♣

算法 7.4.31: 交替最小二乘 (Alternating Least Squares, ALS)**输入:** 已知评分集合 $\Omega = \{(n, m, r_{nm})\}$; 隐因子维度 k ; 最大迭代次数 $T_{\max}$ **输出:** 用户因子矩阵 $V = [v_1, \dots, v_N]^\top \in \mathbb{R}^{N \times k}$; 电影因子矩阵 $W = [w_1, \dots, w_M]^\top \in \mathbb{R}^{M \times k}$ **初始化**随机初始化 $v_n^{(0)}, w_m^{(0)}$ (例如从 $\mathcal{N}(0, \frac{1}{k})$ 抽样)。**repeat** **电影步** **for** 每部电影 $m = 1, \dots, M$ **do**

求解最小二乘

$$w_m \leftarrow \left(\sum_{n:(n,m) \in \Omega} v_n v_n^\top \right)^{-1} \left(\sum_{n:(n,m) \in \Omega} r_{nm} v_n \right).$$

用户步 **for** 每位用户 $n = 1, \dots, N$ **do**

求解最小二乘

$$v_n \leftarrow \left(\sum_{m:(n,m) \in \Omega} w_m w_m^\top \right)^{-1} \left(\sum_{m:(n,m) \in \Omega} r_{nm} w_m \right).$$

until 收敛或迭代次数达到 $T_{\max}$;**收敛保证**

每次交替更新均使目标函数

$$E_{\text{in}} = \sum_{(n,m) \in \Omega} (r_{nm} - v_n^\top w_m)^2$$

单调下降, 算法必收敛。

命题 7.4.1 (线性自编码器与矩阵分解对照)

二者均属于线性映射的降维/特征提取框架, 但目标与求解方式有异。

	线性自编码器	矩阵分解
网络结构	$d \rightarrow \tilde{d} \rightarrow d$ 线性网络	$N \rightarrow k \rightarrow M$ 线性网络
数据矩阵	完整矩阵 $X \in \mathbb{R}^{d \times N}$	稀疏矩阵 $R \in \mathbb{R}^{N \times M}$
误差度量	所有元素平方误差	仅已知元素平方误差
最优解	全局最优: $\tilde{d}$ 个主特征向量	局部最优: 交替最小二乘
用途	降维特征提取	用户/物品隐因子学习

结论 线性自编码器可视为对完整矩阵 X 的“特殊矩阵分解”, 而矩阵分解则针对稀疏矩阵 R 的缺失值补全与隐因子学习。

**例题 7.11 选择题: 交替最小二乘法的迭代复杂度**

在交替最小二乘法 (ALS) 的一次迭代中, 需要求解多少个最小二乘问题?

- 1) 电影数量 M
- 2) 用户数量 N
- 3) $M + N$
- 4) $M \cdot N$

解答 正确选项为 [3]。交替最小二乘法 (ALS) 的核心是交替固定一组变量，优化另一组。对于用户 - 电影矩阵分解场景：

- 固定电影侧参数，优化用户侧参数 $\rightarrow$ 需全局求解 1 个最小二乘问题（对应 N 用户的整体优化逻辑，但题目简化为计数时，视为与用户数 N 相关）；
- 固定用户侧参数，优化电影侧参数 $\rightarrow$ 需全局求解 1 个最小二乘问题（对应电影数 M 相关）。

实际设计中，一次迭代需分别对用户和电影侧各做一次全局优化，因此总最小二乘问题数量为 $M + N$ 。

7.4.3 随机梯度下降

算法 7.4.32: 矩阵分解的随机梯度下降 (SGD)

输入: 已知评分集合 $\Omega = \{(n, m, r_{nm})\}$ ；隐因子维度 k ；学习率 η ；迭代次数 T

输出: 用户因子矩阵 $V = [v_n] \in \mathbb{R}^{N \times k}$ ；电影因子矩阵 $W = [w_m] \in \mathbb{R}^{M \times k}$

初始化

随机初始化 v_n, w_m （例如 $\mathcal{N}(0, 0.01)$ ）。

for $t = 1$ **to** T **do**

随机采样

 均匀随机抽取一条样本 $(n, m, r_{nm}) \in \Omega$ 。

计算残差

$$\delta = r_{nm} - v_n^\top w_m.$$

梯度更新

$$v_n^{\text{new}} \leftarrow v_n^{\text{old}} + 2\eta \delta w_m^{\text{old}},$$

$$w_m^{\text{new}} \leftarrow w_m^{\text{old}} + 2\eta \delta v_n^{\text{old}}.$$

注

- 每次仅更新一对因子向量，计算复杂度 $O(k)$ ，内存占用低；
- 易于实现并可扩展至其他误差函数（如 hinge loss、logistic loss）；
- 可配合动量、正则化、自适应学习率等技巧进一步提升效果。

命题 7.4.2 (KDDCup 2011 Track 1 冠军方案：时间感知 SGD)

NTU 团队在 KDDCup 2011 Track 1 竞赛中夺冠的关键在于针对数据特性的时间偏差进行 SGD 改进。

数据特性

- 训练集按时间顺序早于测试集，存在典型的采样偏差；

- 目标：让模型更关注“近期”样本，以匹配测试分布。

时间感知 SGD 策略

1. 在 SGD 的最后 T' 次迭代中，仅采样时间靠后的训练样本；
2. 保证这些样本在参数更新中最后被学习，从而赋予更高权重；
3. 形式上为时间确定性遍历：先遍历早期样本，再遍历近期样本，最后 T' 步仅遍历近期。

效果 竞赛测试集性能显著提升，验证了“理解技术行为 $\rightarrow$ 针对实际数据微调”的有效性。



例题 7.12 选择题：矩阵分解 SGD 初始化为零向量的情况

若所有 $\mathbf{w}_m$ 和 $\mathbf{v}_n$ 初始化为零向量，矩阵分解的随机梯度下降（SGD）中不会发生以下哪种情况？

- 1) 所有 $\mathbf{w}_m$ 始终为 $\mathbf{0}$
- 2) 所有 $\mathbf{v}_n$ 始终为 $\mathbf{0}$
- 3) 每个残差 $\tilde{r}_{nm}$ 等于原始评分 r_{nm}
- 4) E_{in} 在每次 SGD 更新后减小

解答 正确选项为 [4]。矩阵分解 SGD 的损失函数为 $E_{in} = \sum_{n,m} (r_{nm} - \mathbf{w}_m^T \mathbf{v}_n)^2$ ，参数更新依赖非零初始值产生的残差。

当 $\mathbf{w}_m, \mathbf{v}_n$ 初始为 $\mathbf{0}$ 时：

- 选项 1、2：更新公式中，残差项因初始零向量恒为 r_{nm} ，但更新量依赖对方向量（也为零），故 $\mathbf{w}_m, \mathbf{v}_n$ 始终为 $\mathbf{0}$ ，会发生。
- 选项 3：预测评分 $\hat{r}_{nm} = \mathbf{0}^T \mathbf{0} = 0$ ，残差 $\tilde{r}_{nm} = r_{nm} - 0 = r_{nm}$ ，会发生。
- 选项 4：因 $\mathbf{w}_m, \mathbf{v}_n$ 恒为 $\mathbf{0}$ ， $E_{in} = \sum (r_{nm})^2$ 无变化，不会“每次更新后减小”，故不会发生。



7.4.4 提取模型小结

命题 7.4.3 (特征提取模型族：统一视角)

特征提取模型可形式化为

$$h(x) = \beta^T \Phi(x; \theta),$$

其中

- $\Phi(\cdot; \theta)$ ：由隐藏参数 θ 定义的特征变换；
- β ：线性（或广义线性）模型权重。

成员示例

1. 自适应提升/梯度提升 (Adaptive/Gradient Boosting)

迭代构造弱假设 $g_t(x)$ 并学习组合权重 α_t ：

$$\Phi(x) = [g_1(x), \dots, g_T(x)]^T, \quad \beta = [\alpha_1, \dots, \alpha_T]^T.$$

2. 神经网络/径向基网络 (Neural Network / RBF Network)

隐藏层输出为特征：

$$\Phi(x) = [\text{RBF}(x, \mu_1), \dots, \text{RBF}(x, \mu_M)]^T, \quad \beta = [\beta_1, \dots, \beta_M]^T.$$

3. 矩阵分解 (Matrix Factorization)

将独热编码映射为隐因子：

$$\Phi(x_n) = v_n, \quad \beta = w_m.$$

4. 深度学习 (Deep Learning)

多层非线性变换：

$$\Phi(x) = \text{DeepNet}(x; \theta), \quad \beta = \text{输出层权重}.$$

5. k 近邻 (k Nearest Neighbor)

隐式定义邻居特征：

$$\Phi(x) = \text{OneHot}(\text{neighbor}(x)), \quad \beta = \text{邻居标签}.$$

统一结论 上述模型共享同一数学框架：先通过 θ 提取隐藏特征，再线性组合 β 完成最终预测，构成灵活而强大的特征提取模型族。



命题 7.4.4 (特征提取技术谱系)

不同模型通过各异但互补的技术实现“隐藏特征 + 线性组合”的统一范式。

技术列表

- 自适应提升/梯度提升 (Adaptive/Gradient Boosting)：函数梯度下降 (functional gradient descent)。
- 神经网络/径向基网络 (Neural/RBF Network)：随机梯度下降 (SGD) 与反向传播 (backprop)。
- 矩阵分解 (Matrix Factorization)：交替最小二乘 (alternating least squares)。
- 深度学习 (Deep Learning)：随机梯度下降 (SGD)。
- 自编码器 (Autoencoder)：无监督预训练 + 微调。
- k 均值聚类 (k-Means Clustering)：原型 (中心) 选取。
- k 近邻 (k Nearest Neighbor)：惰性学习 (lazy learning)。

统一结论 尽管技术实现多样，但均服务于同一目标：先通过隐藏变量提取特征，再线性组合完成预测，构成丰富而互补的特征提取技术谱系。



命题 7.4.5 (特征提取模型的优缺点)

- 优点
 - 减轻人工设计特征的负担；
 - 若隐藏变量足够，模型表达能力强大。
- 缺点
 - 优化问题通常非凸，求解困难；
 - 易过拟合，需要恰当的正则化与验证。



例题 7.13 选择题：模型特点匹配

以下哪种提取模型通过 k -means 提取高斯中心，并线性聚合高斯函数？

- 1) 径向基函数网络 (RBF Network)
- 2) 深度学习 (Deep Learning)
- 3) 自适应 boosting (Adaptive Boosting)

4) 矩阵分解 (Matrix Factorization)

解答 正确选项为 1。各模型特点：

- 选项 1 (RBF Network): 通过 k -means 聚类确定高斯径向基函数的中心，输出层对这些高斯函数线性组合，符合题意。
- 选项 2 (Deep Learning): 无 “ k -means 提取高斯中心 + 线性聚合” 的典型逻辑。
- 选项 3 (Adaptive Boosting): 是集成学习算法，与高斯中心提取无关。
- 选项 4 (Matrix Factorization): 聚焦矩阵分解，不涉及此机制。

因此，RBF Network 符合描述。 ■

7.4.5 总结

笔记 [矩阵分解]

- 线性网络假设：从二元向量编码中提取潜在特征。
- 基础矩阵分解：在用户/电影之间交替最小二乘优化。
- 随机梯度下降：高效且易于针对实际需求进行修改。
- 提取模型小结：能力强大，因此需谨慎使用。

7.5 收官

7.5.1 特征利用技术

命题 7.5.1 (利用核方法挖掘海量特征)

- 核函数族

通过 Mercer 核 $K(x, x') = \langle \Phi(x), \Phi(x') \rangle$ 隐式定义海量特征空间：

- 多项式核： $K(x, x') = (1 + x^\top x')^d$ (有限维多项式变换)；
- 高斯核： $K(x, x') = \exp(-\gamma \|x - x'\|^2)$ (无限维特征)；
- Stump 核：以决策桩为基变换的核。

- 核运算规则

Mercer 核的线性组合 (和) 与乘积仍是 Mercer 核，对应特征空间的并集与组合。

- 典型算法

- 核岭回归 (Kernel Ridge Regression)
- 核逻辑回归 (Kernel Logistic Regression)
- 支持向量机 (SVM)、支持向量回归 (SVR)、概率 SVM
- 核 PCA、核 k-Means 等无监督方法。

结论 核方法以“隐式特征 + 线性模型”范式，在无需显式计算高维 $\Phi(x)$ 的情况下，高效利用海量特征并避免维度灾难。

命题 7.5.2 (通过聚合利用预测特征)

设隐藏特征由若干基预测器给出： $\Phi_t(x) = g_t(x)$ 。借助集成策略将简单特征提升为强大预测力。

1. 基预测器示例

- 决策桩 (Decision Stump)：单层阈值函数；
- 决策树 (Decision Tree)：递归划分 + 叶节点预测；
- 高斯 RBF：原型中心影响函数。

2. 聚合策略

- 均匀投票：Bagging (Bootstrap Aggregating)；
- 非均匀加权：AdaBoost、Gradient Boosting；
- 条件聚合：随机森林 (Random Forest)；
- 最近邻：距离加权投票；
- 无限集成：决策树 + SVM 组合等。

结论 通过恰当的聚合机制，简单预测特征被组合成高容量、低偏差且可控方差的强预测器，构成集成学习的核心思想。

命题 7.5.3 (通过“提取”利用隐藏特征)

隐藏特征被视作待与常规权重联合优化的隐藏变量，并可借助无监督学习进行初始化或正则化。

1. 隐藏变量示例

- 神经网络：神经元权重；

- RBF 网络：径向基中心；
- 矩阵分解：用户/电影隐因子；
- 决策树：划分阈值与叶值；
- AdaBoost：弱学习器参数；
- k-Means：聚类中心；
- PCA：主方向；
- 自编码器：编码层权重。

2. 联合优化范式

$$\min_{\theta, \beta} \mathcal{L}(\beta, \Phi(x; \theta)) + \mathcal{R}(\theta),$$

其中

- θ ：隐藏特征参数；
- β ：线性组合权重；
- $\mathcal{R}(\theta)$ ：可选的无监督正则项（预训练、聚类、降维）。

3. 进阶组合

- Gradient-Boosted Neurons：逐步构造并优化神经元；
- 在分解后的特征上再训练深度网络；
- 多阶段预训练（如自编码器 $\rightarrow$ 深层网络）。

结论 通过将隐藏特征作为可学习变量并与下游任务联合优化，模型既能自动发现数据内在结构，又保留端到端的监督优势，构成现代机器学习的主流范式。

命题 7.5.4 (通过压缩利用低维特征)

将原始高维输入压缩为低维表示，再送入后续模型，兼顾表达力与计算效率。

1. 信息保持型压缩

- 自编码器 (Autoencoder)：非线性降维并重建输入；
- PCA：线性正交投影至最大方差子空间。

2. 任务导向型压缩

- 决策桩 (Decision Stump)：沿单一最优轴投影；
- 决策树 / 随机森林：通过递归划分实现“分段”低维嵌入；
- 矩阵分解：将用户-电影高维稀疏向量压缩为低维隐因子。

3. 随机或选择性压缩

- 随机投影：Johnson-Lindenstrauss 保证近似距离保持；
- 特征选择：仅保留“最有帮助”的少数特征。

统一结论 无论信息保持、任务导向还是随机/选择压缩，低维特征既降低过拟合风险，又提升计算效率，是连接高维原始数据与高效学习器的桥梁。

例题 7.14 AdaBoost-Stump 最终假设形式 (PCA 预处理场景)

在经 PCA 预处理的数据集上运行 AdaBoost-Stump，从原始特征 $\mathbf{x}$ 的角度看，最终假设 $G(\mathbf{x})$ 呈现何种形式？

- 1) 隐藏神经元含 $\tanh(\cdot)$ 的神经网络

- 2) 隐藏神经元含 $\text{sign}(\cdot)$ 的神经网络
- 3) 决策树
- 4) 随机森林

解答 正确选项为 [2]。PCA 对原始特征 $\mathbf{x}$ 进行线性变换，不改变数据的线性可分性本质。在变换后的数据上使用决策树桩 (decision stump)，等效于在原始特征空间中使用感知机 (perceptron)，而感知机的激活函数通常为符号函数 $\text{sign}(\cdot)$ 。

AdaBoost-Stump 通过集成多个决策树桩构建强学习器，其最终假设 $G(\mathbf{x})$ 本质是多个感知机的线性组合，对应“隐藏神经元含 $\text{sign}(\cdot)$ 的神经网络”结构（感知机可视为最简单的神经网络形式）。 ■

7.5.2 误差优化技术

命题 7.5.5 (数值优化：梯度下降的统一视角)

当目标函数 E 对参数 θ 可微时，可构造一阶近似更新

$$\theta^{\text{new}} \leftarrow \theta^{\text{old}} - \eta \nabla_{\theta} E,$$

其中 η 为学习率。根据批量大小与策略差异，演化出多种具体算法。

1. 批量梯度下降 (GD) 每次迭代使用全部样本计算梯度，收敛稳定但计算量大。
2. 随机梯度下降 (SGD) 每次仅随机抽取单个样本，更新快、内存省，适用于大规模数据。
3. 小批量梯度下降 (Mini-batch GD) 折中方案：每步使用 B 个样本，兼顾效率与收敛稳定性。
4. 最速下降 (Steepest Descent) 沿线搜索最优步长 η 而非固定值，加速收敛。
5. 函数梯度下降 (Functional GD) 在函数空间执行梯度步，AdaBoost、GradientBoost 均为此例。
6. 典型模型对应
 - 神经网络：反向传播 (backprop)；
 - 矩阵分解：交替 SGD/ALS；
 - 线性 SVM：次梯度下降；
 - 核逻辑回归：核空间梯度下降。
7. 进阶扩展
 - 二阶方法：牛顿法、拟牛顿 (L-BFGS)；
 - 约束优化：投影梯度、Frank-Wolfe。

统一结论 梯度下降及其变体为各类模型提供通用且高效的数值优化框架，依据数据规模、模型结构与计算资源灵活选用。



命题 7.5.6 (间接优化：通过等价解求解)

当原问题难以直接优化时，可构造与原问题等价的易解形式，从而在等价域内获得最优解。

1. 对偶 SVM (Dual SVM)

原问题：带约束的二次规划 (QP)

等价解：对偶 QP，仅需支持向量，核技巧自然嵌入。
2. 核逻辑回归 (Kernel Logistic Regression)

原问题：非线性高维优化

等价解：表示定理（representer theorem）给出有限维参数化，转化为核矩阵上的凸优化。

3. 主成分分析（PCA）

原问题：最大化方差的高维投影

等价解：协方差矩阵的特征问题，直接通过特征分解获得全局最优。

4. 核岭回归（Kernel Ridge Regression）

原问题：无限维正则化最小二乘

等价解：表示定理 + 核矩阵求逆，转化为有限维线性系统。

5. 推广意义

现代核方法与诸多 Boosting 模型均重度依赖“等价解”技术，将复杂或无限维问题转化为有限维、凸或特征问题，实现高效且稳定的求解。

统一结论 “间接优化”通过数学等价性把难解问题映射到易解空间，是机器学习算法设计与工程实现的核心技巧之一。



命题 7.5.7 (复杂优化：多步骤分解策略)

当原始问题难以一次性求解时，可将其拆解为若干更易处理的子问题，通过多阶段、交替或分治策略逐步逼近全局最优。

1. 多阶段（Multi-Stage）优化

- 概率支持向量机（probabilistic SVM）：先求硬间隔 SVM，再校准概率输出；
- 深度网络预训练（DeepNet pre-training）：逐层无监督预训练 + 端到端微调。

2. 交替优化（Alternating Optimization）

- k-Means：交替更新簇划分与聚类中心；
- 交替最小二乘（Alternating Least Squares）：矩阵分解中固定用户因子/电影因子轮流求解；
- RBF 网络：先确定中心（k-Means），再求线性权重。

3. 分治（Divide & Conquer）

- 决策树：递归划分特征空间，在每个叶节点独立拟合；
- 线性混合（Linear Blending）：先训练若干基模型，再线性组合其输出；
- 堆叠（Stacking）：分层模型，逐级提炼预测。

统一结论 通过将复杂优化拆解为易解子问题，并以多阶段、交替或分治方式协同求解，现代机器学习得以训练高容量模型并保持计算与统计可行性。



例题 7.15 DeepNet 算法优化技术判定

在经 PCA 预处理的数据集上运行 Lecture 213 介绍的 DeepNet 算法时，使用了哪种优化技术？

- 1) 梯度下降变种
- 2) 定位等效解
- 3) 多阶段优化
- 4) 以上所有

解答 正确选项为 4。深度网络（DeepNet）训练涉及多环节优化技术：

- 训练阶段：采用小批量梯度下降（minibatch GD），属于梯度下降变种，对应选项 1；
- PCA 预处理：求解特征问题（eigenproblem）时，涉及等效解定位，对应选项 2；
- 预训练阶段：常通过多阶段优化（如逐层预训练）提升模型，对应选项 3。

因涵盖选项 1、2、3 的优化逻辑，故最终为以上所有。

7.5.3 过拟合消除技术

命题 7.5.8 (通过正则化消除过拟合)

当模型过于强大时，可在不同环节“加刹车”抑制过拟合，核心手段如下。

1. 大间隔 / 边界正则化
 - SVM、SVR：最大化几何间隔；
 - AdaBoost：通过加权投票间接实现大间隔。
2. 权重惩罚
 - L2 正则：岭回归、核模型、神经网络权重衰减；
 - L1/L0 正则：权重消除、特征选择。
3. 投票 / 平均化
 - Bagging：Bootstrap 重采样后均匀投票；
 - 随机森林：Bagging + 随机子特征；
 - 均匀混合（uniform blending）：线性组合多模型输出。
4. 去噪 / 鲁棒化
 - 去噪自编码器：对输入加噪声训练；
 - 随机失活（dropout）：神经网络内部去噪。
5. 结构约束
 - 决策树剪枝（pruning）；
 - RBF 网络限制中心数量；
 - 神经网络早停（early stopping）。

结论 正则化技术——从权重惩罚到结构约束——是抑制过拟合、保证模型泛化能力的最重要手段。

命题 7.5.9 (通过验证消除过拟合)

当模型过于强大时，需诚实且严格地监控性能，核心验证手段如下。

- 内部验证 (Internal Validation)
 - SVM / SVR：利用支持向量数量 (#SV) 作为复杂度指标；
 - 决策树：剪枝时采用内部交叉验证或代价复杂度剪枝；
 - 随机森林：计算袋外误差 (OOB) 估计泛化性能；
 - 模型混合 (blending)：在验证集上估计组合权重。
- 简单但必要
 - 留出法、 k 折交叉验证；
 - 早停 (early stopping)：监控验证集损失。

结论 内部或外部验证是防止过拟合的最后防线，确保模型在未见数据上表现可靠。

例题 7.16 随机森林过拟合消除技术判定

随机森林（Random Forest）中消除过拟合的主要技术是什么？

- 1) 投票/平均（voting/averaging）
- 2) 剪枝（pruning）
- 3) 早停（early stopping）
- 4) 权重消除（weight - elimination）

解答 正确选项为 **1**。随机森林是多决策树集成算法，核心通过以下方式消除过拟合：

- 构建多棵决策树（引入随机性，降低单棵树方差）；
- 最终结果由多棵树“投票（分类）”或“平均（回归）”得到，通过集成效应缓解过拟合。

选项分析：

- 选项 1：投票/平均是集成学习的核心操作，有效减少过拟合，正确；
- 选项 2：剪枝是单决策树的优化，非随机森林主要技术，错误；
- 选项 3：早停是神经网络技术，与随机森林无关，错误；
- 选项 4：权重消除是正则化手段（如神经网络 L1/L2），不适用随机森林，错误。

7.5.4 机器学习实践**命题 7.5.10 (NTU KDDCup 2010 冠军方案)**

Yu 等人在 KDDCup 2010 竞赛中夺冠的核心策略为“特征工程 + 分类器集成”。

- 模型架构
 - 采用线性混合（linear blending）融合
 - 逻辑回归（Logistic Regression）；
 - 随机森林（Random Forest）。
- 特征工程
 - 大量原始特征的直接编码（rawly encoded features）；
 - 人工设计的高阶特征（human-designed features）。

结论 通过丰富特征与多模型线性融合，NTU 方案在 KDDCup 2010 取得世界第一。

命题 7.5.11 (NTU KDDCup 2011 Track 1 冠军方案)

Chen 等人在 KDDCup 2011 Track 1（音乐评分预测）中夺冠，采用“多层模型 + 线性集成”的策略。

1. 基模型
 - 神经网络（NNet）；
 - 类决策树模型（DecTree-like）。
2. 矩阵分解及其扩展
 - 多种矩阵分解变体（含概率 PCA）；
 - 受限玻尔兹曼机（RBM）：视为“扩展自编码器”。
3. 其他模型

- k 近邻 (k Nearest Neighbors);
- 概率潜在语义分析 (PLSA): 以“软聚类”作为隐藏变量的提取模型。

4. 集成方式

- 对上述模型输出进行线性回归融合;
- 辅助使用神经网络与梯度提升决策树 (GBDT) 进一步优化预测。

结论 通过丰富的基模型与线性集成, NTU 团队在 KDDCup 2011 Track 1 中取得世界第一。

命题 7.5.12 (NTU KDDCup 2012 Track 2 冠军方案)

Wu 等人在 KDDCup 2012 Track 2 (广告排序) 中夺冠, 采用“两阶段 + 线性混合”的集成框架。

1. 第一阶段: 多样基模型

- 神经网络 (NNet);
- 类梯度提升决策树 (GBDT-like)。

2. 第二阶段: 线性混合对下列模型输出进行线性融合

- 多种线性回归变体 (含线性 SVR);
- 多种逻辑回归变体;
- 多种矩阵分解变体。

3. 关键策略

- 通过谨慎的线性权重学习实现“正确混合而不过拟合”。

结论 凭借两阶段集成与防过拟合的混合策略, NTU 团队在 KDDCup 2012 Track 2 中夺得世界第一。

命题 7.5.13 (NTU KDDCup 2013 Track 1 冠军方案)

Li 等人在 KDDCup 2013 Track 1 (论文-作者匹配) 中夺冠, 核心策略为“巨量特征工程 + 排序模型线性集成”。

1. 模型集成

- 超大随机森林 (Random Forest, 极多棵树);
- 多种梯度提升决策树 (GBDT) 变体。

2. 特征工程

- 投入巨量精力人工设计特征;
- 关键: 结合领域知识构造高区分度特征。

3. 集成方式

- 对上述模型的输出进行线性混合 (linear blending)。

结论 凭借海量领域特征与强集成策略, NTU 团队在 KDDCup 2013 Track 1 中夺得世界第一。

命题 7.5.14 (ICDM 2006 十大经典数据挖掘算法)

2006 年 ICDM 会议评选出的最具影响力的十大算法如下 (按字母顺序):

1. C4.5: 经典决策树扩展。
2. k-Means: 经典的聚类算法。
3. 支持向量机 SVM: 大间隔分类器。

4. AdaBoost: 自适应提升集成方法。
5. Apriori: 频繁项集挖掘。
6. 朴素贝叶斯 Naive Bayes: 基于统计的简单线性概率模型。
7. EM: 用于含隐变量模型的交替优化算法。
8. k 近邻 k Nearest Neighbor: 惰性学习代表。
9. PageRank: 链接分析, 与矩阵分解思想相通。
10. CART: 分类与回归树。

个人补充

在作者看来, 现代机器学习竞赛中最具竞争力的五大算法并未全部入选, 包括:

- 线性回归 LinReg
- 逻辑回归 LogReg
- 随机森林 Random Forest
- 梯度提升决策树 GBDT
- 神经网络 NNet




图 7.5.1: 机器学习丛林

7.5.5 总结

笔记 [收官]

- 特征利用技术: 核方法、集成、特征提取、降维。
- 误差优化技术: 梯度下降、等价转换、分阶段训练。
- 过拟合消除技术: 大量正则化与验证。
- 机器学习实践: 欢迎来到“丛林”!

间章：蒸馏隐含特征：提取模型

笔记 [蒸馏隐含特征：提取模型]

“Distilling Implicit Features: Extraction Models”（蒸馏隐含特征：提取模型）是贯穿神经网络、深度学习、径向基函数网络与矩阵分解的核心脉络。这些模型如同精密的“特征蒸馏器”，从原始数据中萃取隐含模式，其内在逻辑可通过四个维度揭示：

1. 蒸馏的本质：从原始到精炼的特征跃迁

提取模型的核心使命是将原始数据转化为更具表达力的隐含特征，实现“去粗取精”：

- 层级蒸馏：神经网络通过多层非线性变换（如 $\tanh(Wx)$ ）逐层过滤噪声、聚焦关键模式——例如在图像识别中，从像素点的杂乱组合，逐步蒸馏出边缘、纹理、部件等层次化特征；深度学习则通过更深的网络结构，将这种蒸馏推向更抽象的语义层面（如“猫”的概念而非单纯的毛色或形状）。
- 相似性蒸馏：径向基函数（RBF）网络以“距离-响应”为蒸馏逻辑，将输入与原型中心的空间距离转化为相似度特征（如高斯 RBF 的 $\exp(-\gamma\|x - \mu_m\|^2)$ ），本质是用局部相似性度量提炼数据的分布特征。
- 隐因子蒸馏：矩阵分解从稀疏的用户-物品交互数据（如评分矩阵 R ）中，蒸馏出低维隐因子 V （用户偏好）与 W （物品属性），用紧凑的稠密向量替代高维稀疏的原始记录，捕捉那些未被显式表达的潜在关联（如“喜欢科幻片的用户也倾向于喜欢太空题材书籍”）。

这种蒸馏过程无需人工干预，实现了从“原始数据”到“有效特征”的自动化升华。

2. 蒸馏器的共性结构：变换-聚合框架

尽管“蒸馏工艺”不同，所有提取模型均遵循“特征变换 + 线性聚合”的统一架构：

- 变换模块（蒸馏器核心）：负责将输入 x 转化为隐含特征 $\Phi(x)$ ，其参数决定蒸馏方式：
 - 神经网络中， $\Phi(x)$ 是隐藏层输出，由权重矩阵 W 与激活函数共同调控蒸馏的“精细度”；
 - RBF 网络中， $\Phi(x)$ 是径向基函数向量，中心 μ_m 与带宽 γ 决定对局部模式的“捕捉范围”；
 - 矩阵分解中， $\Phi(x_n)$ 是用户隐因子 v_n ，低秩约束 $k \ll N$ 确保蒸馏出的是最核心的模式。
- 聚合模块（整合器）：将蒸馏得到的隐含特征 $\Phi(x)$ 通过权重 β 线性整合，输出最终结果： $g(x) = \beta^T \Phi(x)$ 。例如：
 - 神经网络的输出层聚合隐藏层特征，形成全局决策；
 - RBF 网络通过 β_m 加权组合不同原型的相似性响应；
 - 矩阵分解中，用户-物品交互预测 $v_n^T w_m$ 是隐因子的内积，本质是对双方核心特征的匹配度聚合。

这种“变换-聚合”结构，既保证了特征蒸馏的灵活性，又简化了参数学习的复杂度。

3. 蒸馏过程的调控：参数优化与正则化

有效的特征蒸馏依赖对模型参数的精准调控，以平衡“提取纯度”与“泛化能力”：

- 参数优化（蒸馏火候）：
 - 神经网络与深度学习通过反向传播计算梯度，用随机梯度下降（SGD）调整权重 W ，确保蒸馏出的特征能最小化预测误差；
 - 矩阵分解采用交替最小二乘（ALS），交替优化用户与物品因子，逐步提升隐因子对交互模式

的蒸馏精度。

- 正则化（防过蒸馏机制）：

- 权重衰减（L2）限制神经网络参数规模，避免过度蒸馏噪声；
- 早停策略在验证误差上升前终止训练，防止模型“记住”训练数据的细节而非规律；
- RBF 网络的中心剪枝（ $M \ll N$ ）与矩阵分解的低秩约束，通过限制模型容量防止过拟合。

这些机制共同确保蒸馏出的是“稳定且通用”的隐含特征，而非数据中的偶然噪声。

4. 蒸馏场景的适配：匹配数据特性

不同提取模型的优势源于对特定数据场景的适配性：

- 神经网络/深度学习：擅长处理高维稠密数据（如图像、语音），其层级蒸馏能力能有效捕捉复杂的空间或时序模式，在大数据场景下优势显著；
- **RBF 网络**：适用于局部模式突出的数据（如地理空间数据），通过原型中心的相似性蒸馏，在小样本场景下仍能保持稳健；
- 矩阵分解：专为稀疏交互数据（如推荐系统）设计，通过隐因子蒸馏解决数据稀疏性难题，高效预测缺失关联。

实际应用中，这些模型常被组合（如深度矩阵分解、RBF 增强神经网络），形成更强大的“复合蒸馏器”。

结语：提取模型的价值在于其“自动化特征蒸馏”能力——它们摆脱了人工设计特征的局限，通过统一的“变换-聚合”框架，从数据中自主提炼隐含模式。理解这种“蒸馏逻辑”，是掌握机器学习从“数据驱动”到“智能决策”的关键。